

เอกสารโครงงานฉบับสมบูรณ์

การถ่ายโอนทรงผมและสีผมด้วย GAN เสริมด้วย Diffusion Model สำหรับปรับปรุงความเรียบเนียนของเส้นผม

GAN-based Hair Transfer with Diffusion Post-processing for Seamless Hairline and Texture Refinement

โดย
663380264-9 นายณัฐพงษ์ ด้างถางคำ
663380272-0 นายธนเดช วาตรีบุญเรือง

อาจารย์ที่ปรึกษา
อ.ดร.ญานิกา คงโสรส

รายงานฉบับนี้เป็นส่วนหนึ่งของการศึกษา
หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาปัญญาประดิษฐ์
วิทยาลัยการคอมพิวเตอร์
มหาวิทยาลัยขอนแก่น
ปีการศึกษา 2568

นายณัฐพงษ์ ด้างถางคำ และ นายธนเดช วาตรีบุญเรือง. 2568. **การถ่ายโอนทรงผมและสีผมด้วย GAN เสริมด้วย Diffusion Model สำหรับปรับปรุงความเรียบเนียนของเส้นผม.** โครงงานคอมพิวเตอร์. ปริญญาวิทยาศาสตรบัณฑิต หลักสูตรปัญญาประดิษฐ์ สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น.
อาจารย์ที่ปรึกษา: อ.ดร.ญานิกา คงโสรส

บทคัดย่อ

การถ่ายโอนทรงผมและสีผมคือการเปลี่ยนผมของคนในภาพให้มีทรงและสีตามภาพอ้างอิง โดยที่ใบหน้า ผิว เสื้อผ้า และฉากหลังยังต้องเหมือนเดิม จากการทดลองเบื้องต้น ผู้วิจัยพบว่าโมเดลที่มีอยู่ยังมีจุดอ่อน HairFastGAN ทำงานเร็วแต่ให้สีผมเป็นปื้นและใบหน้าซีด ส่วน Barbershop ให้ภาพที่ดีแต่ใช้เวลาหลายนาทีต่อภาพ โครงงานนี้จึงปรับจูน (Fine-tune) โมเดลทั้งสองด้วยข้อมูลของผู้วิจัย ซึ่งแบ่งเป็นชุดฝึก 150 ชุด ชุดตรวจสอบ 9 ชุด และชุดทดสอบ 10 ชุด ทั้งสองโมเดลใช้ฟังก์ชันสูญเสียหลักชุดเดียวกันที่วัด 5 ด้าน คือ สีผม ทรงผม ความเหมือนของใบหน้า บริเวณที่ต้องคงเดิม และรายละเอียดของเส้นผม โดย HairFastGAN มีค่าสูญเสียส่วนเพิ่มที่ใช้กับโมเดลนี้เท่านั้น คือวัดสีและทรงที่ภาพกลางด้วย และยึดรหัสไม่ให้ห่างจากค่าเดิม ผู้วิจัยทดลองอัตราการเรียนรู้ 4 ชุด (Trial A–D) ชุดละ 30 รอบ (Epoch) และเลือกจุดบันทึก (Checkpoint) บนชุดตรวจสอบด้วยกติกาฉบับแก้ไขที่เปิดเผยไว้ในบทวิธีดำเนินการวิจัย จากนั้นเพิ่มขั้นขัดเกลาด้วย Stable Diffusion Inpainting แบบแรงต่ำ (Strength 0.15) เพื่อเติมรายละเอียดเส้นผม แล้วตามด้วยการเก็บรายละเอียดพื้นหลังและการเพิ่มความคม

ผลบนชุดทดสอบพบว่าการปรับจูนช่วยทั้งสองโมเดล HairFastGAN (Trial B Epoch 24) ลดความคลาดเคลื่อนของสีผมจาก 13.03 เหลือ 8.99 เพิ่มความเหมือนของใบหน้าที่วัดด้วย ArcFace (Additive Angular Margin Loss) จาก 0.728 เป็น 0.794 และลดการเปลี่ยนแปลงนอกบริเวณผม (Mean Absolute Error: MAE) จาก 0.041 เหลือ 0.014 ส่วน Barbershop-FT ซึ่งคือ Barbershop ที่ปรับจูนแล้ว (Trial A Epoch 30) ให้สีผมใกล้เป้าหมายที่สุด (7.86) และเพิ่มค่า ArcFace อย่างมีนัยสำคัญ (+0.013, ช่วงความเชื่อมั่น (Confidence Interval: CI) 95% +0.008 ถึง +0.019) แต่ใช้เวลาประมาณ 657 วินาทีต่อภาพ เทียบกับประมาณ 10 วินาทีของ HairFastGAN

การประเมินโดยผู้ใช้ 41 คน (164 คำตอบ) ซึ่งไม่รู้ว่าภาพมาจากโมเดลใด พบว่า Diffusion ทำให้ภาพสมจริงขึ้น (Barbershop-FT +0.59, 95% CI +0.27 ถึง +0.93) แต่ความเหมือนของใบหน้าลดลงเล็กน้อย ซึ่งสอดคล้องกับค่า ArcFace ที่ลดลง และร้อยละ 84 ของคำตอบยอมรอผลได้ไม่เกิน 5 นาที ผู้วิจัยจึงเลือก HairFastGAN Trial B Epoch 24 (B24) + Diffusion ไปพัฒนาเป็นเว็บแอปพลิเคชันชื่อ LOOKLAB (https://looklab2.vercel.app/) เนื่องจากได้คะแนนความพึงพอใจสูงสุด (3.90 จาก 5) ใช้เวลาประมาณ 13 วินาทีต่อภาพ และรักษาใบหน้าได้ดีกว่า Barbershop-FT + Diffusion อย่างชัดเจน (+0.73) การทดลองใช้งานเว็บจริง 100 ครั้งได้คะแนนความพึงพอใจโดยรวม 4.73 จาก 5 และเวลารอมีค่ามัธยฐาน 14.9 วินาที

คำสำคัญ: การถ่ายโอนทรงผม, การถ่ายโอนสีผม, การปรับจูนโมเดล, การปรับปรุงคุณภาพหลังกระบวนการด้วยดิฟฟิวชัน, การคงเอกลักษณ์ใบหน้า

Nattapong Dangthangkham and Thanadet Wateeboonreang. 2025. **GAN-based Hair Transfer with Diffusion Post-processing for Seamless Hairline and Texture Refinement.** Computer Project, Bachelor of Science, Program in Artificial Intelligence, Department of Computer Science, College of Computing, Khon Kaen University.

Project Advisor: Lecturer Yanika Kongsorot, Ph.D.

ABSTRACT

Hair transfer must change the hairstyle and hair color to match reference images while preserving the person's face, skin, clothing, and background. This project fine-tunes two GAN-based models, HairFastGAN and Barbershop, on our own dataset of 150 training, 9 validation, and 10 test triplets, using a shared core objective with architecture-specific auxiliary terms, covering five aspects: hair color, hair shape, face identity, protected regions, and hair detail. Four learning-rate settings (Trials A–D) were trained for 30 epochs each, and checkpoints were selected on the validation set with a common amended rule; the amendment and unequal checkpoint availability are disclosed in the methodology. A low-strength Stable Diffusion inpainting stage (strength 0.15), followed by background detail recovery and native sharpening, was then added as post-processing.

On the test set, fine-tuning improved both models. HairFastGAN (Trial B, epoch 24) reduced the hair-color error from 13.03 to 8.99, raised ArcFace identity similarity from 0.728 to 0.794, and reduced the change outside the hair (MAE) from 0.041 to 0.014. Barbershop-FT (Trial A, epoch 30) gave the closest hair color (7.86) and a significant ArcFace gain (+0.013, 95% CI +0.008 to +0.019), but needed about 657 seconds per image versus about 10 seconds for HairFastGAN.

A blind user study with 41 participants (164 responses) showed that diffusion made images more realistic (Barbershop-FT +0.59, 95% CI +0.27 to +0.93) but slightly reduced perceived face similarity, consistent with the ArcFace drop, and 84% of responses accepted a wait of at most five minutes. HairFastGAN B24 + Diffusion was therefore deployed as a web application named LOOKLAB (https://looklab2.vercel.app/): it received the highest satisfaction score (3.90/5), takes about 13 seconds per image, and preserves the face clearly better than Barbershop-FT + Diffusion (+0.73). In 100 real uses of the web application, overall satisfaction was 4.73 out of 5 with a median waiting time of 14.9 seconds.

Keywords: Hairstyle Transfer, Hair Color Transfer, Fine-tuning, Diffusion Post-processing, Identity Preservation

กิตติกรรมประกาศ

ข้าพเจ้าขอขอบพระคุณอาจารย์ที่ปรึกษาโครงงาน อ.ดร.ญานิกา คงโสรส ที่ได้กรุณาให้คำแนะนำ คำปรึกษา และข้อเสนอแนะอันเป็นประโยชน์ ตลอดระยะเวลาการดำเนินโครงงานฉบับนี้ รวมทั้งสละเวลาในการตรวจแก้ไขและให้กำลังใจ จนทำให้โครงงานนี้สำเร็จลุล่วงไปได้ด้วยดี

ขอ ขอบพระคุณ คณาจารย์ ใน สาขา วิชา ปัญญา ประดิษฐ์ วิทยาลัย การ คอมพิวเตอร์ มหาวิทยาลัย ขอนแก่น ทุก ท่าน ที่ได้ ถ่ายทอด ความ รู้ ทาง วิชาการ ซึ่ง เป็น พื้น ฐาน สำคัญ ใน การศึกษาค้นคว้าและจัดทำโครงงานนี้

ขอขอบพระคุณเพื่อนร่วมชั้นและผู้ที่เกี่ยวข้องทุกท่าน ที่ได้ให้ความช่วยเหลือ แนะนำ และแลกเปลี่ยนความคิดเห็น ซึ่งเป็นประโยชน์ต่อการดำเนินงานในหลายด้าน

ท้ายที่สุดนี้ ข้าพเจ้าขอขอบพระคุณบิดา มารดา และครอบครัว ที่ให้การสนับสนุน ส่งเสริม และเป็นกำลังใจ ตลอดระยะเวลาของการศึกษา

ผู้จัดทำ
นายณัฐพงษ์ ด้างถางคำ
นายธนเดช วาตรีบุญเรือง

สารบัญ

บทคัดย่อ ก

ABSTRACT ข

กิตติกรรมประกาศ ค

สารบัญ ง

สารบัญภาพ ซ

สารบัญตาราง ฎ

1 บทนำ **1**
1.1 ความเป็นมาและความสำคัญของโครงงาน 1
1.2 วัตถุประสงค์ของโครงงาน 2
1.3 ขอบเขตของโครงงาน 2
1.4 ข้อจำกัดของโครงงาน 3

2 เอกสารและงานวิจัยที่เกี่ยวข้อง **4**
2.1 งานวิจัยด้านการถ่ายโอนทรงผมด้วยเทคนิคปัญญาประดิษฐ์ 4
2.2 เทคนิคและเครื่องมือที่เกี่ยวข้อง 6
2.3 ทฤษฎีที่เกี่ยวข้อง 8
2.3.1 StyleGAN2 และพื้นที่แฝง (Latent Space) 8
2.3.2 การทำงานของโมเดล HairFastGAN 12
2.3.3 การทำงานของโมเดล Barbershop 21
2.3.4 การเปรียบเทียบ HairFastGAN และ Barbershop 25
2.3.5 การแบ่งส่วนภาพด้วย SegFormer 26
2.3.6 การปรับปรุงคุณภาพภาพด้วย Stable Diffusion 28
2.3.7 การเรียนรู้แบบถ่ายโอนและการปรับจูนโมเดล 33
2.3.8 ตัวชี้วัดคุณภาพภาพ 33

3 วิธีดำเนินการวิจัย **35**
3.1 ภาพรวมกระบวนการวิจัย 35
3.2 ชุดข้อมูล 35
3.3 เครื่องมือและสภาพแวดล้อม 37
3.4 ขั้นตอนการทำงานของ Barbershop-FT (Barbershop ที่ปรับจูนแล้ว) 38

3.5 ขั้นตอนการทำงานของ HairFastGAN 42
3.6 การปรับจูนโมเดล 45
3.6.1 ฟังก์ชันความสูญเสีย 46
3.6.2 ขั้นตอนการฝึกและการตั้งค่า 50
3.7 การเลือก Checkpoint 50
3.8 การทดสอบและตัวชี้วัด 52
3.9 ขั้นขัดเกลาด้วย Diffusion 53
3.10 การประเมินโดยผู้ใช้ 56
3.11 การออกแบบเว็บแอปพลิเคชันต้นแบบ 58
3.11.1 โครงสร้างของระบบ 58
3.11.2 หน้าหลักและการเตรียมภาพ 58
3.11.3 ตัวเลือกทรงผมและสีผม 59
3.11.4 โหมดกล้องสด 59
3.11.5 หน้าผลลัพธ์และแบบสอบถาม 61
3.12 ข้อควรระวังในการตีความและรายละเอียดการคำนวณ 61

4 ผลการทดลองและอภิปรายผล 63
4.1 ผลการปรับจูนและการเลือก Checkpoint 63
4.1.1 ตัวอย่างการคำนวณค่าสูญเสีย 63
4.1.2 HairFastGAN: เลือก Trial B Epoch 24 64
4.1.3 Barbershop-FT: เลือก Trial A Epoch 30 66
4.2 ผลบนชุดทดสอบ 68
4.3 ผลของขั้นขัดเกลาด้วย Diffusion 72
4.4 ผลการประเมินโดยผู้ใช้ 75
4.4.1 ผลของ Diffusion ในสายตาผู้ใช้ 77
4.4.2 เวลาที่ผู้ใช้ยอมรอ 79
4.4.3 สรุปผลของ Diffusion จากตัวเลขและผู้ใช้ 80
4.5 การคัดเลือกโมเดลสำหรับเว็บแอปพลิเคชัน 80
4.6 ผลการทดลองใช้งานเว็บแอปพลิเคชัน 81
4.7 อภิปรายผล 82
4.7.1 เหตุผลที่ปรับจูนเฉพาะโมดูล Color และ Refinement ของ HairFastGAN 82
4.7.2 ทรงผมของ Barbershop-FT แทบไม่เปลี่ยนหลังปรับจูน 82
4.7.3 เหตุที่ Diffusion ทำให้ภาพดูดีขึ้นแต่ใบหน้าเหมือนเดิมน้อยลง 83
4.7.4 เหตุผลที่เลือก HairFastGAN B24 + Diffusion ไปใช้บนเว็บ 83
4.7.5 สีผมของ HairFastGAN บนชุดทดสอบ 83
4.7.6 ความจำเป็นของด่าน 5 ด่าน 83
4.8 ข้อจำกัดที่พบ 84

5 สรุปผลและข้อเสนอแนะ **85**
5.1 สรุปผล 85
5.1.1 สรุปภาพรวมของโครงงาน 85
5.1.2 สรุปข้อค้นพบหลัก 85
5.1.3 การบรรลุวัตถุประสงค์ของโครงงาน 86
5.2 ข้อเสนอแนะ 87

บรรณานุกรม **88**

ภาคผนวก **92**

ภาคผนวก ก: การตั้งค่าที่ใช้ในการทดลอง **93**
ก.1 ค่าที่ใช้ในการปรับจูนและการเลือก Checkpoint 93
ก.2 ค่าที่ใช้ในขั้นขัดเกลาด้วย Diffusion 93

ภาคผนวก ข: แบบประเมินที่ใช้ในโครงงาน **97**
ข.1 แบบประเมินภาพแบบปกปิดชื่อโมเดล 97
ข.2 แบบประเมินหลังใช้งานเว็บแอปพลิเคชัน 97

ภาคผนวก ค: ผลการทดลองเพิ่มเติม **100**
ค.1 ตัวอย่างผลลัพธ์ของโมเดลตั้งต้น 100
ค.2 การเปรียบเทียบข้อความสั่งงานของ Diffusion 100

ภาคผนวก ง: คู่มือการใช้งานเว็บแอปพลิเคชัน LOOKLAB **104**
ง.1 การเข้าใช้งาน 104
ง.2 ขั้นตอนการใช้งานโหมดอัปโหลดรูป 104
ง.3 การใช้โหมดกล้องสด 108
ง.4 ข้อแนะนำในการเตรียมรูป 111
ง.5 การแก้ปัญหาเบื้องต้น 111

ภาคผนวก จ: การนำ Artificial Intelligence (AI) มาใช้ในงานวิจัย **114**
จ.1 การสร้าง Colab ทดลอง HairFastGAN แบบ Pretrained (ChatGPT) 114
จ.2 การเพิ่มขั้นปรับภาพด้วย Realistic Vision V5.1 (ChatGPT) 115
จ.3 การวิเคราะห์ว่าส่วนไหนของ HairFastGAN ปรับจูนได้ (ChatGPT) 116
จ.4 การสร้าง Colab ทดลอง Barbershop แบบ Pretrained (ChatGPT) 119
จ.5 การเพิ่มขั้นปรับภาพต่อจาก Barbershop (ChatGPT) 121
จ.6 การวิเคราะห์ว่าส่วนไหนของ Barbershop ปรับจูนได้ (ChatGPT) 122
จ.7 การเปรียบเทียบ Barbershop A30 กับ HairFastGAN B24 (ChatGPT) 125
จ.8 การออกแบบหน้าเว็บ LOOKLAB (ChatGPT) 126
จ.9 การเขียนข้อความสั่งงานเพื่อสร้างหน้าเว็บจริง (ChatGPT) 128
จ.10 การสร้างหน้าเว็บตามแบบที่เลือก (Google AI Studio) 129

จ.11 การนำเว็บขึ้นใช้งานบน Vercel และ RunPod (Claude) 131
จ.12 สรุปการใช้คำตอบจาก AI 133

สารบัญภาพ

ภาพที่ 1 ความสัมพันธ์ระหว่าง FS Latent Space และ W^+ Space 11
ภาพที่ 2 เปรียบเทียบคุณภาพการสร้างภาพคืนระหว่าง W^+ และ FS 12
ภาพที่ 3 ภาพรวมขั้นตอนการทำงานของโมเดล HairFastGAN 13
ภาพที่ 4 ตัวอย่างการทำงานของ Pose Alignment 15
ภาพที่ 5 บล็อกผสมพื้นที่แฝงและโมดูลถ่ายโอนรูปทรงของ HairFastGAN 17
ภาพที่ 6 ตัวอย่างการทำงานของ Shape Alignment 17
ภาพที่ 7 โครงสร้างโมดูล Color และ Refinement ของ HairFastGAN 20
ภาพที่ 8 ตัวอย่างการทำงานของ Color และ Refinement Alignment 20
ภาพที่ 9 ภาพรวมกระบวนการทำงานของโมเดล Barbershop 21
ภาพที่ 10 การสร้างหน้ากากเป้าหมายของ Barbershop 22
ภาพที่ 11 ภาพรวมกระบวนการทำงานของ SegFormer 27
ภาพที่ 12 สถาปัตยกรรมและการทำงานภายในของ Stable Diffusion 29
ภาพที่ 13 การบีบอัดเชิงการรับรู้และเชิงความหมายของ LDM 30
ภาพที่ 14 ตัวอย่างการ Inpainting ด้วย Latent Diffusion Model 32
ภาพที่ 15 ภาพรวมกระบวนการวิจัย ตั้งแต่ข้อมูล การปรับจูน การเลือก Checkpoint การทดสอบ การขัดเกลาด้วย Diffusion จนถึงการคัดเลือกโมเดลสำหรับเว็บแอปพลิเคชัน . . 36
ภาพที่ 16 ตัวอย่างข้อมูลนำเข้าหนึ่งชุด ได้แก่ ภาพใบหน้าต้นฉบับ ภาพอ้างอิงทรงผม และภาพอ้างอิงสีผม 37
ภาพที่ 17 ขั้นตอนการทำงานของ Barbershop-FT + Diffusion ตั้งแต่ภาพนำเข้า 3 ภาพ จนถึงภาพผลลัพธ์ พร้อมส่วนที่ปรับจูน 39
ภาพที่ 18 ขั้นตอนการทำงานของ HairFastGAN (ปรับจูน) + Stable Diffusion แสดงโมดูลที่ล็อกไว้ โมดูลที่ปรับจูน และขั้นขัดเกลาที่เพิ่มเข้ามา 43
ภาพที่ 19 ตัวอย่างภาพผลลัพธ์จาก HairFastGAN และ Barbershop จากภาพนำเข้าชุดเดียวกัน 45
ภาพที่ 20 ขั้นตอนการปรับจูน: วนฝึกทุกตัวอย่างในชุดฝึก และตรวจสอบบนชุดตรวจสอบหลังจบทุก Epoch 46
ภาพที่ 21 ขั้นขัดเกลาด้วย Diffusion (แถวบน) และสรุปการปรับจูน HairFastGAN (แถวล่าง) 54
ภาพที่ 22 หน้าหลักของเว็บแอปพลิเคชัน LOOKLAB 59
ภาพที่ 23 หน้าแคตตาล็อกทรงผมและสีผมของ LOOKLAB 60
ภาพที่ 24 โหมดกล้องสดของ LOOKLAB 60
ภาพที่ 25 หน้าผลลัพธ์และแบบสอบถามของ LOOKLAB 61
ภาพที่ 26 คะแนนบนชุดตรวจสอบทุก Epoch ของ HairFastGAN (เส้นสีคือ Trial B ที่เลือก) 65
ภาพที่ 27 ตัวชี้วัด 5 ด้านบนชุดตรวจสอบทุก Epoch ของ HairFastGAN ทั้ง 4 Trial 66

ภาพที่ 28 คะแนนบนชุดตรวจสอบทุก Epoch ของ Barbershop-FT (เส้นสีคือ Trial A ที่เลือก) 67
ภาพที่ 29 ตัวชี้วัด 5 ด้านบนชุดตรวจสอบทุก Epoch ของ Barbershop-FT ทั้ง 4 Trial . . . 68
ภาพที่ 30 ผลบนชุดทดสอบรายภาพ (จุดจาง = 1 ภาพ, ขีดเข้ม = ค่าเฉลี่ย) 70
ภาพที่ 31 ตัวอย่างผลบนชุดทดสอบ (test_000) ของโมเดลก่อนและหลังปรับจูน 72
ภาพที่ 32 ตัวอย่างภาพหลังแต่ละขั้นของการขัดเกลา 2 ชุดจาก 8 ชุด (แถวบน BS-FT A30, แถวล่าง HFG B24) 73
ภาพที่ 33 คุณภาพภาพและเอกลักษณ์ใบหน้าหลังแต่ละขั้นของการขัดเกลา (เส้นจาง = แต่ละชุดภาพ, เส้นเข้ม = ค่าเฉลี่ย 8 ชุด) 74
ภาพที่ 34 ตัวอย่างผลลัพธ์ของ 4 ระบบจากภาพนำเข้าชุดเดียวกัน 76
ภาพที่ 35 หน้าแบบประเมินที่ไม่เปิดเผยชื่อโมเดลและสลับลำดับภาพทุกคน 77
ภาพที่ 36 คะแนนผู้ใช้ก่อน (จุดเทา) และหลัง Diffusion (จุดสี) เครื่องหมาย * คือช่วงความเชื่อมั่น 95% ไม่คร่อมศูนย์ 78
ภาพที่ 37 เวลาที่ผู้ใช้ยอมรอเพื่อให้ได้ภาพคุณภาพเท่าภาพที่เห็น (41 คน $\times$ 4 ภาพ) 79
ภาพที่ 38 ผลการทดลองใช้งานเว็บแอปพลิเคชัน 100 ครั้ง 82
ภาพที่ 39 หน้าหลังส่งแบบประเมินบนเว็บ LOOKLAB 98
ภาพที่ 40 ตัวอย่างภาพนำเข้าและผลลัพธ์ของ HairFastGAN และ Barbershop ก่อนปรับจูน 100
ภาพที่ 41 ผลของข้อความสั่งงาน 6 แบบกับภาพจาก HairFastGAN และ Barbershop (ตัวอย่างที่ 1) 101
ภาพที่ 42 ผลของข้อความสั่งงาน 6 แบบกับภาพจาก HairFastGAN และ Barbershop (ตัวอย่างที่ 2) 101
ภาพที่ 43 ตัวชี้วัดของภาพก่อนผ่าน Diffusion (Base) และหลังผ่านด้วยข้อความ P1–P6 . . 102
ภาพที่ 44 คิวอาร์โค้ดสำหรับเข้าเว็บแอปพลิเคชัน LOOKLAB 104
ภาพที่ 45 หน้าต่างคู่มือการใช้งานที่แสดงเมื่อเปิดเว็บครั้งแรก 104
ภาพที่ 46 หน้าหลักก่อนใส่รูปและปุ่มอัปโหลดรูปภาพ 105
ภาพที่ 47 การตรวจพบใบหน้าและการเลือกทรงผม 106
ภาพที่ 48 การเลือกสีผมและปุ่มสร้างลุคใหม่ของคุณ 107
ภาพที่ 49 หน้าต่างแสดงสถานะระหว่างสร้างภาพทรงผม 107
ภาพที่ 50 ภาพผลลัพธ์พร้อมแถบเลื่อนเปรียบเทียบก่อนและหลัง 108
ภาพที่ 51 ปุ่มเปิดกล้องสำหรับเข้าสู่โหมดกล้องสด 109
ภาพที่ 52 การเลือกทรงผม สีผม และการนับถอยหลังเพื่อถ่ายภาพในโหมดกล้องสด 110
ภาพที่ 53 หน้าต่างแบบสอบถามประเมินผลลัพธ์ภาพทรงผมจากภาพที่ถ่ายด้วยกล้อง . . . 110
ภาพที่ 54 ทรงผมใหม่ที่แสดงบนภาพจากกล้องแบบเรียลไทม์ 111
ภาพที่ 55 ข้อความสั่งงานและคำตอบของ ChatGPT ในการสร้าง Colab สำหรับรัน HairFastGAN แบบ Pretrained 115
ภาพที่ 56 ข้อความสั่งงานและคำตอบของ ChatGPT ในการเพิ่มขั้นปรับภาพด้วย Realistic Vision V5.1 116

ภาพที่ 57 ข้อความสั่งงานและตอนต้นของคำตอบ ChatGPT เรื่องส่วนที่ปรับจูนได้ของ HairFastGAN 118
ภาพที่ 58 ตารางในคำตอบของ ChatGPT ที่แยกการปรับจูนน้ำหนักจริงออกจากการปรับค่าตอนสร้างภาพ 119
ภาพที่ 59 ข้อความสั่งงานและคำตอบของ ChatGPT ในการสร้าง Colab สำหรับรัน Barbershop แบบ Pretrained 120
ภาพที่ 60 ข้อความสั่งงานและคำตอบของ ChatGPT ในการเพิ่มขั้นปรับภาพต่อจาก Barbershop 121
ภาพที่ 61 ข้อความสั่งงานและตอนต้นของคำตอบ ChatGPT เรื่องส่วนที่ปรับจูนได้ของ Barbershop 123
ภาพที่ 62 คำตอบของ ChatGPT เรื่องส่วนของ StyleGAN2 ที่ควรปรับจูนใน Barbershop . 124
ภาพที่ 63 ข้อความสั่งงานและคำตอบของ ChatGPT ในการสร้างไฟล์เปรียบเทียบ Barbershop A30 กับ HairFastGAN B24 126
ภาพที่ 64 ข้อความสั่งงานและภาพตัวอย่างหน้าเว็บที่ ChatGPT ออกแบบ (แบบ 03 Peach Room) 127
ภาพที่ 65 ตารางสรุปหน้าเว็บ 10 แบบที่ ChatGPT ออกแบบให้เลือก 127
ภาพที่ 66 ข้อความสั่งงานและข้อความสำหรับ Google AI Studio ที่ ChatGPT เขียนให้ . . 128
ภาพที่ 67 หน้าเว็บที่ Google AI Studio สร้างตามข้อความสั่งงานและแบบ 03 Peach Room 129
ภาพที่ 68 ข้อความสั่งงานและคำตอบของ Claude เรื่องการนำเว็บขึ้น Vercel และ RunPod 132
ภาพที่ 69 ขั้นตอนที่ Claude ให้ผู้วิจัยทำต่อ และสิ่งที่ Claude แก้เพิ่ม 132

สารบัญตาราง

ตารางที่ 1 สรุปรายละเอียดงานวิจัยที่เกี่ยวข้องกับการถ่ายโอนทรงผมด้วยเทคนิคปัญญาประดิษฐ์ 7
ตารางที่ 2 พื้นที่แฝงของ StyleGAN2 ที่เกี่ยวข้องกับงานวิจัย 10
ตารางที่ 3 การเปรียบเทียบคุณสมบัติของ HairFastGAN และ Barbershop 26
ตารางที่ 4 การแบ่งชุดข้อมูล 38
ตารางที่ 5 อัตราการเรียนรู้ของ 4 Trial 51
ตารางที่ 6 ด่านที่ Checkpoint ต้องผ่าน (เทียบกับ Epoch 0) 52
ตารางที่ 7 ตัวชี้วัด 5 ด้านที่ใช้ทั้งการเลือก Checkpoint และการทดสอบ 53
ตารางที่ 8 เกณฑ์ประเมินขั้น Diffusion 56
ตารางที่ 9 คำถามในแบบประเมินของผู้ใช้ 57
ตารางที่ 10 ค่าสูญเสียแยกแต่ละส่วนของ HFG Trial B (ค่าเฉลี่ยชุดตรวจสอบ) 64
ตารางที่ 11 ผลการเลือก Checkpoint ของ HairFastGAN (ชุดตรวจสอบ 9 ชุด) 65
ตารางที่ 12 ผลการเลือก Checkpoint ของ Barbershop-FT ที่ Epoch 30 (ชุดตรวจสอบ 9 ชุด) 67
ตารางที่ 13 ผลบนชุดทดสอบ 10 ชุด (ค่าเฉลี่ย) และผลต่างแบบจับคู่ของ Barbershop . . . 69
ตารางที่ 14 ผลของการขัดเกลาด้วย Diffusion ใน 8 ชุดภาพ 74
ตารางที่ 15 คะแนนเฉลี่ยจากผู้ใช้ 41 คน (คะแนน 1–5) 77
ตารางที่ 16 ผลต่างคะแนนแบบจับคู่รายคน (95% CI จากบูตสแตรป) 78
ตารางที่ 17 การตัดสินผลของ Diffusion จากตัวชี้วัดเชิงตัวเลขร่วมกับผู้ใช้ 80
ตารางที่ 18 ผลการทดลองใช้งานเว็บแอปพลิเคชัน 100 ครั้ง 81
ตารางที่ 19 ค่าที่ใช้ในการปรับจูนและการเลือก Checkpoint 94
ตารางที่ 20 ค่าที่ใช้ในขั้นขัดเกลาด้วย Diffusion 95
ตารางที่ 21 คำถามในแบบประเมินภาพแบบปกปิดชื่อโมเดล 97
ตารางที่ 22 หัวข้อในแบบประเมินหลังใช้งานเว็บแอปพลิเคชัน LOOKLAB 98
ตารางที่ 23 เปรียบเทียบโค้ดที่ Google AI Studio สร้างกับเว็บ LOOKLAB ที่ใช้จริง 130
ตารางที่ 24 เปรียบเทียบหน้าเว็บสำหรับ Vercel ที่ Claude ทำให้กับที่ใช้จริง 133
ตารางที่ 25 สรุปการใช้คำตอบจาก AI ในโครงงาน 134

บทที่ 1

บทนำ

1.1 ความเป็นมาและความสำคัญของโครงงาน

หลายคนเคยตัดผมหรือทำสีผมแล้วได้ผลไม่ตรงกับที่คิดไว้ และเมื่อตัดหรือทำสีไปแล้วก็แก้กลับได้ยาก ถ้ามีระบบที่ช่วยให้เห็นภาพตัวเองในทรงผมและสีผมใหม่ก่อนลงมือจริง ก็จะช่วยให้ตัดสินใจได้ง่ายขึ้น งานลักษณะนี้ในสาขาคอมพิวเตอร์วิทัศน์ (Computer Vision) เรียกว่าการถ่ายโอนทรงผมและสีผม (Hair Transfer) [1, 2] ระบบจะรับภาพ 3 ภาพ ได้แก่ ภาพใบหน้าของผู้ใช้ ภาพที่มีทรงผมที่ต้องการ และภาพที่มีสีผมที่ต้องการ แล้วสร้างภาพใหม่ที่ยังเป็นผู้ใช้คนเดิม สวมเสื้อตัวเดิม และอยู่หน้าฉากหลังเดิม แต่มีทรงผมและสีผมตามภาพอ้างอิง

งานนี้ฟังดูเหมือนเป็นการตัดผมจากภาพหนึ่งไปแปะลงอีกภาพ แต่ในทางปฏิบัติยากกว่านั้นมาก เพราะเส้นผมมีรายละเอียดเล็ก ๆ จำนวนมาก แสงและเงาบนผมเปลี่ยนไปตามทิศทางของเส้นผม และขอบผมยังซ้อนทับกับหน้าผาก หู และฉากหลัง เมื่อเปลี่ยนจากผมยาวเป็นผมสั้น ระบบยังต้องคาดเดาว่าส่วนที่ผมเดิมเคยบังไว้ เช่น หูหรือลำคอ ควรมีลักษณะอย่างไร ปัญหาอีกข้อหนึ่งคือไม่มีภาพเฉลยให้เทียบ เพราะไม่มีภาพจริงของคนคนนั้นในทรงผมใหม่ การตัดสินว่าภาพใดดีกว่าจึงต้องแยกพิจารณาทีละด้าน เช่น สีตรงหรือไม่ ทรงตรงหรือไม่ และใบหน้ายังเหมือนเดิมหรือไม่ และสุดท้ายยังต้องให้คนที่ดูภาพเป็นผู้ประเมินด้วย

งานวิจัยที่ผ่านมาแก้ปัญหานี้ได้หลายแนวทาง เช่น ใช้โมเดลตระกูล StyleGAN [3] ใช้ข้อความสั่งงานผ่านโมเดล CLIP (Contrastive Language-Image Pre-training) [4] หรือใช้แบบจำลองดิฟฟิวชัน (Diffusion Models) [5] แต่ยังไม่มีวิธีใดที่ดีครบทุกด้าน ผู้วิจัยสนใจโมเดล 2 ตัวที่ทำงานต่างกันอย่างชัดเจน ตัวแรกคือ Barbershop [1] ซึ่งค้นหารหัสที่ใช้แทนภาพแต่ละภาพด้วยการปรับค่าซ้ำหลายร้อยรอบ (Optimization-based) จึงได้ภาพที่สมจริง แต่ใช้เวลาหลายนาทีต่อภาพ ตัวที่สองคือ HairFastGAN [2] ซึ่งใช้ตัวเข้ารหัส (Encoder-based) คำนวณรหัสออกมาในครั้งเดียว จึงทำงานเสร็จในระดับวินาที อย่างไรก็ตาม เมื่อผู้วิจัยทดลองใช้ HairFastGAN กับภาพของผู้วิจัยเองในช่วงแรก พบว่าสีผมมักออกมาเป็นปื้นสีเดียว ไม่ไล่เฉดเหมือนผมจริง และใบหน้าดูซีดกว่าภาพต้นฉบับ

จากข้อสังเกตนี้จึงเกิดคำถามว่า หากนำโมเดลทั้งสองมาปรับจูน (Fine-tune) ด้วยข้อมูลของผู้วิจัยเอง จุดอ่อนเหล่านี้จะลดลงได้มากเพียงใด และเมื่อปรับแล้วโมเดลใดเหมาะกับการใช้งานจริงมากกว่า คำถามนี้ตอบจากงานวิจัยเดิมไม่ได้ เพราะแต่ละงานฝึกและวัดผลด้วยข้อมูลและตัวชี้วัดคนละชุด ผู้วิจัยจึงปรับจูนโมเดลทั้งสองด้วยข้อมูล ฟังก์ชันสูญเสีย และกติกาการเลือกโมเดลชุดเดียวกัน เพื่อให้การเปรียบเทียบเป็นธรรม

อีกปัญหาหนึ่งที่พบคือ ภาพจากโมเดลโครงข่ายปรปักษ์เชิงกำเนิด (Generative Adversarial Network: GAN) ทั้งสองตัว มีเส้นผมที่ดูนุ่มและเบลอเกินไป ไม่เห็นเป็นเส้นชัดเหมือนภาพถ่าย

จริง ขณะที่ Stable Diffusion วาดรายละเอียดได้ดีมาก แต่ถ้าให้ Stable Diffusion สร้างทรงผมเองทั้งหมด จะควบคุมทรงผม สีผม และใบหน้าได้ยาก ผู้วิจัยจึงแบ่งหน้าที่ให้แต่ละโมเดลทำในส่วนที่ถนัด คือให้ GAN จัดทรงและสีผมให้ถูกต้องก่อน แล้วใช้ Stable Diffusion แบบแรงต่ำเติมเฉพาะพื้นผิวของเส้นผมและผิวหน้าในภายหลัง จากนั้นวัดผลทั้งด้วยตัวชี้วัดเชิงตัวเลข 5 ด้าน และด้วยความเห็นของผู้ใช้ที่ไม่รู้ว่าภาพมาจากโมเดลใด แล้วนำตัวเลือกที่เหมาะสมที่สุดไปพัฒนาเป็นเว็บแอปพลิเคชันให้คนทั่วไปทดลองใช้ได้จริง เนื่องจากงานวิจัยส่วนใหญ่เผยแพร่เพียงโค้ดต้นฉบับ (Source Code) ซึ่งผู้ที่ไม่ได้เขียนโปรแกรมนำไปใช้ได้ยาก

1.2 วัตถุประสงค์ของโครงงาน

1.2.1. เพื่อศึกษาและเปรียบเทียบประสิทธิภาพของโมเดลการเรียนรู้เชิงลึก 2 โมเดล ได้แก่ HairFastGAN และ Barbershop ในการถ่ายโอนทรงผมและสีผม ทั้งก่อนและหลังปรับจูนด้วยข้อมูลและกติกาเดียวกัน

1.2.2. เพื่อวิเคราะห์ข้อดีและข้อจำกัดของแต่ละโมเดล ในด้านความถูกต้องของสีผมและทรงผม การรักษาใบหน้าให้เป็นคนเดิม ความสมจริง และเวลาประมวลผล รวมถึงผลของการขัดเกลาภาพด้วย Diffusion โดยใช้ตัวชี้วัดเชิงตัวเลข 5 ด้าน ร่วมกับการประเมินโดยผู้ใช้

1.2.3. เพื่อพัฒนาเว็บแอปพลิเคชันต้นแบบที่ให้ผู้ใช้ทดลองเปลี่ยนทรงผมและสีผมได้ง่าย โดยใช้โมเดลที่ได้ผลดีที่สุดจากการประเมิน

1.3 ขอบเขตของโครงงาน

1.3.1. ศึกษาและเปรียบเทียบโมเดลหลัก 2 โมเดล ได้แก่ HairFastGAN และ Barbershop โดยเริ่มจากน้ำหนักที่ผู้พัฒนาเผยแพร่ไว้ (Pretrained Weights) ทั้งสองโมเดลใช้ StyleGAN2 (Style-based Generative Adversarial Network รุ่นที่ 2) [3] ที่ฝึกด้วยชุดภาพใบหน้า FFHQ (Flickr-Faces-HQ) เป็นตัวสร้างภาพ

1.3.2. ใช้ชุดข้อมูลของผู้วิจัย 169 ชุด แต่ละชุดมี 3 ภาพ คือ ภาพใบหน้า ภาพทรงผม และภาพสีผม แบ่งเป็นชุดฝึก 150 ชุด ชุดตรวจสอบ 9 ชุด และชุดทดสอบ 10 ชุด ภาพทั้งหมดถูกครอปและจัดตำแหน่งใบหน้าตามรูปแบบของ FFHQ ที่ขนาด 1024×1024 พิกเซล

1.3.3. ปรับจูนเฉพาะส่วนของโมเดลที่ควบคุมสีและรายละเอียดของภาพ คือโมดูล Color และ Refinement ของ HairFastGAN และชั้นของ StyleGAN2 ที่วาดภาพความละเอียด 64–1024 พิกเซลของ Barbershop ทั้งสองโมเดลใช้ฟังก์ชันสูญเสียหลักชุดเดียวกันซึ่งวัด 5 ด้าน โดย HairFastGAN มีค่าสูญเสียส่วนเพิ่มที่ใช้กับโมเดลนี้เท่านั้น ทดลองอัตราการเรียนรู้ 4 ชุดต่อโมเดล ชุดละ 30 Epoch และเลือก Checkpoint ด้วยกติกาเดียวกันบนชุดตรวจสอบ

1.3.4. ขัดเกลาภาพด้วย Stable Diffusion Inpainting ที่ความแรง (Strength) 0.15 เฉพาะบริเวณผมและใบหน้า แล้วตามด้วยการเก็บรายละเอียดพื้นหลังและการเพิ่มความคม โดยไม่ฝึก Diffusion เพิ่ม

1.3.5. เปรียบเทียบ 4 เงื่อนไขหลัก ได้แก่ HairFastGAN B24, HairFastGAN B24 + Diffusion, Barbershop-FT A30 และ Barbershop-FT A30 + Diffusion (B24 คือน้ำหนักของ Trial B Epoch 24, Barbershop-FT คือ Barbershop ที่ปรับจูนแล้ว และ A30 คือน้ำหนักของ Trial A Epoch 30) และใช้โมเดลก่อนปรับจูนของทั้งสองเป็นจุดอ้างอิง

1.3.6. ประเมินผลด้วยตัวชี้วัดเชิงตัวเลข 5 ด้าน ได้แก่ ความคลาดเคลื่อนของสีผมในปริภูมิสี CIELAB (Lab), ความตรงของทรงผม (Intersection over Union: IoU), ความเหมือนของใบหน้า (ArcFace: Additive Angular Margin Loss), การเปลี่ยนแปลงนอกบริเวณผม (Mean Absolute Error: MAE และ Structural Similarity Index: SSIM) และรายละเอียดของเส้นผม พร้อมวัดเวลาประมวลผลต่อภาพ ร่วมกับการประเมินโดยผู้ใช้ 41 คนแบบไม่บอกชื่อโมเดล และการทดลองใช้งานเว็บแอปพลิเคชันจริง 100 ครั้ง

1.3.7. ศึกษาเฉพาะภาพใบหน้าที่หันตรง (Frontal View) และประมวลผลการทดลองบน Google Colab ด้วยหน่วยประมวลผลกราฟิก (Graphics Processing Unit: GPU) NVIDIA A100 หน่วยความจำ 40 GB

1.4 ข้อจำกัดของโครงงาน

1.4.1. ชุดตรวจสอบและชุดทดสอบมีขนาดเล็ก (9 และ 10 ชุด) จึงใช้ตัวชี้วัดที่ต้องอาศัยภาพจำนวนมาก เช่น FID (Fréchet Inception Distance) ไม่ได้ และผลของตัวชี้วัดบางตัวยังแกว่งมาก

1.4.2. ระบบต้องใช้ GPU ประสิทธิภาพสูงจึงจะได้เวลาประมวลผลประมาณ 11–14 วินาทีต่อภาพ

1.4.3. ความสามารถในการลบผมเดิมที่บังใบหน้า (Face Occlusion) ขึ้นอยู่กับโมเดลตั้งต้น จึงอาจยังเห็นร่องรอยของผมเดิมปนอยู่ในภาพผลลัพธ์

1.4.4. ขั้น Diffusion อาจทำให้รายละเอียดของใบหน้าเปลี่ยนไปเล็กน้อย และบริเวณที่ถูกแก้ไขขึ้นกับความแม่นยำของการแบ่งส่วนภาพ

1.4.5. ระบบใช้ได้ดีกับภาพใบหน้าตรงเท่านั้น ผมต้องไม่บังใบหน้า ฉากหลังควรเรียบและไม่มีสิ่งใดบัง และภาพต้องถ่ายในที่ที่มีแสงสว่างเพียงพอ

1.4.6. โหมดกล้องบนเว็บแอปพลิเคชันยังไม่เป็นแบบเรียลไทม์เต็มรูปแบบ เพราะหลังถ่ายภาพต้องรอประมวลผลประมาณ 15 วินาที ทรงผมใหม่จึงจะปรากฏบนภาพจากกล้อง

บทที่ 2

เอกสารและงานวิจัยที่เกี่ยวข้อง

2.1 งานวิจัยด้านการถ่ายโอนทรงผมด้วยเทคนิคปัญญาประดิษฐ์

ก่อนเลือกโมเดลมาใช้ ผู้วิจัยได้ทบทวนงานด้านการถ่ายโอนทรงผมและสีผม (Hair Transfer) [1, 2] ที่ผ่านมา เพื่อดูว่าแต่ละแนวทางแก้ปัญหาใดได้แล้ว และยังมีข้อจำกัดอะไร งานเหล่านี้แบ่งได้เป็น 3 กลุ่ม กลุ่มแรกคือโมเดลโครงข่ายปรปักษ์เชิงกำเนิด (Generative Adversarial Network: GAN) [6] ที่หารหัสของภาพด้วยการปรับค่าซ้ำหลายรอบ (Optimization-based) ซึ่งได้ภาพดีแต่ช้า กลุ่มที่สองคือโมเดล GAN ที่ใช้ตัวเข้ารหัส (Encoder-based) คำนวณรหัสออกมาในครั้งเดียว ซึ่งเร็วแต่มักเสียรายละเอียด และกลุ่มที่สามคือแบบจำลองดิฟฟิวชัน (Diffusion-based) ที่วาดรายละเอียดได้ดี แต่ควบคุมผลได้ยากและใช้เวลามากกว่า หัวข้อนี้เล่าถึงงานแต่ละชิ้นตามลำดับที่แนวคิดพัฒนาต่อกันมา

งานแรกที่ควรรู้จักคือ StyleGAN2 (Style-based Generative Adversarial Network รุ่นที่ 2) ของ Karras และคณะ [3] เพราะทั้ง Barbershop และ HairFastGAN ใช้ StyleGAN2 เป็นตัววาดภาพ StyleGAN2 เป็นโมเดลที่รับตัวเลขชุดหนึ่ง (เรียกว่ารหัส w) แล้ววาดออกมาเป็นภาพใบหน้าคน โดยเริ่มวาดจากภาพขนาดเล็ก 4×4 พิกเซล แล้วขยายขึ้นทีละขั้นจนได้ภาพขนาด 1024×1024 พิกเซล รหัสที่ต่างกันจะได้ใบหน้าที่ต่างกัน StyleGAN2 พัฒนาต่อจาก StyleGAN รุ่นแรก [7] ซึ่งมักมีจุดเพี้ยนในภาพ จนได้ภาพที่สมจริงมาก โดยมีค่า Fréchet Inception Distance (FID) เท่ากับ 2.84 บนชุดภาพใบหน้า Flickr-Faces-HQ (FFHQ) ค่า FID วัดว่าภาพที่สร้างขึ้นมีลักษณะโดยรวมใกล้กับภาพจริงเพียงใด ยิ่งต่ำยิ่งดี ข้อจำกัดของ StyleGAN2 คือ ถ้าต้องการแก้ไขภาพถ่ายจริงของคนคนหนึ่ง ต้องหาให้ได้ก่อนว่าภาพนั้นตรงกับรหัสใด ขั้นตอนนี้เรียกว่าการแปลงภาพกลับเป็นรหัสแฝง (GAN Inversion)

Barbershop ของ Zhu และคณะ [1] เป็นงานเปลี่ยนทรงผมที่ถูกอ้างถึงมาก แนวคิดหลักคือแยกรหัสของภาพออกเป็น 2 ส่วน ส่วนแรก F (Structure Tensor) เก็บข้อมูลว่าสิ่งใดอยู่ตรงไหนในภาพ เช่น ผมอยู่บริเวณใด ส่วนที่สอง S (Appearance Code) เก็บข้อมูลว่าแต่ละส่วนมีลักษณะอย่างไร เช่น ผมสีอะไร ทั้งสองส่วนรวมกันเรียกว่าพื้นที่แฝง FS (FS Latent Space) เมื่อแยกได้แบบนี้ จึงนำ “ตำแหน่งของผม” จากภาพหนึ่ง และ “สีผม” จากอีกภาพหนึ่งมาประกอบกันได้ โดยใบหน้ายังเป็นของคนเดิม ขั้นตอนโดยสรุปคือ แบ่งส่วนภาพด้วยหน้ากาก (Segmentation Mask) ซึ่งเป็นภาพที่ระบุว่าพิกเซลใดเป็นผม ใบหน้า หรือพื้นหลัง แล้วแปลงทุกภาพเป็นรหัส FS ปรับรหัสให้ผมอยู่ตามหน้ากากเป้าหมาย แล้วให้ StyleGAN2 วาดภาพใหม่ ผลที่ได้คือภาพที่สมจริงมาก ในการทดสอบกับผู้ใช้ ผู้ใช้เลือกภาพของ Barbershop มากกว่าภาพของวิธีเดิมประมาณร้อยละ 95–96 แต่เพราะต้องค้นหารหัสซ้ำหลายร้อยรอบกับทุกภาพ จึงใช้เวลาประมาณ 3.5–10.8 นาทีต่อภาพ ซึ่งนานเกินไปสำหรับการใช้งานที่ผู้ใช้ต้องรอผล

Style Your Hair ของ Kim และคณะ [8] แก้ปัญหาของ Barbershop ในกรณีที่คนในภาพใบหน้ากับคนในภาพทรงผมหันหน้าไปคนละทาง (ท่าทางหรือ Pose ต่างกัน) ซึ่ง Barbershop มักวางผมผิดตำแหน่ง โดยเพิ่มค่าสูญเสีย (Loss) ซึ่งเป็นตัวเลขที่บอกว่าผลลัพธ์ยังห่างจากสิ่งที่ต้องการเพียงใด อีก 2 ตัว ได้แก่ ค่าสูญเสียที่ช่วยจัดท่าทางจากจุดสำคัญบนใบหน้าแบบสามมิติ (Pose Align Loss) และค่าสูญเสียที่รักษาลวดลายของผมเฉพาะจุด (Local-Style-Matching Loss) วิธีนี้ได้ค่า FID 17.06 ซึ่งดีกว่า Barbershop (18.07) แต่ยังเป็นการค้นหาแบบปรับค่าซ้ำ จึงยังช้า ประมาณ 3–4 นาทีต่อภาพ

HairCLIP ของ Wei และคณะ [4] ให้ผู้ใช้สั่งเปลี่ยนผมได้ด้วยข้อความ เช่น พิมพ์ว่า “ผมหยิกสีบลอนด์” หรือจะใช้ภาพอ้างอิงก็ได้ งานนี้อาศัย CLIP (Contrastive Language-Image Pre-training) [9] ซึ่งเป็นโมเดลที่เข้าใจทั้งภาพและข้อความในพื้นที่เดียวกัน แล้วใช้เครือข่ายขนาดเล็ก (Mapper) ปรับรหัส W^+ ของ StyleGAN (รหัสแฝงแบบหนึ่ง ซึ่งอธิบายในหัวข้อที่ 2.3.1) ตามคำสั่ง จุดเด่นคือเร็วมาก ใช้เวลา 0.10–0.36 วินาทีต่อภาพ และภาพผลลัพธ์ยังคล้ายภาพเดิม (ดัชนีความคล้ายเชิงโครงสร้าง หรือ Structural Similarity Index Measure: SSIM ประมาณ 0.92) แต่รายละเอียดของเส้นผมมักหายไป ต่อมามี HairCLIPv2 [10] ที่รวมวิธีสั่งงานหลายแบบไว้ในระบบเดียว ทั้งข้อความ หน้ากาก ภาพร่าง และภาพอ้างอิง โดยใช้การผสมคุณลักษณะจากภาพตัวแทน (Proxy Feature Blending) ทำให้รักษาพื้นหลังและใบหน้าได้ดีขึ้น (อัตราส่วนสัญญาณสูงสุดต่อสัญญาณรบกวน หรือ Peak Signal-to-Noise Ratio: PSNR ประมาณ 29.5 dB) แต่ถ้าสั่งด้วยข้อความจะใช้เวลานานขึ้นเป็น 0.5–58.9 วินาที

HairFastGAN ของ Nikolaev และคณะ [2] ตั้งใจแก้ปัญหาความช้าของ Barbershop แทนที่จะค้นหารหัสซ้ำกับทุกภาพ HairFastGAN ฝึกเครือข่ายตัวเข้ารหัส (Encoder) ไว้ล่วงหน้าให้คำนวณรหัสออกมาได้ในครั้งเดียว โดยยังทำงานบนพื้นที่ FS เหมือน Barbershop และเพิ่มตัวหมุนรหัส (Rotate Encoder) ที่หมุนผมในภาพอ้างอิงให้หันตามใบหน้า กับโมดูลปรับรายละเอียด (Refinement Alignment) ที่ดึงรายละเอียดของใบหน้าจริงกลับมา ผลคือทำงานเร็วมาก ประมาณ 0.41 วินาทีต่อภาพบนหน่วยประมวลผลกราฟิก (Graphics Processing Unit: GPU) รุ่น A100 และได้ค่า FID 13.12 ซึ่งดีที่สุดในกลุ่มที่เปรียบเทียบ แต่ยังทำทรงที่ซับซ้อน เช่น ผมเปียหรือหางม้า ได้ไม่ดี นอกจากนี้ยังไม่มีงานใดนำ HairFastGAN และ Barbershop มาปรับจูนด้วยข้อมูลและเงื่อนไขเดียวกันเพื่อเปรียบเทียบกันโดยตรง

โมเดลกลุ่ม GAN ข้างต้นมีจุดอ่อนร่วมกัน คือผมที่ได้มักดูนุ่มและเบลอ ไม่เห็นเป็นเส้นชัดเหมือนภาพถ่าย ผู้วิจัยจึงศึกษาอีกแนวทางหนึ่งคือแบบจำลองดิฟฟิวชัน งานของ Rombach และคณะ [5] เสนอแบบจำลองดิฟฟิวชันในพื้นที่แฝง (Latent Diffusion Model: LDM) ซึ่งเป็นพื้นฐานของ Stable Diffusion แบบจำลองดิฟฟิวชันสร้างภาพโดยเริ่มจากภาพที่มีแต่สัญญาณรบกวน (Noise) แล้วค่อย ๆ ลบสัญญาณรบกวนออกทีละขั้นจนได้ภาพ ปัญหาของแบบจำลองรุ่นก่อนคือทำงานบนภาพขนาดเต็ม จึงต้องคำนวณมาก LDM แก้ปัญหานี้โดยบีบภาพให้เล็กลงก่อนด้วยตัวเข้ารหัสอัตโนมัติ (Autoencoder) แล้วจึงลบสัญญาณรบกวนบนภาพที่บีบแล้ว ด้วยโครงข่ายรูปตัว U (U-Net) [11] ที่รับข้อความสั่งงานผ่านกลไกความสนใจข้าม (Cross-Attention) [12] ผลคือได้ภาพที่ละเอียดมาก (FID 5.11) โดยใช้ทรัพยากรน้อยกว่าเดิมมาก แต่ยังช้ากว่า GAN และเพราะ

มีการสุ่มอยู่ในกระบวนการ จึงอาจเปลี่ยนส่วนที่ผู้ใช้ไม่ได้ต้องการให้เปลี่ยน

ตารางที่ 1 สรุปงานทั้ง 7 ชิ้นไว้ในที่เดียว แต่ละแถวคืองานหนึ่งชิ้น และแต่ละคอลัมน์อธิบายในมุมเดียวกัน คือ แนวคิดหลัก วิธีการ และข้อดีกับข้อจำกัด เมื่ออ่านคอลัมน์สุดท้ายจากบนลงล่างจะเห็นรูปแบบที่ชัดเจน งานที่ค้นหารหัสทีละภาพ (Barbershop และ Style Your Hair) ให้ภาพสมจริงแต่ใช้เวลาเป็นนาที งานที่ใช้ตัวเข้ารหัส (HairCLIP และ HairFastGAN) เร็วในระดับวินาทีแต่เสียรายละเอียดบางส่วน และทุกงานในกลุ่ม GAN ใช้ StyleGAN2 เป็นตัววาดภาพ จึงได้ผมที่นุ่มคล้ายกัน ส่วน LDM เด่นเรื่องรายละเอียด ซึ่งเป็นจุดที่ GAN ทำได้ไม่ดี แต่ผลมีความสุ่มและควบคุมยาก ข้อสังเกตนี้เป็นที่มาของแนวคิดในโครงงาน คือให้ GAN ทำส่วนที่ต้องแม่นยำ (ทรงและสีผม) แล้วให้ Diffusion เติมเฉพาะส่วนที่ GAN ทำได้ไม่ดี (พื้นผิวของเส้นผม)

2.2 เทคนิคและเครื่องมือที่เกี่ยวข้อง

นอกจากงานที่เกี่ยวกับการถ่ายโอนทรงผมโดยตรงแล้ว งานวิจัยนี้ยังใช้เทคนิคและเครื่องมือพื้นฐานทางปัญญาประดิษฐ์อีกหลายอย่าง ซึ่งได้รับการพัฒนาและทดสอบมาแล้วในงานวิจัยก่อนหน้า

ด้านเทคนิค การแปลงภาพกลับเป็นรหัสแฝง (GAN Inversion) คือการนำภาพจริงกลับเข้าไปในพื้นที่แฝง (Latent Space) หรือก็คือการค้นหารหัสแฝง (Latent Code) ที่เมื่อส่งเข้าตัวสร้างภาพแล้วได้ภาพใกล้กับภาพจริงมากที่สุด ขั้นตอนนี้เป็นขั้นแรกของทั้ง Barbershop [1] และ HairFastGAN [2] ซึ่งต้องแปลงภาพเข้าสู่พื้นที่แฝง FS ก่อนจึงจะย้ายทรงผมได้

การจัดการพื้นที่แฝง FS (FS Latent Space Manipulation) แยกการควบคุมภาพออกเป็น 2 ส่วน คือเทนเซอร์โครงสร้าง (Structure Tensor: F) ที่ควบคุมตำแหน่งและรูปร่างของสิ่งต่าง ๆ ในภาพ และรหัสลักษณะปรากฏ (Appearance Code: S) ที่ควบคุมสไตล์ สี และพื้นผิว ทำให้ย้ายทรงผมและสีผมแยกกันได้ แนวคิดนี้เป็นแกนหลักของทั้ง Barbershop [1] และ HairFastGAN [2]

การจัดแนวพื้นที่แฝงด้วย CLIP (CLIP-based Latent Alignment) ใช้โมเดล CLIP [9] สร้างพื้นที่ร่วมที่ภาพและข้อความถูกแปลงเป็นเวกเตอร์ชุดเดียวกัน เพื่อตีความคำสั่งที่เป็นข้อความ (Text Prompt) แล้วแปลงเป็นการเปลี่ยนแปลงในพื้นที่แฝงของภาพ เทคนิคนี้เป็นหัวใจของ HairCLIP [4] และ HairCLIPv2 [10]

การจัดท่าทาง (Pose Alignment) มีเป้าหมายให้ผมจากภาพอ้างอิงหันไปทางเดียวกับใบหน้าในภาพต้นฉบับ แนวทางหนึ่งคือ Pose Align Loss ของ Style Your Hair [8] ซึ่งจัดท่าทางด้วยการปรับรหัสแฝงซ้ำหลายรอบ (Latent Optimization) อีกแนวทางคือ Rotate Encoder ของ HairFastGAN [2] ที่หมุนรหัสของภาพอ้างอิงให้หันตามใบหน้าต้นฉบับได้ในครั้งเดียวโดยไม่ต้องค้นหาทีละภาพ (งานวิจัยนี้ใช้การหมุนเฉพาะกับภาพสีผม รายละเอียดอยู่ในหัวข้อที่ 3.5)

ด้านเครื่องมือ StyleGAN2 [3] เป็นสถาปัตยกรรม GAN ที่สร้างภาพใบหน้ามนุษย์ได้คุณภาพสูง และงานถ่ายโอนทรงผมทุกงานที่ศึกษาในบทนี้ใช้ StyleGAN2 เป็นโครงสร้างพื้นฐาน

โครงข่ายแบ่งส่วนภาพสองทาง (Bilateral Segmentation Network: BiSeNet) [14] เป็นโมเดลแบ่งส่วนภาพเชิงความหมาย (Semantic Segmentation) คือระบุว่าแต่ละพิกเซลในภาพ

ตารางที่ 1 สรุปรายละเอียดงานวิจัยที่เกี่ยวข้องกับการถ่ายโอนทรงผมด้วยเทคนิคปัญญาประดิษฐ์

งานวิจัย	แนวคิดหลัก	วิธีการดำเนินงาน	ผลลัพธ์ (ข้อดี/ข้อจำกัด)
StyleGAN2 (2020) [3]	แปลงรหัส w เป็นภาพใบหน้า โดยขยายความละเอียดทีละขั้น 4 ถึง 1024 พิกเซล	Mapping Network ($z \rightarrow w$) ร่วมกับ Style Modulation/ Demodulation	**ข้อดี:** ภาพใบหน้าคุณภาพสูง (FID 2.84 บน FFHQ) เป็นแกนของทั้งสองโมเดล **ข้อจำกัด:** แก้ไขภาพจริงต้องทำ GAN Inversion หารหัสก่อน
Barbershop (2021) [1]	ผสมภาพโดยใช้พื้นที่แฝง FS ที่แยกโครงสร้างเชิงพื้นที่ออกจากลักษณะภายนอก	GAN Inversion แบบ II2S (Improved Image2StyleGAN) [13] ร่วมกับการจัดวางเชิงความหมาย (Semantic Alignment) ให้ตรงหน้ากากเป้าหมาย	**ข้อดี:** สมจริงสูง เก็บรายละเอียดเฉพาะบุคคล (ไฝ ริ้วรอย) ได้ดี **ข้อจำกัด:** ช้ามาก (ประมาณ 3.5–10.8 นาทีต่อภาพ)
Style Your Hair (2022) [8]	ถ่ายโอนทรงผมแบบไม่ขึ้นกับท่าทาง (Pose-invariant)	Pose Align Loss (จุดสำคัญใบหน้า 3 มิติ) และ Local-Style-Matching Loss	**ข้อดี:** จัดการท่าทางที่ต่างกันได้ดี รักษาพื้นผิวเส้นผม (FID 17.06) **ข้อจำกัด:** ช้า (3–4 นาที) และสร้างผมส่วนที่ถูกบังไม่ได้
HairCLIP (2022) [4]	แก้ไขทรงและสีผมด้วยข้อความหรือภาพอ้างอิงในโมเดลเดียว	ใช้ CLIP [9] สร้างพื้นที่ฝังตัวร่วม และ Mapper ปรับรหัสใน W^+	**ข้อดี:** เร็วมาก (0.10–0.36 วินาที) โต้ตอบง่าย **ข้อจำกัด:** สูญเสียรายละเอียดโครงสร้างเส้นผม
HairCLIPv2 (2023) [10]	รวมการแก้ไขทุกรูปแบบ (ข้อความ Mask ภาพร่าง ภาพ) ผ่าน Proxy Feature Blending	แปลงคำสั่งเป็นภาพตัวแทน แล้วผสมคุณลักษณะกับภาพต้นฉบับในพื้นที่แฝง	**ข้อดี:** รักษาพื้นหลังและเอกลักษณ์ได้ดี (PSNR 29.5 dB) **ข้อจำกัด:** งานข้อความใช้เวลา 0.5–58.9 วินาที
HairFastGAN (2024) [2]	ถ่ายโอนทรงผมเร็วระดับใกล้เวลาจริงและทนต่อท่าทางที่ต่างกัน	Encoder ทั้งหมด มี Rotate Encoder ปรับท่าทาง และ Refinement คืนรายละเอียด	**ข้อดี:** เร็ว (น้อยกว่า 1 วินาที) สมจริง (FID 13.12) **ข้อจำกัด:** ทรงซับซ้อน (ผมเปีย หางม้า) ยังทำได้ไม่ดี
LDM (2022) [5]	ทำ Diffusion ในพื้นที่แฝงแทนพื้นที่พิกเซลเพื่อลดการคำนวณ	Autoencoder บีบอัดภาพ และ U-Net [11] ที่มี Cross-Attention รับข้อความ	**ข้อดี:** รายละเอียดสูงด้วยทรัพยากรน้อยลงมาก (FID 5.11) **ข้อจำกัด:** ช้ากว่า GAN และผลลัพธ์มีความสุ่ม

หมายเหตุ: StyleGAN2 = Style-based Generative Adversarial Network รุ่นที่ 2, FID = Fréchet Inception Distance, FFHQ = Flickr-Faces-HQ, GAN = Generative Adversarial Network, II2S = Improved Image2StyleGAN, CLIP = Contrastive Language-Image Pre-training, PSNR = Peak Signal-to-Noise Ratio, LDM = Latent Diffusion Model

ภาพเป็นส่วนใด เช่น ผม ผิวหน้า หรือพื้นหลัง และทำงานได้เร็วพอใช้แบบเวลาจริง ภายในประกอบด้วยสายที่เก็บรายละเอียดเชิงพื้นที่ (Spatial Path) และสายที่เก็บบริบทของภาพทั้งภาพ (Context Path) ในงานวิจัยนี้ BiSeNet ถูกใช้ภายในทั้ง Barbershop และ HairFastGAN เพื่อสร้างหน้ากากผม และยังใช้ทำนายบริเวณผมของภาพผลลัพธ์ เพื่อคำนวณค่าสูญเสียด้านทรงผม และค่าการทับซ้อนของบริเวณผม (Intersection over Union: IoU)

Segmentation Transformer (SegFormer) [15] เป็นโมเดลแบ่งส่วนภาพอีกตัวหนึ่ง ใช้ตัวเข้ารหัสแบบทรานส์ฟอร์เมอร์ที่มีหลายระดับ (Hierarchical Transformer Encoder) ร่วมกับตัวถอดรหัสขนาดเล็กที่เป็นเครือข่ายเชิงเส้นหลายชั้น (Multi-Layer Perceptron: MLP) และแบ่งพื้นที่ภาพได้แม่นยำกว่าโครงข่ายประสาทเทียมแบบคอนโวลูชัน (Convolutional Neural Network: CNN) แบบดั้งเดิม งานวิจัยนี้ใช้ SegFormer-B2 ในขั้นขัดเกลา เพื่อกำหนดบริเวณผมและใบหน้าที่อนุญาตให้ Stable Diffusion แก้ไข สรุปคือ BiSeNet ใช้ภายในโมเดล GAN และในการวัดทรงผม ส่วน SegFormer ใช้ในขั้นขัดเกลาภาพ

Stable Diffusion [5] เป็นแบบจำลองดิฟฟิวชันในพื้นที่แฝง (LDM) ที่สร้างภาพด้วยการค่อย ๆ ลดสัญญาณรบกวนในพื้นที่แฝงของตัวเข้ารหัสอัตโนมัติ (Autoencoder) โดยรับข้อความสั่งงานเป็นเงื่อนไขผ่านตัวเข้ารหัสข้อความของ CLIP งานวิจัยนี้ใช้ Stable Diffusion ในขั้นขัดเกลา เพื่อเติมรายละเอียดให้ภาพผลลัพธ์จากโมเดล GAN เฉพาะบริเวณที่หน้ากากจาก SegFormer กำหนด

CLIP [9] เป็นโมเดลที่ฝึกด้วยคู่ภาพกับข้อความจำนวนมาก จึงสรุปลักษณะของภาพ เช่น สีและลักษณะของผม ออกมาเป็นเวกเตอร์ได้ดี งานวิจัยนี้ใช้ CLIP ในโมดูลสีของ HairFastGAN เพื่ออ่านสีผมจากภาพอ้างอิง และใช้เป็นตัวเข้ารหัสข้อความของ Stable Diffusion

ArcFace (Additive Angular Margin Loss) [16] เป็นโมเดลจดจำใบหน้าที่แปลงใบหน้าเป็นเวกเตอร์ 512 มิติ ใบหน้าของคนเดียวกันจะได้เวกเตอร์ที่ชี้ไปทางเดียวกัน งานวิจัยนี้ใช้ ArcFace ทั้งในค่าสูญเสียด้านความเหมือนของใบหน้าระหว่างการปรับจูน และใช้เป็นตัวชี้วัดว่าภาพผลลัพธ์ยังเป็นคนเดิมหรือไม่

2.3 ทฤษฎีที่เกี่ยวข้อง

หัวข้อนี้อธิบายหลักการ โครงสร้าง ขั้นตอนการทำงาน และฟังก์ชันความสูญเสีย (Loss Function) ของแบบจำลองที่ใช้ในงานวิจัย ได้แก่ ตัวสร้างภาพ StyleGAN2 และพื้นที่แฝง แบบจำลองถ่ายโอนทรงผม (HairFastGAN และ Barbershop) แบบจำลองแบ่งส่วนภาพ (SegFormer) และแบบจำลองปรับปรุงคุณภาพภาพ (Stable Diffusion) รวมถึงหลักการปรับจูนโมเดลและตัวชี้วัดที่ใช้ประเมินผล

2.3.1 StyleGAN2 และพื้นที่แฝง (Latent Space)

ในงานนี้ StyleGAN2 ทำหน้าที่วาดภาพใบหน้า โดยรับรหัสแฝง (Latent) เข้าไป ไม่ได้รับภาพเข้าไปโดยตรง

GAN [6] ประกอบด้วยเครือข่าย 2 ตัวที่ฝึกแข่งกัน เปรียบได้กับผู้ปลอมธนบัตร

กับเจ้าหน้าที่ตรวจธนบัตร ตัวสร้าง (Generator) เปรียบเหมือนผู้ปลอม ซึ่งพยายามสร้างภาพจากตัวเลขสุ่มให้เหมือนภาพจริง ส่วนตัวจำแนก (Discriminator) เปรียบเหมือนเจ้าหน้าที่ ซึ่งพยายามแยกให้ออกว่าภาพใดจริงและภาพใดปลอม ทั้งสองผลัดกันเก่งขึ้นตามสมการที่ (1) จนในที่สุดตัวสร้างสร้างภาพที่ตัวจำแนกแยกไม่ออก

$$\min_G \max_D \; \mathbb{E}_x \left[\log D(x)\right] + \mathbb{E}_z \left[\log\left(1 - D(G(z))\right)\right] \tag{1}$$

โดยที่

G = ตัวสร้างภาพ (Generator)

D = ตัวจำแนก (Discriminator) ให้ค่าความน่าจะเป็นที่ภาพเป็นภาพจริง

x = ภาพจริงจากชุดข้อมูล

z = เวกเตอร์สุ่มที่ใช้เป็นจุดเริ่มต้นของการสร้างภาพ

$\mathbb{E}$ = ค่าคาดหมาย (ค่าเฉลี่ย) เหนือข้อมูลทั้งหมด

งานวิจัยนี้ใช้เฉพาะตัวสร้างของ StyleGAN2 ที่ฝึกบน FFHQ เสร็จแล้วเป็นตัววาดภาพใบหน้า และไม่ได้ใช้ตัวจำแนกระหว่างการปรับจูน เพราะมีเป้าหมายที่วัดได้โดยตรงผ่านฟังก์ชันความสูญเสีย 5 ด้าน (หัวข้อที่ 3.6.1)

StyleGAN2 [3] มี 2 ส่วน ส่วนแรกคือเครือข่ายแปลงรหัส (Mapping Network) ซึ่งเป็นชั้นเชิงเส้น 8 ชั้น ทำหน้าที่แปลงตัวเลขสุ่ม z เป็นรหัส w ที่ใช้ควบคุมลักษณะของใบหน้าได้ง่ายกว่า ส่วนที่สองคือเครือข่ายวาดภาพ (Synthesis Network) ซึ่งเริ่มวาดจากภาพขนาด 4×4 แล้วขยายทีละ 2 เท่าจนถึง 1024×1024 รหัส w ควบคุมทุกชั้นโดยไปคูณกับน้ำหนักของชั้นนั้น ๆ ตามสมการที่ (2) คล้ายกับการหมุนปุ่มปรับระดับเสียงของแต่ละช่องสัญญาณ

$$w'_{ijk} = s_i \cdot w_{ijk}, \qquad w''_{ijk} = \frac{w'_{ijk}}{\sqrt{\sum_{i,k}\left(w'_{ijk}\right)^2 + \epsilon}} \tag{2}$$

โดยที่

w_{ijk} = น้ำหนักเดิมของคอนโวลูชันจากช่องสัญญาณขาเข้า i ไปช่องสัญญาณขาออก j ที่ตำแหน่งเคอร์เนล k

s_i = ตัวคูณของช่องสัญญาณขาเข้า i ที่คำนวณจากรหัส w (Modulation)

w'_{ijk} = น้ำหนักหลังคูณด้วยสไตล์

w''_{ijk} = น้ำหนักหลังปรับสเกลกลับ (Demodulation) ให้ผลลัพธ์มีความแปรปรวนคงที่

ϵ = ค่าคงที่ขนาดเล็กเพื่อกันการหารด้วยศูนย์

ชั้นความละเอียดต่ำ (4–32 พิกเซล) ควบคุมโครงหน้าและท่าทาง ส่วนชั้นความละเอียดสูง (64–1024 พิกเซล) ควบคุมเส้นผม ผิว และสี นี่คือเหตุผลที่งานวิจัยนี้เลือกปรับจูนเฉพาะชั้นความละเอียดสูงของ Barbershop

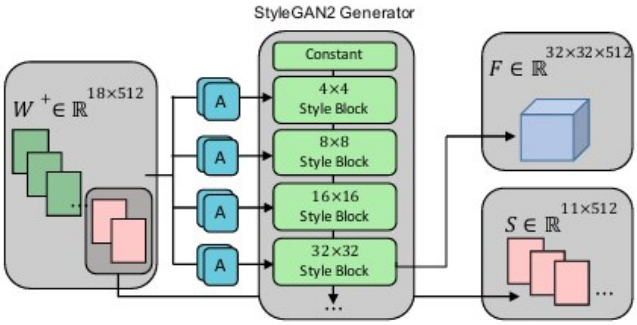
ตารางที่ 2 สรุปพื้นที่แฝงของ StyleGAN2 ที่เกี่ยวข้องกับงานวิจัย คอลัมน์ “ขนาด” บอกจำนวนค่าในรหัส และคอลัมน์ “ความหมาย” บอกว่ารหัสนั้นควบคุมอะไร จะเห็นว่ารหัสที่มีขนาดใหญ่ขึ้นและแยกตามตำแหน่งมากขึ้น (จาก Z ไปจนถึง FS) แทนภาพจริงได้แม่นยำขึ้น โดยเฉพาะ FS ที่แยกโครงร่าง (F) ออกจากสีและพื้นผิว (S) ซึ่งเป็นหัวใจของทั้งสองโมเดล การย้ายทรงผมทำได้โดยนำ F บริเวณผมจากภาพทรงผม นำ S ส่วนผมจากภาพสีผม และนำส่วนที่เหลือจากภาพใบหน้า แล้วให้ StyleGAN2 วาดภาพใหม่

ตารางที่ 2 พื้นที่แฝงของ StyleGAN2 ที่เกี่ยวข้องกับงานวิจัย

พื้นที่	**ขนาด**	**ความหมาย**
Z	512	เวกเตอร์สุ่มก่อนเข้า Mapping Network
W	512	รหัสหลัง Mapping Network ใช้รหัสเดียวกันทุกชั้น
W^+	18×512	รหัสแยกชั้นละหนึ่งเวกเตอร์ แทนภาพจริงได้ใกล้กว่า W โดยเวกเตอร์ 6 ลำดับแรกควบคุมท่าทางและรูปทรงของศีรษะ
FS	F: $32 \times 32 \times 512$ S: Style ของชั้นที่เหลือ	F คือแผนที่คุณลักษณะ (Feature Map) ที่บอกว่าอะไรอยู่ตรงไหน (โครงร่าง) และ S ควบคุมสีและพื้นผิว

หมายเหตุ: StyleGAN2 = Style-based Generative Adversarial Network รุ่นที่ 2

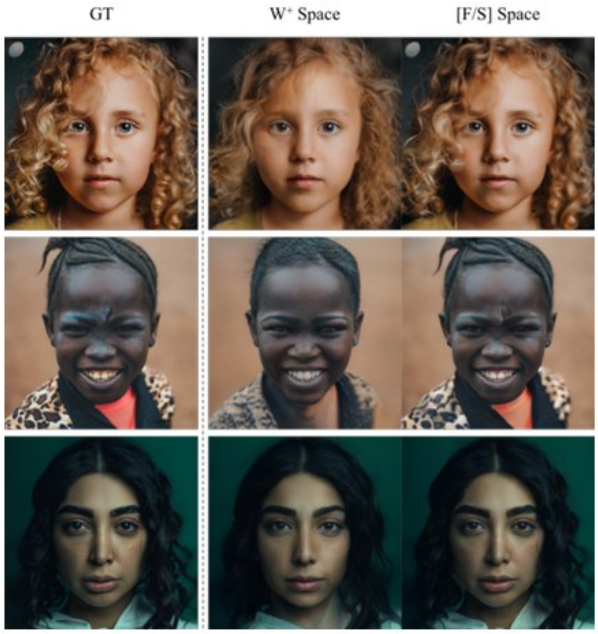
ภาพที่ 1 แสดงตำแหน่งของ F และ S ภายในตัวสร้าง StyleGAN2 ด้านซ้ายคือรหัส W^+ ขนาด 18×512 ที่ป้อนเข้าบล็อกสไตล์แต่ละชั้น ผลลัพธ์ของบล็อกขนาด 32×32 ถูกเก็บไว้เป็น F ส่วนรหัสของชั้นที่เหลือถูกเก็บไว้เป็น S ภาพนี้จึงแสดงว่า FS คือการ “ตัด” ตัวสร้างที่ชั้นกลาง เพื่อแยกโครงร่างออกจากสไตล์



ภาพที่ 1 ความสัมพันธ์ระหว่าง FS Latent Space และ W^+ Space ใน StyleGAN2 Generator (ดัดแปลงจาก [1])

หมายเหตุ: StyleGAN2 = Style-based Generative Adversarial Network รุ่นที่ 2

การแปลงภาพกลับเป็นรหัสแฝง (GAN Inversion) มี 2 แนวทาง แนวทางแรกคือแบบปรับค่าซ้ำ (Optimization) ซึ่งตรึงตัวสร้างไว้ แล้วปรับรหัสด้วยการลดค่าตามเกรเดียนต์ (Gradient Descent) ซ้ำหลายร้อยรอบ เกรเดียนต์ (Gradient) คือทิศทางที่บอกว่าควรปรับค่าไปทางใดเพื่อให้ค่าสูญเสียลดลง วิธีนี้แม่นยำแต่ช้า ตัวอย่างคือวิธี Improved Image2StyleGAN (II2S) [13] ที่ Barbershop ใช้ แนวทางที่สองคือแบบตัวเข้ารหัส (Encoder) ซึ่งฝึกเครือข่ายให้คำนวณรหัสของภาพได้ในการคำนวณรอบเดียว วิธีนี้เร็ว ตัวอย่างคือ Encoder for Editing (E4E) [17] และ FS Encoder ที่ HairFastGAN ใช้ ภาพที่ 2 เปรียบเทียบภาพจริง (GT) กับภาพที่สร้างคืนจาก W^+ และจาก FS ภาพในแถวเดียวกันเป็นคนเดียวกัน จะเห็นว่าภาพจาก W^+ เสียรายละเอียด เช่น ทรงผมและฉากหลัง ขณะที่ภาพจาก FS ใกล้กับภาพจริงมาก ซึ่งเป็นเหตุผลที่ทั้งสองโมเดลเลือกทำงานในพื้นที่ FS

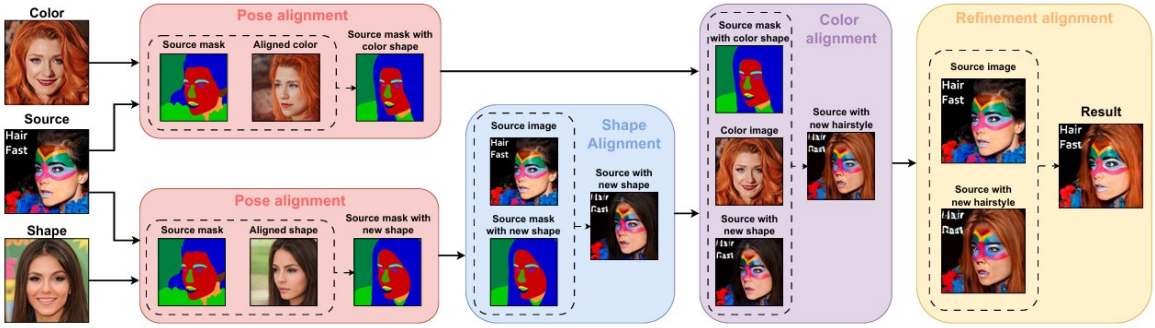


ภาพที่ 2 เปรียบเทียบคุณภาพการสร้างภาพคืน (Reconstruction) ระหว่างภาพจริง (GT), W^+ Space และ FS Space (จาก [1])

2.3.2 การทำงานของโมเดล HairFastGAN

HairFastGAN [2] รับภาพ 3 ภาพ ได้แก่ ภาพใบหน้าของผู้ใช้ (Source Image) ภาพที่มีทรงผมที่ต้องการ (Shape Image) และภาพที่มีสีผมที่ต้องการ (Color Image) แล้วสร้างภาพที่ยังเป็นใบหน้าของผู้ใช้ แต่ทรงผมและสีผมเปลี่ยนตามภาพอ้างอิง ทุกขั้นทำบนพื้นที่ FS ที่อธิบายในหัวข้อที่ 2.3.1 โดย F (ขนาด 32×32) บอกรูปร่างของผมและกรอบหน้า และ S บอกสีและพื้นผิว เพราะสองส่วนนี้แยกกัน จึงเปลี่ยนทรงหรือสีผมได้โดยไม่กระทบใบหน้า

ภาพที่ 3 แสดงภาพรวมของ HairFastGAN ข้อมูลไหลจากซ้ายไปขวา ภาพทั้ง 3 ภาพถูกเข้ารหัสก่อน แล้วผ่านโมดูลจัดแนว 4 โมดูลตามลำดับ ได้แก่ การปรับท่าทาง (Pose Alignment กรอบสีแดง) การถ่ายโอนรูปทรง (Shape Alignment กรอบสีฟ้า) การถ่ายโอนสี (Color Alignment กรอบสีม่วง) และการปรับรายละเอียด (Refinement Alignment กรอบสีเหลือง) ภาพย่อยในแต่ละกรอบแสดงหน้ากากและภาพกลางที่เกิดขึ้นในขั้นนั้น



ภาพที่ 3 ภาพรวมสถาปัตยกรรมและกระบวนการทำงานของโมเดล HairFastGAN ผ่านโมดูล Pose, Shape, Color และ Refinement Alignment (จาก [2])

2.3.2.1 Pose Alignment (การปรับท่าทาง)

ถ้าคนในภาพทรงผมหันไปคนละทางกับคนในภาพใบหน้า ผมจะถูกวางผิดตำแหน่ง โมดูลนี้จึงใช้ Rotate Encoder คำนวณรหัสชุดใหม่ของภาพทรงผมให้หันไปทางเดียวกับภาพใบหน้า ตามสมการที่ (3) รหัสที่ใช้ในขั้นนี้มาจาก E4E ซึ่งละเอียดพอสำหรับการสร้างหน้ากาก เพราะขั้นนี้ยังไม่ต้องใช้รายละเอียดของเส้นผม Rotate Encoder แก้เฉพาะรหัส 6 ลำดับแรกของ W^+ ซึ่งควบคุมลักษณะทางเรขาคณิต เช่น มุมที่ศีรษะหัน และไม่แตะรหัสอีก 12 ลำดับที่เหลือ จึงหมุนท่าทางได้โดยไม่เปลี่ยนทรงผม ในงานต้นฉบับ ภาพสีผมก็ผ่านขั้นนี้ด้วย เพื่อหาหน้ากากผมของภาพสีผมที่หันตามใบหน้า สำหรับใช้ต่อในโมดูลสี

$$w_{\text{rotate}}^{1:6} = \text{RotateEnc}\left(w_{\text{source}}^{1:6},\ w_{\text{shape}}^{1:6}\right) \tag{3}$$

โดยที่

$w_{\text{rotate}}^{1:6}$ = รหัสในพื้นที่ W^+ 6 ลำดับแรกของภาพทรงผมที่ถูกหมุนให้หันตามใบหน้าแล้ว

RotateEnc = เครือข่ายหมุนรหัส (Rotate Encoder)

$w_{\text{source}}^{1:6}$ = รหัส 6 ลำดับแรกของภาพใบหน้าต้นฉบับ (เก็บท่าทางเป้าหมาย)

$w_{\text{shape}}^{1:6}$ = รหัส 6 ลำดับแรกของภาพอ้างอิงทรงผม

จากนั้นนำรหัสที่หมุนแล้วไปวาดเป็นภาพ แล้วให้ BiSeNet (Bilateral Segmentation Network) แบ่งส่วนภาพ จะได้หน้ากากของภาพอ้างอิงที่หันตามใบหน้า หน้ากากนี้และหน้ากากของภาพใบหน้าจะถูกส่งเข้า Shape Encoder และ Shape Adaptor เพื่อทำนายหน้ากากของใบหน้าเดิมเมื่อสวมทรงผมใหม่ ตามสมการที่ (4)

$$\begin{aligned} M_{\text{rotate}} &= \text{BiSeNet}(G(w_{\text{rotate}})) \\ M_{\text{align}} &= \text{ShapeAdaptor}\left(\text{ShapeEnc}^{\text{hair}}(M_{\text{rotate}}),\ \text{ShapeEnc}^{\text{face}}(M_{\text{source}})\right) \end{aligned} \tag{4}$$

โดยที่

G = ตัวสร้างภาพ StyleGAN2

w_{rotate} = รหัสเต็ม 18 ลำดับของภาพอ้างอิง (6 ลำดับแรกที่หมุนแล้ว และ 12 ลำดับเดิม)

M_{rotate} = หน้ากากของภาพอ้างอิงหลังหมุน

M_{source} = หน้ากากของภาพใบหน้าต้นฉบับจาก BiSeNet

$\text{ShapeEnc}^{\text{hair}}$, $\text{ShapeEnc}^{\text{face}}$ = ตัวเข้ารหัสที่แยกหน้ากากเป็นส่วนผมและส่วนใบหน้า

ShapeAdaptor = เครือข่ายที่รวมสองส่วนกลับเป็นหน้ากากเดียว และเติมบริเวณที่ขาดหาย

M_{align} = หน้ากากเป้าหมาย คือใบหน้าเดิมที่มีทรงผมใหม่ (H_{align} คือส่วนผมของหน้ากากนี้)

ผู้พัฒนาฝึก Rotate Encoder ด้วยค่าสูญเสีย 3 ส่วน ได้แก่ การจัดท่าทาง การคงรหัสเดิม และการรักษาความเหมือนของใบหน้า โดยหารแต่ละส่วนด้วยค่าเฉลี่ยเคลื่อนที่ของส่วนนั้นเอง เพื่อให้ทั้งสามส่วนมีขนาดใกล้เคียงกัน

$$\mathcal{L}_{\text{Rotate}} = \frac{\lambda_{\text{pose}}\mathcal{L}_{\text{pose}}}{\text{EMA}_t(\mathcal{L}_{\text{pose}})} + \frac{\lambda_{\text{recon}}\mathcal{L}_{\text{recon}}}{\text{EMA}_t(\mathcal{L}_{\text{recon}})} + \frac{\lambda_{\text{id}}\mathcal{L}_{\text{id}}}{\text{EMA}_t(\mathcal{L}_{\text{id}})} \tag{5}$$

โดยที่

$\mathcal{L}_{\text{pose}}$ = ค่าสูญเสียจากความต่างของจุดสังเกตบนใบหน้า (Facial Keypoints) 76 จุด

$\mathcal{L}_{\text{recon}}$ = ค่าสูญเสียการคงรหัสเดิม (หมุนไปแล้วหมุนกลับต้องได้รหัสเดิม)

$\mathcal{L}_{\text{id}}$ = ค่าสูญเสียเอกลักษณ์ใบหน้าจาก ArcFace ตามสมการที่ (6)

$\lambda_{\text{pose}}, \lambda_{\text{recon}}, \lambda_{\text{id}}$ = น้ำหนักของแต่ละส่วน (6, 2 และ 1 ตามลำดับ)

EMA_t = ค่าเฉลี่ยเคลื่อนที่แบบเอ็กซ์โพเนนเชียล (Exponential Moving Average) ของค่าสูญเสียแต่ละส่วน (ค่าตัวคูณ 0.02)

ค่าสูญเสียด้านความเหมือนของใบหน้าคำนวณจากเวกเตอร์ใบหน้าของ ArcFace ตามสมการที่ (6) ถ้า $\mathcal{L}_{\text{id}}$ มีค่าต่ำ (ค่าโคไซน์สูง) แปลว่าใบหน้ายังเหมือนเดิม

$$\mathcal{L}_{\text{id}} = 1 - \cos\left(v_{\text{output}},\ v_{\text{source}}\right) = 1 - \frac{v_{\text{output}} \cdot v_{\text{source}}}{\|v_{\text{output}}\|\,\|v_{\text{source}}\|} \tag{6}$$

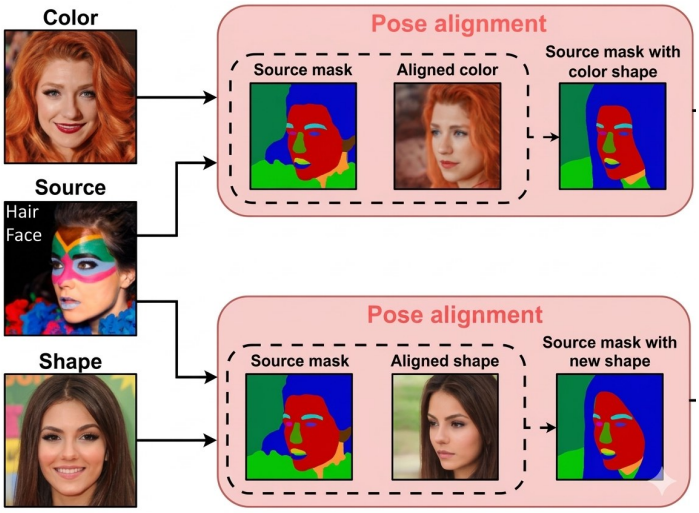
โดยที่

v_{output} = เวกเตอร์ใบหน้า 512 มิติจาก ArcFace ของภาพที่สร้างขึ้น

v_{source} = เวกเตอร์ใบหน้าของภาพต้นฉบับ

$\cos(\cdot,\cdot)$ = ความคล้ายโคไซน์ (Cosine Similarity) มีค่า -1 ถึง 1 โดย 1 คือเหมือนที่สุด

ภาพที่ 4 แสดงตัวอย่างการทำงานของโมดูลนี้ แถวบนคือการหมุนหน้ากากของภาพสีผม (ใช้ในขั้นสี) และแถวล่างคือการหมุนภาพทรงผม ภาพ “Source mask” คือหน้ากากของใบหน้าต้นฉบับ ภาพ “Aligned shape” คือภาพทรงผมที่หมุนแล้ว และภาพขวาสุดคือหน้ากากใหม่ที่ผมหันตรงกับใบหน้าต้นฉบับ



ภาพที่ 4 ตัวอย่างการทำงานของ Pose Alignment ที่ปรับ Mask ผมของภาพอ้างอิงให้หันตามใบหน้าต้นฉบับ (จาก [2])

2.3.2.2 Shape Alignment (การถ่ายโอนรูปทรงผม)

โมดูลนี้นำทรงผมใหม่มาวางบนโครงหน้าเดิม แต่ก่อนย้ายทรงผมต้องแก้ปัญหาหนึ่งก่อน คือ F ที่ได้จาก FS Encoder สร้างภาพคืนได้แม่นยำมาก แต่เก็บรายละเอียดของผมไว้แน่นจนเปลี่ยนสีผมผ่าน S ได้ยาก ผู้พัฒนาจึงเข้ารหัสภาพเดียวกันด้วย E4E อีกทางหนึ่ง ซึ่งสร้างภาพคืนได้หยาบกว่าแต่แก้ไขได้ง่ายกว่า แล้วผสม F ทั้งสองแบบเฉพาะบริเวณผม (FS and W^+ Mixing) ตามสมการที่ (7)

$$F_{32}^{\text{mix}} = \bar{H} \cdot F_{32}^{\text{FSE}} + (1-\alpha) \cdot H \cdot F_{32}^{\text{FSE}} + \alpha \cdot H \cdot F_{32}^{\text{E4E}} \tag{7}$$

โดยที่

F_{32}^{mix} = แผนที่คุณลักษณะขนาด 32×32 หลังผสม

$F_{32}^{\text{FSE}}, F_{32}^{\text{E4E}}$ = แผนที่คุณลักษณะที่ได้จาก FS Encoder และจาก E4E

$H, \bar{H}$ = หน้ากากผมจาก BiSeNet ที่ย่อเหลือ 32×32 และส่วนกลับ ($\bar{H} = 1 - H$)

α = สัดส่วนการผสม ผู้พัฒนาและงานวิจัยนี้ใช้ 0.95

ค่า $\alpha = 0.95$ หมายความว่าบริเวณผมใช้ F จาก E4E ร้อยละ 95 และจาก FS Encoder เพียงร้อยละ 5 ส่วนใบหน้าและพื้นหลังยังใช้ F จาก FS Encoder ทั้งหมด จึงเก็บรายละเอียดของใบหน้าไว้ได้ครบ

ขั้นต่อมาคือเติมส่วนที่ขาดหาย (Inpainting) เช่น หน้าผากที่เคยถูกผมบังแต่ทรงใหม่เปิดออก ผู้พัฒนาใช้ SEAN (Semantic Region-Adaptive Normalization) [18] ซึ่งเข้ารหัสสไตล์ของแต่ละบริเวณในภาพ แล้ววาดภาพใหม่ขนาด 256×256 ตามหน้ากาก M_{align} จากนั้นเข้ารหัสภาพที่ได้ด้วย E4E อีกครั้งเป็น F^{inpaint} เพราะ E4E ช่วยลบสิ่งแปลกปลอมที่ SEAN อาจสร้างขึ้น เช่น ใบหูที่ผิดรูป ขั้นตอนทั้งหมดนี้ทำกับทั้งภาพต้นฉบับและภาพทรงผม สุดท้ายจึงเลือก F จาก 4 แหล่งตามหน้ากาก ดังสมการที่ (8)

$$
\begin{aligned}
F_{32}^{\text{align}} = {} & H_{\text{align}} \cdot H_{\text{shape}} \cdot F_{\text{shape}}^{\text{mix}} + H_{\text{align}} \cdot \bar{H}_{\text{shape}} \cdot F_{\text{shape}}^{\text{inpaint}} \\
& + \bar{H}_{\text{align}} \cdot \bar{H}_{\text{source}} \cdot F_{\text{source}}^{\text{mix}} + \bar{H}_{\text{align}} \cdot H_{\text{source}} \cdot F_{\text{source}}^{\text{inpaint}}
\end{aligned}
\tag{8}
$$

โดยที่

F_{32}^{align} = แผนที่คุณลักษณะขนาด 32×32 ขั้นสุดท้ายที่จัดทรงผมเข้ากับใบหน้าแล้ว

H_{align} = หน้ากากทรงผมเป้าหมาย (บริเวณที่ควรมีผมมีค่า 1) และ $\bar{H}_{\text{align}} = 1 - H_{\text{align}}$

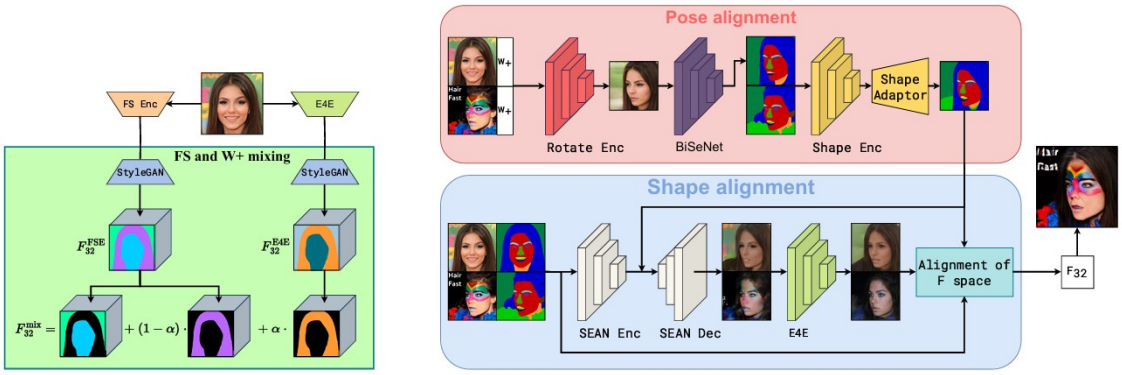
$H_{\text{shape}}, H_{\text{source}}$ = หน้ากากเส้นผมเดิมของภาพอ้างอิงทรงผมและภาพต้นฉบับ (ขีดบนคือส่วนกลับ)

$F_{\text{shape}}^{\text{mix}}, F_{\text{source}}^{\text{mix}}$ = แผนที่คุณลักษณะหลังผสมตามสมการที่ (7) ของภาพทรงผมและภาพต้นฉบับ

$F_{\text{shape}}^{\text{inpaint}}, F_{\text{source}}^{\text{inpaint}}$ = แผนที่คุณลักษณะของภาพที่เติมส่วนที่ขาดหายด้วย SEAN แล้วเข้ารหัสด้วย E4E

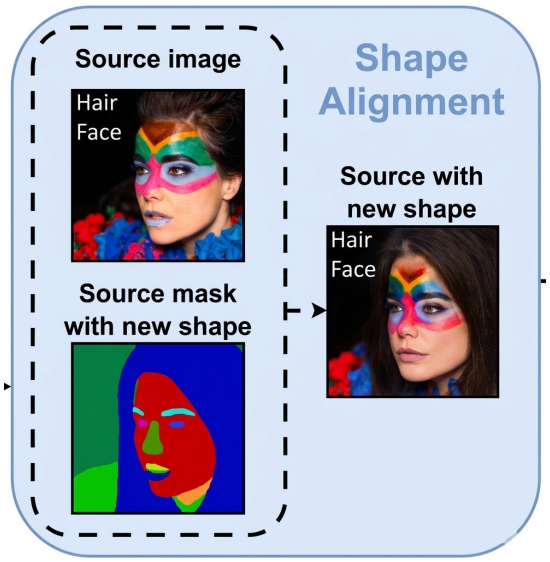
สมการนี้แบ่งพิกเซลเป็น 4 กรณี ตามว่าพิกเซลนั้นอยู่ในบริเวณผมใหม่หรือไม่ และภาพเดิมมีผมอยู่ตรงนั้นหรือไม่ ถ้าเป็นบริเวณผมใหม่และภาพทรงผมมีผมอยู่ตรงนั้นจริง ก็ใช้ผมจากภาพทรงผมได้ทันที ถ้าเป็นบริเวณผมใหม่แต่ภาพทรงผมไม่มีผมตรงนั้น (เช่น ภาพทรงผมหันคนละมุม) ต้องใช้ผมที่ SEAN เติมให้ ส่วนบริเวณที่ไม่ใช่ผม ถ้าภาพต้นฉบับไม่เคยมีผมตรงนั้น ก็ใช้ภาพต้นฉบับได้ทันที แต่ถ้าเคยมีผมบังอยู่ (เช่น ผมหน้าม้าเดิม) ต้องใช้ส่วนที่ SEAN เติมให้แทน

ภาพที่ 5 แสดงโครงสร้างภายในของขั้นนี้ ภาพ (a) คือบล็อกผสมพื้นที่แฝง ซึ่งนำ F จาก FS Encoder และจาก W^+ มาผสมกันด้วยสัดส่วน α ภาพ (b) แสดงลำดับของโมดูล Pose (สีแดง) ที่ใช้ Rotate Encoder และ BiSeNet ตามด้วยโมดูล Shape (สีฟ้า) ที่ใช้ตัวเข้ารหัสและตัวถอดรหัสของ SEAN สร้างทรงผมเป้าหมายบนพื้นที่ F ส่วนภาพที่ 6 แสดงตัวอย่างผลของขั้นนี้ คือหน้ากากของภาพต้นฉบับที่มีรูปทรงผมใหม่ และภาพต้นฉบับที่สวมทรงผมใหม่แล้ว



(a) Visualization of the mixing block. (b) Modules for transferring the desired hair shape.

ภาพที่ 5 (a) บล็อกผสมพื้นที่แฝง FS กับ W^+ และ (b) โมดูลถ่ายโอนรูปทรงผม (Pose และ Shape Alignment) ของ HairFastGAN (จาก [2])



ภาพที่ 6 ตัวอย่างการทำงานของ Shape Alignment ที่สร้างภาพต้นฉบับพร้อมรูปทรงผมใหม่ (จาก [2])

2.3.2.3 Color Alignment (การถ่ายโอนสีผม)

โมดูลนี้เปลี่ยนสีของทรงผมใหม่ให้เป็นสีตามภาพสีผม ผู้พัฒนาพบว่าการผสม S ของสองภาพด้วยการถัวเฉลี่ยแบบงานก่อนหน้ายังให้สีที่ไม่ดีพอ จึงสร้างตัวเข้ารหัสผสม (Blending Encoder) ที่ทำนายว่า S ของภาพต้นฉบับต้องเปลี่ยนไปเท่าใด ภายในประกอบด้วยชั้นปรับค่า (Modulation) 5 บล็อก ซึ่งรับ S ของภาพสีผมและเวกเตอร์จาก CLIP (Contrastive Language-Image Pre-training) มาคำนวณค่าสเกลและค่าเลื่อน ดังสมการที่ (9) โดย emb_{face} คือเวกเตอร์ของภาพต้นฉบับที่ลบผมออกแล้ว และ emb_{hair} คือเวกเตอร์ของภาพสีผมที่เหลือแต่ผม จากนั้นวาดภาพด้วย F_{32}^{align} จากโมดูล Shape และ S_{blend} จะได้ภาพ I_{blend}

$$S_{\text{blend}} = \text{BlendEnc}(S_{\text{source}},\ S_{\text{color}},\ \text{emb}_{\text{face}},\ \text{emb}_{\text{hair}}) \tag{9}$$

โดยที่

S_{blend} = รหัสสไตล์ชุดใหม่ที่มีสีผมตามภาพอ้างอิง
BlendEnc = ตัวเข้ารหัสผสม (Blending Encoder)
$S_{\text{source}}, S_{\text{color}}$ = รหัสสไตล์ของภาพใบหน้าต้นฉบับและภาพอ้างอิงสีผม
$\text{emb}_{\text{face}}, \text{emb}_{\text{hair}}$ = เวกเตอร์ความหมายจาก CLIP ของบริเวณใบหน้าและบริเวณผม

ผู้พัฒนาฝึกโมดูลนี้ด้วยค่าสูญเสียที่วัดความคล้ายเชิงความหมายผ่าน CLIP แทนการวัดความต่างทีละพิกเซล ตามสมการที่ (10) ส่วนแรกบังคับให้ผมมีสีเหมือนภาพสีผม และส่วนที่สองบังคับให้ใบหน้ายังเหมือนภาพต้นฉบับ

$$\begin{aligned}\mathcal{L}_{\text{ColorModule}} = {} & \lambda_{\text{color}}\mathcal{L}_{\text{CLIP}}\left(I_{\text{blend}}, I_{\text{color}}, H_{\text{align}}, H_{\text{color}}\right) \\ & + \lambda_{\text{face}}\mathcal{L}_{\text{CLIP}}\left(I_{\text{blend}}, I_{\text{source}}, M_{\text{target}}, M_{\text{target}}\right)\end{aligned} \tag{10}$$

โดยที่

$\mathcal{L}_{\text{CLIP}}$ = ค่าสูญเสีย $1-$ ความคล้ายโคไซน์ของคุณลักษณะจาก CLIP เฉพาะบริเวณที่กำหนด
I_{blend} = ภาพที่สร้างหลังเปลี่ยนสีผม
$I_{\text{color}}, I_{\text{source}}$ = ภาพอ้างอิงสีผมและภาพใบหน้าต้นฉบับ
$H_{\text{align}}, H_{\text{color}}$ = หน้ากากผมของภาพผลลัพธ์และของภาพอ้างอิงสีผม
M_{target} = หน้ากากบริเวณที่ไม่ใช่ผมทั้งในภาพต้นฉบับและในทรงใหม่ $(\bar{H}_{\text{source}} \cdot \bar{H}_{\text{align}})$
$\lambda_{\text{color}}, \lambda_{\text{face}}$ = น้ำหนักของส่วนสีผมและส่วนใบหน้า (ผู้พัฒนาใช้ 1 ทั้งคู่)

2.3.2.4 Refinement Alignment (การฟื้นฟูรายละเอียด)

แม้สีผมจะถูกต้องแล้ว แต่ภาพ I_{blend} ผ่านการเข้ารหัสมาหลายครั้ง รายละเอียดของใบหน้าและพื้นหลังจึงหายไปบางส่วน และสีผิวอาจเพี้ยนจากเดิม โมดูลนี้

(ในโค้ดเรียกว่า PostProcess) จึงเข้ารหัสทั้ง I_{blend} และภาพต้นฉบับใหม่ ด้วย FS Encoder ตัวใหญ่ที่ให้ F ขนาด 64×64 ซึ่งละเอียดกว่าขั้นก่อน 4 เท่า แล้วใช้ตัวผสม Fused F และ Fused S Encoder รวมสองภาพเข้าด้วยกัน ให้ได้ทั้งผมใหม่จาก I_{blend} และรายละเอียดใบหน้าจากภาพต้นฉบับ ก่อนส่งให้ StyleGAN2 วาดภาพสุดท้าย ดังสมการที่ (11)

$$I_{\text{final}} = \text{StyleGAN}\Big(\text{FusedFEnc}(F_{64}^{\text{blend}}, F_{64}^{\text{source}}),\ S_{\text{final}}\Big) \tag{11}$$

โดยที่

I_{final} = ภาพผลลัพธ์สุดท้ายของ HairFastGAN

FusedFEnc = ตัวเข้ารหัสที่ผสมแผนที่คุณลักษณะของสองภาพ

F_{64}^{blend} = แผนที่คุณลักษณะขนาด 64×64 ของภาพหลังเปลี่ยนทรงและสีผม

F_{64}^{source} = แผนที่คุณลักษณะขนาด 64×64 ของภาพใบหน้าต้นฉบับ

S_{final} = รหัสสไตล์สุดท้าย เท่ากับรหัสเฉลี่ยของ StyleGAN2 บวกผลจากตัวเข้ารหัส Fused S ที่รับ S ของสองภาพ

StyleGAN = ตัวสร้างภาพ StyleGAN2 ที่ตรึงไว้

โมดูลนี้ถูกฝึกด้วยค่าสูญเสียหลายส่วน ซึ่งเขียนแบบย่อได้ดังสมการที่ (12) ในงานต้นฉบับ แต่ละส่วนคำนวณกับภาพหลายคู่ เช่น เทียบใบหน้าของผลลัพธ์กับภาพต้นฉบับ และเทียบผมของผลลัพธ์กับ I_{blend} โดยคูณหน้ากากก่อนเทียบ

$$\mathcal{L}_{\text{Refine}} = \lambda_{\text{id}}\mathcal{L}_{\text{id}} + \lambda_{\text{m-LPIPS}}\mathcal{L}_{\text{m-LPIPS}} + \lambda_{\text{feat}}\mathcal{L}_{\text{feat}} + \lambda_{\text{DSC++}}\mathcal{L}_{\text{DSC++}} + \lambda_{\text{inpaint}}\mathcal{L}_{\text{inpaint}} + \lambda_{\text{ADV}}\mathcal{L}_{\text{ADV}} \tag{12}$$

โดยที่

$\mathcal{L}_{\text{id}}$ = ค่าสูญเสียเอกลักษณ์ใบหน้าจาก ArcFace ตามสมการที่ (6)

$\mathcal{L}_{\text{m-LPIPS}}$ = ค่าความต่างเชิงการรับรู้แบบหลายสเกล (Multi-scale LPIPS) ที่ผู้พัฒนา FS Encoder เสนอ

$\mathcal{L}_{\text{feat}}$ = ค่าความต่างกำลังสองระหว่าง F ที่ได้กับ F ที่วาดจาก S ช่วยให้การฝึกช่วงแรกนิ่ง

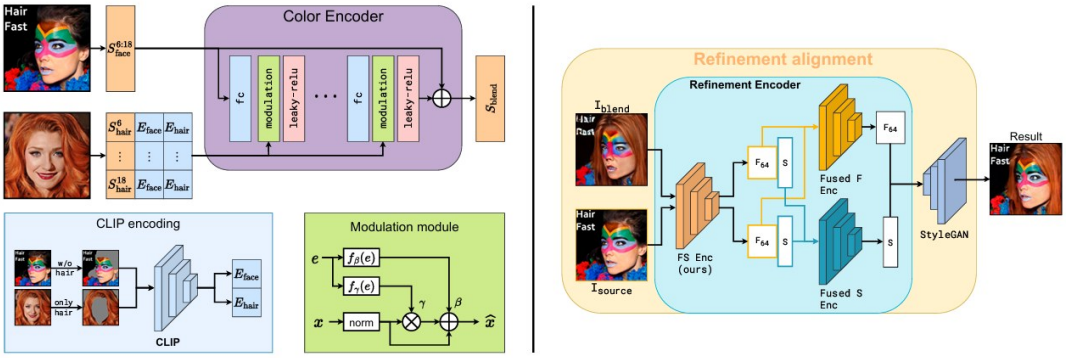
$\mathcal{L}_{\text{DSC++}}$ = ค่าสูญเสียไดซ์แบบปรับเทียบ (DSC++) [19] ที่บังคับให้หน้ากากผมของผลลัพธ์ตรงกับของ I_{blend}

$\mathcal{L}_{\text{inpaint}}$ = ค่า m-LPIPS เฉพาะบริเวณที่ต้องเติมใหม่ ช่วยให้ส่วนที่เติมกลืนกับภาพ

$\mathcal{L}_{\text{ADV}}$ = ค่าสูญเสียปรปักษ์ (Adversarial Loss) จากตัวจำแนกของ StyleGAN2 เพื่อให้ภาพสมจริง

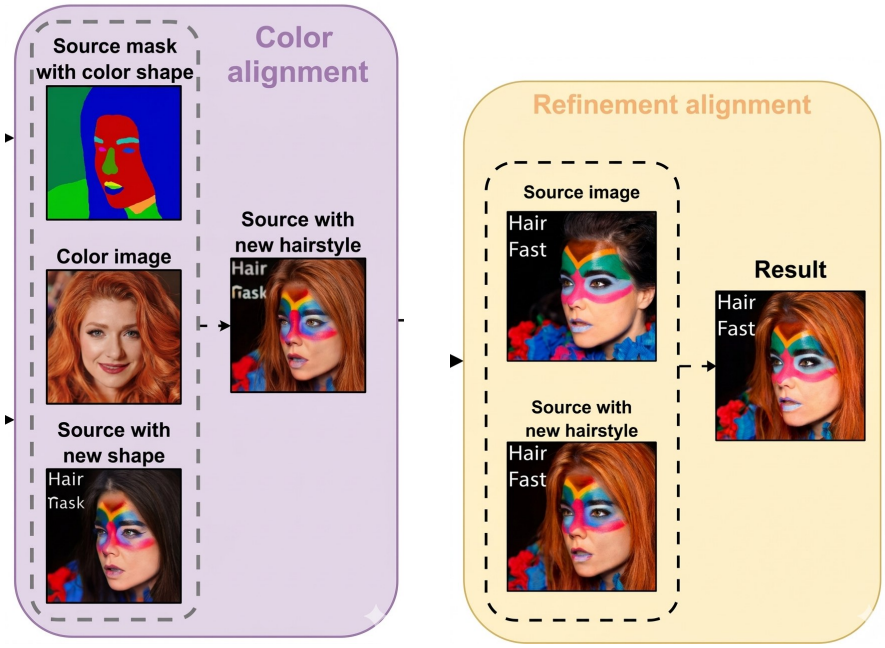
λ = น้ำหนักของแต่ละส่วน ผู้พัฒนาใช้ $\lambda_{\text{id}} = 0.1$, $\lambda_{\text{m-LPIPS}} = 0.4$, $\lambda_{\text{feat}} = 0.01$, $\lambda_{\text{DSC++}} = 0.1$, $\lambda_{\text{inpaint}} = 0.2$ และ $\lambda_{\text{ADV}} = 0.2$

ภาพที่ 7 แสดงโครงสร้างของสองโมดูลสุดท้าย ภาพ (a) แสดงโมดูลสีที่นำภาพสีผมเข้า CLIP แล้วส่งเวกเตอร์ไปยังชั้นปรับค่า (Modulation) เพื่อเปลี่ยนรหัสสไตล์ ภาพ (b) แสดงโมดูลปรับรายละเอียดที่รับทั้งภาพหลังเปลี่ยนสีและภาพต้นฉบับ แล้วผสมคุณลักษณะผ่าน Fused F และ Fused S Encoder ก่อนส่งเข้า StyleGAN2 ส่วนภาพที่ 8 แสดงตัวอย่างผล (a) คือภาพที่ได้สีผมจากภาพสีผมแล้ว และ (b) คือภาพผลลัพธ์สุดท้ายที่ได้จากการผสมภาพต้นฉบับกับภาพที่มีทรงและสีใหม่



(a) Diagram color alignment (b) Refinement alignment diagram

ภาพที่ 7 (a) โครงสร้างโมดูล Color Alignment และ (b) โมดูล Refinement Alignment ของ HairFastGAN (จาก [2])



(a) Color Alignment **(b)** Refinement Alignment

ภาพที่ 8 ตัวอย่างการทำงานของโมดูล Color และ Refinement Alignment (จาก [2])

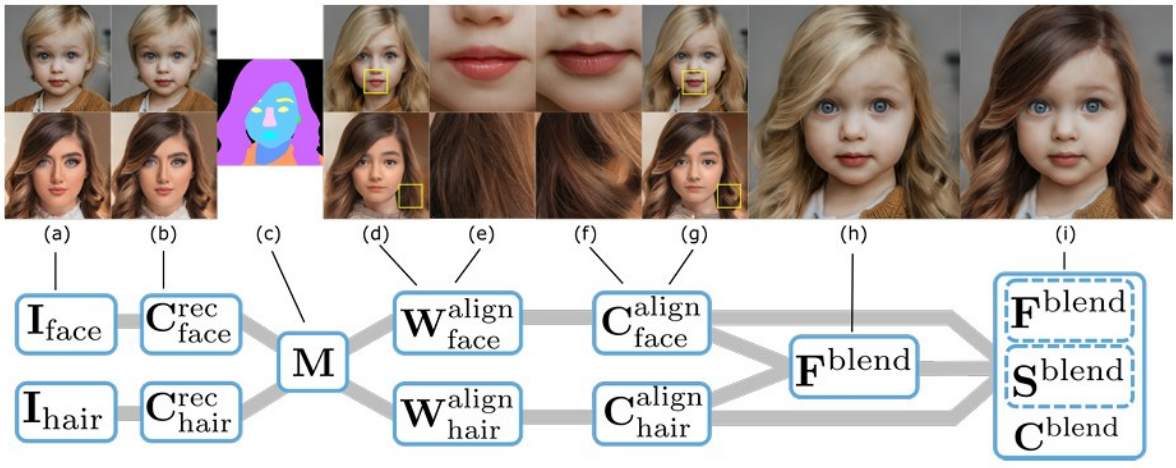
เมื่อเข้าใจหน้าที่ของแต่ละโมดูลแล้ว ผู้วิจัยจึงย้อนกลับไปดูปัญหา

ที่พบจากการรันโมเดลตั้งต้น สีผมที่เป็นปื้นเกิดจากโมดูล Color ส่วนใบหน้าที่ซีดเกิดจากโมดูล Refinement ที่ดึงรายละเอียดของภาพต้นฉบับกลับมาได้ไม่ครบ ขณะที่ทรงผมและท่าทางส่วนใหญ่ออกมาถูกต้องอยู่แล้ว ผู้วิจัยจึงล็อกโมดูล Embedding, Pose และ Shape ไว้ คือไม่ปรับน้ำหนักของโมดูลเหล่านี้ และปรับจูนเฉพาะโมดูล Color (ชั้น Modulation ของ Blending Encoder) กับโมดูล Refinement ทั้งโมดูล (PostProcess ซึ่งประกอบด้วย FS Encoder ตัวใหญ่และตัวผสม Fused F/S) โดยใช้ฟังก์ชันความสูญเสียที่ผู้วิจัยออกแบบเองแทนฟังก์ชันเดิมของผู้พัฒนา (รายละเอียดในหัวข้อที่ 3.5 และ 3.6.1)

2.3.3 การทำงานของโมเดล Barbershop

Barbershop [1] ไม่ได้ฝึกเครือข่ายให้คำนวณรหัสเหมือน HairFastGAN แต่ค้นหารหัสที่ดีที่สุดด้วยการปรับค่าซ้ำไปเรื่อย ๆ หลายร้อยรอบ (Iterative Optimization) คล้ายการค่อย ๆ หมุนปุ่มจนภาพที่ได้ตรงที่สุด วิธีนี้ช้า แต่ได้รหัสที่เหมาะกับภาพนั้นจริง ๆ จึงเก็บรายละเอียดเฉพาะของแต่ละคน เช่น ไฝหรือริ้วรอย ได้ดี และทำงานบนพื้นที่ FS เหมือน HairFastGAN ข้อเสียคือต้องค้นหารหัสแฝง (Latent) ใหม่ทุกภาพ ยิ่งตั้งให้ค้นหานาน ผลลัพธ์ก็ยิ่งดีขึ้น แต่ก็ยิ่งช้า

ภาพที่ 9 แสดงขั้นตอนของ Barbershop จากซ้ายไปขวา ภาพนำเข้า (a)–(b) ถูกเข้ารหัสเป็น C^{rec} จากนั้นสร้างหน้ากากเป้าหมาย M (c) แล้วปรับรหัสของแต่ละภาพให้ตรงกับ M ได้ W^{align} และ C^{align} (d)–(g) จากนั้นผสมโครงสร้างเป็น F^{blend} (h) และผสมสไตล์เป็น S^{blend} ก่อนรวมเป็น C^{blend} (i) ที่ใช้วาดภาพผลลัพธ์



ภาพที่ 9 สถาปัตยกรรมและอัลกอริทึมการทำงานของโมเดล Barbershop ในพื้นที่ FS Latent Space (จาก [1])

2.3.3.1 FS Latent Space Embedding (การค้นหารหัสของภาพ)

ขั้นแรกคือค้นหารหัสแฝง $C = (F, S)$ ที่เมื่อส่งเข้า StyleGAN2 แล้วได้ภาพใกล้กับภาพนำเข้าแต่ละภาพมากที่สุด ด้วยการลดค่าตามเกรเดียนต์ซ้ำหลายรอบ ตาม

สมการที่ (13)

$$C_k^{\text{rec}} = \arg\min_{C} \ (\mathcal{L}_{\text{LPIPS}}(G(C),\ I_k) + \mathcal{L}_F(F)) \tag{13}$$

โดยที่

C_k^{rec} = รหัสแฝงที่ดีที่สุดของภาพที่ k

$G(C)$ = ภาพที่ StyleGAN2 วาดจากรหัส C

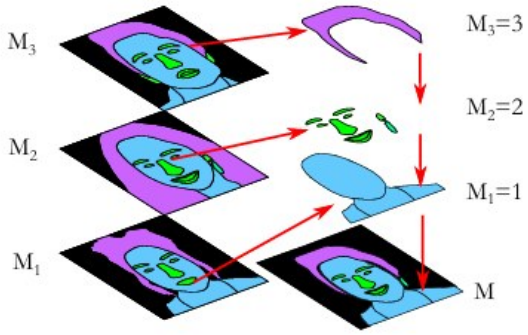
I_k = ภาพนำเข้าภาพที่ k (ภาพใบหน้า ภาพทรงผม หรือภาพสีผม)

$\mathcal{L}_{\text{LPIPS}}$ = ค่าความต่างเชิงการรับรู้ (Learned Perceptual Image Patch Similarity) [20] ที่วัดจากคุณลักษณะของเครือข่าย VGG (Visual Geometry Group) [21]

$\mathcal{L}_F(F)$ = ค่าสูญเสียที่ไม่ให้ F ห่างจากค่าเริ่มต้น เท่ากับ $\|F - F_k^{\text{init}}\|^2$

2.3.3.2 Aligned Embedding (การ ปรับ โครงสร้าง ให้ ตรง หน้ากาก)

ขั้นนี้บังคับให้รหัสแฝงสร้างภาพที่มีผมอยู่ตามหน้ากากเป้าหมาย M ภาพที่ 10 แสดงวิธีสร้าง M จากหน้ากากของแต่ละภาพ หน้ากาก M_1, M_2 และ M_3 คือแผนที่ส่วนภาพของภาพนำเข้าแต่ละภาพ ลูกศรสีแดงแสดงว่าบริเวณผมนำมาจากภาพทรงผม ส่วนบริเวณใบหน้าและส่วนอื่นนำมาจากภาพใบหน้า แล้วรวมเป็นหน้ากาก M เพียงหน้ากากเดียว ที่บอกว่าแต่ละพิกเซลของผลลัพธ์ควรเป็นส่วนใด



ภาพที่ 10 การสร้างหน้ากากเป้าหมาย M จากหน้ากากของภาพแต่ละภาพ (M_1, M_2, M_3) (จาก [1])

การค้นหารหัสที่ตรงกับ M ใช้ค่าสูญเสียตามสมการที่ (14)

$$w_k^{\text{align}} = \arg\min_{W} \ \text{XEnt}(M,\ \text{Segment}(G(W))) + \lambda_s \mathcal{L}_s(W) \tag{14}$$

โดยที่

w_k^{align} = รหัส W^+ ของภาพที่ k ที่จัดให้ตรงกับหน้ากากแล้ว

XEnt = ค่าสูญเสียครอสเอนโทรปี (Cross-Entropy) ระหว่างหน้ากากเป้าหมายกับผลแบ่งส่วนภาพ

$\text{Segment}(G(W))$ = ผลแบ่งส่วนภาพด้วย BiSeNet ของภาพที่วาดจากรหัส W

$\mathcal{L}_s(W)$ = ค่าสูญเสียสไตล์เฉพาะบริเวณ (Masked Style Loss) จากเมทริกซ์แกรม

λ_s = น้ำหนักของค่าสูญเสียสไตล์

ขั้นนี้ปรับเฉพาะส่วนของรหัสที่ใช้สร้าง F และหยุดค้นหาเร็ว (บทความต้นฉบับระบุ 100 รอบ ส่วนค่าเริ่มต้นในโค้ดที่ใช้ในงานนี้คือ 140 รอบสำหรับจัดทรงและ 100 รอบสำหรับจัดสี) เพื่อไม่ให้รหัสใหม่ห่างจากรหัสเดิมของภาพมากเกินไป ค่าสูญเสียสไตล์ใช้เมทริกซ์แกรม (Gram Matrix) ตามสมการที่ (15) ซึ่งจับรูปแบบของพื้นผิวและสีในภาพโดยไม่ขึ้นกับตำแหน่ง และคำนวณเฉพาะบริเวณประเภท k ของแต่ละภาพ จึงรักษาสีและพื้นผิวของแต่ละส่วนได้แม่นยำ หน้ากากของภาพที่วาดได้ถูกคำนวณใหม่ทุกรอบ เพราะรหัสเปลี่ยนไปทุกรอบ

$$K_\ell(I) = \gamma_\ell^T \gamma_\ell, \qquad \mathcal{L}_s = \sum_\ell \| K_\ell(\rho_k(G(w)) \odot G(w)) - K_\ell(\rho_k(I_k) \odot I_k) \|^2 \tag{15}$$

โดยที่

$K_\ell(I)$ = เมทริกซ์แกรมของภาพ I ที่ชั้น ℓ

γ_ℓ = ค่าคุณลักษณะของ VGG-16 ชั้นที่ ℓ จัดเป็นเมทริกซ์ขนาด $H_\ell W_\ell \times C_\ell$

H_ℓ, W_ℓ, C_ℓ = ความสูง ความกว้าง และจำนวนช่องสัญญาณของชั้นที่ ℓ

ℓ = ชั้น relu1_2, relu2_2, relu3_3 และ relu4_3 ของ VGG-16

$\rho_k(I)$ = หน้ากากของบริเวณประเภท k ในภาพ I (มีค่า 1 ในบริเวณนั้น)

$G(w), I_k$ = ภาพที่วาดจากรหัส w และภาพอ้างอิงที่ k

เมื่อได้ w_k^{align} แล้ว จึงประกอบโครงสร้าง F ตามหน้ากาก ดังสมการที่ (16)

$$F_k^{\text{align}} = (\alpha_k \cdot \beta_k) \cdot F_k^{\text{rec}} + (1 - \alpha_k \cdot \beta_k) \cdot G_m(w_k^{\text{align}}) \tag{16}$$

โดยที่

F_k^{align} = แผนที่คุณลักษณะของภาพที่ k หลังจัดให้ตรงหน้ากาก

α_k = บริเวณที่หน้ากากเป้าหมาย M กำหนดให้เอามาจากภาพที่ k (ย่อขนาดให้เท่าชั้น m)

β_k = บริเวณเดียวกันในหน้ากากเดิมของภาพที่ k ผลคูณ $\alpha_k \cdot \beta_k$ จึงเป็นบริเวณที่ทั้งสองหน้ากากตรงกัน ซึ่งคัดลอกรายละเอียดเดิมได้อย่างปลอดภัย

F_k^{rec} = แผนที่คุณลักษณะเดิมจากขั้น Embedding

$G_m(w_k^{\text{align}})$ = แผนที่คุณลักษณะที่ได้จากการวาดรหัส w_k^{align} ถึงชั้นกลาง m ของ StyleGAN2

2.3.3.3 Appearance Blending (การผสมสีและพื้นผิว)

เมื่อแต่ละภาพมี F_k^{align} แล้ว การรวมโครงสร้างทำได้ง่าย คือตัด F ของแต่ละภาพตามบริเวณในหน้ากากเป้าหมายแล้วนำมาต่อกัน ดังสมการที่ (17)

$$F^{\text{blend}} = \sum_{k=1}^{K} \alpha_{k,m} \odot F_k^{\text{align}} \tag{17}$$

โดยที่

F^{blend} = แผนที่คุณลักษณะที่รวมโครงสร้างของทุกภาพแล้ว

$\alpha_{k,m}$ = หน้ากากบริเวณ k ที่ย่อขนาดให้เท่าชั้น m

K = จำนวนภาพนำเข้า

ส่วนสไตล์ผสมได้ยากกว่า เพราะ S ไม่ได้แยกตามตำแหน่ง Barbershop จึงค้นหาน้ำหนักผสม u_k ของแต่ละภาพ ให้ผมมีสีเหมือนภาพสีผม และใบหน้ายังเหมือนภาพใบหน้า ดังสมการที่ (18)

$$S^{\text{blend}} = \sum_{k=1}^{K} u_k \odot S_k, \qquad \sum_{k=1}^{K} u_k = 1, \quad u_k \geq 0 \tag{18}$$

โดยที่

S^{blend} = รหัสสไตล์ที่ผสมแล้ว

S_k = รหัสสไตล์ของภาพที่ k

u_k = น้ำหนักผสมของภาพที่ k มีขนาดเท่ากับ S_k จึงให้น้ำหนักแยกได้ทุกค่า โดยทุกค่าไม่ติดลบและรวมกันได้ 1

$\odot$ = การคูณทีละสมาชิก

เงื่อนไขนี้ทำให้ S^{blend} เป็นค่ากลางระหว่างรหัสของภาพนำเข้าเสมอ ไม่หลุดออกไปไกลจนได้ภาพแปลก น้ำหนัก u_k ถูกค้นหาให้ค่า LPIPS เฉพาะบริเวณต่ำที่สุด (LPIPS คือความต่างของภาพตาม

ที่ตาคนรับรู้) ตามสมการที่ (19)

$$\mathcal{L}_{\text{mask}} = \sum_{\ell} \frac{1}{H_\ell W_\ell} \sum_{k,i,j} (\alpha_{k\ell})_{ij} \left\| w_\ell^{\text{pips}} \odot \left(\text{VGG}_{i,j}^{\ell}(I) - \text{VGG}_{i,j}^{\ell}(\hat{I}_k) \right) \right\|^2 \quad (19)$$

โดยที่

$\text{VGG}_{i,j}^{\ell}$ = คุณลักษณะจากเครือข่าย VGG ชั้นที่ ℓ ที่ตำแหน่ง (i, j)

I = ภาพที่วาดจาก S^{blend}

$\hat{I}_k$ = ภาพอ้างอิงที่ k

$(\alpha_{k\ell})_{ij}$ = หน้ากากบริเวณ k ที่ย่อขนาดตามชั้น ℓ เพื่อเปรียบเทียบเฉพาะส่วน

w_ℓ^{pips} = น้ำหนักของช่องสัญญาณที่ LPIPS เรียนรู้มา

$\odot$ = การคูณทีละสมาชิก

สุดท้าย F^{blend} และ S^{blend} ถูกส่งเข้า StyleGAN2 เพื่อวาดภาพผลลัพธ์ สิ่งที่ควรสังเกตคือขั้นตอนทั้งหมดข้างต้นเป็นการ “ค้นหา” รหัส ไม่มีน้ำหนักให้เรียนรู้ ส่วนเดียวของ Barbershop ที่ปรับจูนได้จริงจึงเป็นตัววาดภาพ StyleGAN2 ผู้วิจัยเลือกปรับเฉพาะชั้นความละเอียด 64–1024 พิกเซล ซึ่งควบคุมเส้นผม ผิว และสี และไม่แตะชั้นที่ควบคุมโครงหน้า เพื่อไม่ให้ใบหน้าเปลี่ยน (รายละเอียดในหัวข้อที่ 3.4)

2.3.4 การเปรียบเทียบ HairFastGAN และ Barbershop

แม้ทั้งสองโมเดลทำงานบนพื้นที่ FS ของ StyleGAN2 เหมือนกัน แต่แนวทางการออกแบบต่างกันมาก ดังตารางที่ 3 แถวแรกแสดงว่า HairFastGAN ใช้ตัวเข้ารหัสที่คำนวณรหัสในครั้งเดียว ขณะที่ Barbershop ค้นหารหัสด้วยการปรับค่าซ้ำหลายร้อยรอบ ความต่างนี้ทำให้ความเร็วต่างกันมาก ทั้งในงานวิจัยต้นฉบับ (น้อยกว่า 1 วินาที เทียบกับหลายนาที) และเมื่อรันขั้นตอนทั้งหมดในงานวิจัยนี้ (ประมาณ 10 วินาที เทียบกับ 657 วินาที) แถวสุดท้ายระบุส่วนที่ผู้วิจัยปรับจูนในแต่ละโมเดล ซึ่งเลือกจากตำแหน่งที่ควบคุมสีและรายละเอียด

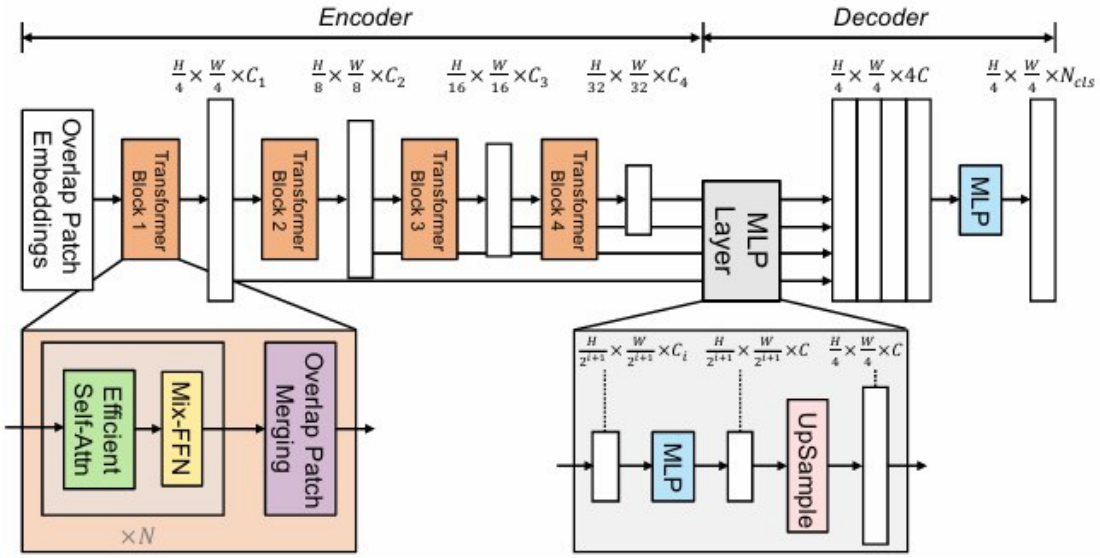
ตารางที่ 3 การเปรียบเทียบคุณสมบัติของ HairFastGAN และ Barbershop

คุณสมบัติ	**HairFastGAN**	**Barbershop**
วิธีการ	Encoder-based	Optimization-based
การหารหัสแฝง	Encoder ผ่านครั้งเดียว	ค้นหาด้วย Gradient Descent หลายร้อยรอบ
ความเร็ว (งานวิจัยต้นฉบับ)	0.41–0.78 วินาที	ประมาณ 3.5–10.8 นาที
ความเร็ว (ทุกขั้นตอนในงานวิจัยนี้)	ประมาณ 10 วินาที	ประมาณ 657 วินาที
การจัดการท่าทางที่ต่างกัน	มี Rotate Encoder	จำกัด
ส่วนที่ปรับจูนในงานวิจัยนี้	Color และ Refinement	ชั้นวาดภาพ 64–1024 พิกเซล

จากตารางจะเห็นว่าทั้งสองโมเดลต้องเลือกระหว่างความเร็วกับความยืดหยุ่น HairFastGAN เร็วพอจะใช้บนเว็บได้ ส่วน Barbershop ค้นหารหัสเฉพาะของแต่ละภาพ จึงเก็บรายละเอียดเฉพาะตัวได้ดีกว่า แต่ช้าเกินกว่าจะให้ผู้ใช้นั่งรอ ผู้วิจัยไม่ต้องการตัดสินจากตัวเลขในงานต้นฉบับ เพราะแต่ละงานวัดผลต่างกัน จึงนำทั้งสองโมเดลมาปรับจูนและวัดผลภายใต้เงื่อนไขเดียวกัน

2.3.5 การแบ่งส่วนภาพด้วย SegFormer

งานวิจัยนี้ใช้ SegFormer [15] สร้างหน้ากากของบริเวณที่จะแก้ไขโดยอัตโนมัติ ภาพที่ 11 แสดงสถาปัตยกรรมของ SegFormer ด้านซ้ายคือตัวเข้ารหัส (Encoder) ที่แบ่งภาพเป็นส่วนย่อยแบบซ้อนทับกัน (Overlap Patch Embeddings) แล้วส่งผ่านบล็อกทรานส์ฟอร์เมอร์ 4 ระดับ แต่ละระดับลดขนาดภาพลงและเพิ่มจำนวนช่องสัญญาณ ด้านขวาคือตัวถอดรหัส (Decoder) ที่นำคุณลักษณะทั้ง 4 ระดับมาปรับให้มีขนาดเท่ากันด้วย MLP แล้วรวมกันเพื่อทำนายว่าแต่ละพิกเซลเป็นส่วนใด



ภาพที่ 11 ภาพรวมกระบวนการทำงานของ SegFormer (จาก [15])

หมายเหตุ: SegFormer = Segmentation Transformer

2.3.5.1 Hierarchical Transformer Encoder (ส่วน สกัดคุณลักษณะ)

ตัวเข้ารหัสแปลงภาพเป็นคุณลักษณะ 4 ระดับความละเอียด โดยใช้กลไกความสนใจตนเองแบบประหยัด (Efficient Self-Attention) ซึ่งย่อความยาวลำดับของคีย์และค่าลงด้วยอัตราส่วน R ทำให้ปริมาณการคำนวณลดจาก $O(n^2)$ เหลือ $O(n^2/R)$ ดังสมการที่ (20)

$$\text{Attention}(Q, \hat{K}, V) = \text{Softmax}\left(\frac{Q\hat{K}^T}{\sqrt{d_{\text{head}}}}\right)V \tag{20}$$

โดยที่

Q = เมทริกซ์ควิรี (Query) คือคุณลักษณะของตำแหน่งที่กำลังพิจารณา

$\hat{K}$ = เมทริกซ์คีย์ (Key) ที่ถูกลดความยาวลำดับด้วยอัตราส่วน R

V = เมทริกซ์ค่า (Value) ที่ถูกดึงมารวมตามน้ำหนักความสนใจ

d_{head} = มิติของหัวความสนใจ (Attention Head) ใช้ปรับสเกล

n = จำนวนส่วนย่อยของภาพ เท่ากับ HW/P^2 เมื่อ P คือขนาดของส่วนย่อย

2.3.5.2 All-MLP Decoder (ส่วนทำนายผลลัพธ์)

ตัวถอดรหัสรวมคุณลักษณะจากหลายความละเอียดผ่าน MLP เพื่อทำนายประเภทของทุกพิกเซล จากนั้นสร้างหน้ากากแบบสองค่า (มีเฉพาะ 0 กับ 1) ของ

บริเวณที่สนใจ เช่น บริเวณผม ตามสมการที่ (21)

$$B(x,y) = \begin{cases} 1 & \text{ถ้า } \arg\max_c M(x,y,c) = \text{“Hair”} \\ 0 & \text{ในกรณีอื่น} \end{cases} \tag{21}$$

โดยที่

$B(x,y)$ = ค่าหน้ากากเส้นผม ณ พิกเซล (x,y) (1 = เป็นผม)
$M(x,y,c)$ = คะแนนที่โมเดลทำนายว่าพิกเซล (x,y) เป็นประเภท c
$\arg\max_c$ = การเลือกประเภทที่มีคะแนนสูงสุด

ผู้พัฒนาฝึก SegFormer ด้วยค่าสูญเสียครอสเอนโทรปีรายพิกเซล ตามสมการที่ (22)

$$\mathcal{L}_{\text{seg}} = -\sum_{x,y}\sum_{c=1}^{C} 1\left[y_{xy} = c\right] \log \hat{p}_{xy,c} \tag{22}$$

โดยที่

y_{xy} = ประเภทจริงของพิกเซล (x,y)
$\hat{p}_{xy,c}$ = ความน่าจะเป็นที่โมเดลทำนายว่าพิกเซล (x,y) เป็นประเภท c
C = จำนวนประเภททั้งหมด
$1[\cdot]$ = ฟังก์ชันบ่งชี้ มีค่า 1 เมื่อเงื่อนไขเป็นจริง และ 0 ในกรณีอื่น

งานวิจัยนี้ใช้ SegFormer-B2 ที่ฝึกมาสำหรับแยกส่วนต่าง ๆ ของบุคคล และรวมหน้ากากผมกับหน้ากากใบหน้าเป็นบริเวณที่อนุญาตให้ Diffusion แก้ไข ตามสมการที่ (23) ส่วนเสื้อผ้าและพื้นหลังจะไม่ถูกแก้ไข

$$M_{\text{edit}}(x,y) = B_{\text{hair}}(x,y) \vee B_{\text{face}}(x,y) \tag{23}$$

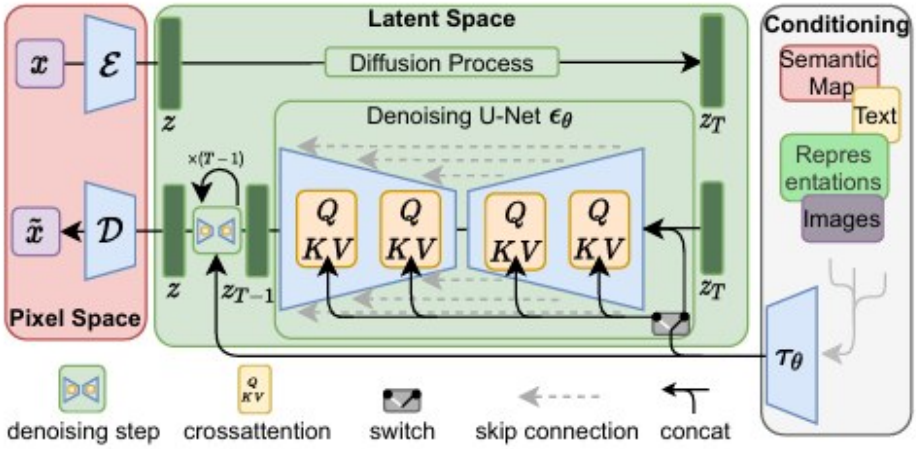
โดยที่

M_{edit} = หน้ากากบริเวณที่อนุญาตให้แก้ไข
$B_{\text{hair}}, B_{\text{face}}$ = หน้ากากบริเวณผมและบริเวณใบหน้าจาก SegFormer
$\vee$ = การรวม (OR) คือเป็น 1 เมื่อพิกเซลอยู่ในบริเวณใดบริเวณหนึ่ง

2.3.6 การปรับปรุงคุณภาพภาพด้วย Stable Diffusion

Stable Diffusion [5] เป็นแบบจำลองดิฟฟิวชันในพื้นที่แฝง (Latent Diffusion Model: LDM) ที่งานวิจัยนี้ใช้เป็นขั้นขัดเกลาภาพ (Post-processing) โดยรับภาพจาก HairFast-GAN หรือ Barbershop และหน้ากาก M_{edit} แล้วเติมรายละเอียดของเส้นผมและผิวให้สมจริงขึ้น ภาพที่ 12 แสดงสถาปัตยกรรมของ Stable Diffusion ซึ่งแบ่งเป็น 3 ส่วน ส่วนซ้าย (Pixel Space

สีแดง) คือตัวเข้ารหัส $\mathcal{E}$ และตัวถอดรหัส $\mathcal{D}$ ที่แปลงภาพไปและกลับจากพื้นที่แฝง ส่วนกลาง (Latent Space สีเขียว) คือกระบวนการดิฟฟิวชันที่ U-Net ลบสัญญาณรบกวนทีละขั้น โดยมีบล็อก Q, K, V เป็นจุดรับเงื่อนไข และส่วนขวา (Conditioning สีเทา) คือแหล่งของเงื่อนไข เช่น ข้อความหรือแผนที่ความหมาย ซึ่งถูกแปลงด้วยตัวเข้ารหัส τ_θ



ภาพที่ 12 สถาปัตยกรรมและการทำงานของ Stable Diffusion ใน Latent Space (จาก [5])

2.3.6.1 Perceptual Image Compression (การบีบอัดและคืนสภาพภาพ)

ตัวเข้ารหัสอัตโนมัติแบบแปรผัน (Variational Autoencoder: VAE) บีบภาพให้เป็นข้อมูลแฝงที่เล็กลง 8 เท่าในแต่ละด้าน และถอดรหัสกลับเป็นภาพ ตามสมการที่ (24) การทำดิฟฟิวชันบนข้อมูลแฝงขนาดเล็กนี้แทนการทำบนพิกเซลโดยตรงช่วยลดการคำนวณลงมาก

$$z = \mathcal{E}(x), \qquad \tilde{x} = \mathcal{D}(z) \tag{24}$$

โดยที่

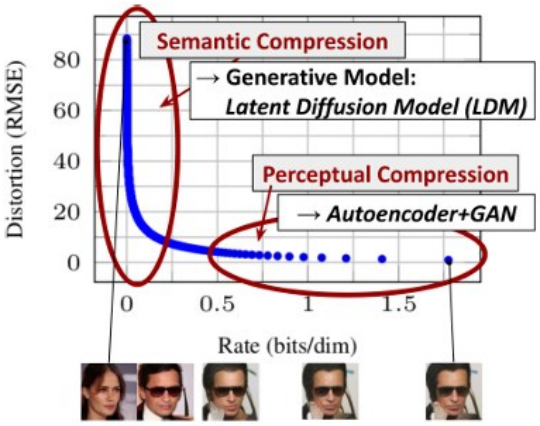
x = ภาพนำเข้า

$\tilde{x}$ = ภาพที่สร้างคืนจากข้อมูลแฝง

$\mathcal{E}, \mathcal{D}$ = ตัวเข้ารหัส (Encoder) และตัวถอดรหัส (Decoder)

z = ข้อมูลแฝงที่ถูกบีบอัดแล้ว (ภาพ 1024×1024 เหลือ $128 \times 128 \times 4$)

ภาพที่ 13 อธิบายว่าทำไมจึงบีบอัดภาพได้ แกนนอนคืออัตราการเก็บข้อมูล (บิตต่อมิติ) และแกนตั้งคือความผิดเพี้ยนของภาพ ช่วงซ้ายที่เส้นชันมาก (Semantic Compression) คือส่วนที่เก็บความหมายหลักของภาพ ส่วนช่วงขวาที่เส้นเกือบแบน (Perceptual Compression) คือรายละเอียดที่ตาแทบมองไม่เห็นแต่ใช้ข้อมูลมาก LDM จึงให้ Autoencoder ตัดส่วนหลังนี้ทิ้ง และให้ดิฟฟิวชันทำงานเฉพาะกับส่วนที่มีความหมาย



ภาพที่ 13 การบีบอัดเชิงการรับรู้ (Perceptual Compression) และเชิงความหมาย (Semantic Compression) ของ Latent Diffusion Model (จาก [5])

หมายเหตุ: LDM = Latent Diffusion Model

2.3.6.2 Denoising U-Net (กระบวนการลบสัญญาณรบกวน)

แบบจำลองดิฟฟิวชัน [22] เรียนรู้การลบสัญญาณรบกวนออกจากข้อมูลแฝงทีละขั้นเวลา ระหว่างการฝึก ข้อมูลแฝง z_0 จะถูกผสมสัญญาณรบกวนตามสมการที่ (25)

$$z_t = \sqrt{\bar{\alpha}_t}\, z_0 + \sqrt{1 - \bar{\alpha}_t}\, \epsilon, \qquad \epsilon \sim \mathcal{N}(0, I) \tag{25}$$

โดยที่

z_0 = ข้อมูลแฝงของภาพที่ไม่มีสัญญาณรบกวน

z_t = ข้อมูลแฝงที่ขั้นเวลา t ซึ่งมีสัญญาณรบกวนปนอยู่

$\bar{\alpha}_t$ = ตารางสัดส่วนของภาพเดิมที่เหลืออยู่ ลดจาก 1 ไปใกล้ 0 เมื่อ t เพิ่มขึ้น

ϵ = สัญญาณรบกวนแบบเกาส์เซียน

$\mathcal{N}(0, I)$ = การแจกแจงปกติที่มีค่าเฉลี่ย 0 และความแปรปรวน 1

จากนั้นฝึก U-Net ให้ทายว่าสัญญาณรบกวนที่ใส่ลงไปมีค่าเท่าใด ด้วยสมการที่ (26)

$$\mathcal{L}_{\text{LDM}} = \mathbb{E}_{z,\, \epsilon,\, t}\left[\|\epsilon - \epsilon_\theta(z_t,\ t)\|_2^2\right] \tag{26}$$

โดยที่

$\mathcal{L}_{\text{LDM}}$ = ค่าความผิดพลาดกำลังสองเฉลี่ย (Mean Squared Error: MSE) ของการทายสัญญาณรบกวน

ϵ_θ = เครือข่าย U-Net ที่มีพารามิเตอร์ θ ทำหน้าที่ทายสัญญาณรบกวน

t = ขั้นเวลาที่สุ่มมาในการฝึก

2.3.6.3 Cross-Attention Mechanism (การ ควบคุม ด้วย ข้อความ)

กลไกความสนใจข้าม (Cross-Attention) เชื่อมข้อความสั่งงานเข้ากับการสร้างภาพ ตามสมการที่ (27) และ (28) เพื่อให้ U-Net สร้างรายละเอียดตามที่ข้อความกำหนด

$$Q = W_Q \cdot \varphi(z_t), \quad K = W_K \cdot \tau_\theta(y), \quad V = W_V \cdot \tau_\theta(y) \tag{27}$$

$$\text{CrossAttn}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d}}\right) \cdot V \tag{28}$$

โดยที่

$\varphi(z_t)$ = คุณลักษณะของภาพภายใน U-Net ณ ขั้นเวลา t

y = ข้อความสั่งงาน (Prompt)

$\tau_\theta(y)$ = เวกเตอร์ของข้อความจากตัวเข้ารหัสข้อความ (CLIP Text Encoder)

W_Q, W_K, W_V = เมทริกซ์น้ำหนักที่แปลงเป็นคิวรี คีย์ และค่า

d = มิติของเวกเตอร์คีย์ ใช้ปรับสเกล

เมื่อรวมเงื่อนไขข้อความเข้ากับการลบสัญญาณรบกวน จะได้ฟังก์ชันสูญเสียตามสมการที่ (29)

$$\mathcal{L}_{\text{LDM-Cond}} = \mathbb{E}_{z,\, y,\, \epsilon,\, t}\left[\|\epsilon - \epsilon_\theta(z_t,\ t,\ \tau_\theta(y))\|_2^2\right] \tag{29}$$

โดยที่

$\mathcal{L}_{\text{LDM-Cond}}$ = ค่าสูญเสียของ LDM แบบมีเงื่อนไข

$\epsilon_\theta(z_t, t, \tau_\theta(y))$ = สัญญาณรบกวนที่ U-Net ทายเมื่อได้รับเงื่อนไขข้อความ

2.3.6.4 Inpainting, Strength, Classifier-Free Guidance และ Scheduler

ในงานวิจัยนี้ Stable Diffusion ทำงานแบบเติมภาพเฉพาะบริเวณ (Inpainting) ผ่าน `StableDiffusionInpaintPipeline` ของไลบรารี Diffusers ด้วยรุ่น Realistic Vision v5.1 ซึ่งเป็นรุ่นสร้างภาพทั่วไปที่ U-Net รับข้อมูลแฝงเพียง 4 ช่องสัญญาณ ไม่ใช่รุ่นที่ฝึกมาเพื่องานเติมภาพโดยเฉพาะ ซึ่งรับ 9 ช่องสัญญาณ (เพิ่มข้อมูลแฝงของภาพเดิม 4 ช่อง และหน้ากาก 1 ช่อง) เมื่อใช้รุ่น 4 ช่องสัญญาณ ไลบรารีจะควบคุมบริเวณที่แก้ไขด้วยการแทนค่าในทุกขั้นของการลบสัญญาณรบกวน คือบริเวณนอกหน้ากาก M_{edit} จะถูกแทนด้วยข้อมูลแฝงของภาพเดิมที่เติมสัญญาณรบกวนถึงระดับเดียวกัน ส่วนบริเวณในหน้ากากใช้ค่าที่ U-Net เพิ่งลบสัญญาณรบกวน ภาพจึงถูกวาดใหม่เฉพาะในหน้ากาก โดยยังใช้ส่วนที่เหลือของภาพเป็นบริบท แต่ในตอนท้าย ตัวถอดรหัส $\mathcal{D}$ จะถอดรหัสทั้งภาพ บริเวณนอกหน้ากากจึงเปลี่ยนไปเล็กน้อยจาก

การบีบอัดแล้วคืนสภาพ ภาพที่ 14 แสดงตัวอย่างของ LDM ในงานวิจัยต้นฉบับ คอลัมน์ซ้ายคือภาพนำเข้าที่มีกรอบสีแดงล้อมบริเวณที่จะแก้ไข และคอลัมน์ขวาคือผลที่บริเวณนั้นถูกเติมใหม่ให้กลืนกับภาพเดิม ขณะที่ส่วนอื่นไม่เปลี่ยน



ภาพที่ 14 ตัวอย่างผลลัพธ์การ Inpainting ด้วย Latent Diffusion Model (จาก [5])

งาน วิจัย นี้ ใช้ ดิฟฟิว ชัน แบบ แรง ต่ำ โดย กำหนด ความ แรง (Strength) ซึ่งหมายถึงการเติมสัญญาณรบกวนให้ภาพเดิมตามสมการที่ (25) เพียงถึงขั้นเวลา $t = \text{strength} \times T$ แล้วจึงลบสัญญาณรบกวนออก แทนที่จะเริ่มจากสัญญาณรบกวนล้วน เมื่อใช้ค่า 0.15 ภาพเดิมยังคงอยู่เกือบทั้งหมด จึงเปลี่ยนเฉพาะพื้นผิวของเส้นผมและผิว นอกจากนี้ยังใช้การนำทางแบบไม่ใช้ตัวจำแนก (Classifier-Free Guidance: CFG) [23] ซึ่งผสมผลทำนายเมื่อได้รับข้อความสั่งงาน กับผลทำนายเมื่อได้รับข้อความเชิงลบ (Negative Prompt) ตามสมการที่ (30) เพื่อดันผลลัพธ์ให้ตรงกับข้อความสั่งงานและห่างจากสิ่งที่ไม่ต้องการ

$$\hat{\epsilon} = \epsilon_{\text{neg}} + s \cdot (\epsilon_{\text{prompt}} - \epsilon_{\text{neg}}) \tag{30}$$

โดยที่

$\hat{\epsilon}$ = สัญญาณรบกวนที่ใช้จริงในการลบแต่ละขั้น
ϵ_{prompt} = สัญญาณรบกวนที่ U-Net ทายเมื่อได้รับข้อความสั่งงาน
ϵ_{neg} = สัญญาณรบกวนที่ U-Net ทายเมื่อได้รับข้อความเชิงลบ
s = ค่านำทาง (Guidance Scale) งานวิจัยนี้ใช้ 2.5 ซึ่งเป็นค่าต่ำเพื่อไม่ให้ภาพเพี้ยน
T = จำนวนขั้นเวลาทั้งหมดของกระบวนการดิฟฟิวชัน

สำหรับ วิธี คำนวณ แต่ละ ขั้น ของ การ ลบ สัญญาณ รบกวน (Scheduler) งาน วิจัย นี้ ใช้ Unified

Predictor-Corrector (UniPC) [24] ซึ่งใช้จำนวนขั้นน้อยแต่ยังได้ภาพคุณภาพดี เมื่อตั้งไว้ 30 ขั้น ร่วมกับความแรง 0.15 จะลบสัญญาณรบกวนจริงประมาณ 4 ขั้น

2.3.7 การเรียนรู้แบบถ่ายโอนและการปรับจูนโมเดล

การปรับจูน (Fine-tuning) คือการนำโมเดลที่ผู้อื่นฝึกไว้แล้วมาฝึกต่ออีกเล็กน้อยด้วยข้อมูลของเราเอง หรือที่เรียกว่าการเรียนรู้แบบถ่ายโอน (Transfer Learning) [25] เปรียบเหมือนช่างตัดผมที่มีฝีมืออยู่แล้วมาเรียนเพิ่มเฉพาะเทคนิคใหม่ โดยไม่ต้องเริ่มเรียนตั้งแต่ศูนย์ โดยทั่วไปจะล็อกส่วนต้นของโมเดลไว้ และปรับเฉพาะบางส่วนด้วยอัตราการเรียนรู้ (Learning Rate: LR) ซึ่งเป็นขนาดของการปรับน้ำหนักในแต่ละครั้ง โดยตั้งให้ต่ำมาก เพื่อไม่ให้โมเดลลืมสิ่งที่เคยเรียนมา (Catastrophic Forgetting) การฝึกหนึ่งรอบเริ่มจากคำนวณไปข้างหน้าจนได้ผลลัพธ์ แล้วคำนวณค่าสูญเสีย หาอนุพันธ์ย้อนกลับ (Backpropagation) ด้วยกฎลูกโซ่ จากนั้นปรับน้ำหนักด้วยตัวปรับค่า Adaptive Moment Estimation (Adam) [26] ซึ่งจำค่าเฉลี่ยเคลื่อนที่ของเกรเดียนต์และของเกรเดียนต์ยกกำลังสอง เพื่อปรับขนาดก้าวให้เหมาะกับแต่ละพารามิเตอร์ ตามสมการที่ (31)

$$m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t, \quad v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2, \quad \theta_t = \theta_{t-1} - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} \tag{31}$$

โดยที่

θ_t = ค่าพารามิเตอร์ (น้ำหนัก) ของโมเดลหลังการปรับรอบที่ t

g_t = เกรเดียนต์ของค่าสูญเสียเทียบกับพารามิเตอร์ในรอบที่ t

m_t, v_t = ค่าเฉลี่ยเคลื่อนที่ของเกรเดียนต์และของเกรเดียนต์ยกกำลังสอง

$\hat{m}_t, \hat{v}_t$ = ค่า m_t และ v_t ที่แก้ความเอนเอียงช่วงต้น (หารด้วย $1-\beta^t$)

β_1, β_2 = ค่าคงที่ของค่าเฉลี่ยเคลื่อนที่ (0.9 และ 0.999)

η = อัตราการเรียนรู้

ϵ = ค่าคงที่ขนาดเล็กเพื่อกันการหารด้วยศูนย์

2.3.8 ตัวชี้วัดคุณภาพภาพ

งานวิจัยนี้ใช้ตัวชี้วัดหลายตัว เพื่อวัดแต่ละด้านแยกกัน ด้านสีผมวัดในปริภูมิสี CIELAB (Lab) ซึ่งแยกความสว่าง (L มีค่า 0–100) ออกจากสี (a คือแกนเขียวถึงแดง และ b คือแกนน้ำเงินถึงเหลือง) และออกแบบให้ระยะห่างของค่าสีใกล้เคียงกับความต่างที่ตามนุษย์รับรู้ [27]

ด้านทรงผมวัดด้วยค่าการทับซ้อนของบริเวณผมสองบริเวณ ได้แก่ IoU และสัมประสิทธิ์ไดซ์ (Dice Coefficient) [28] ตามสมการที่ (32) ทั้งสองค่ามีช่วง 0–1 โดย 1 หมายถึงทับกันพอดี

$$\mathrm{IoU} = \frac{|A \cap B|}{|A \cup B|}, \qquad \mathrm{Dice} = \frac{2|A \cap B|}{|A| + |B|} \tag{32}$$

โดยที่

A = เซตของพิกเซลที่เป็นผมในภาพผลลัพธ์

B = เซตของพิกเซลที่เป็นผมในทรงเป้าหมาย

$|\cdot|$ = จำนวนพิกเซลในเซต

$\cap, \cup$ = ส่วนที่ทับกันและส่วนรวมของสองเซต

ด้านการคงส่วนที่ไม่ควรเปลี่ยน วัดด้วย SSIM [29] ตามสมการที่ (33) ซึ่งเทียบความสว่าง ความต่างของแสง และโครงสร้างในหน้าต่างย่อย ค่า 1.0 หมายถึงเหมือนกันทุกจุด และวัดด้วยค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย (Mean Absolute Error: MAE) ตามสมการที่ (34) ซึ่งยิ่งต่ำยิ่งแปลว่าภาพเปลี่ยนน้อย

$$\mathrm{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \tag{33}$$

โดยที่

x, y = หน้าต่างย่อยของภาพสองภาพที่ตำแหน่งเดียวกัน

μ_x, μ_y = ค่าเฉลี่ยความสว่างในหน้าต่าง

σ_x^2, σ_y^2 = ความแปรปรวน (ความต่างของแสง) ในหน้าต่าง

σ_{xy} = ความแปรปรวนร่วม (ความคล้ายเชิงโครงสร้าง)

C_1, C_2 = ค่าคงที่ขนาดเล็กเพื่อกันการหารด้วยศูนย์

$$\mathrm{MAE} = \frac{1}{N}\sum_{p=1}^{N} |x_p - y_p| \tag{34}$$

โดยที่

x_p, y_p = ค่าสีของพิกเซล p ในภาพผลลัพธ์และภาพต้นฉบับ (ปรับเป็นช่วง 0–1)

N = จำนวนพิกเซลในบริเวณที่วัด

ด้าน คุณภาพ ภาพ โดย รวม ใช้ Multi-scale Image Quality Transformer (MUSIQ) [30] ซึ่งให้คะแนน 0–100 โดยไม่ต้องมีภาพอ้างอิง ส่วนการบอกว่าผลต่างที่วัดได้เกิดขึ้นจริงหรือเกิดจากความบังเอิญ งานวิจัยนี้ใช้ช่วงความเชื่อมั่น (Confidence Interval: CI) แบบบูตสแตรป (Bootstrap) [31] คือสุ่มตัวอย่างจากข้อมูลเดิมแบบใส่คืนซ้ำหลายพันครั้ง คำนวณค่าเฉลี่ยทุกครั้ง แล้วใช้เปอร์เซ็นไทล์ที่ 2.5 และ 97.5 ของค่าเฉลี่ยเหล่านั้นเป็นขอบของช่วงความเชื่อมั่น 95% ถ้าช่วงนี้ไม่ครอบคลุมเลข 0 แสดงว่าการเปลี่ยนแปลงนั้นไม่น่าเกิดจากความบังเอิญ วิธีนี้ไม่ต้องสมมติรูปแบบการแจกแจงของข้อมูล แต่เมื่อข้อมูลมีน้อย ช่วงความเชื่อมั่นอาจยังไม่นิ่ง จึงควรตีความเป็นผลเชิงสำรวจจากชุดตัวอย่างที่ศึกษาเท่านั้น

บทที่ 3
วิธีดำเนินการวิจัย

3.1 ภาพรวมกระบวนการวิจัย

หลักที่ผู้วิจัยยึดตลอดโครงงานคือ ให้ทั้งสองโมเดลใช้ข้อมูลและตัวชี้วัดชุดเดียวกัน และระบุให้ชัดว่าสองโมเดลต่างกันตรงไหน ทั้งโครงสร้างของโมเดล ค่าสูญเสียส่วนเพิ่มของ HairFastGAN และ Epoch ที่มีไฟล์น้ำหนักให้เลือก เพื่อให้ผลที่ต่างกันมาจากตัวโมเดลจริง ไม่ได้มาจากเงื่อนไขการทดลองที่ต่างกัน งานทั้งหมดแบ่งเป็น 7 ขั้น ขั้นแรกคือเตรียมข้อมูล 169 ชุด แล้วแบ่งเป็นชุดฝึก ชุดตรวจสอบ และชุดทดสอบ จากนั้นโหลดน้ำหนักทางการของ HairFastGAN (HFG) และ Barbershop (BS) มาเป็นจุดเริ่มต้น แล้วปรับจูนเฉพาะส่วนที่ควบคุมสีและรายละเอียด โดยทดลองอัตราการเรียนรู้ 4 ชุด (เรียกแต่ละชุดว่า Trial) ชุดละ 30 รอบการฝึก (Epoch) หลังจบแต่ละ Epoch จะวัดผลบนชุดตรวจสอบ แล้วใช้กติกาฉบับแก้ไขที่อธิบายในบทนี้ เลือกน้ำหนักที่เหมาะสมจากไฟล์น้ำหนักที่บันทึกไว้ (Checkpoint) เมื่อเลือกได้แล้วจึงนำไปวัดผลบนชุดทดสอบเพียงครั้งเดียว ขั้นต่อมาคือเติมรายละเอียดด้วย Stable Diffusion และขั้นสุดท้ายคือให้ผู้ใช้ 41 คนประเมินภาพโดยไม่รู้ชื่อโมเดล เพื่อตัดสินว่าจะใช้โมเดลใดบนเว็บ แล้วจึงเปิดให้ทดลองใช้งานจริง 100 ครั้ง

ภาพที่ 15 สรุปทั้ง 7 ขั้นไว้ในภาพเดียว ให้อ่านจากซ้ายไปขวาตามขั้นที่ 1–6 ส่วนขั้นที่ 7 อยู่ในแถวล่างสุด ในคอลัมน์ของแต่ละขั้น แถวบนเป็นของ HairFastGAN และแถวล่างเป็นของ Barbershop สีของกรอบบอกประเภทของงาน กรอบสีน้ำเงินคือส่วนเดิมของโมเดลที่ล็อกไว้ (ไม่ปรับน้ำหนัก) กรอบสีส้มเส้นประคือส่วนที่ผู้วิจัยฝึกเพิ่ม กรอบสีเขียวคือขั้นขัดเกลาที่ผู้วิจัยเพิ่มเข้าไป และกรอบสีม่วงคือการวัดผลและการเลือก ตัวเลขในกรอบเป็นผลจริงของขั้นนั้น เช่น คะแนนของ Checkpoint ที่เลือก ผู้อ่านจึงใช้ภาพนี้เป็นแผนที่ย้อนกลับมาดูได้ระหว่างอ่านบทที่ 3 และบทที่ 4

3.2 ชุดข้อมูล

ข้อมูลหนึ่งชุดมี 3 ภาพ แต่ละภาพมีหน้าที่ต่างกัน ภาพใบหน้าคือภาพของคนที่จะเปลี่ยนผมให้ ทุกอย่างในภาพนี้ยกเว้นผมต้องคงเดิม ทั้งใบหน้า ผิว เสื้อผ้า และฉากหลัง ภาพอ้างอิงทรงผมใช้เฉพาะรูปทรงของผม และภาพอ้างอิงสีผมใช้เฉพาะสีของผม ภาพที่ 16 เป็นตัวอย่างข้อมูลหนึ่งชุด จากซ้ายไปขวาคือภาพใบหน้า ภาพทรงผม และภาพสีผม เครื่องหมายบวกระหว่างภาพหมายถึงทั้งสามภาพถูกใช้ร่วมกันเพื่อสร้างภาพผลลัพธ์หนึ่งภาพ จะเห็นว่าภาพทรงผมกับภาพสีผมเป็นคนละคนกันได้ ซึ่งทำให้งานยากขึ้น

ก่อนใช้งาน ภาพทุกภาพถูกครอปและจัดตำแหน่งใบหน้าให้ตรงกับรูปแบบของชุดข้อมูล Flickr-Faces-HQ (FFHQ) ขนาด 1024×1024 พิกเซล เพราะ StyleGAN2 (Style-based



ภาพที่ 15 ภาพรวมกระบวนการวิจัย ตั้งแต่ข้อมูล การปรับจูน การเลือก Checkpoint การทดสอบ การขัดเกลาด้วย Diffusion จนถึงการคัดเลือกโมเดลสำหรับเว็บแอปพลิเคชัน

หมายเหตุ: HFG = HairFastGAN, BS = Barbershop, BS-FT (Barbershop-FT) = Barbershop ที่ปรับจูนแล้ว (Fine-tuned), B24 = น้ำหนักของ Trial B Epoch 24, A30 = น้ำหนักของ Trial A Epoch 30, IoU = Intersection over Union (สัดส่วนพื้นที่ผมที่ทับกัน), MAE = Mean Absolute Error (ค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย)

Generative Adversarial Network รุ่นที่ 2) ของทั้งสองโมเดลถูกฝึกมากับภาพลักษณะนี้ ถ้าตำแหน่งตาหรือขนาดใบหน้าไม่ตรง โมเดลจะสร้างภาพเพี้ยนตั้งแต่ขั้นแรก จากนั้นสร้างหน้ากาก (Mask) ขนาด 256×256 ไว้ 3 แบบ คือ หน้ากากผมเดิม หน้ากากทรงผมเป้าหมาย และหน้ากากบริเวณที่ต้องคงเดิม ซึ่งหมายถึงทุกพิกเซลที่ไม่ได้อยู่ในผมเดิมหรือผมใหม่ หน้ากากเหล่านี้ใช้ทั้งตอนคำนวณค่าสูญเสียและตอนวัดผล ผู้วิจัยระวังไม่ให้ภาพเดียวกันไปอยู่ในหลายชุด เพราะถ้าภาพในชุดทดสอบเคยอยู่ในชุดฝึก ผลทดสอบจะดีเกินจริง (เรียกว่าข้อมูลรั่ว หรือ Data Leakage) และได้ตรวจไฟล์ทุกไฟล์ด้วยค่าแฮช SHA-256 (Secure Hash Algorithm 256 บิต) ซึ่งเป็นรหัสประจำไฟล์ที่จะเปลี่ยนทันทีถ้าไฟล์ถูกแก้ เพื่อยืนยันว่าไม่มีไฟล์ซ้ำข้ามชุดข้อมูล และข้อมูลไม่ถูกแก้ระหว่างการทดลอง



ภาพที่ 16 ตัวอย่างข้อมูลนำเข้าหนึ่งชุด ได้แก่ ภาพใบหน้าต้นฉบับ ภาพอ้างอิงทรงผม และภาพอ้างอิงสีผม

ตารางที่ 4 แสดงว่าข้อมูล 169 ชุดถูกแบ่งอย่างไร และแต่ละส่วนมีไว้ทำอะไร ชุดฝึก 150 ชุดเป็นชุดเดียวที่โมเดลได้เรียนรู้ ชุดตรวจสอบ 9 ชุดใช้ดูผลหลังจบแต่ละ Epoch เพื่อเลือก Checkpoint และชุดทดสอบ 10 ชุดใช้ประเมิน Checkpoint ที่เลือกไว้แล้ว อย่างไรก็ตาม ผู้วิจัยเคยประเมินโมเดลก่อนปรับจูนบนชุดทดสอบนี้ไปแล้วครั้งหนึ่งก่อนแก้กติกาการเลือก ชุดทดสอบจึงไม่ใช่ชุดที่ไม่เคยถูกเปิดดูเลย เหตุผลที่ต้องแยกชุดตรวจสอบออกจากชุดทดสอบคือ ถ้าใช้ชุดเดียวกันทั้งเลือกโมเดลและวัดผล ผู้วิจัยอาจเผลอเลือกโมเดลที่บังเอิญเข้ากับข้อมูลชุดนั้น แล้วรายงานผลที่ดีเกินจริง

3.3 เครื่องมือและสภาพแวดล้อม

โค้ดทั้งหมดเขียนด้วยภาษา Python โดยใช้ PyTorch สำหรับโมเดล GAN (Generative Adversarial Network) และใช้ไลบรารี Hugging Face Diffusers กับ Transformers สำหรับ Stable Diffusion และ SegFormer (Segmentation Transformer) การทดลองทุกขั้น รวมถึงการจับเวลา รันบน Google Colab ด้วยหน่วยประมวลผลกราฟิก (Graphics Processing Unit: GPU) NVIDIA A100 หน่วยความจำ 40 GB เพื่อให้เวลาของทุกระบบเทียบกันได้ โมเดลที่นำมาใช้โดยไม่ได้ฝึกเอง ได้แก่ น้ำหนักทางการของ HairFastGAN และ Barbershop (ซึ่งมี StyleGAN2 ที่ฝึกบน FFHQ อยู่ภายใน), BiSeNet (Bilateral Segmentation Network), ArcFace (Additive Angular Margin Loss), CLIP (Contrastive Language-Image Pre-training), SegFormer-B2

ตารางที่ 4 การแบ่งชุดข้อมูล

ชุดข้อมูล	จำนวนชุด	หน้าที่
ชุดฝึก (Train)	150	ใช้ปรับน้ำหนักโมเดล เป็นชุดเดียวที่โมเดลเห็นระหว่างการฝึก
ชุดตรวจสอบ (Validation)	9	วัดผลหลังจบทุก Epoch เพื่อเลือก Checkpoint
ชุดทดสอบ (Test)	10	ล็อก Checkpoint ไว้ก่อน แล้ววัดผลเพียงครั้งเดียว
รวม	**169**	

และ Stable Diffusion แบบเติมภาพ (Inpainting) รุ่น Realistic Vision v5.1 ทุกการทดลองใช้ค่าเริ่มต้นของตัวสุ่ม (Seed) 3407 และบันทึกค่าแฮชของ Checkpoint ข้อมูล และการตั้งค่า เพื่อให้รันซ้ำแล้วได้ผลเดิม

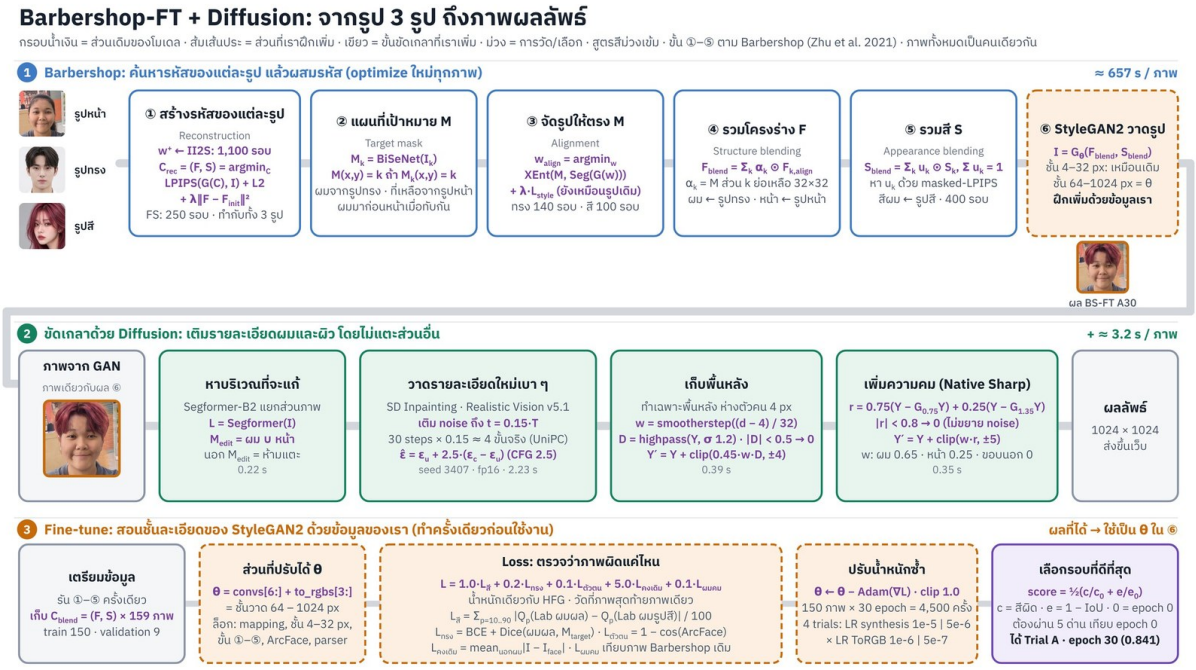
3.4 ขั้นตอนการทำงานของ Barbershop-FT (Barbershop ที่ปรับจูนแล้ว)

Barbershop (หลักการอยู่ในหัวข้อที่ 2.3.3) ทำงาน 6 ขั้น ห้าขั้นแรกเป็นการค้นหารหัสของภาพ ซึ่งเป็นส่วนเดิมของโมเดลที่ผู้วิจัยไม่ได้แก้ ขั้นที่ 6 คือการวาดภาพด้วย StyleGAN2 ซึ่งเป็นขั้นเดียวที่มีน้ำหนักให้ปรับจูน ในเล่มนี้เรียก Barbershop ที่ปรับจูนแล้วว่า Barbershop-FT (BS-FT) ภาพที่ 17 แสดงทั้งระบบเป็น 3 แถว แถวแรกคือ 6 ขั้นของ Barbershop-FT ตั้งแต่ภาพนำเข้าจนได้ภาพจาก GAN แถวที่สองคือขั้นขัดเกลาด้วย Diffusion ที่ต่อท้าย และแถวที่สามคือวิธีปรับจูน ในแต่ละกล่องมีสูตรและค่าที่ใช้จริงกำกับไว้ ซึ่งจะอธิบายทีละขั้นต่อไปนี้

ขั้นที่ 1 คือการแปลงภาพกลับเป็นรหัส (GAN Inversion) StyleGAN2 วาดภาพได้จากรหัสเท่านั้น จึงต้องหาก่อนว่ารหัสแบบใดที่เมื่อวาดออกมาแล้วได้ภาพนั้น Barbershop ทำโดยตรึง StyleGAN2 ไว้ แล้วค่อย ๆ ปรับรหัส w โดยเริ่มจากรหัสเฉลี่ย จนภาพที่วาดได้ใกล้ภาพจริงที่สุด ตามสมการที่ (35) การค้นหาเริ่มในพื้นที่ W^+ ด้วยวิธี II2S (Improved Image2StyleGAN) 1,100 รอบ แล้วค้นต่อในพื้นที่ FS อีก 250 รอบ ด้วยอัตราการเรียนรู้ 0.01 โดยทำแบบนี้กับทั้ง 3 ภาพ ผลที่ได้ของแต่ละภาพคือ F ซึ่งเป็นคุณลักษณะขนาด $32 \times 32 \times 512$ ที่เก็บโครงร่างของภาพ และ S ซึ่งเป็นสไตล์ของชั้นที่เหลือที่เก็บสีและพื้นผิว ขั้นนี้ใช้เวลามากที่สุดของ Barbershop

$$w^* = \arg\min_{w} \ \mathrm{LPIPS}\left(G(w), I\right) + \lambda \left\| G(w) - I \right\|_2^2 \tag{35}$$

โดยที่



ภาพที่ 17 ขั้นตอนการทำงานของ Barbershop-FT + Diffusion ตั้งแต่ภาพนำเข้า 3 ภาพ จนถึงภาพผลลัพธ์ พร้อมส่วนที่ปรับจูน

หมายเหตุ: BS-FT (Barbershop-FT) = Barbershop ที่ปรับจูนแล้ว (Fine-tuned), LPIPS = Learned Perceptual Image Patch Similarity, StyleGAN2 = Style-based Generative Adversarial Network รุ่นที่ 2, BiSeNet = Bilateral Segmentation Network, SegFormer = Segmentation Transformer

w^* = รหัสแฝงที่ดีที่สุดของภาพ I

$G(w)$ = ภาพที่ StyleGAN2 วาดจากรหัส w

I = ภาพนำเข้า

LPIPS = ระยะห่างเชิงการรับรู้ (Learned Perceptual Image Patch Similarity)

$\|\cdot\|_2^2$ = ผลรวมกำลังสองของผลต่างทีละพิกเซล (ระยะ L2)

λ = น้ำหนักของค่า L2

เมื่อค้นต่อในพื้นที่ FS จะเพิ่มค่าสูญเสีย $\mathcal{L}_F$ ตามสมการที่ (13) เพื่อไม่ให้ F ห่างจากค่าที่ได้จาก W^+ มากเกินไป

ขั้นที่ 2 คือการกำหนดว่าภาพผลลัพธ์ควรมีส่วนต่าง ๆ อยู่ตรงไหน โดยสร้างแผนที่เป้าหมาย M BiSeNet แบ่งภาพใบหน้าและภาพทรงผมออกเป็นส่วน ๆ เช่น ผม ใบหน้า คอ และพื้นหลัง แล้วนำมาประกอบกัน บริเวณผมเอามาจากภาพทรงผม ส่วนบริเวณอื่นเอามาจากภาพใบหน้า ถ้าสองส่วนทับกันให้ใช้ผม ตามสมการที่ (36)

$$M_k = \mathrm{BiSeNet}(I_k), \qquad M(x,y) = k \;\text{ ถ้า }\; M_k(x,y) = k \tag{36}$$

โดยที่

M_k = แผนที่ส่วนภาพของภาพที่ k

I_k = ภาพนำเข้าภาพที่ k

$M(x,y)$ = ประเภทของพิกเซล (x,y) ในแผนที่เป้าหมาย

k = ประเภทของบริเวณ เช่น ผม ใบหน้า คอ หรือพื้นหลัง

ขั้นที่ 3 คือการจัดรูปให้ตรงแผนที่ (Semantic Alignment) รหัสจากขั้นที่ 1 ยังวาดผมทรงเดิมอยู่ จึงต้องค้นหารหัสต่อจนภาพที่วาดได้มีผมอยู่ตาม M ในขั้นนี้ BiSeNet ทำหน้าที่เหมือนผู้ตรวจงาน เพราะคำนวณอนุพันธ์ได้ จึงบอกได้ว่าพิกเซลใดยังผิดประเภท และควรปรับรหัสไปทางใด ส่วนค่าสูญเสียสไตล์มีไว้กันไม่ให้สีและพื้นผิวเพี้ยนไประหว่างจัดทรง ตามสมการที่ (37) ขั้นนี้จัดทรง 140 รอบและจัดสี 100 รอบ รูปทรงผมของผลลัพธ์ถูกกำหนดเสร็จในขั้นนี้

$$w_{align} = \arg\min_{w} \; \mathrm{XEnt}\left(M, \mathrm{BiSeNet}(G(w))\right) + \lambda\, L_{style} \tag{37}$$

โดยที่

w_{align} = รหัสที่จัดให้ตรงแผนที่แล้ว

XEnt = ค่าสูญเสียครอสเอนโทรปี (Cross-Entropy)

$= -\sum \log p$(ประเภทที่ถูกต้อง) ต่อพิกเซล

L_{style} = ค่าสูญเสียสไตล์จากเมทริกซ์แกรม

λ = น้ำหนักของค่าสูญเสียสไตล์

ขั้นที่ 4 คือการรวมโครงร่าง (Feature-space Blending) เมื่อแต่ละภาพมี F ที่ตรงกับแผนที่แล้ว ก็ตัดต่อ F ตามหน้ากากที่ย่อเหลือ 32×32 บริเวณผมใช้ F ของภาพทรงผม และบริเวณอื่นใช้ F ของภาพใบหน้า ตามสมการที่ (38) ที่ตัดต่อในระดับคุณลักษณะแทนระดับพิกเซล เพราะชั้นที่เหลือของ StyleGAN2 จะช่วยเกลี่ยรอยต่อให้เอง ภาพจึงไม่มีขอบตัดแปะให้เห็น ขั้นนี้เป็นการคำนวณโดยตรง ไม่ต้องวนซ้ำ

$$F_{blend} = \sum_{k} \alpha_k \odot F_{k,align} \tag{38}$$

โดยที่

F_{blend} = แผนที่คุณลักษณะที่ผสมแล้ว
α_k = หน้ากากของบริเวณ k ที่ย่อเหลือ 32×32
$F_{k,align}$ = แผนที่คุณลักษณะของภาพที่ใช้ในบริเวณ k หลังจัดรูปแล้ว
$\odot$ = การคูณทีละสมาชิก

ขั้นที่ 5 คือการผสมสไตล์ (Appearance Blending) เพื่อกำหนดสี ระบบค้นหาสัดส่วน u_k สำหรับผสมสไตล์ของแต่ละภาพ ให้ผมมีสีเหมือนภาพสีผม ขณะที่ใบหน้ายังมีสีผิวเหมือนภาพใบหน้า โดยใช้ LPIPS (Learned Perceptual Image Patch Similarity) เฉพาะบริเวณเป็นตัววัดและค้นหา 400 รอบ ตามสมการที่ (39)

$$S_{blend} = \sum_{k} u_k \odot S_k, \quad \sum_{k} u_k = 1, \quad u_k \geq 0 \tag{39}$$

โดยที่

S_{blend} = รหัสสไตล์ที่ผสมแล้ว
S_k = รหัสสไตล์ของภาพที่ k
u_k = สัดส่วนผสมของภาพที่ k มีขนาดเท่ากับ S_k ทุกค่าไม่ติดลบ และรวมทุกภาพได้ 1
$\odot$ = การคูณทีละสมาชิก

ขั้นที่ 6 คือการวาดภาพ ซึ่งเป็นขั้นที่ผู้วิจัยปรับจูน F_{blend} ถูกป้อนเข้าที่ชั้น 32×32 แล้วชั้นถัดไปขยายภาพทีละ 2 เท่าจนถึง 1024 โดยมี S_{blend} ควบคุมสไตล์ทุกชั้น ตามสมการที่ (40) ผู้วิจัยปรับเฉพาะชั้นคอนโวลูชันตั้งแต่ชั้นที่ 7 และชั้นแปลงเป็นภาพสี (ToRGB) ตั้งแต่ชั้นที่ 4 ซึ่งทำงานที่ความละเอียด 64–1024 พิกเซล และเป็นชั้นที่สร้างรายละเอียดของเส้นผม ผิว และสี ส่วนชั้น 4–32 พิกเซลที่ควบคุมโครงหน้าถูกล็อกไว้ เพราะถ้าชั้นเหล่านี้เปลี่ยน ใบหน้าจะเปลี่ยนตาม

$$I = G_\theta \left(F_{blend}, S_{blend} \right) \tag{40}$$

โดยที่

I = ภาพผลลัพธ์ของ Barbershop-FT

G_θ = ตัวสร้าง StyleGAN2 ที่ส่วน θ ถูกปรับจูน

θ = พารามิเตอร์ที่ปรับจูน คือ `convs[6:]` และ `to_rgbs[3:]` (ชั้น 64–1024 พิกเซล)

ขั้นที่ 1–5 ใช้เวลานานมาก แต่ไม่มีน้ำหนักให้เรียนรู้ ผู้วิจัยจึงรันห้าขั้นนี้เพียงครั้งเดียว แล้วเก็บ (F_{blend}, S_{blend}) ของทั้ง 159 ชุด (ชุดฝึกและชุดตรวจสอบ) ไว้ จากนั้นจึงฝึก θ ซ้ำบนรหัสที่เก็บไว้ ถ้าต้องค้นหาใหม่ทุกครั้ง การฝึก 30 Epoch ของ Trial เดียวจะใช้เวลาหลายสัปดาห์ แต่วิธีนี้มีผลข้างเคียงที่ต้องยอมรับ คือรูปทรงผมถูกกำหนดไปแล้วตั้งแต่ขั้นที่ 3 การปรับจูนขั้นที่ 6 จึงแก้ได้เพียงสีและรายละเอียด แทบไม่มีผลกับทรง และเวลาที่ใช้จริงต่อภาพยังเท่าเดิม คือประมาณ 657 วินาที

3.5 ขั้นตอนการทำงานของ HairFastGAN

HairFastGAN ต่างจาก Barbershop ตรงที่ทุกขั้นใช้เครือข่ายที่ฝึกไว้แล้วคำนวณผลออกมาได้ทันที ไม่ต้องค้นหาซ้ำ ภาพผ่านเครือข่ายเพียงครั้งเดียวก็ได้ผลลัพธ์ จึงใช้เวลาประมาณ 10 วินาทีต่อภาพ ระบบมี 5 โมดูล (หลักการอยู่ในหัวข้อที่ 2.3.2) ผู้วิจัยล็อกโมดูล Embedding, Pose และ Shape ไว้ และปรับจูนโมดูล Color กับ Refinement ภาพที่ 18 แสดงทั้งระบบหลังปรับจูนรวมกับขั้นขัดเกลา กรอบบน (Stage 1) คือ 5 โมดูลของ HairFastGAN โดยโมดูลที่มีป้ายสีส้มคือโมดูลที่ปรับจูน กรอบล่างซ้าย (Stage 2) คือ Stable Diffusion Inpainting และกรอบล่างขวา (Stage 3) คือการเก็บรายละเอียดพื้นหลังและการเพิ่มความคม ก่อนได้ภาพผลลัพธ์ทางขวาสุด

โมดูลแรก Embedding ทำหน้าที่เดียวกับขั้นที่ 1 ของ Barbershop แต่ใช้ FS Encoder และ E4E (Encoder for Editing) คำนวณรหัส F ($32\times32\times512$) และ S (รหัสสไตล์ของชั้นถัดจาก F) ของทั้ง 3 ภาพในครั้งเดียว เฉพาะบริเวณผมจะผสม F จาก FS Encoder กับ F จาก E4E ตามสมการที่ (41) ซึ่งเป็นสมการที่ (7) ในบทที่ 2 ที่เขียนให้สั้นลง เหตุผลคือ F จาก FS Encoder เก็บรายละเอียดของผมไว้แน่นจนเปลี่ยนสีผมได้ยาก ส่วน F จาก E4E หยาบกว่าแต่แก้ไขง่าย งานวิจัยนี้ใช้ค่าผสม 0.95 เท่ากับงานต้นฉบับ คือบริเวณผมใช้ F จาก E4E ร้อยละ 95 และจาก FS Encoder ร้อยละ 5 ส่วนใบหน้าและพื้นหลังใช้ FS Encoder ทั้งหมด

$$(F_{FS}, S) = E_{FS}(I), \qquad F_{hair} = 0.05 \cdot F_{FS} + 0.95 \cdot F_{E4E} \tag{41}$$

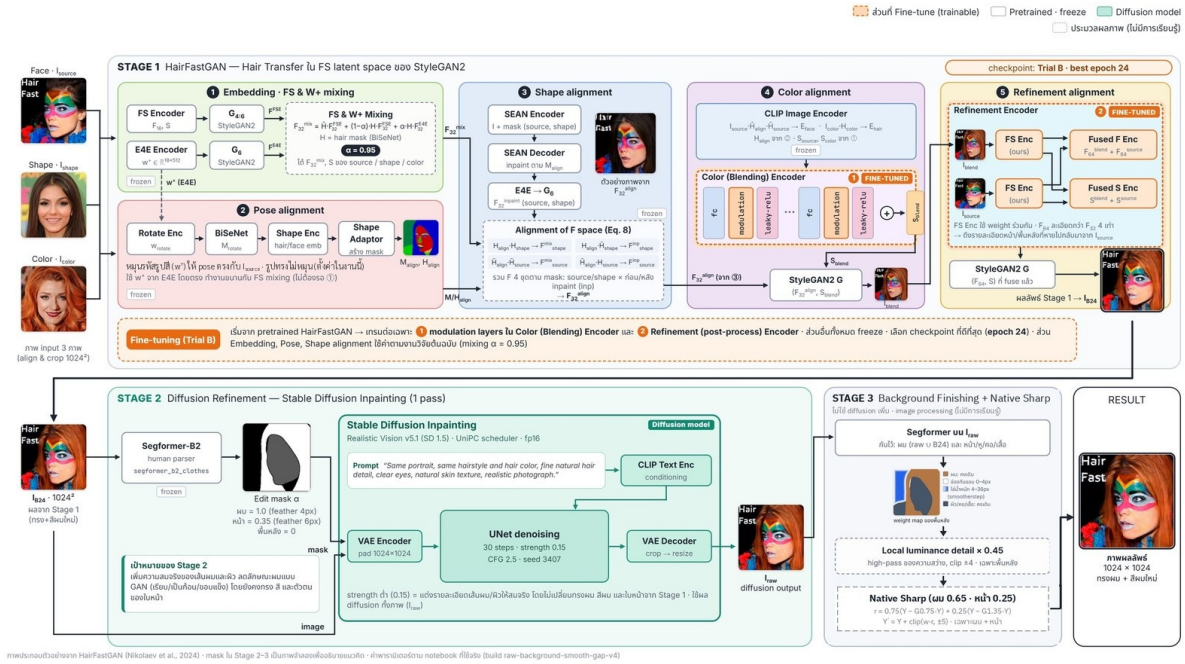
โดยที่

E_{FS} = ตัวเข้ารหัส FS Encoder

I = ภาพนำเข้า

F_{hair} = แผนที่คุณลักษณะบริเวณผมที่ใช้ต่อ

F_{FS}, F_{E4E} = แผนที่คุณลักษณะที่ได้จาก FS Encoder และจากการวาดรหัส W^+ ของ E4E ถึงชั้น 32×32



ภาพที่ 18 ขั้นตอนการทำงานของ HairFastGAN (ปรับจูน) + Stable Diffusion แสดงโมดูลที่ล็อกไว้ โมดูลที่ปรับจูน และขั้นขัดเกลาที่เพิ่มเข้ามา

หมายเหตุ: HFG = HairFastGAN, E4E = Encoder for Editing, SEAN = Semantic Region-Adaptive Normalization, CLIP = Contrastive Language-Image Pre-training, BiSeNet = Bilateral Segmentation Network, SegFormer = Segmentation Transformer

โมดูลที่สอง Pose ใช้ Rotate Encoder หมุนรหัสของภาพอ้างอิงให้หันตามใบหน้า โดยแก้เฉพาะ 6 เวกเตอร์แรกของ W^+ ซึ่งควบคุมท่าทาง แล้ววาดภาพที่หมุนแล้วส่งให้ BiSeNet หาหน้ากากผมที่หันถูกทาง ตามสมการที่ (42) งานต้นฉบับหมุนทั้งภาพทรงผมและภาพสีผม แต่ในงานวิจัยนี้ผู้วิจัยปิดการหมุนของภาพทรงผม และเปิดไว้เฉพาะภาพสีผม เพื่อหาหน้ากากผมของภาพสีผมสำหรับใช้ในโมดูล Color เหตุผลคือภาพในชุดข้อมูลเป็นภาพหน้าตรงที่จัดตำแหน่งแล้ว จึงใช้หน้ากากของภาพทรงผมได้โดยตรง และไม่เสี่ยงให้ทรงผมเพี้ยนจากการหมุน การตั้งค่านี้ใช้เหมือนกันทั้งตอนฝึก ตอนทดสอบ และบนเว็บ

$$w_{rotate} = \mathrm{RotateEnc}\left(w_{face}, w_{color}\right), \qquad M_{rotate} = \mathrm{BiSeNet}\left(G(w_{rotate})\right) \tag{42}$$

โดยที่

w_{face}, w_{color} = รหัส W^+ จาก E4E ของภาพใบหน้าและภาพสีผม

w_{rotate} = รหัสของภาพสีผมที่หมุนให้หันตามใบหน้าแล้ว

G = ตัวสร้างภาพ StyleGAN2

M_{rotate} = หน้ากากของภาพสีผมที่หมุนแล้ว

โมดูลที่สาม Shape ทำนายว่าทรงผมนี้เมื่ออยู่บนศีรษะของคนในภาพใบหน้าจะมีรูปร่าง

แบบใด ได้เป็นหน้ากาก M_{target} (ซึ่งคือ M_{align} ในสมการที่ (4)) แล้วประกอบ F ให้ผมไปอยู่ตามทรงนั้น โดยใช้ SEAN (Semantic Region-Adaptive Normalization) เติมส่วนที่ขาดหาย ตามสมการที่ (43) ซึ่งเป็นสมการที่ (8) ที่เขียนแบบย่อ ผู้วิจัยใช้ M_{target} นี้เป็นทรงเป้าหมายในการคำนวณค่าสูญเสียด้านทรงและค่า IoU (Intersection over Union) ของทั้งสองโมเดล เพื่อให้ทั้งคู่ถูกวัดกับเป้าหมายเดียวกัน

$$M_{target} = \text{Shape}\left(M_{face}, M_{shape}\right), \qquad F_{align} = \text{SEAN}\left(F_{face}, M_{target}\right) \tag{43}$$

โดยที่

M_{face} = แผนที่ส่วนภาพของภาพใบหน้า
M_{shape} = แผนที่ส่วนภาพของภาพทรงผม (ไม่หมุน)
M_{target} = หน้ากากทรงผมเป้าหมายบนใบหน้านี้
F_{face} = แผนที่คุณลักษณะของภาพใบหน้า
F_{align} = แผนที่คุณลักษณะที่มีทรงผมใหม่

โมดูลที่สี่ Color เป็นโมดูลแรกที่ผู้วิจัยปรับจูน และเป็นต้นเหตุของสีผมที่เป็นปื้น CLIP อ่านสีผมจากภาพสีผมออกมาเป็นเวกเตอร์ แล้ว Blending Encoder ใช้เวกเตอร์นี้คำนวณค่าสเกลและค่าเลื่อน ไปปรับ S ทีละชั้น ได้ภาพกลาง I_{pre} ซึ่งผมเป็นสีใหม่แล้ว ตามสมการที่ (44) ผู้วิจัยปรับเฉพาะชั้นปรับค่า (Modulation) ของ Blending Encoder ซึ่งเป็นจุดที่แปลงเวกเตอร์สีเป็นการเปลี่ยนแปลงของภาพ

$$S_{blend} = \text{Blend}\left(S_{face}, S_{color}, e_{hair}, e_{face}\right), \qquad I_{pre} = G\left(F_{align}, S_{blend}\right) \tag{44}$$

โดยที่

S_{face}, S_{color} = รหัสสไตล์ของภาพใบหน้าและภาพสีผม
e_{hair}, e_{face} = เวกเตอร์จาก CLIP ของบริเวณผมในภาพสีผมและบริเวณใบหน้า
S_{blend} = รหัสสไตล์ใหม่
I_{pre} = ภาพกลางที่ได้สีผมใหม่แต่ยังไม่ผ่าน Refinement

โมดูลที่ห้า Refinement เป็นโมดูลที่สองที่ปรับจูน และเป็นต้นเหตุของใบหน้าที่ซีด ภาพ I_{pre} ผ่านการเข้ารหัสที่ขนาด 32×32 มาแล้ว รายละเอียดของผิว ตา และฉากหลังจึงหายไปบางส่วน โมดูลนี้ (ในโค้ดชื่อ PostProcess) ใช้ FS Encoder ตัวใหญ่แปลงทั้ง I_{pre} และภาพใบหน้าเดิม เป็นคุณลักษณะขนาด 64×64 ซึ่งละเอียดกว่า แล้วใช้ตัวผสม Fused F/S รวมกัน ก่อนให้ StyleGAN2 วาดภาพ เพื่อดึงผิว ตา และฉากหลังจากภาพจริงกลับมา โดยยังคงผมใหม่ไว้ ตาม

สมการที่ (45) ผู้วิจัยปรับจูนทั้งโมดูล

$$I_{final} = \mathrm{Post}\left(I_{pre}, I_{face}\right) \tag{45}$$

โดยที่

I_{final} = ภาพผลลัพธ์สุดท้ายของ HairFastGAN

Post = โมดูล PostProcess (FS Encoder ตัวใหญ่ ตัวผสม Fused F/S และ StyleGAN2 ที่ล็อกไว้) ตามสมการที่ (11)

I_{face} = ภาพใบหน้าต้นฉบับ

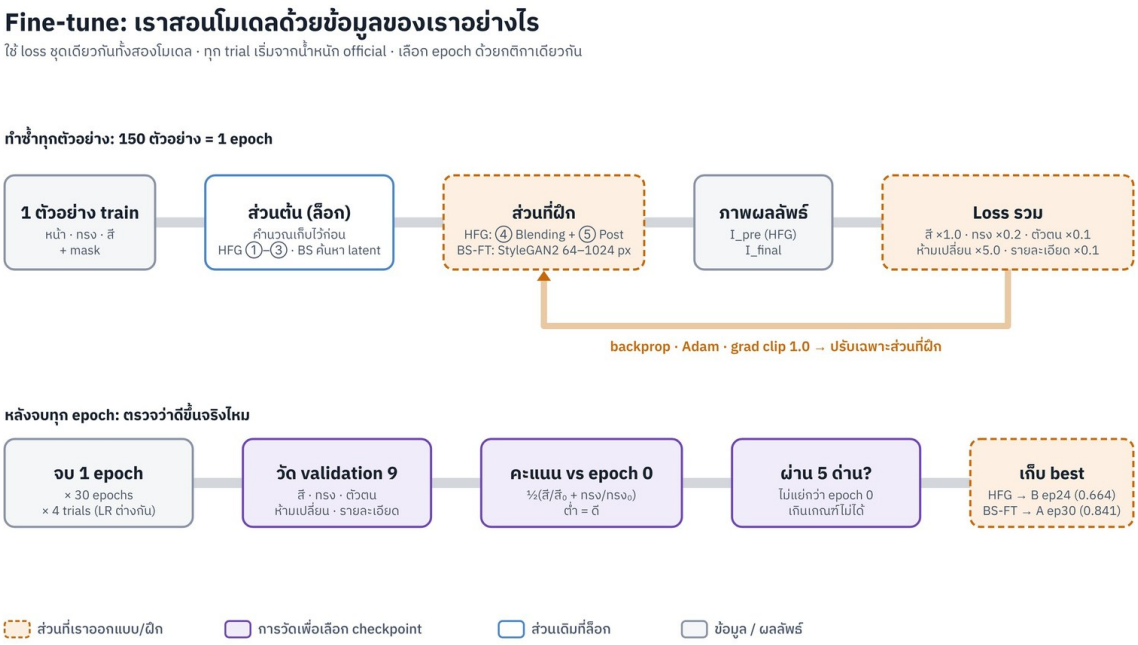
เหตุผลที่ปรับเพียงสองโมดูลนี้ คือปัญหาที่เห็นจากโมเดลตั้งต้นอยู่ที่สีและใบหน้า ไม่ได้อยู่ที่ทรง อีกเหตุผลหนึ่งคือข้อมูล 150 ชุดน้อยเกินกว่าจะฝึกทั้งระบบ ถ้าปลดล็อกทุกโมดูล โมเดลมีแนวโน้มจะจำชุดฝึกได้แต่ลืมสิ่งที่เคยเรียนจากข้อมูลจำนวนมากของผู้พัฒนา ผลของสามโมดูลแรกที่ล็อกไว้จึงคำนวณเพียงครั้งเดียวแล้วเก็บไว้ใช้ตลอดการฝึก ซึ่งช่วยให้ฝึกได้เร็วขึ้นมาก ภาพที่ 19 เปรียบเทียบผลของสองโมเดลจากภาพนำเข้าชุดเดียวกัน ซ้ายคือ HairFastGAN และขวาคือ Barbershop ทั้งสองวางทรงและสีได้ใกล้ภาพอ้างอิง แต่ถ้าดูใกล้ ๆ จะเห็นว่าเนื้อผมและสีผิวต่างกัน ซึ่งเป็นสิ่งที่การปรับจูนพยายามแก้



ภาพที่ 19 ตัวอย่างภาพผลลัพธ์จาก HairFastGAN และ Barbershop จากภาพนำเข้าชุดเดียวกัน

3.6 การปรับจูนโมเดล

ทั้ง สอง โมเดล ปรับ จู นภา ย ใต้ เป้า หมาย หลัก ชุด เดียวกัน แต่ ราย ละเอียด ต่าง กัน ตาม โครงสร้างของแต่ละโมเดล และทุก Trial เริ่มจากน้ำหนักทางการชุดเดิม ภาพที่ 20 แบ่งเป็นสองแถว แถวบนคือสิ่งที่เกิดกับข้อมูลหนึ่งตัวอย่าง ข้อมูลผ่านส่วนที่ล็อกไว้ (กรอบน้ำเงิน) แล้วผ่านส่วนที่ฝึก (กรอบส้มเส้นประ) จนได้ภาพผลลัพธ์ จากนั้นคำนวณค่าสูญเสียรวม แล้วลูกศรย้อนกลับแสดงว่าเกรเดียนต์ถูกส่งกลับไปปรับเฉพาะส่วนที่ฝึก ทำแบบนี้จนครบ 150 ตัวอย่าง นับเป็น 1 Epoch แถวล่างคือสิ่งที่ทำหลังจบแต่ละ Epoch คือวัดผลบนชุดตรวจสอบ 9 ชุด คิดคะแนนเทียบกับ Epoch 0 ตรวจว่าผ่านเกณฑ์ทั้ง 5 ด่านหรือไม่ แล้วเก็บ Checkpoint ที่ดีที่สุดไว้



ภาพที่ 20 ขั้นตอนการปรับจูน: วนฝึกทุกตัวอย่างในชุดฝึก และตรวจสอบบนชุดตรวจสอบหลังจบทุก Epoch

หมายเหตุ: HFG = HairFastGAN, BS = Barbershop, BS-FT (Barbershop-FT) = Barbershop ที่ปรับจูนแล้ว (Fine-tuned), B24 = น้ำหนักของ Trial B Epoch 24, ep = Epoch, A30 = น้ำหนักของ Trial A Epoch 30, Adam = Adaptive Moment Estimation

3.6.1 ฟังก์ชันความสูญเสีย

ฟังก์ชันความสูญเสียเป็นส่วนที่ผู้วิจัยใช้เวลาออกแบบมากที่สุด เพราะเป็นสิ่งที่บอกโมเดลว่าภาพที่ดีควรเป็นอย่างไร ถ้าวัดแค่สี โมเดลอาจเปลี่ยนสีผิวหน้าไปด้วย ถ้าวัดแค่ใบหน้า โมเดลอาจไม่เปลี่ยนอะไรเลย ผู้วิจัยจึงแยกสิ่งที่ต้องการออกเป็น 5 ด้าน แล้วรวมกันแบบถ่วงน้ำหนักตามสมการที่ (46) ทุกด้านยิ่งต่ำยิ่งดี และคำนวณบนภาพผลลัพธ์สุดท้าย

$$L = 1.0\,L_{color} + 0.2\,L_{shape} + 0.1\,L_{id} + 5.0\,L_{protect} + 0.1\,L_{detail} \tag{46}$$

โดยที่

L = ค่าสูญเสียรวม

L_{color} = ค่าสูญเสียด้านสีผม (สมการที่ 47)

L_{shape} = ค่าสูญเสียด้านทรงผม (สมการที่ 48)

L_{id} = ค่าสูญเสียด้านเอกลักษณ์ใบหน้า (สมการที่ 49)

$L_{protect}$ = ค่าสูญเสียด้านบริเวณที่ต้องคงเดิม (สมการที่ 50)

L_{detail} = ค่าสูญเสียด้านรายละเอียดเส้นผม (สมการที่ 51)

1.0, 0.2, 0.1, 5.0, 0.1 = น้ำหนักของแต่ละด้าน

ด้านแรกคือสีผม L_{color} ผู้วิจัยแปลงภาพเป็นปริภูมิสี Lab เพราะระยะห่างของค่าในปริภูมินี้ใกล้กับความต่างที่ตาคนเห็น แล้วเลือกเฉพาะพิกเซลผมด้านใน (ตัดขอบผมออก) จากนั้นเทียบค่าเปอร์เซ็นไทล์ที่ 10 ถึง 90 ของผมในภาพผลลัพธ์กับผมในภาพสีผม ตามสมการที่ (47) ที่ไม่ใช้ค่าเฉลี่ยของสี เพราะค่าเฉลี่ยไม่บอกว่าสีไล่เฉดอย่างไร ผมที่เป็นปื้นสีเดียวอาจมีค่าเฉลี่ยเท่ากับผมจริงที่มีทั้งส่วนสว่างและส่วนเงา การเทียบหลายเปอร์เซ็นไทล์จึงบังคับให้การกระจายของสีตรงกันด้วย และการตัดค่าที่ต่ำกว่าเปอร์เซ็นไทล์ที่ 10 และสูงกว่าเปอร์เซ็นไทล์ที่ 90 ออก ช่วยไม่ให้พิกเซลผิดปกติ เช่น แสงสะท้อน มีผลมากเกินไป ข้อดีอีกข้อคือวิธีนี้ไม่ขึ้นกับตำแหน่งของผม จึงใช้ได้แม้ทรงผมของสองภาพจะต่างกัน

$$
\begin{aligned}
E_L &= \underset{p\in[10,90]}{\text{mean}} \left| Q_p(L_{out}) - Q_p(L_{ref}) \right| \\
E_{ab} &= \text{ค่าเดียวกันเฉลี่ยรวมช่อง } a \text{ และ } b, \qquad L_{color} = \frac{E_L + E_{ab}}{100}
\end{aligned}
\tag{47}
$$

โดยที่

E_L = ความคลาดเคลื่อนของความสว่างผม

E_{ab} = ความคลาดเคลื่อนของสีผม (ช่อง a และ b)

$Q_p(\cdot)$ = ค่าเปอร์เซ็นไทล์ที่ p ของพิกเซลผม

L_{out}, L_{ref} = ค่าความสว่างของผมในภาพผลลัพธ์และในภาพสีผม

p = เปอร์เซ็นไทล์ 9 ค่า คือ 10, 20, ..., 90

100 = ตัวหารเพื่อปรับสเกลให้อยู่ในช่วงเดียวกับค่าสูญเสียอื่น

ตัวชี้วัด “สีผิด” ที่รายงานในบทที่ 4 คือค่า $E_L + E_{ab}$ ก่อนหารด้วย 100 ยิ่งต่ำยิ่งแปลว่าสีผมใกล้กับภาพสีผม

ด้านที่สองคือทรงผม L_{shape} ซึ่งดูว่าผมในภาพผลลัพธ์อยู่ตรงกับ M_{target} หรือไม่ ผู้วิจัยใช้ค่าสองส่วนรวมกันตามสมการที่ (48) ส่วนแรกคือครอสเอนโทรปีแบบสองค่า (Binary Cross-Entropy: BCE) แบบถ่วงดุล ซึ่งลงโทษทีละพิกเซล โดยหาค่าเฉลี่ยในบริเวณผมและนอกบริเวณผมแยกกัน แล้วนำมาเฉลี่ยอีกครั้ง เพราะ BCE แบบธรรมดาจะถูกพื้นหลังซึ่งมีจำนวนพิกเซลมากกว่าผมครอบงำ ส่วนที่สองคือค่าสูญเสียไดซ์ (Dice Loss) ซึ่งดูการทับกันของผมทั้งก้อน โดยบวก 1 ทั้งเศษและส่วนเพื่อกันการหารด้วยศูนย์ ส่วน Dice ไม่ขึ้นกับขนาดของผม คนผมสั้นและคนผมยาวจึงถูกวัดอย่างเท่าเทียม

$$
\begin{aligned}
L_{shape} &= \frac{1}{2}\left(\frac{\sum y\, b}{\sum y} + \frac{\sum (1-y)\, b}{\sum (1-y)} \right) + 1 - \frac{2\sum p\, y + 1}{\sum p + \sum y + 1} \\
b &= -\left[y \log p + (1-y) \log(1-p) \right]
\end{aligned}
\tag{48}
$$

โดยที่

p = ความน่าจะเป็นที่พิกเซลเป็นผม ซึ่ง BiSeNet ทำนายจากภาพผลลัพธ์

y = ค่าของหน้ากากทรงเป้าหมาย M_{target} (1 = ควรเป็นผม)

b = ค่า BCE ของแต่ละพิกเซล

$\sum$ = ผลรวมทุกพิกเซลของภาพ

ด้านที่สามคือใบหน้ายังเป็นคนเดิมหรือไม่ L_{id} ใช้ ArcFace แปลงใบหน้าในภาพผลลัพธ์และภาพต้นฉบับเป็นเวกเตอร์ แล้ววัดว่าสองเวกเตอร์ชี้ไปทางเดียวกันเพียงใด ตามสมการที่ (49) ถ้าเป็นคนเดียวกัน ค่าจะใกล้ 0

$$L_{id} = 1 - \cos\left(\mathrm{ArcFace}(I_{out}), \mathrm{ArcFace}(I_{face})\right) \tag{49}$$

โดยที่

$\mathrm{ArcFace}(\cdot)$ = เวกเตอร์ใบหน้า 512 มิติจาก ArcFace

I_{out}, I_{face} = ภาพผลลัพธ์และภาพใบหน้าต้นฉบับ

$\cos$ = ความคล้ายโคไซน์ (1 = เหมือนที่สุด)

ด้านที่สี่คือบริเวณที่ต้องคงเดิม $L_{protect}$ ผู้วิจัยดูทุกพิกเซลที่ไม่ใช่ผมเดิมและไม่ใช่ผมใหม่ แล้วหาค่าเฉลี่ยว่าสี RGB (Red, Green, Blue) ต่างจากภาพต้นฉบับเท่าใด ตามสมการที่ (50) ค่าถูกปรับให้อยู่ในช่วง 0–1 เช่น ค่า 0.04 หมายถึงต่างกันโดยเฉลี่ยประมาณ 10 จาก 255 ระดับ ซึ่งเป็นความต่างที่ตาเริ่มสังเกตเห็น ด้านนี้ตรงกับปัญหาใบหน้าซีดของ HairFastGAN โดยตรง

$$L_{protect} = \frac{1}{|\Omega|} \sum_{(x,y)\in\Omega} \left|I_{out}(x,y) - I_{face}(x,y)\right| \tag{50}$$

$$\Omega = \text{นอก}\left(\text{ผมเดิม} \cup \text{ผมใหม่}\right)$$

โดยที่

Ω = เซตของพิกเซลนอกบริเวณผมเดิมและผมใหม่

$|\Omega|$ = จำนวนพิกเซลในเซต Ω

$I_{out}(x,y), I_{face}(x,y)$ = ค่าสี RGB ของพิกเซล (x,y) ในภาพผลลัพธ์และภาพต้นฉบับ

ด้านที่ห้าคือรายละเอียดของเส้นผม L_{detail} ด้านนี้มีไว้กันทางลัดที่โมเดลอาจเลือก คือเมื่อพยายามลด L_{color} โมเดลอาจทำให้ผมเรียบเป็นปื้น เพราะผมที่เรียบควบคุมสีได้ง่ายกว่าผมที่เห็นเป็นเส้น ซึ่งจะย้อนกลับไปเป็นปัญหาเดิมที่ต้องการแก้ L_{detail} จึงวัดค่า MAE (Mean Absolute Error) ของรายละเอียดบริเวณผมเทียบกับภาพอ้างอิง เพื่อกันไม่ให้เนื้อผมหายไป สำหรับ HairFastGAN ภาพอ้างอิงคือภาพกลาง I_{pre} ซึ่งยังไม่ผ่านโมดูล Refinement และมีรายละเอียดผมต่างจากภาพผลลัพธ์อยู่แล้วตั้งแต่ก่อนฝึก ค่านี้จึงไม่เป็น 0 ตั้งแต่ Epoch 0 (0.5816

ในตารางที่ 10) ส่วน Barbershop-FT ภาพอ้างอิงคือภาพของ Barbershop ก่อนปรับจูน ซึ่งเป็นภาพเดียวกับผลลัพธ์ที่ Epoch 0 ค่านี้จึงเริ่มจาก 0 คำว่า “รายละเอียด” ในที่นี้คือความสว่างที่ลบค่าเฉลี่ยของพิกเซลรอบข้าง แล้วหารด้วยส่วนเบี่ยงเบนมาตรฐานของพิกเซลรอบข้าง จึงเหลือแต่ลายเส้นผมโดยไม่ขึ้นกับว่าผมสีอ่อนหรือเข้ม และคำนวณเฉพาะผมด้านในที่หดขอบเข้ามา 4 พิกเซล ที่ความละเอียด 256 และ 512 พิกเซล แล้วเฉลี่ยสองค่า ตามสมการที่ (51)

$$\mathcal{T}(I) = \frac{Y - \mu_9(Y)}{\sqrt{\sigma_9^2(Y) + 0.001}}, \qquad L_{detail} = \frac{1}{2} \sum_{r \in \{256,512\}} \frac{1}{|\Omega_r|} \sum_{(x,y) \in \Omega_r} \left| \mathcal{T}(I^r_{out}) - \mathcal{T}(I^r_{ref}) \right| \quad (51)$$

โดยที่

$\mathcal{T}(I)$ = รายละเอียดเฉพาะที่ของภาพ I

Y = ความสว่าง คือค่าเฉลี่ยของสามช่องสี RGB

μ_9, σ_9^2 = ค่าเฉลี่ยและความแปรปรวนในหน้าต่าง 9×9 พิกเซลรอบแต่ละจุด

0.001 = ค่าคงที่กันการหารด้วยศูนย์ในบริเวณที่เรียบ

r = ความละเอียดที่ย่อภาพลงไปคำนวณ

I^r_{out}, I^r_{ref} = ภาพผลลัพธ์และภาพอ้างอิงที่ย่อเป็นขนาด $r \times r$

Ω_r = พิกเซลผมด้านในที่ขนาด r (หน้ากากผมที่หดขอบเข้ามา 4 พิกเซล)

น้ำหนักที่คูณแต่ละด้านไม่ได้ตั้งตามความสำคัญ แต่ตั้งเพื่อให้แต่ละด้านมีผลต่อการฝึกใกล้เคียงกัน เพราะค่าดิบของแต่ละด้านมีขนาดต่างกันมาก เช่น $L_{protect}$ มีค่าเพียงประมาณ 0.04 ถ้าคูณ 1 ก็แทบไม่มีผล จึงคูณ 5.0 ให้มีขนาดประมาณ 0.19 ขณะที่ L_{shape} มีค่าประมาณ 0.46 แต่ขยับได้น้อยเพราะส่วนที่ควบคุมทรงถูกล็อกไว้เกือบทั้งหมด จึงคูณเพียง 0.2 สำหรับ HairFastGAN ผู้วิจัยเพิ่มค่าสูญเสียอีกสองส่วน ซึ่งในเล่มนี้เรียกรวมว่าค่าสูญเสียส่วนเพิ่มตามสมการที่ (52) ส่วนแรกคือวัดสีและทรงที่ภาพกลาง I_{pre} ด้วย (Deep Supervision) เพราะถ้าวัดแค่ภาพสุดท้าย สัญญาณที่ส่งกลับไปถึง Blending Encoder ต้องผ่าน Refinement ก่อน ทำให้เรียนรู้ได้ช้า ส่วนที่สองคือค่าสูญเสียยึดรหัส (Latent Anchor) ที่กันไม่ให้รหัสลอยห่างจากค่าเดิมมากเกินไป Barbershop-FT ไม่มีสองส่วนนี้ เพราะไม่มีภาพกลางที่ฝึกได้

$$L_{HFG} = L + 0.5\, L_{color}(I_{pre}) + 0.1\, L_{shape}(I_{pre}) + 0.01\, \mathrm{MSE}(z, z_0) \quad (52)$$

โดยที่

L_{HFG} = ค่าสูญเสียรวมของ HairFastGAN

$L_{color}(I_{pre}), L_{shape}(I_{pre})$ = ค่าสูญเสียด้านสีและทรงที่คำนวณบนภาพกลาง I_{pre}

$\mathrm{MSE}(z, z_0)$ = ค่าความผิดพลาดกำลังสองเฉลี่ยระหว่างรหัสปัจจุบัน z กับรหัสเริ่มต้น z_0

3.6.2 ขั้นตอนการฝึกและการตั้งค่า

การปรับน้ำหนักหนึ่งครั้ง (1 Update) มีลำดับดังนี้ เริ่มจากรันโมเดลไปข้างหน้าจากรหัสที่เก็บไว้จนได้ภาพ คำนวณ L ตามสมการที่ (46) แล้วหาอนุพันธ์ $\partial L/\partial\theta$ ย้อนกลับผ่าน ArcFace, BiSeNet และตัวสร้างภาพมาจนถึง θ (ส่วนที่ล็อกไว้ยังส่งเกรเดียนต์ผ่านได้ เพียงแต่น้ำหนักของส่วนนั้นไม่ถูกปรับ) จากนั้นปรับ θ ด้วย Adam (Adaptive Moment Estimation) ($\beta_1 = 0.9$, $\beta_2 = 0.999$) ตามสมการที่ (31) ก่อนปรับจะย่อขนาดของเกรเดียนต์ไม่ให้เกิน 1.0 (Gradient Clipping) ตามสมการที่ (53) เพราะในข้อมูลมีบางชุดที่ยากมาก เช่น ทรงผมกับใบหน้าต่างกันมาก ชุดแบบนี้ให้เกรเดียนต์ใหญ่ผิดปกติ และอาจผลักโมเดลไปไกลในการปรับครั้งเดียว

$$g \leftarrow g \cdot \min\left(1, \frac{1.0}{\|g\|}\right) \tag{53}$$

โดยที่

g = เวกเตอร์เกรเดียนต์ของพารามิเตอร์ทั้งหมดที่ฝึก

$\|g\|$ = ขนาด (Norm) ของเวกเตอร์เกรเดียนต์

1.0 = ขนาดสูงสุดที่อนุญาต

การฝึกใช้ขนาดชุดย่อย (Batch Size) เท่ากับ 1 เพราะภาพขนาด 1024×1024 ใช้หน่วยความจำมาก รวมเป็น 150 ตัวอย่าง $\times$ 30 Epoch = 4,500 Updates ต่อ Trial ผู้วิจัยไม่ทราบล่วงหน้าว่าอัตราการเรียนรู้เท่าใดเหมาะสม จึงทดลอง 2 ค่าสำหรับพารามิเตอร์แต่ละกลุ่ม รวม $2 \times 2 = 4$ Trial ดังตารางที่ 5 คอลัมน์ “กลุ่มแรก” คือส่วนหลักที่ทำงานเรื่องสี (Barbershop: ชั้นคอนโวลูชัน 64–1024 พิกเซล; HairFastGAN: Blending Encoder) ส่วนคอลัมน์ “กลุ่มหลัง” คือส่วนที่อยู่ใกล้ภาพผลลัพธ์ (Barbershop: ชั้น ToRGB; HairFastGAN: PostProcess) กลุ่มหลังตั้งค่าให้ต่ำกว่า เพราะขยับเพียงเล็กน้อยก็เปลี่ยนภาพทั้งภาพ ตัวเลขในวงเล็บคือค่าเดียวกันที่เขียนเป็นทศนิยม จะเห็นว่าทุกค่าต่ำมาก ซึ่งตั้งใจให้เป็นเช่นนั้น เพราะต้องการ “ขยับ” โมเดลที่ดีอยู่แล้วทีละน้อย ไม่ใช่สอนใหม่ทั้งหมด ทุก Trial ใช้ Seed ข้อมูล ฟังก์ชันความสูญเสีย และจำนวน Update เท่ากัน ผลที่ต่างกันจึงมาจากอัตราการเรียนรู้เพียงอย่างเดียว

3.7 การเลือก Checkpoint

4 Trial $\times$ 30 Epoch $\times$ 2 โมเดล ทำให้มีผลการตรวจสอบราย Epoch รวม 240 จุด แต่จำนวนจุดที่ประเมินไม่เท่ากับจำนวนไฟล์น้ำหนักที่บันทึกไว้ HairFastGAN เลือกน้ำหนักได้จากทุก Epoch ขณะที่ Barbershop-FT มีไฟล์น้ำหนักเฉพาะ Epoch 0 และ 30 จึงเลือกโมเดลหลังปรับ

ตารางที่ 5 อัตราการเรียนรู้ของ 4 Trial

Trial	กลุ่มแรก (BS: Synthesis · HFG: Blending)	กลุ่มหลัง (BS: ToRGB · HFG: PostProcess)
A	1×10^{-5} (0.00001)	1×10^{-6} (0.000001)
B	1×10^{-5} (0.00001)	5×10^{-7} (0.0000005)
C	5×10^{-6} (0.000005)	1×10^{-6} (0.000001)
D	5×10^{-6} (0.000005)	5×10^{-7} (0.0000005)

หมายเหตุ: BS = Barbershop, HFG = HairFastGAN

จูนได้เฉพาะ Epoch 30 ของแต่ละ Trial ขอบเขตการเลือกของสองโมเดลจึงไม่เท่ากัน ถ้าเลือกด้วยการเปิดดูภาพทีละตัว ผลจะขึ้นกับความรู้สึก และถ้าเลือกซ้ำอาจได้คนละตัว ผู้วิจัยจึงกำหนดสูตรคะแนนและเกณฑ์คัดเลือกไว้ โดยมีการแก้ไขเกณฑ์ด้านรายละเอียดผมภายหลัง ตามที่อธิบายไว้ด้านล่าง และใช้เกณฑ์ฉบับแก้ไขกับทั้งสองโมเดล ทุกครั้งที่จบ Epoch จะวัดผลบนชุดตรวจสอบ 9 ชุด และเทียบกับ Epoch 0 ของ Trial เดียวกันเสมอ คะแนนบนชุดทดสอบของ Checkpoint หลังปรับจูนไม่ถูกนำมาใช้จัดอันดับในขั้นนี้ ส่วนการที่เคยดูผลของโมเดลก่อนปรับจูน (Baseline) บนชุดทดสอบและการแก้เกณฑ์ อธิบายไว้ด้านล่าง กติกามี 3 ขั้น ดังนี้

ขั้นที่ 1 คือคิดคะแนน (ยิ่งต่ำยิ่งดี) จากความผิดพลาดของสีและทรง ตามสมการที่ (54) ปัญหาคือสีผิดมีหน่วยเป็นระดับสี Lab (ค่าประมาณ 14) ส่วนทรงผิดเป็นสัดส่วน (ค่าประมาณ 0.1) ถ้าบวกกันตรง ๆ สีจะกลบทรงจนหมด ผู้วิจัยจึงหารแต่ละค่าด้วยค่าที่ Epoch 0 ก่อน ทำให้ทั้งสองค่ากลายเป็น “สัดส่วนเทียบกับตอนเริ่ม” แล้วจึงหาค่าเฉลี่ย Epoch 0 จึงได้คะแนน 1.00 เสมอ และคะแนน 0.66 หมายถึงความผิดพลาดเหลือร้อยละ 66 ของตอนก่อนฝึก

$$\text{score} = \frac{1}{2}\left(\frac{c}{c_0} + \frac{e}{e_0}\right), \qquad e = 1 - \mathrm{IoU} \tag{54}$$

โดยที่

c = สีผิด ($E_L + E_{ab}$) เฉลี่ยบนชุดตรวจสอบ ณ Epoch ที่พิจารณา

e = ทรงผิด เท่ากับ $1 - \mathrm{IoU}$

c_0, e_0 = ค่า c และ e ที่ Epoch 0 ของ Trial เดียวกัน

ขั้นที่ 2 คือตรวจเกณฑ์ขั้นต่ำ 5 ข้อ ซึ่งในเล่มนี้เรียกว่า “ด่าน” ตามตารางที่ 6 คะแนนในขั้นที่ 1 ดูเพียงสีกับทรง โมเดลจึงอาจได้คะแนนดีทั้งที่ใบหน้าหรือพื้นหลังเพี้ยน ด่านมีไว้จับกรณีแบบนี้ แต่ละแถวในตารางคือตัวชี้วัดหนึ่งด้าน และคอลัมน์ “ผ่านเมื่อ” คือขอบเขตที่ยอมรับได้เมื่อเทียบกับ Epoch 0 สองด่านแรก (สีและทรง) ต้องไม่แย่กว่าตอนเริ่มเลย เพราะเป็นเป้าหมายหลักของการปรับจูน ส่วนอีกสามด่านยอมให้แย่ลงได้เล็กน้อยตามขอบที่กำหนด เพราะการแก้สีย่อมกระทบส่วนอื่นบ้าง Checkpoint ที่ไม่ผ่านแม้เพียงด่านเดียวจะไม่ถูกนำมาพิจารณา

ขั้นที่ 3 คือการเลือก สำหรับ HairFastGAN ให้เลือก Epoch ที่ผ่านครบ 5 ด่านและมีคะแนนต่ำสุดในแต่ละ Trial ส่วน Barbershop-FT ตรวจเฉพาะน้ำหนัก Epoch 30 ที่บันทึกไว้ หากไม่ผ่าน

ตารางที่ 6 ด่านที่ Checkpoint ต้องผ่าน (เทียบกับ Epoch 0)

ด่าน	ตัวชี้วัด	ผ่านเมื่อ
1	สีผิด ($E_L + E_{ab}$)	ไม่มากกว่า Epoch 0
2	IoU ทรงผม	ไม่น้อยกว่า Epoch 0
3	เอกลักษณ์ใบหน้า (ArcFace)	ลดลงได้ไม่เกิน 0.02
4	บริเวณที่ต้องคงเดิม (MAE)	เพิ่มขึ้นได้ไม่เกิน 0.01
5	รายละเอียดผม (Detail MAE)	เพิ่มขึ้นได้ไม่เกิน 0.091

หมายเหตุ: E_L, E_{ab} = ความคลาดเคลื่อนของความสว่างและของสีผมในปริภูมิสี Lab, IoU = Intersection over Union (สัดส่วนพื้นที่ผมที่ทับกัน), ArcFace = โมเดลจดจำใบหน้าที่ใช้วัดความเหมือนของใบหน้า, MAE = Mean Absolute Error (ค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย)

ให้ใช้โมเดลก่อนปรับจูนต่อไป ถ้าไม่มี Epoch ใดผ่านเลยให้ถือว่า Epoch 0 ชนะ จากนั้นเทียบ Trial A–D แล้วเลือกตัวที่คะแนนต่ำสุด

ด่านที่ 5 มีเรื่องที่ผู้วิจัยต้องบันทึกไว้อย่างตรงไปตรงมา ขอบของด่านนี้คือ $0.091 \approx 0.15 \times 0.6086$ หรือร้อยละ 15 ของค่ารายละเอียดผมของ HairFastGAN ที่ Epoch 0 และใช้กับทั้งสองโมเดล แต่ในตอนแรก Barbershop-FT ใช้ขอบ 0.02 ซึ่งผู้วิจัยพบภายหลังว่าไม่เป็นธรรม เพราะ Barbershop-FT เทียบรายละเอียดกับตัวเองก่อนปรับจูน ค่าเริ่มต้นจึงเป็น 0 และขยับเพียงเล็กน้อยก็ตกด่าน ขณะที่ HairFastGAN มีช่องให้ขยับมากกว่า ผู้วิจัยจึงบันทึกการแก้ไขกติกา (Protocol Amendment) และใช้ขอบ 0.091 กับทั้งสองโมเดล โดยแก้ก่อนประเมิน Checkpoint ใด ๆ บนชุดทดสอบ และไม่เปลี่ยนสูตรคะแนนหรือด่านอื่น อย่างไรก็ตาม ผู้วิจัยขอเปิดเผยว่าก่อนแก้ไข เคยดูผลทดสอบของโมเดลก่อนปรับจูนมาแล้ว แต่ Checkpoint ที่ถูกเลือกยังไม่เคยถูกวัดบนชุดทดสอบเลย

3.8 การทดสอบและตัวชี้วัด

เมื่อเลือก Checkpoint ได้แล้ว ผู้วิจัยล็อกไว้และวัดผลบนชุดทดสอบ 10 ชุดเพียงครั้งเดียว เทียบกับโมเดลก่อนปรับจูน ด้วยตัวชี้วัดชุดเดียวกับที่ใช้เลือก และจับเวลาต่อภาพบน GPU A100 ตารางที่ 7 สรุปตัวชี้วัดทั้ง 5 ด้าน ซึ่งจับคู่กับ 5 ด้านของฟังก์ชันความสูญเสีย คอลัมน์ “ความหมาย” บอกว่าตัวชี้วัดนั้นตอบคำถามอะไร และคอลัมน์ “ทิศทาง” บอกว่าค่าแบบใดดี เช่น สีผิดและ MAE ยิ่งต่ำยิ่งดี ส่วน IoU, ArcFace และ SSIM (Structural Similarity Index) ยิ่งสูงยิ่งดี ด้านที่ 4 ใช้สองตัวชี้วัด เพราะ MAE บอกว่าสีเพี้ยนไปเท่าใด ส่วน SSIM บอกว่าโครงสร้าง เช่น ขอบและลวดลายยังอยู่ครบหรือไม่

ชุดทดสอบมีเพียง 10 ภาพ ค่าเฉลี่ยจึงแกว่งได้ง่าย ถ้าภาพหนึ่งดีขึ้นมากผิดปกติ ค่าเฉลี่ยก็ดูดีขึ้นทั้งที่ภาพอื่นไม่เปลี่ยน ผู้วิจัยจึงไม่ดูเฉพาะค่าเฉลี่ย แต่คำนวณผลต่างแบบจับคู่ทีละภาพ (ภาพเดียวกัน ค่าหลังปรับจูนลบค่าก่อนปรับจูน) แล้วหาช่วงความเชื่อมั่น 95% ด้วยวิธีบูตสแตรป โดยสุ่มเลือก 10 ภาพแบบใส่คืน 10,000 ครั้ง ตามสมการที่ (55) ถ้าช่วงที่ได้ไม่ครอบคลุมเลข 0 ก็

ตารางที่ 7 ตัวชี้วัด 5 ด้านที่ใช้ทั้งการเลือก Checkpoint และการทดสอบ

ด้าน	ตัวชี้วัด	ความหมาย	ทิศทาง
1	สีผิด $E_L + E_{ab}$	ความต่างสีผมกับผมในภาพสีผม (Lab ช่วงเปอร์เซ็นไทล์ 10–90)	ต่ำ = ดี
2	IoU	พื้นที่ผมที่ทับกับทรงเป้าหมาย หารด้วยพื้นที่รวม	สูง = ดี
3	ArcFace Cosine	ความเหมือนของใบหน้ากับภาพใบหน้านำเข้า	สูง = ดี
4	MAE, SSIM	การเปลี่ยนแปลงของใบหน้า เสื้อผ้า และพื้นหลังนอกบริเวณผม	MAE ต่ำ, SSIM สูง
5	Detail MAE	ความคมของเส้นผมเทียบภาพอ้างอิง (ใช้เป็นด่าน)	ไม่เพิ่มเกินเกณฑ์

หมายเหตุ: E_L, E_{ab} = ความคลาดเคลื่อนของความสว่างและของสีผมในปริภูมิสี Lab, IoU = Intersection over Union (สัดส่วนพื้นที่ผมที่ทับกัน), ArcFace = โมเดลจดจำใบหน้าที่ใช้วัดความเหมือนของใบหน้า, MAE = Mean Absolute Error (ค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย), SSIM = Structural Similarity Index (ดัชนีความคล้ายเชิงโครงสร้าง)

กล่าวได้ว่าการเปลี่ยนแปลงนั้นไม่น่าเกิดจากความบังเอิญ

$$\bar{d} = \frac{1}{10}\sum_{i=1}^{10} d_i, \qquad \mathrm{CI}_{95} = \left[Q_{2.5}(\bar{d}^*),\ Q_{97.5}(\bar{d}^*)\right] \tag{55}$$

โดยที่

d_i = ผลต่างของภาพทดสอบที่ i เท่ากับค่าของโมเดลหลังปรับจูนลบค่าของโมเดลเดียวกันก่อนปรับจูน (เช่น BS-FT ลบ BS)

$\bar{d}$ = ค่าเฉลี่ยผลต่างของ 10 ภาพ

$\bar{d}^*$ = ค่าเฉลี่ยผลต่างที่ได้จากการสุ่มซ้ำแต่ละครั้ง (10,000 ค่า)

$Q_{2.5}, Q_{97.5}$ = เปอร์เซ็นไทล์ที่ 2.5 และ 97.5 ของค่า $\bar{d}^*$

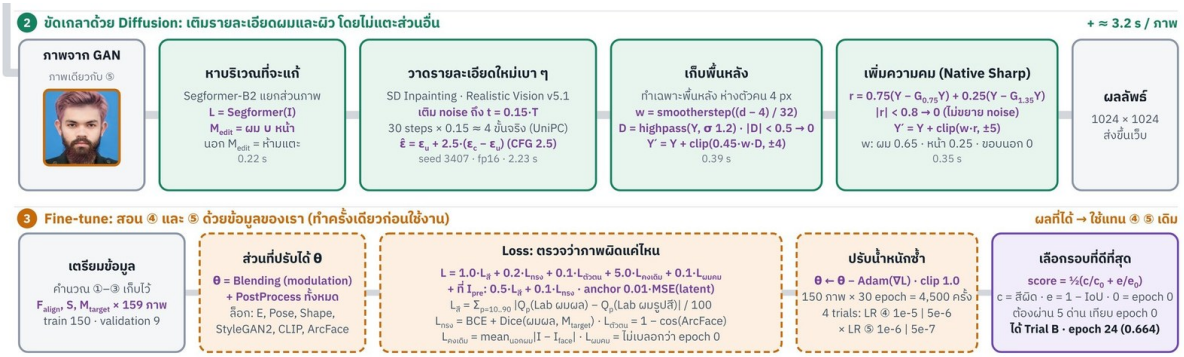
CI_{95} = ช่วงความเชื่อมั่น 95%

ผู้วิจัยไม่ได้ใช้ FID (Fréchet Inception Distance) ซึ่งงานอื่นนิยมใช้ เพราะ FID ต้องใช้ภาพหลายพันภาพจึงจะให้ค่าที่นิ่ง ถ้าคำนวณจาก 10 ภาพ ตัวเลขจะไม่มีความหมาย

3.9 ขั้นขัดเกลาด้วย Diffusion

แม้ปรับจูนแล้ว ผมที่ได้จาก GAN ก็ยังดูนุ่มและเบลอ ไม่เห็นเป็นเส้นเหมือนภาพถ่าย ผู้วิจัยจึงเพิ่มขั้นขัดเกลาด้วย Diffusion โดยตั้งใจให้ทำงาน “เบา” ที่สุดเท่าที่ยังได้ผล GAN ยังเป็นตัวกำหนดทรงและสี ส่วน Diffusion มีหน้าที่เพียงเติมพื้นผิวของเส้นผมและผิวหน้า และถูกจำกัด

ด้วยหน้ากากให้แก้ได้เฉพาะผมกับใบหน้า ขั้นนี้ไม่มีการฝึกเพิ่ม และใช้เวลารวมประมาณ 3.2 วินาทีต่อภาพ ภาพที่ 21 แถวบนแสดงขั้นย่อย 4 ขั้นเรียงจากซ้ายไปขวา พร้อมสูตรและเวลาของแต่ละขั้น ส่วนแถวล่างเป็นสรุปการปรับจูน HairFastGAN ที่อธิบายไปแล้ว ใส่ไว้เพื่อให้เห็นว่าสองส่วนต่อกันอย่างไร เวลาที่เขียนในภาพเป็นของชุดภาพตัวอย่างหนึ่งชุด ส่วนเวลาในย่อหน้าต่อไปเป็นค่าเฉลี่ยของ HairFastGAN จาก 8 ชุดภาพในบทที่ 4



ภาพที่ 21 ขั้นขัดเกลาด้วย Diffusion (แถวบน) และสรุปการปรับจูน HairFastGAN (แถวล่าง)
หมายเหตุ: HFG = HairFastGAN, SegFormer = Segmentation Transformer, UniPC = Unified Predictor-Corrector, CFG = Classifier-Free Guidance

ขั้นย่อยที่ 1 คือกำหนดบริเวณที่จะแก้ไข (0.23 วินาที) SegFormer-B2 แบ่งส่วนของภาพจาก GAN แล้วรวมบริเวณผมกับใบหน้าเป็น M_{edit} ตามสมการที่ (23) เสื้อผ้าและพื้นหลังที่อยู่นอก M_{edit} จะไม่ถูกวาดใหม่ แต่ยังต้องผ่านการบีบอัดและคืนสภาพของ VAE (Variational Autoencoder) จึงอาจเปลี่ยนไปเล็กน้อยมาก ซึ่งเป็นเหตุผลที่บทที่ 4 วัดความต่างนอกหน้ากากด้วย

ขั้นย่อยที่ 2 คือวาดรายละเอียดใหม่แบบเบา (2.15 วินาที) ด้วย Stable Diffusion Inpainting รุ่น Realistic Vision v5.1 ที่ความละเอียด 1024 ค่าที่สำคัญที่สุดคือความแรง (Strength) 0.15 ซึ่งกำหนดว่าจะเติมสัญญาณรบกวนมากเพียงใดและจะลบสัญญาณรบกวนกี่ขั้น เมื่อกำหนด UniPC (Unified Predictor-Corrector) 30 ขั้น `StableDiffusionInpaintPipeline` ของไลบรารี Diffusers จะตัดตารางเวลาให้เหลือ $\lfloor 30 \times 0.15 \rfloor = 4$ ขั้นสุดท้าย จึงลบสัญญาณรบกวนจริงเพียง 4 ขั้น การตั้งค่านี้มุ่งจำกัดการเปลี่ยนแปลงและรักษาทรงเดิม แต่ไม่รับประกันว่าทรง สี หรือใบหน้าจะคงเดิมทั้งหมด จึงต้องประเมินผลหลังประมวลผลด้วย ยิ่งความแรงสูง Diffusion ยิ่งมีอิสระวาดใหม่ ซึ่งรวมถึงใบหน้าด้วย ผู้วิจัยจึงเลือกค่าต่ำ ค่า CFG (Classifier-Free Guidance) 2.5 ก็ตั้งต่ำด้วยเหตุผลเดียวกัน คือให้ข้อความมีผลเพียงพอชี้ทาง ไม่ใช่บังคับ และใช้ Seed 3407 (สมการที่ (25) และ (30)) ข้อความสั่งงาน (Prompt) เขียนสั้น ๆ เพื่อบอก Diffusion ว่านี่คือคนเดิม ทรงเดิม และสีเดิม แต่ต้องการรายละเอียดเส้นผม ตา และผิวที่เป็นธรรมชาติ ส่วนข้อความเชิงลบ (Negative Prompt) ระบุสิ่งที่ไม่ต้องการ เช่น ทรงหรือสีผมเปลี่ยน ใบหน้าเปลี่ยน ผิวดูเหมือนขี้ผึ้ง ภาพเบลอ และขอบสว่างรอบเส้นผม ข้อความที่ใช้จริงในโค้ดมีดังนี้

Prompt: `Same portrait, same hairstyle and hair color, fine`

`natural hair detail, clear eyes, natural skin texture, realistic photograph.`

Negative Prompt: `changed hairstyle, changed hair color, changed face, waxy skin, blur, halos, noise`

ขั้นย่อยที่ 3 คือเก็บรายละเอียดพื้นหลัง (0.41 วินาที) ฉากหลังที่ผ่าน GAN มักเรียบเกินไปจนดูไม่เหมือนภาพถ่าย ผู้วิจัยจึงดึงรายละเอียดความสว่างแบบความถี่สูง (High-pass คือภาพเดิมลบด้วยภาพที่เบลอแล้ว) ออกมา แล้วบวกกลับเข้าไปเฉพาะพื้นหลัง ตามสมการที่ (56) น้ำหนักเป็นศูนย์ตรงที่ติดกับตัวคน แล้วค่อย ๆ เพิ่มจนเต็มที่ที่ระยะ 36 พิกเซล เพื่อไม่ให้เกิดเส้นขอบรอบตัวคน ขั้นนี้เป็นการคำนวณโดยตรง ไม่มีการเรียนรู้

$$w = \mathrm{smootherstep}\left(\frac{d-4}{32}\right), \qquad D = \mathrm{sign}(D_0)\max\left(|D_0| - 0.5,\ 0\right), \quad D_0 = Y - G_{1.2}(Y)$$
$$Y' = Y + \mathrm{clip}\left(0.45\, w\, D, \pm 4\right) \tag{56}$$

โดยที่

Y = ช่องความสว่างของภาพ

d = ระยะห่าง (พิกเซล) จากขอบตัวคน

w = น้ำหนักการเติมรายละเอียด มีค่า 0 ที่ $d \le 4$ และ 1 ที่ $d \ge 36$

$\mathrm{smootherstep}(x)$ = ฟังก์ชัน $6x^5 - 15x^4 + 10x^3$ ที่เปลี่ยนค่าอย่างนุ่มนวล (x ถูกจำกัดในช่วง 0–1)

$G_{1.2}$ = ตัวกรองเกาส์เซียน (Gaussian Blur) ที่ส่วนเบี่ยงเบนมาตรฐาน 1.2

D_0, D = รายละเอียดความถี่สูงก่อนและหลังหักออก 0.5 ระดับ (ค่าที่เล็กกว่า 0.5 กลายเป็น 0) เพื่อไม่ขยายสัญญาณรบกวน

$\mathrm{clip}(\cdot, \pm 4)$ = การจำกัดค่าไม่ให้เกิน ± 4 ระดับ

Y' = ความสว่างหลังเก็บพื้นหลัง

ขั้นย่อยที่ 4 คือเพิ่มความคม (Native Sharp, 0.36 วินาที) ใช้การเพิ่มความคมแบบอันชาร์ปมาสก์ (Unsharp Mask) สองระดับ คือระดับละเอียดสำหรับเส้นผม และระดับหยาบสำหรับเงา ตัดค่าที่เล็กมากทิ้งเพื่อไม่ให้สัญญาณรบกวนถูกขยายตามไปด้วย แล้วบวกกลับโดยให้น้ำหนักบริเวณผม 0.65 ใบหน้า 0.25 และส่วนอื่น 0 ใบหน้าได้น้ำหนักน้อยกว่า เพราะผิวที่คมเกินไปจะดูแข็งและเห็นรูขุมขนอย่างไม่เป็นธรรมชาติ สุดท้ายจำกัดไม่ให้แต่ละพิกเซลเปลี่ยนเกิน ± 5 ระดับ ได้ภาพขนาด 1024×1024 ตามสมการที่ (57)

$$r_0 = 0.75\left(Y - G_{0.75}Y\right) + 0.25\left(Y - G_{1.35}Y\right), \quad r = \mathrm{sign}(r_0)\max\left(|r_0| - 0.8,\ 0\right)$$
$$Y' = Y + \mathrm{clip}\left(w \cdot r, \pm 5\right) \tag{57}$$

โดยที่

r_0, r = รายละเอียดที่จะเพิ่ม รวมจากระดับละเอียด (น้ำหนัก 0.75) และระดับหยาบ (น้ำหนัก 0.25) ก่อนและหลังหักค่าเล็กออก

$G_{0.75}, G_{1.35}$ = ตัวกรองเกาส์เซียนที่ส่วนเบี่ยงเบนมาตรฐาน 0.75 และ 1.35

w = น้ำหนักตามบริเวณ (ผม 0.65 ใบหน้า 0.25 นอกนั้น 0)

0.8 = ขนาดที่หักออก รายละเอียดที่เล็กกว่านี้จึงไม่ถูกเพิ่ม

Y, Y' = ความสว่างก่อนและหลังเพิ่มความคม (เพิ่มเท่ากันทั้งสามช่องสี)

คำถามต่อมาคือจะรู้ได้อย่างไรว่า Diffusion ช่วยได้จริง ผู้วิจัยเทียบภาพเดียวกันก่อนและหลังทีละขั้นย่อย เพื่อดูว่าการเปลี่ยนแปลงมาจากขั้นใด และตั้งเกณฑ์ไว้ล่วงหน้าตามตารางที่ 8 เกณฑ์แบ่งเป็น 3 กลุ่ม กลุ่มแรกคือสิ่งที่ควรดีขึ้น ได้แก่ คุณภาพภาพที่วัดด้วย MUSIQ (Multi-scale Image Quality Transformer) กลุ่มที่สองคือสิ่งที่ต้องไม่แย่ลง ได้แก่ ใบหน้า ทรงผม และพื้นที่นอกหน้ากาก และกลุ่มที่สามคือสิ่งที่ให้ผู้ใช้ตัดสิน คอลัมน์ “เกณฑ์” คือค่าที่ถือว่าผ่าน ผู้วิจัยตั้งใจให้ตัวเลขทำหน้าที่จับสิ่งที่ “เสีย” และให้คนเป็นผู้ตัดสินว่าภาพ “ดีขึ้น” หรือไม่

ตารางที่ 8 เกณฑ์ประเมินขั้น Diffusion

กลุ่ม	**วัดอะไร**	**เกณฑ์**
ควรดีขึ้น	คุณภาพภาพ (MUSIQ)	เพิ่มขึ้นอย่างน้อย +1
ต้องไม่แย่ลง	เอกลักษณ์ใบหน้า (ArcFace)	ลดลงไม่เกิน 0.02
	ทรงผม (IoU เทียบภาพก่อน Diffusion)	ไม่น้อยกว่า 0.97
	นอกหน้ากาก (MAE, SSIM)	MAE ไม่เกิน 0.005 และ SSIM ไม่น้อยกว่า 0.98
ให้ผู้ใช้ตัดสิน	คะแนน 1–5 แบบปกปิดชื่อโมเดล	คะแนนของภาพที่ผ่าน Diffusion สูงกว่า

หมายเหตุ: MUSIQ = Multi-scale Image Quality Transformer (คะแนนคุณภาพภาพ), ArcFace = โมเดลจดจำใบหน้าที่ใช้วัดความเหมือนของใบหน้า, IoU = Intersection over Union (สัดส่วนพื้นที่ผมที่ทับกัน), MAE = Mean Absolute Error (ค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย), SSIM = Structural Similarity Index (ดัชนีความคล้ายเชิงโครงสร้าง)

3.10 การประเมินโดยผู้ใช้

ต้องมีการประเมินโดยผู้ใช้ร่วมด้วย เพราะ ArcFace วัดความคล้ายของใบหน้า ส่วน MUSIQ วัดคุณภาพภาพโดยรวม ทั้งสองตัวไม่ได้วัดความตรงของทรงและสีผม หรือความพึงพอใจของผู้ใช้ ความคล้ายของใบหน้า คุณภาพภาพโดยรวม และความพึงพอใจเป็นคนละเรื่องกัน การประเมินโดยผู้ใช้จึงช่วยเติมข้อมูลด้านการรับรู้ที่ตัวชี้วัดแต่ละตัวไม่ได้ครอบคลุม ผู้วิจัยเชิญผู้ใช้ 41 คนส่งภาพใบหน้าของตัวเอง และเลือกภาพทรงผมกับภาพสีผมที่อยากลอง ระบบสร้างภาพให้คนละ 4 ภาพ คือ HFG B24, HFG B24 + Diffusion, BS-FT A30 และ BS-FT A30 + Diffusion

(HFG B24 คือ HairFastGAN Trial B Epoch 24 และ BS-FT A30 คือ Barbershop ที่ปรับจูนแล้ว Trial A Epoch 30) ผู้ใช้ไม่รู้ว่าภาพใดมาจากระบบใด และลำดับของภาพถูกสุ่มใหม่สำหรับทุกคน (Blind and Randomized Evaluation) เพื่อไม่ให้ชื่อโมเดลหรือตำแหน่งของภาพมีผลต่อคะแนนที่ให้ผู้ใช้ใช้ภาพของตัวเอง เพราะคนจะตัดสินได้ดีที่สุดว่า “หน้ายังเป็นเราไหม” ก็ต่อเมื่อเป็นหน้าของตัวเอง แต่ละภาพมีคำถาม 6 ข้อ รวม 41 คน $\times$ 4 ภาพ = 164 คำตอบ

ตารางที่ 9 คือคำถามทั้ง 6 ข้อ ข้อ 1–5 ให้คะแนน 1–5 (1 = น้อยที่สุด 5 = มากที่สุด) ผู้วิจัยออกแบบให้ข้อ 1–4 ตรงกับสิ่งที่ตัวชี้วัดพยายามวัด คือ ทรง สี ความสมจริง และใบหน้า เพื่อเทียบได้ว่าตัวเลขกับความรู้สึกของคนไปในทางเดียวกันหรือไม่ ข้อ 5 ถามความพึงพอใจโดยรวม ส่วนข้อ 6 ถามว่ายอมรอได้นานเท่าใดเพื่อให้ได้ภาพแบบนี้ โดยมีให้เลือก 6 ช่วง ตั้งแต่น้อยกว่า 1 นาที จนถึงมากกว่า 40 นาที ข้อนี้ใส่ไว้เพราะสองโมเดลใช้เวลาต่างกันมาก และผู้วิจัยต้องการรู้ว่าความต่างนี้สำคัญกับผู้ใช้เพียงใด

ตารางที่ 9 คำถามในแบบประเมินของผู้ใช้

ข้อ	คำถาม	คำตอบ
1	ทรงผมใกล้เคียงกับภาพอ้างอิงมากเพียงใด	1–5
2	สีผมตรงกับภาพอ้างอิงมากเพียงใด	1–5
3	ภาพดูสมจริงและเป็นธรรมชาติมากเพียงใด	1–5
4	ใบหน้ายังคงเหมือนตัวคุณมากเพียงใด	1–5
5	คุณพึงพอใจกับภาพนี้สำหรับการใช้งานจริงมากเพียงใด	1–5
6	หากต้องรอให้ระบบสร้างภาพที่มีคุณภาพเหมือนภาพนี้ คุณยินดีรอได้นานที่สุดเท่าใด	6 ช่วงเวลา

แต่ละคนให้คะแนนต่างกัน บางคนให้ 4–5 ทุกภาพ บางคนให้ไม่เกิน 3 ถ้านำคะแนนของทุกคนมาเฉลี่ยรวมแล้วเทียบกัน ความต่างของนิสัยการให้คะแนนจะกลบผลของ Diffusion ผู้วิจัยจึงวิเคราะห์แบบจับคู่รายคน (Paired) คือดูว่าคนเดียวกันให้คะแนนภาพที่ผ่าน Diffusion มากหรือน้อยกว่าภาพก่อนผ่านเท่าใด ตามสมการที่ (58) แล้วหาช่วงความเชื่อมั่น 95% ด้วยบูตสแตรปแบบเดียวกับการทดสอบ ภาพของผู้ใช้ใช้เพื่อการประเมินนี้เท่านั้น และภาพที่ปรากฏในเล่มได้รับอนุญาตจากเจ้าของภาพแล้ว

$$\Delta_j = \text{score}_j(\text{+Diff}) - \text{score}_j(\text{no Diff}), \qquad \bar{\Delta} = \frac{1}{41}\sum_{j=1}^{41}\Delta_j \tag{58}$$

โดยที่

$\text{score}_j(+\text{Diff})$ = คะแนนที่ผู้ใช้คนที่ j ให้ภาพที่ผ่าน Diffusion

$\text{score}_j(\text{no Diff})$ = คะแนนที่ผู้ใช้คนเดียวกันให้ภาพก่อน Diffusion ของโมเดลเดียวกัน

Δ_j = ผลต่างคะแนนของผู้ใช้คนที่ j

$\bar{\Delta}$ = ค่าเฉลี่ยผลต่างของผู้ใช้ 41 คน

3.11 การออกแบบเว็บแอปพลิเคชันต้นแบบ

เป้าหมายสุดท้ายของโครงงานคือให้คนทั่วไปลองทรงผมได้เองโดยไม่ต้องเขียนโปรแกรม ผู้วิจัยจึงนำโมเดลที่ได้รับเลือก (HairFastGAN B24 + Diffusion) ไปพัฒนาเป็นเว็บแอปพลิเคชัน ชื่อ LOOKLAB ซึ่งเปิดใช้งานได้ที่ https://looklab2.vercel.app/ ผ่านเว็บเบราว์เซอร์ โดยไม่ต้องติดตั้งโปรแกรม คู่มือการใช้งานแบบละเอียดพร้อมคิวอาร์โค้ดสำหรับเข้าเว็บอยู่ในภาคผนวก ง

3.11.1 โครงสร้างของระบบ

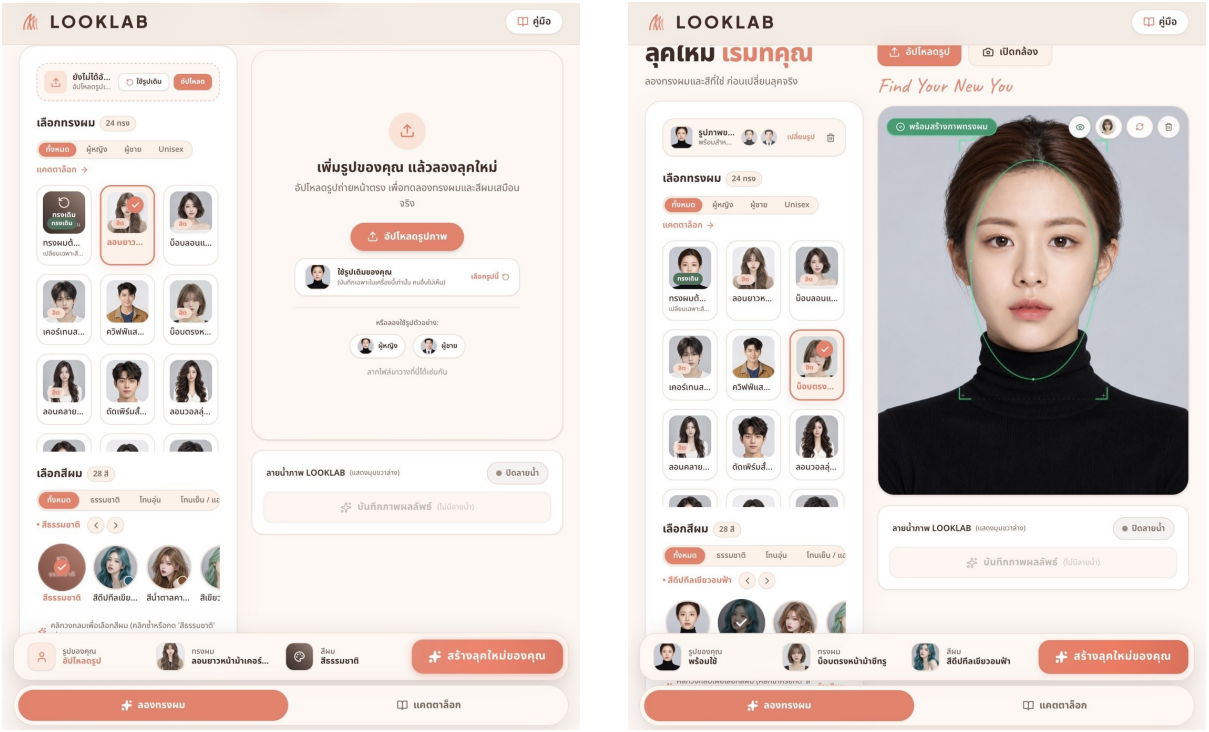
ระบบแบ่งเป็น 3 ส่วน ส่วนแรกคือส่วนหน้า (Frontend) ที่ผู้ใช้เห็น เขียนด้วย React และ TypeScript สร้างด้วย Vite และเผยแพร่บน Vercel ส่วนที่สองคือเซิร์ฟเวอร์ตัวกลางที่เขียนด้วย Express ซึ่งรันเป็นฟังก์ชันบน Vercel ทำหน้าที่ส่งต่อคำขอสร้างภาพและแบบสอบถามไปยังเซิร์ฟเวอร์ประมวลผล ทำให้ส่วนหน้าไม่ต้องรู้ที่อยู่จริงของเซิร์ฟเวอร์ประมวลผล และไม่ต้องเก็บกุญแจสำหรับเรียกใช้บริการ (API Key; API ย่อมาจาก Application Programming Interface) ไว้ฝั่งผู้ใช้ ส่วนที่สามคือเซิร์ฟเวอร์ประมวลผลที่เขียนด้วย FastAPI และรันโมเดลบน GPU ของบริการ RunPod ในช่วงพัฒนา ผู้วิจัยทดสอบเว็บบนเครื่องของตัวเองโดยเชื่อมกับเซิร์ฟเวอร์ประมวลผลผ่านอุโมงค์ ngrok แต่เว็บที่เปิดให้ใช้งานจริง รวมถึงการทดลองใช้งาน 100 ครั้งในบทที่ 4 ใช้เซิร์ฟเวอร์บน RunPod (รายละเอียดการย้ายระบบอยู่ในหัวข้อที่ จ.11) เมื่อผู้ใช้กดสร้างภาพ ส่วนหน้าจะส่งภาพใบหน้า ภาพอ้างอิงทรงผม และภาพอ้างอิงสีผมไปยังเซิร์ฟเวอร์ประมวลผล ซึ่งจัดตำแหน่งใบหน้า สร้างภาพด้วย HairFastGAN B24 ขัดเกลาด้วย Diffusion แล้วส่งภาพกลับมาแสดง ส่วนการตรวจจับใบหน้าในโหมดกล้องทำบนเครื่องของผู้ใช้เอง ด้วย MediaPipe Face Landmarker จึงตอบสนองได้ทันทีโดยไม่ต้องรอเซิร์ฟเวอร์

3.11.2 หน้าหลักและการเตรียมภาพ

ภาพที่ 22 (a) คือหน้าหลักของ LOOKLAB ด้านซ้ายเป็นแผงเลือกทรงผมและสีผม ด้านขวาเป็นพื้นที่แสดงภาพ ผู้ใช้ใส่ภาพใบหน้าได้ 3 วิธี คือ อัปโหลดรูป (หรือลากไฟล์มาวาง) เปิดกล้อง หรือใช้รูปตัวอย่างผู้หญิงและผู้ชายที่ระบบเตรียมไว้ สำหรับคนที่ยังไม่สะดวกใช้รูปของตัวเอง ถ้าเคยใช้รูปมาก่อน ระบบจะเสนอให้ใช้รูปเดิม ซึ่งเก็บไว้ในเครื่องของผู้ใช้เท่านั้น

เมื่ออัปโหลดรูปแล้ว ระบบจะตรวจหาใบหน้าและวาดกรอบวงรีสีเขียวรอบใบหน้า พร้อมป้าย “พร้อมสร้างภาพทรงผม” ดังภาพที่ 22 (b) ถ้าตรวจไม่พบใบหน้าหรือใบหน้าเอียงมาก ระบบจะเตือนก่อน เพื่อไม่ให้ผู้ใช้เสียเวลารอภาพที่ออกมาเพี้ยน แถบสรุปด้านล่างของ

หน้าจอแสดงรูป ทรงผม และสีผมที่เลือกอยู่ พร้อมปุ่ม “สร้างลุคใหม่ของคุณ”



(a) หน้าหลักก่อนใส่รูป **(b)** หลังอัปโหลดรูปและตรวจพบใบหน้า

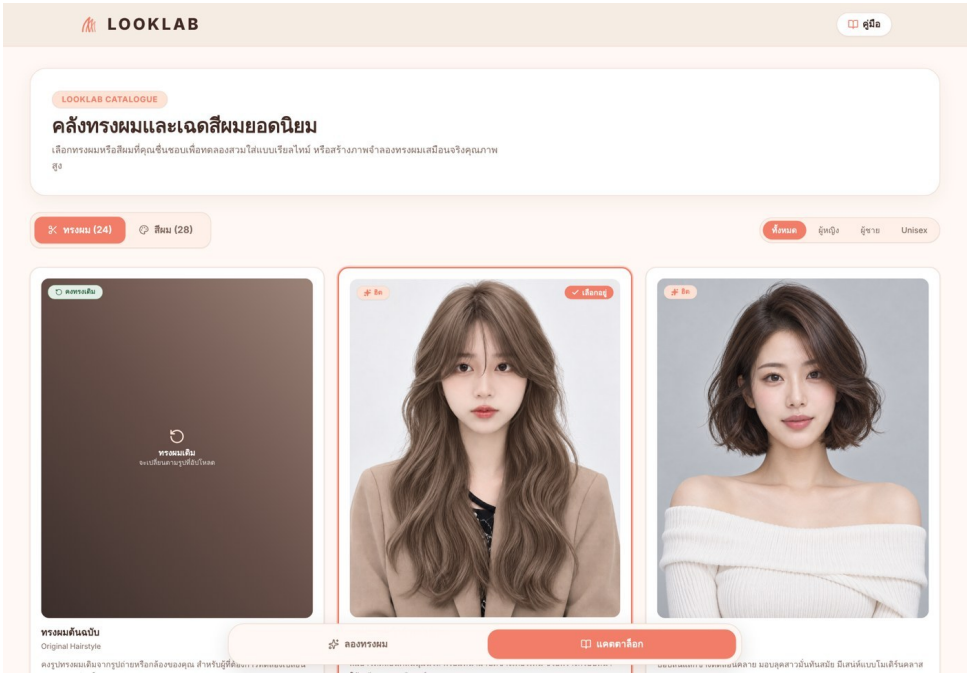
ภาพที่ 22 หน้าหลักของเว็บแอปพลิเคชัน LOOKLAB

3.11.3 ตัวเลือกทรงผมและสีผม

ระบบมีทรงผม 24 แบบ ประกอบด้วยทรงยอดนิยม 23 แบบ เช่น ลอนยาวหน้าม้าเคอร์เทน บ็อบ วูล์ฟคัต ทูบล็อก และควิฟฟ์ และตัวเลือก “ทรงผมต้นฉบับ” สำหรับคนที่อยากเปลี่ยนเฉพาะสี ทรงผมกรองได้ตามกลุ่มผู้หญิง ผู้ชาย และ Unisex ส่วนสีผมมี 28 สี และมีตัวเลือก “สีธรรมชาติ” เพิ่มอีกหนึ่งตัว สำหรับคนที่อยากเปลี่ยนเฉพาะทรง สีผมกรองได้ตามโทน คือ ธรรมชาติ โทนอุ่น โทนเย็นหรือแอช และแฟชั่นหรือพาสเทล แต่ละตัวเลือกคือภาพอ้างอิงหนึ่งภาพที่ถูกส่งเข้าโมเดลจริง ไม่ใช่เพียงชื่อทรงหรือรหัสสี นอกจากนี้ยังมีหน้าแคตตาล็อกที่แสดงทรงผมและสีผมเป็นภาพขนาดใหญ่พร้อมคำอธิบาย ดังภาพที่ 23

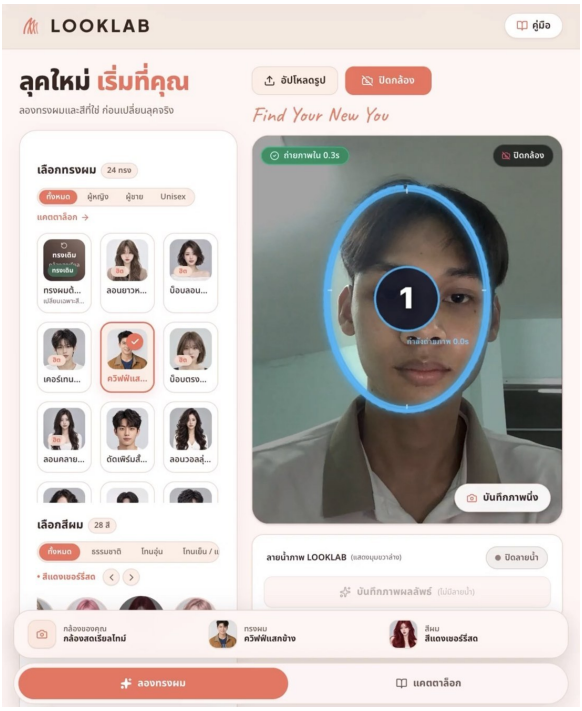
3.11.4 โหมดกล้องสด

โหมดกล้องสดออกแบบมาสำหรับคนที่ไม่มีรูปหน้าตรงพร้อมใช้ เมื่อเปิดกล้อง ระบบจะแสดงวงรีนำทางและบอกผู้ใช้ เช่น “ขยับใบหน้าให้อยู่ตรงกลางกรอบ” เมื่อใบหน้าอยู่ในกรอบ วงรีจะเปลี่ยนเป็นสีฟ้าและนับถอยหลัง 5 วินาทีก่อนถ่ายภาพอัตโนมัติ ดังภาพที่ 24 (a) ภาพที่ถ่ายได้จะถูกส่งไปสร้างทรงผมด้วยโมเดล ซึ่งต้องรอประมาณ 15 วินาที จากนั้นระบบจึงนำผมที่ได้มาซ้อนบนภาพจากกล้อง โดยใช้จุดสังเกตบนใบหน้าจาก MediaPipe ให้ผมขยับตามศีรษะแบบเรียลไทม์ ดังภาพที่ 24 (b) ผู้ใช้กดปุ่ม “บันทึกภาพนิ่ง” เพื่อเก็บภาพในมุมที่ชอบได้ ภาพใน

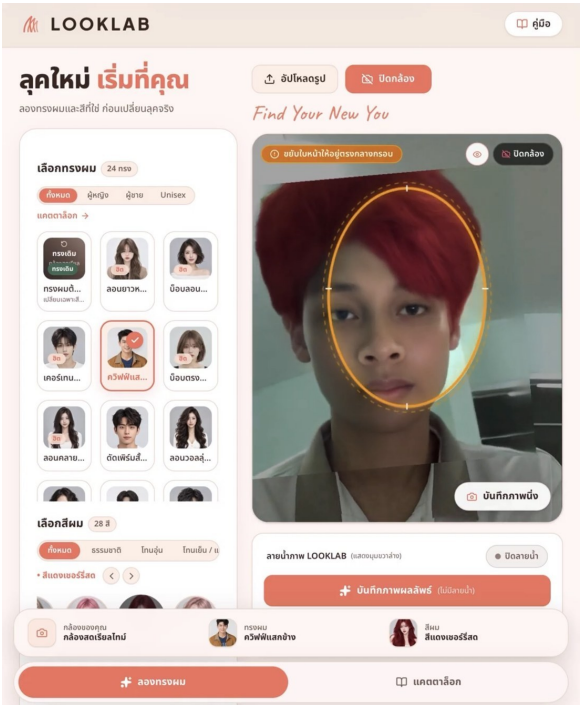


ภาพที่ 23 หน้าแคตตาล็อกทรงผมและสีผมของ LOOKLAB

โหมดนี้เป็นการซ้อนภาพผมที่โมเดลสร้างไว้แล้ว ความละเอียดจึงต่ำกว่าโหมดอัปโหลดรูป ผู้วิจัยจึงแนะนำโหมดอัปโหลดรูปเมื่อต้องการภาพคุณภาพสูงที่สุด



(a) นับถอยหลังก่อนถ่ายภาพ



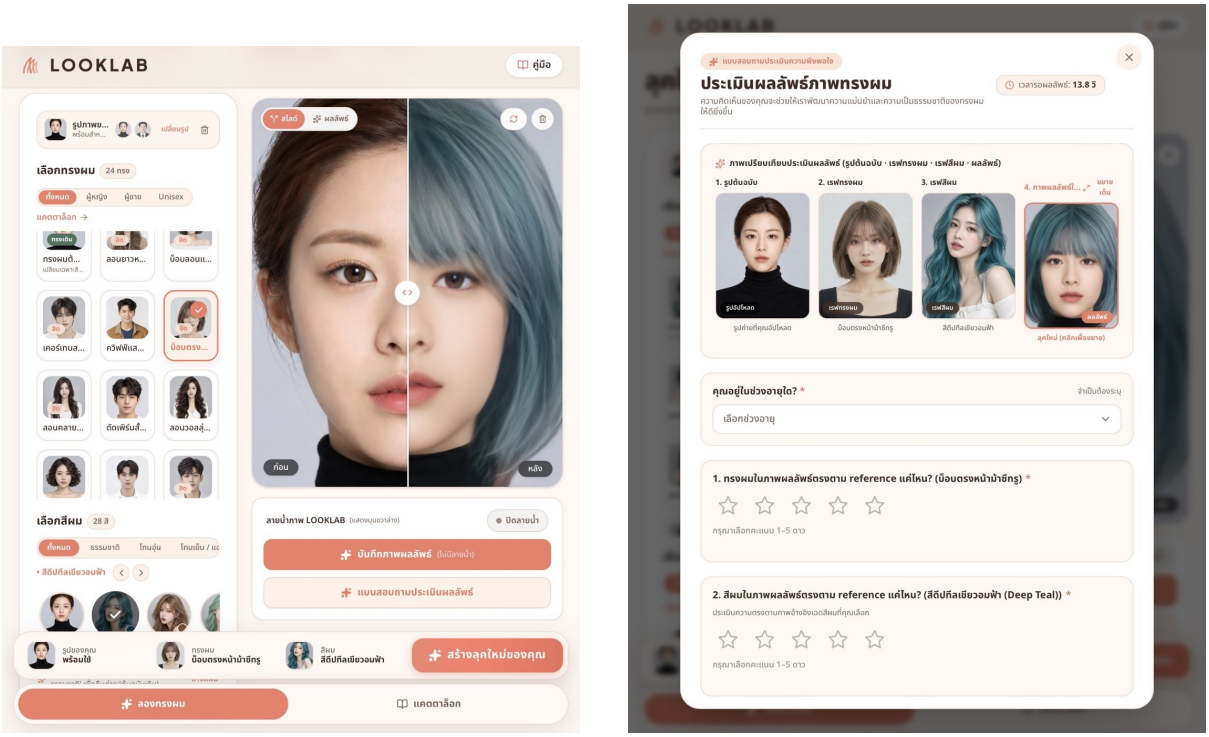
(b) ทรงผมใหม่ขยับตามใบหน้าแบบเรียลไทม์

ภาพที่ 24 โหมดกล้องสดของ LOOKLAB

3.11.5 หน้าผลลัพธ์และแบบสอบถาม

เมื่อสร้างภาพเสร็จ ภาพผลลัพธ์จะแสดงในพื้นที่เดิม พร้อมแถบเลื่อนเปรียบเทียบก่อนและหลัง (Before/After) ดังภาพที่ 25 (a) ผู้ใช้เลื่อนเส้นกลางไปทางซ้ายหรือขวาเพื่อดูความต่าง หรือสลับไปดูภาพผลลัพธ์เต็มภาพ และกดขยายเต็มจอได้ ด้านล่างมีปุ่มบันทึกภาพลงเครื่อง ซึ่งเลือกได้ว่าจะใส่ลายน้ำ LOOKLAB หรือไม่ และมีปุ่มเปิดแบบสอบถามประเมินผลลัพธ์

แบบสอบถามในภาพที่ 25 (b) แสดงภาพ 4 ภาพเรียงกันก่อนเสมอ คือ รูปต้นฉบับ ภาพอ้างอิงทรงผม ภาพอ้างอิงสีผม และภาพผลลัพธ์ เพื่อให้ผู้ใช้ตอบโดยเห็นภาพจริงอยู่ตรงหน้า มุมขวาบนแสดงเวลารอผลลัพธ์จริงที่ระบบจับไว้ จากนั้นผู้ใช้เลือกช่วงอายุ และให้คะแนน 1–5 ดาวใน 6 ข้อ ตามตารางที่ 22 ในภาคผนวก ข ผลการทดลองใช้งาน 100 ครั้งในบทที่ 4 มาจากแบบสอบถามนี้



(a) เปรียบเทียบก่อนและหลัง **(b)** แบบสอบถามประเมินผลลัพธ์

ภาพที่ 25 หน้าผลลัพธ์และแบบสอบถามของ LOOKLAB

3.12 ข้อควรระวังในการตีความและรายละเอียดการคำนวณ

แม้ทั้งสองโมเดลใช้ฟังก์ชันสูญเสียหลักชุดเดียวกัน แต่ค่าสูญเสียไม่ได้เหมือนกันทุกส่วน HairFastGAN มีการวัดที่ภาพกลาง (Deep Supervision) และค่าสูญเสียยึดรหัส (Latent Anchor) เพิ่มเติม และภาพอ้างอิงของ L_{detail} ก็ต่างจาก Barbershop-FT จึงไม่ควรนำขนาดหรืออัตราการลดของค่าสูญเสียรวมมาเปรียบเทียบความสามารถของสองโมเดลโดยตรง แต่ควรเปรียบเทียบจากตัวชี้วัดของผลลัพธ์บนข้อมูลชุดเดียวกัน

รายละเอียดการคำนวณในโค้ดมีดังนี้ ภาพทุกภาพถูกปรับค่าให้อยู่ในช่วง 0–1 ก่อน

คำนวณ E_L และ E_{ab} ใช้เปอร์เซ็นไทล์ 9 ค่า (10, 20, ..., 90) ของพิกเซลผมด้านใน โดย E_{ab} เป็นค่าเฉลี่ยรวมของช่อง a และ b ส่วน $L_{protect}$ เฉลี่ยผลต่างของทั้ง 3 ช่องสี RGB L_{detail} แปลงภาพเป็นความสว่าง แล้วปรับค่าในหน้าต่าง 9×9 พิกเซลให้มีค่าเฉลี่ย 0 และความแปรปรวน 1 จากนั้นหา MAE เทียบกับภาพอ้างอิงเฉพาะพิกเซลผมด้านใน ที่ความละเอียด 256 และ 512 พิกเซล ส่วน L_{shape} ใช้ BCE แบบถ่วงดุลและ Dice ที่บวก 1 ตามสมการที่ (48)

ในการประเมินโดยผู้ใช้ หน่วยของการวิเคราะห์คือบุคคล 41 คน ส่วน 164 รายการคือจำนวนภาพที่บุคคลเหล่านี้ประเมิน (คนละ 4 ภาพ) ไม่ใช่ผู้เข้าร่วม 164 คน การหาช่วงความเชื่อมั่นจึงสุ่มบูตสแตรปในระดับบุคคล และเก็บคะแนนที่จับคู่กันของแต่ละคนไว้ด้วยกัน ส่วนข้อมูลจากเว็บ 100 ครั้งคือจำนวนครั้งที่ใช้งานและตอบแบบประเมิน ซึ่งผู้ใช้หนึ่งคนอาจใช้งานมากกว่าหนึ่งครั้ง

บทที่ 4

ผลการทดลองและอภิปรายผล

บทนี้นำเสนอผลตามลำดับที่ทำจริง เริ่มจากการปรับจูนและการเลือก Checkpoint ตามด้วยผลบนชุดทดสอบ ผลของ Diffusion ความเห็นของผู้ใช้ เหตุผลที่เลือกโมเดลไปใช้บนเว็บ และผลการใช้งานเว็บจริง ท้ายบทเป็นการอภิปรายว่าผลเหล่านี้บอกอะไร เพื่อให้อ่านง่าย บทนี้ใช้ตัวย่อดังนี้ HFG คือ HairFastGAN, BS คือ Barbershop ก่อนปรับจูน, BS-FT หรือ Barbershop-FT คือ Barbershop ที่ปรับจูนแล้ว (Fine-tuned), B24 คือ Trial B Epoch 24, A30 คือ Trial A Epoch 30 และ Diff คือขั้นขัดเกลาด้วย Diffusion

4.1 ผลการปรับจูนและการเลือก Checkpoint

4.1.1 ตัวอย่างการคำนวณค่าสูญเสีย

ก่อนดูผลการเลือก ผู้วิจัยขอแสดงตัวอย่างว่าค่าสูญเสียในบทที่ 3 คำนวณออกมาเป็นตัวเลขอย่างไร ตารางที่ 10 ใช้ HFG Trial B เป็นตัวอย่าง โดยเทียบ Epoch 0 (ก่อนฝึก) กับ Epoch 24 (ตัวที่ถูกเลือก) ทุกค่าเป็นค่าเฉลี่ยบนชุดตรวจสอบ 9 ชุด คอลัมน์ “น้ำหนัก” คือตัวคูณตามสมการที่ (46) และ (52) คอลัมน์ Epoch 0 และ Epoch 24 คือค่าก่อนคูณ และคอลัมน์ “× น้ำหนัก” คือค่าหลังคูณ ซึ่งรวมกันได้ค่าในแถวสุดท้าย (0.6183 และ 0.3957) ตรงกับค่าที่บันทึกไว้ระหว่างการฝึก

ตารางนี้บอกได้มากกว่าตัวเลขรวม ถ้าดูคอลัมน์หลังคูณน้ำหนัก จะเห็นว่าที่ Epoch 0 สองด้านที่มีค่ามากที่สุดคือบริเวณที่ต้องคงเดิม (0.194) และสีผม (0.141) ซึ่งตรงกับปัญหาใบหน้าซีดและสีเป็นปื้นที่เห็นด้วยตา หลังฝึก สองด้านนี้ก็ลดลงมากที่สุด (เหลือ 0.085 และ 0.073) ส่วนทรงผมลดลงเพียงเล็กน้อย ซึ่งเป็นไปตามที่คาด เพราะโมดูลที่ควบคุมทรงถูกล็อกไว้ ค่าสูญเสียยึดรหัส (Anchor) เป็น 0 ที่ Epoch 0 เพราะยังไม่มีอะไรเปลี่ยน และเพิ่มขึ้นเล็กน้อยเมื่อโมเดลเริ่มเปลี่ยน

ลองคำนวณบางส่วนด้วยมือ เช่น L_{color} ที่ Epoch 0 มี $E_L = 8.053$ และ $E_{ab} = 6.071$ จึงได้ $L_{color} = (8.053 + 6.071)/100 = 0.1412$ และ L_{id} มีค่าโคไซน์ของ ArcFace (Additive Angular Margin Loss) เท่ากับ 0.7477 จึงได้ $L_{id} = 1 - 0.7477 = 0.2523$ สำหรับ BS-FT Trial A ซึ่งไม่มีส่วนที่วัดภาพกลาง ค่ารวมที่ Epoch 0 คือ $0.1501 + 0.2 \times 0.4432 + 0.1 \times 0.2554 + 5 \times 0.0373 + 0.1 \times 0 = 0.4508$ และลดลงเหลือ 0.4036 ที่ Epoch 30 ซึ่งลดลงน้อยกว่า HFG มาก สาเหตุจะเห็นชัดในหัวข้อถัดไป

ตารางที่ 10 ค่าสูญเสียแยกแต่ละส่วนของ HFG Trial B (ค่าเฉลี่ยชุดตรวจสอบ)

ส่วนของค่าสูญเสีย	น้ำหนัก	Epoch 0	× น้ำหนัก	Epoch 24	× น้ำหนัก
L_{color}	1.0	0.1412	0.1412	0.0732	0.0732
L_{shape}	0.2	0.4590	0.0918	0.4263	0.0853
L_{id}	0.1	0.2523	0.0252	0.1945	0.0194
$L_{protect}$	5.0	0.0387	0.1936	0.0170	0.0851
L_{detail}	0.1	0.5816	0.0582	0.5009	0.0501
$L_{color}(I_{pre})$	0.5	0.1280	0.0640	0.0778	0.0389
$L_{shape}(I_{pre})$	0.1	0.4428	0.0443	0.4122	0.0412
Anchor	0.01	0.0000	0.0000	0.2556	0.0026
รวม			**0.6183**		**0.3957**

หมายเหตุ: HFG = HairFastGAN

4.1.2 HairFastGAN: เลือก Trial B Epoch 24

ตารางที่ 11 สรุป Checkpoint ที่ดีที่สุดของแต่ละ Trial ของ HFG คอลัมน์ “Epoch ที่ดีที่สุด” คือ Epoch ที่คะแนนต่ำสุดใน Trial นั้น คอลัมน์ “คะแนน” คิดตามสมการที่ (54) และคอลัมน์สุดท้ายคือจำนวน Epoch ที่ผ่านครบ 5 ด่าน สิ่งที่น่าพอใจของ HFG คือทุก Trial ผ่านด่านครบทุก Epoch แปลว่าการปรับจูนไม่ได้ทำให้ด้านอื่นแย่ลงเลย การตัดสินจึงขึ้นกับคะแนนเพียงอย่างเดียว และ Trial B Epoch 24 ได้คะแนนดีที่สุดคือ 0.664 แม้จะต่างจาก Trial A เพียง 0.023 แต่ผู้วิจัยยึดตามกติกาที่ตั้งไว้ ไม่เลือกตามความชอบ คะแนนของ B24 คำนวณได้ดังนี้

$$\text{score} = \frac{1}{2}\left(\frac{7.32}{14.12} + \frac{1-0.924}{1-0.906}\right) = \frac{1}{2}\left(0.518 + 0.810\right) = 0.664 \tag{59}$$

โดยที่

7.32, 14.12 = สีผิดเฉลี่ยที่ Epoch 24 และที่ Epoch 0
0.924, 0.906 = IoU เฉลี่ยที่ Epoch 24 และที่ Epoch 0
0.518, 0.810 = สัดส่วนสีผิดและทรงผิดเทียบกับตอนก่อนฝึก

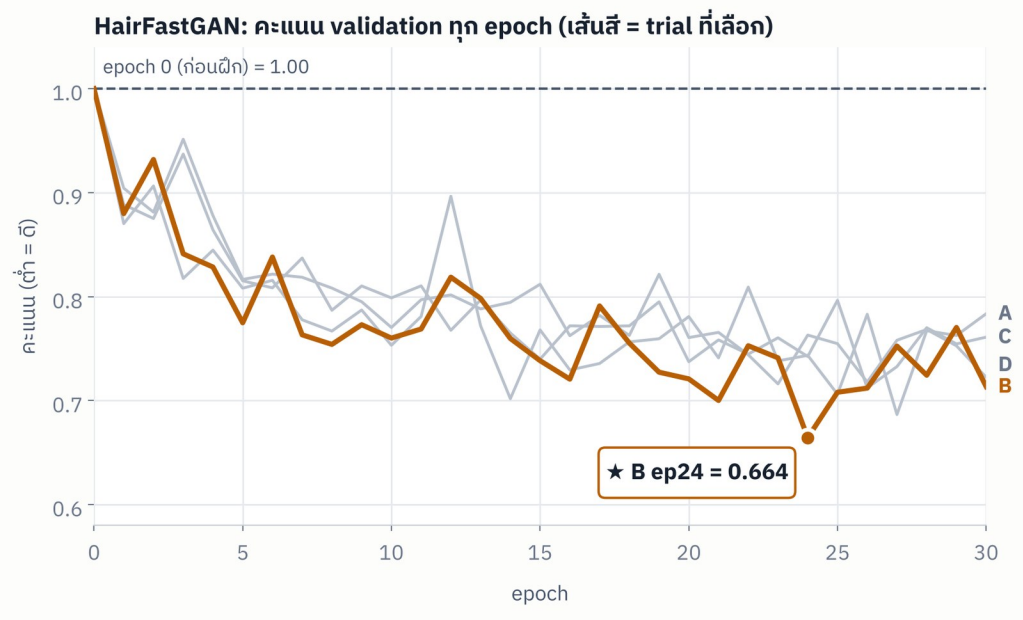
แปลว่าความผิดพลาดของสีและทรงโดยเฉลี่ยเหลือร้อยละ 66.4 ของตอนก่อนฝึก แต่ถ้าแยกดูจะเห็นว่าสีผิดลดลงเกือบครึ่ง (เหลือ 0.518) ขณะที่ทรงผิดลดลงไม่ถึงหนึ่งในห้า (เหลือ 0.810) คะแนนที่ดีขึ้นส่วนใหญ่จึงมาจากเรื่องสี

ภาพที่ 26 แสดงว่าคะแนนเปลี่ยนไปอย่างไรตลอด 30 Epoch แกนนอนคือ Epoch แกนตั้งคือคะแนน (ยิ่งต่ำยิ่งดี) เส้นประด้านบนคือระดับ 1.00 ของ Epoch 0 เส้นสีส้มเข้มคือ Trial B ที่ถูกเลือก เส้นสีเทาคืออีกสาม Trial และจุดที่มีกรอบคือ Epoch 24 สิ่งแรกที่เห็นคือทุก Trial ดีขึ้นเร็วมากในช่วง 5 Epoch แรก หลังจากนั้นคะแนนแกว่งขึ้นลง ส่วนใหญ่อยู่ระหว่าง 0.70–0.82 (ต่ำสุด 0.664 ที่ B24 และมีบางจุดขึ้นไปถึงประมาณ 0.90) ไม่ได้ลดลงเรื่อย ๆ อย่าง

ตารางที่ 11 ผลการเลือก Checkpoint ของ HairFastGAN (ชุดตรวจสอบ 9 ชุด)

Trial	Epoch ที่ดีที่สุด	คะแนน	Epoch ที่ผ่าน 5 ด่าน
A	27	0.687	30/30
B	**24**	**0.664**	30/30
C	26	0.712	30/30
D	23	0.716	30/30

ที่อาจคาดไว้ การแกว่งนี้ส่วนหนึ่งเป็นเพราะชุดตรวจสอบมีเพียง 9 ชุด ภาพเดียวที่ดีขึ้นหรือแย่ลงก็ทำให้ค่าเฉลี่ยกระโดดได้ นี่คือเหตุผลที่ต้องตั้งกติกาไว้ล่วงหน้า ถ้าดูกราฟแล้วเลือกด้วยตา อาจเลือกได้หลายจุดและอธิบายไม่ได้ว่าทำไม



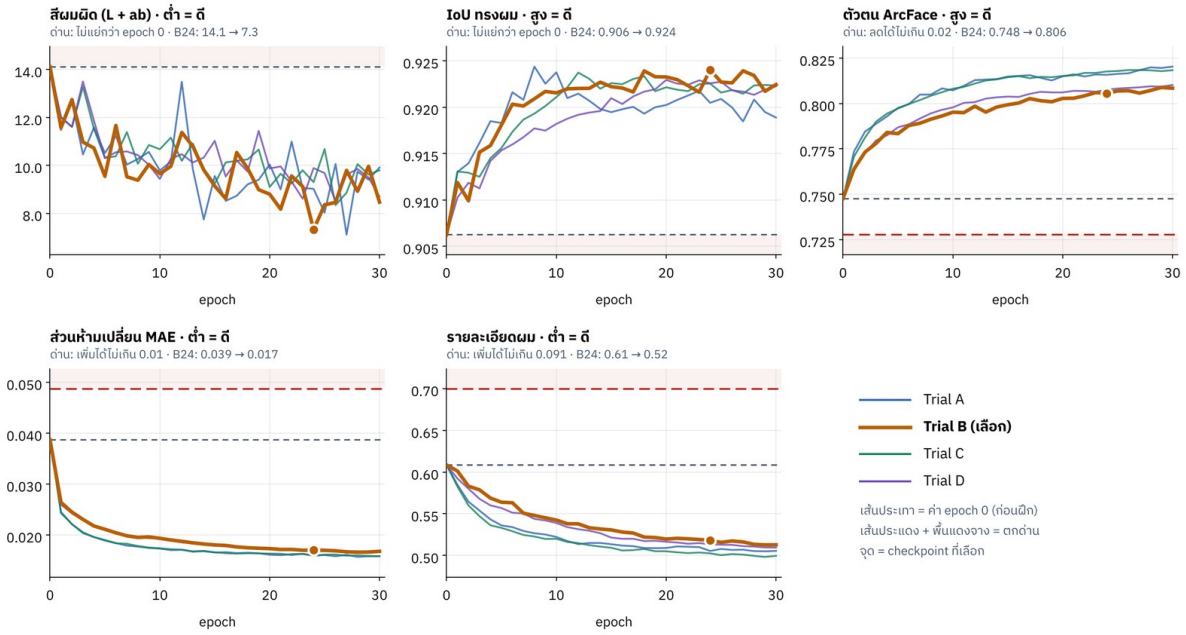
ภาพที่ 26 คะแนนบนชุดตรวจสอบทุก Epoch ของ HairFastGAN (เส้นสีคือ Trial B ที่เลือก)

หมายเหตุ: HFG = HairFastGAN, B24 = น้ำหนักของ Trial B Epoch 24, ep = Epoch

คะแนนดูเพียงสีกับทรง ภาพที่ 27 จึงแยกออกเป็น 5 กราฟเพื่อดูทุกด้านพร้อมกัน แต่ละกราฟมีแกนนอนเป็น Epoch แกนตั้งเป็นค่าของตัวชี้วัด และเส้นสีแต่ละเส้นคือหนึ่ง Trial เส้นประสีเทาคือค่าที่ Epoch 0 ส่วนเส้นประสีแดงกับพื้นสีแดงจางคือเขตที่ไม่ผ่านด่าน จุดคือ Checkpoint ที่เลือก และใต้ชื่อกราฟเขียนเกณฑ์ของด่าน พร้อมค่าก่อนและหลังของ B24 ไว้

ภาพนี้ยืนยันว่า HFG ดีขึ้นทุกด้านพร้อมกัน ไม่ได้แลกด้านหนึ่งกับอีกด้านหนึ่ง ที่ B24 สีผิดลดจาก 14.12 เหลือ 7.32 IoU (Intersection over Union) เพิ่มจาก 0.906 เป็น 0.924 ArcFace เพิ่มจาก 0.748 เป็น 0.806 MAE (Mean Absolute Error) ของบริเวณที่ต้องคงเดิมลดจาก 0.039 เหลือ 0.017 และค่ารายละเอียดผมลดจาก 0.61 เหลือ 0.52 ทุกเส้นอยู่ฝั่งที่ผ่านด่านตลอด (ค่ารายละเอียดผมในกราฟนี้คือค่าที่ระบบบันทึกตอนตรวจด่านที่ 5 ซึ่งบันทึกแยกจากค่า L_{detail} ในตารางที่ 10 ตัวเลขจึงไม่เท่ากันพอดี) ที่น่าสนใจคือ ArcFace และ MAE ดีขึ้นอย่างสม่ำเสมอ เส้น

เรียบและไม่ค่อยแกว่ง ขณะที่เส้นสีผิดแกว่งมากที่สุด แปลว่าโมดูล Refinement เรียนเรื่องใบหน้าได้ง่ายและนิ่ง ส่วนเรื่องสีขึ้นกับภาพแต่ละชุดมากกว่า



ภาพที่ 27 ตัวชี้วัด 5 ด้านบนชุดตรวจสอบทุก Epoch ของ HairFastGAN ทั้ง 4 Trial

หมายเหตุ: IoU = Intersection over Union (สัดส่วนพื้นที่ผมที่ทับกัน), MAE = Mean Absolute Error (ค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย), ArcFace = โมเดลจดจำใบหน้าที่ใช้วัดความเหมือนของใบหน้า, HFG = HairFastGAN

4.1.3 Barbershop-FT: เลือก Trial A Epoch 30

การเลือกของ Barbershop-FT ซับซ้อนกว่า ตารางที่ 12 แสดงผลที่ Epoch 30 ของแต่ละ Trial คอลัมน์ “ผล” บอกว่าผ่านครบ 5 ด่านหรือไม่ผ่านด่านใด และคอลัมน์สุดท้ายคือจำนวน Epoch ที่ผ่านครบ ต่างจาก HFG ตรงที่ BS-FT มีหลาย Epoch ที่ไม่ผ่านด่าน และด่านที่เป็นปัญหาคือด่านทรงผม Trial C และ D มี IoU ต่ำกว่าตอนก่อนฝึกทุก Epoch จึงไม่มีสิทธิ์ถูกเลือกเลย ส่วน Trial A และ B เพิ่งผ่านในช่วงท้ายของการฝึก

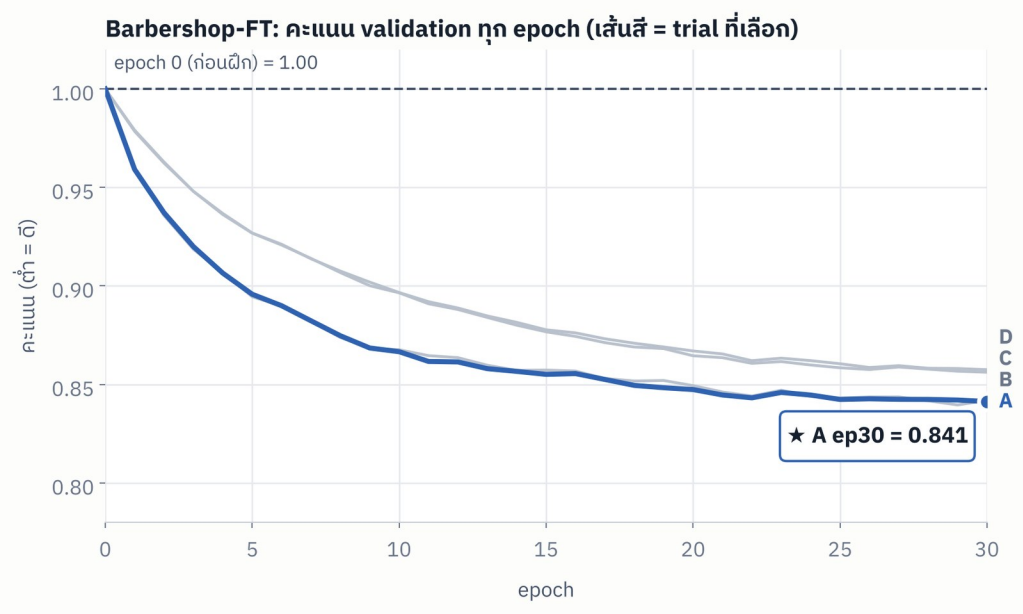
ตรงนี้มีข้อจำกัดที่ผู้วิจัยต้องยอมรับ ระหว่างฝึก BS-FT ระบบวัดผลทุก Epoch ก็จริง แต่บันทึกไฟล์น้ำหนักไว้เพียง Epoch 0 และ 30 ตัวเลือกที่ใช้ได้จริงจึงมีเพียง Epoch 30 ซึ่ง Trial A ได้คะแนนดีที่สุดคือ 0.841 ถ้าบันทึกไว้ครบทุก Epoch ตัวที่ดีที่สุดจะเป็น Trial B Epoch 29 (0.840) แต่ต่างกันเพียง 0.001 และไม่มีไฟล์ให้ใช้ ผู้วิจัยจึงใช้ A30

ภาพที่ 28 อ่านแบบเดียวกับภาพที่ 26 โดยเส้นสีน้ำเงินเข้มคือ Trial A ลักษณะของกราฟต่างจาก HFG อย่างชัดเจน คะแนนลดลงต่อเนื่องและเรียบกว่ามาก เพราะ BS-FT ฝึกบนรหัสชุดเดิมที่เก็บไว้ ข้อมูลที่โมเดลเห็นจึงไม่เปลี่ยน แต่ลดลงได้น้อยกว่า HFG มาก โดยไปหยุดที่ประมาณ 0.84 เทียบกับ 0.66 ของ HFG สาเหตุคือทรงผมของ BS-FT ถูกกำหนดเสร็จตั้งแต่ขั้นจัดรูป ก่อนถึงชั้นที่ปรับจูน ครึ่งหนึ่งของคะแนน (ส่วนทรง) จึงแทบขยับไม่ได้

ตารางที่ 12 ผลการเลือก Checkpoint ของ Barbershop-FT ที่ Epoch 30 (ชุดตรวจสอบ 9 ชุด)

Trial	คะแนน Epoch 30	ผล	Epoch ที่ผ่าน 5 ด่าน
A	**0.841**	ผ่านครบ	13/30
B	0.842	ผ่านครบ	8/30
C	0.856	ตกด่านทรง	0/30
D	0.858	ตกด่านทรง	0/30

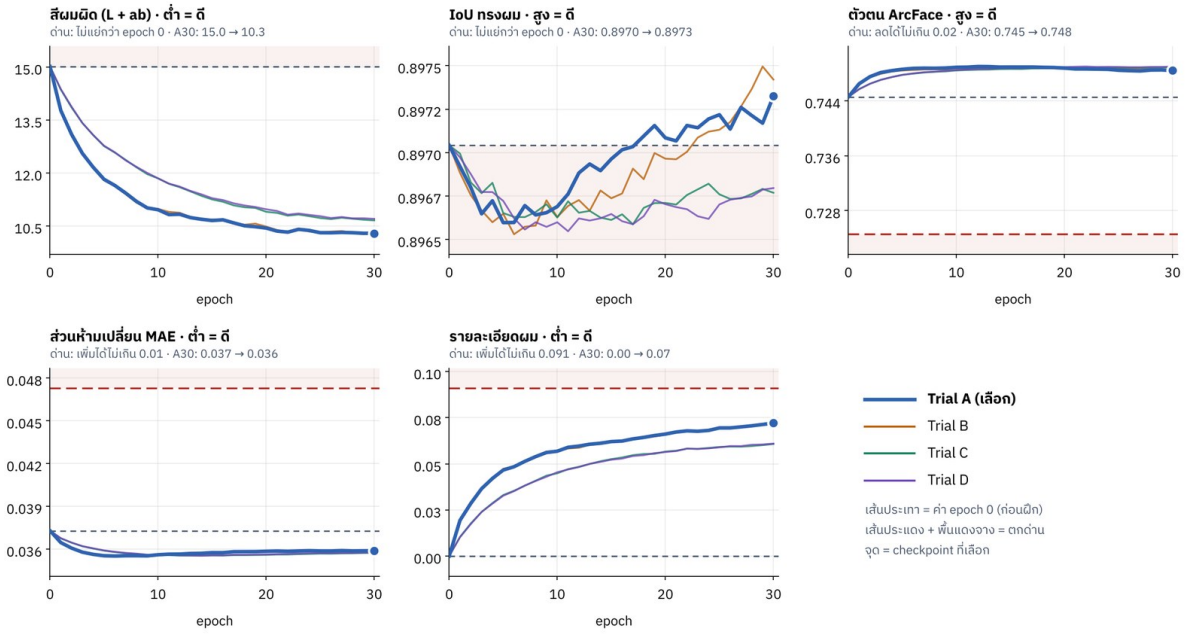
หมายเหตุ: BS-FT (Barbershop-FT) = Barbershop ที่ปรับจูนแล้ว (Fine-tuned)



ภาพที่ 28 คะแนนบนชุดตรวจสอบทุก Epoch ของ Barbershop-FT (เส้นสีคือ Trial A ที่เลือก)

หมายเหตุ: BS-FT (Barbershop-FT) = Barbershop ที่ปรับจูนแล้ว (Fine-tuned), A30 = น้ำหนักของ Trial A Epoch 30, ep = Epoch

ภาพที่ 29 แยกดูทั้ง 5 ด้านของ BS-FT แบบเดียวกับภาพที่ 27 ที่ A30 สีผิดลดจาก 15.0 เหลือ 10.3 ArcFace เพิ่มจาก 0.745 เป็น 0.748 MAE ลดจาก 0.037 เหลือ 0.036 และค่ารายละเอียดผมเพิ่มจาก 0 เป็น 0.07 ซึ่งยังอยู่ในขอบ 0.091 กราฟที่ควรดูมากที่สุดคือกราฟ IoU เส้นของ Trial C และ D (สีเขียวและสีม่วง) อยู่ในพื้นที่สีแดงตลอด ส่วน Trial A ค่อย ๆ ไต่ขึ้นมาเหนือเส้นประสีเทาหลัง Epoch ที่ 17 และจบที่ 0.8973 กราฟนี้แสดงว่าอัตราการเรียนรู้ของกลุ่มแรกมีผลกับทรงผม Trial C และ D ใช้อัตราการเรียนรู้กลุ่มแรกที่ต่ำกว่า และไม่เคยดึงทรงกลับขึ้นมาได้



ภาพที่ 29 ตัวชี้วัด 5 ด้านบนชุดตรวจสอบทุก Epoch ของ Barbershop-FT ทั้ง 4 Trial

หมายเหตุ: BS-FT (Barbershop-FT) = Barbershop ที่ปรับจูนแล้ว (Fine-tuned), IoU = Intersection over Union (สัดส่วนพื้นที่ผมที่ทับกัน), MAE = Mean Absolute Error (ค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย), ArcFace = โมเดลจดจำใบหน้าที่ใช้วัดความเหมือนของใบหน้า

4.2 ผลบนชุดทดสอบ

หัวข้อนี้เป็นผลการวัด Checkpoint ที่เลือกบนชุดทดสอบ 10 ชุด หลังจากล็อกตัวเลือกแล้ว ซึ่งเป็นตัวเลขที่ผู้วิจัยให้น้ำหนักมากที่สุด ทั้งนี้ ผู้วิจัยเคยประเมินโมเดลก่อนปรับจูน (Baseline) บนชุดนี้ไปแล้วครั้งหนึ่งก่อนแก้กติกาการเลือก ตามที่เปิดเผยไว้ในบทที่ 3 ตารางที่ 13 แสดงค่าเฉลี่ยก่อนและหลังปรับจูนของแต่ละโมเดลในคอลัมน์ที่สองและสาม ลูกศรหลังชื่อตัวชี้วัดบอกทิศทางที่ดี (↓ ต่ำ = ดี, ↑ สูง = ดี) คอลัมน์ที่สี่คือผลต่างแบบจับคู่ของ BS-FT ลบ BS พร้อมช่วงความเชื่อมั่น 95% และคอลัมน์สุดท้ายคือข้อสรุป คำว่า “ชัด” หมายถึงช่วงความเชื่อมั่นไม่ครอบคลุมเลข 0

ผลบนชุดทดสอบไปในทางเดียวกับชุดตรวจสอบ คือการปรับจูนช่วยทั้งสองโมเดล HFG

B24 ดีขึ้นมากด้านใบหน้า (ArcFace จาก 0.728 เป็น 0.794) และบริเวณที่ต้องคงเดิม (MAE ลดลงเกือบสามเท่า) ส่วน BS-FT A30 ดีขึ้นน้อยกว่าในทุกด้าน แต่ให้สีผมใกล้เป้าหมายที่สุดในตาราง (7.86) ประเด็นที่ไม่ควรมองข้ามคือเวลา HFG ใช้ประมาณ 10 วินาที ส่วน BS ใช้ประมาณ 657 วินาที หรือเกือบ 11 นาที

ตารางที่ 13 ผลบนชุดทดสอบ 10 ชุด (ค่าเฉลี่ย) และผลต่างแบบจับคู่ของ Barbershop

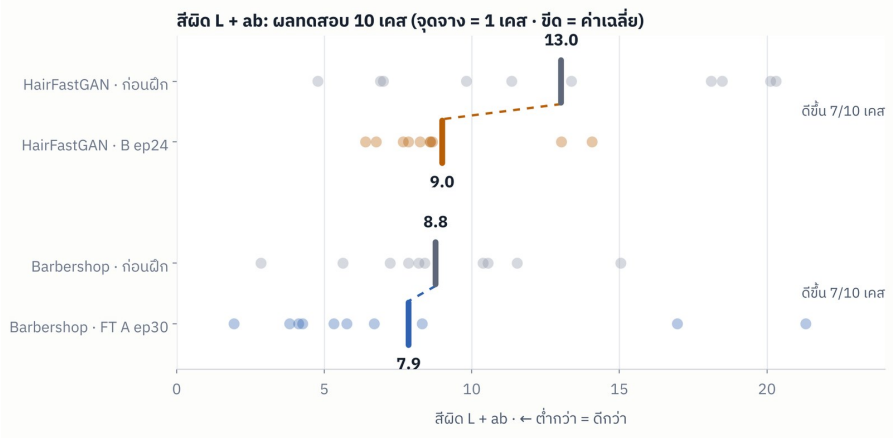
ตัวชี้วัด	HFG ก่อน → B24	BS ก่อน → FT A30	BS-FT − BS (95% CI)	สรุป BS
สีผิด ↓	13.03 → 8.99	8.77 → 7.86	-0.91 (-3.54 ถึง $+1.90$)	ยังไม่ชัด
IoU ทรง ↑	0.904 → 0.920	0.885 → 0.888	$+0.003$ ($+0.000$ ถึง $+0.006$)	เล็กน้อย
ArcFace ↑	0.728 → 0.794	0.711 → 0.724	$+0.013$ ($+0.008$ ถึง $+0.019$)	ชัด
MAE ↓	0.041 → 0.014	0.036 → 0.033	-0.003 (-0.004 ถึง -0.001)	ชัด
SSIM ↑	0.904 → 0.947	0.899 → 0.911	$+0.012$ ($+0.008$ ถึง $+0.015$)	ชัด
เวลาต่อภาพ ↓	ประมาณ 10 วินาที	ประมาณ 657 วินาที	–	–

หมายเหตุ: HFG = HairFastGAN, B24 = น้ำหนักของ Trial B Epoch 24, BS = Barbershop ก่อนปรับจูน, BS-FT (Barbershop-FT) = Barbershop ที่ปรับจูนแล้ว (Fine-tuned), A30 = น้ำหนักของ Trial A Epoch 30, CI = Confidence Interval (ช่วงความเชื่อมั่น), IoU = Intersection over Union (สัดส่วนพื้นที่ผมที่ทับกัน), ArcFace = โมเดลจดจำใบหน้าที่ใช้วัดความเหมือนของใบหน้า, MAE = Mean Absolute Error (ค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย), SSIM = Structural Similarity Index (ดัชนีความคล้ายเชิงโครงสร้าง)

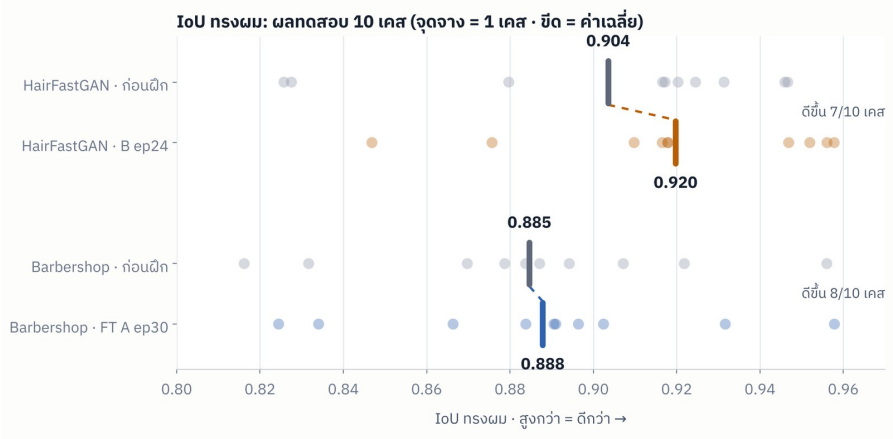
ค่าเฉลี่ยของ 10 ภาพอาจถูกดึงขึ้นหรือลงด้วยภาพเดียวได้ ภาพที่ 30 จึงแสดงผลรายภาพ แต่ละกราฟมี 4 แถวคือ 4 ระบบ (HFG ก่อนฝึก, HFG B24, BS ก่อนฝึก และ BS-FT A30) จุดจางแต่ละจุดคือภาพทดสอบหนึ่งภาพ ขีดเข้มคือค่าเฉลี่ย เส้นประเชื่อมค่าเฉลี่ยก่อนและหลังปรับจูน และข้อความด้านขวาบอกว่าดีขึ้นกี่ภาพจาก 10 ภาพ

เมื่อดูรายภาพ ผลของ HFG น่าเชื่อถือขึ้นมาก เพราะ ArcFace, MAE และ SSIM (Structural Similarity Index) ดีขึ้นครบ 10 จาก 10 ภาพ แปลว่าค่าเฉลี่ยไม่ได้ถูกดึงขึ้นด้วยภาพเพียงไม่กี่ภาพ แต่ดีขึ้นทุกภาพจริง ช่วงความเชื่อมั่นของ IoU ($+0.016$; $+0.003$ ถึง $+0.033$), ArcFace ($+0.066$; $+0.051$ ถึง $+0.082$), MAE (-0.027) และ SSIM ($+0.043$) ไม่ครอบคลุมเลข 0 ทั้งหมด ที่ยังไม่ชัดคือสี แม้สีผิดลดลงเฉลี่ย 4.04 แต่ช่วงความเชื่อมั่นยังแตะ 0 (-8.19 ถึง $+0.30$) เพราะมี 3 ภาพที่สีแย่ลง จึงยังสรุปไม่ได้ว่าการปรับจูนแก้เรื่องสีได้ทุกกรณี สำหรับ BS-FT ArcFace และ SSIM ดีขึ้นครบ 10 จาก 10 ภาพเช่นกัน MAE ดีขึ้น 8 ภาพ และสีดีขึ้น 7 ภาพ แม้ขนาดของการเปลี่ยนแปลงจะเล็ก แต่ทิศทางสม่ำเสมอ

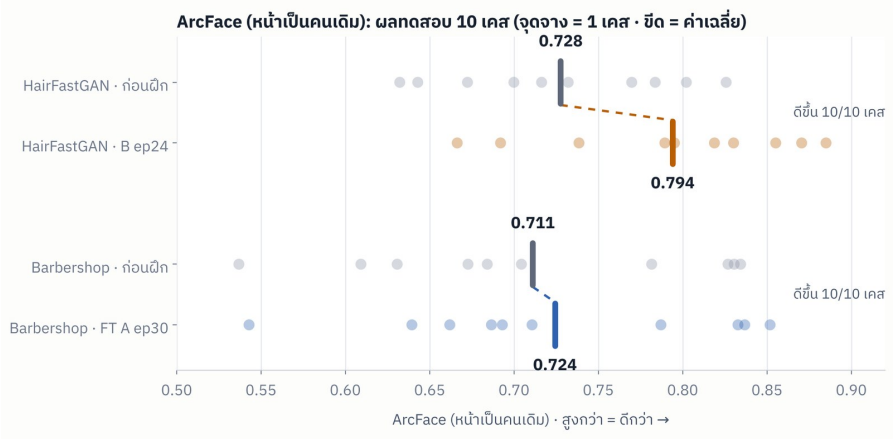
ตัวเลขทั้งหมดข้างต้นจะเข้าใจง่ายขึ้นเมื่อดูภาพจริง ภาพที่ 31 คือชุดทดสอบ test_000 แถวบนคือภาพนำเข้า (ใบหน้า ทรงผม และสีผม) และแถวล่างคือผลของ 4 ระบบ เรียงจากซ้ายไปขวาเป็น HFG ก่อนฝึก, HFG B24, BS ก่อนฝึก และ BS-FT A30 ถ้าเทียบสองภาพแรกจะเห็นปัญหาที่กล่าวถึงตั้งแต่บทที่ 1 คือ HFG ก่อนปรับจูนให้ผมเป็นปื้นที่สีไม่สม่ำเสมอ หลังปรับจูนสีกลืนกันมากขึ้นและใกล้ภาพอ้างอิงขึ้น ส่วนคู่ของ Barbershop สีดีขึ้นเล็กน้อย แต่ทรงผมแทบเหมือนเดิม ในบางภาพผมยังขาดเป็นช่วง หรือไม่เข้ากับรูปหน้า ซึ่งเป็นผลโดยตรงจากการที่ทรงถูกกำหนดก่อนถึงขั้นที่ปรับจูน



(a) สีผิด



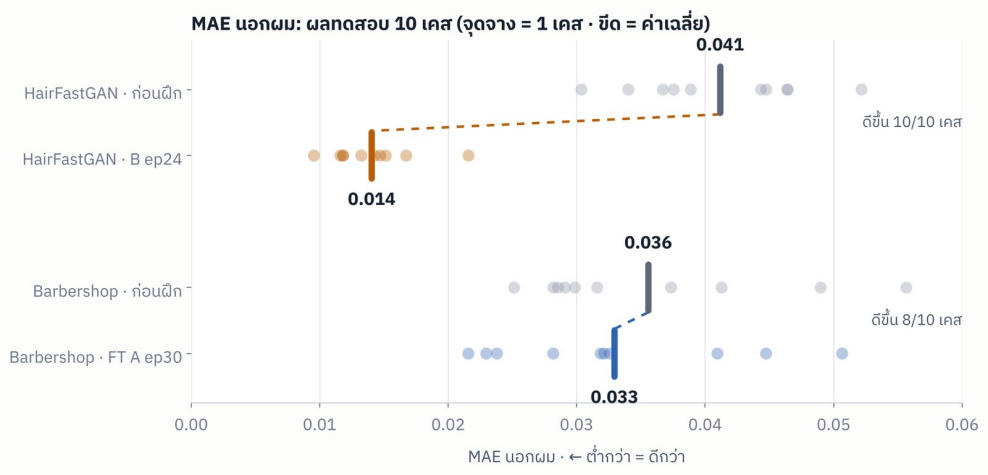
(b) IoU ทรงผม



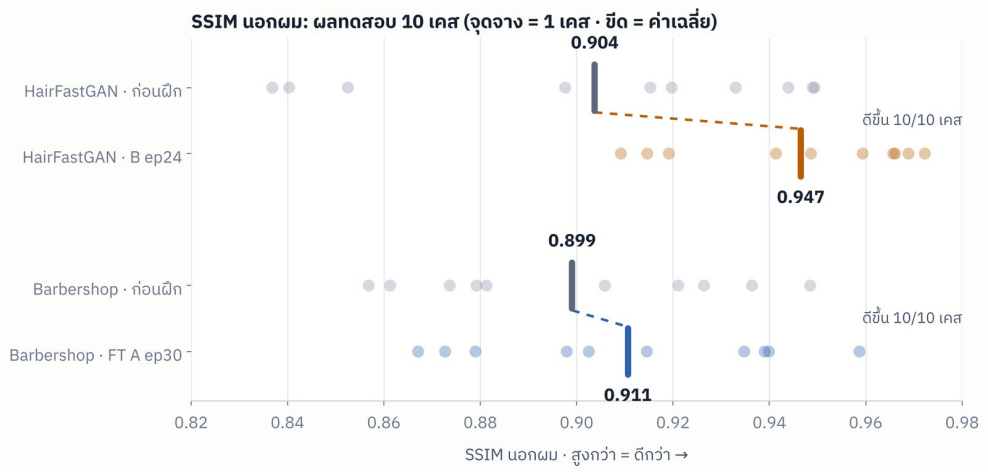
(c) ArcFace

ภาพที่ 30 ผลบนชุดทดสอบรายภาพ (จุดจาง = 1 ภาพ, ขีดเข้ม = ค่าเฉลี่ย)

หมายเหตุ: IoU = Intersection over Union (สัดส่วนพื้นที่ผมที่ทับกัน), ArcFace = โมเดลจดจำใบหน้าที่ใช้วัดความเหมือนของใบหน้า, MAE = Mean Absolute Error (ค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย), SSIM = Structural Similarity Index (ดัชนีความคล้ายเชิงโครงสร้าง), HFG = HairFastGAN, BS = Barbershop ก่อนปรับจูน, BS-FT (Barbershop-FT) = Barbershop ที่ปรับจูนแล้ว (Fine-tuned), B24 = น้ำหนักของ Trial B Epoch 24, ep = Epoch, A30 = น้ำหนักของ Trial A Epoch 30



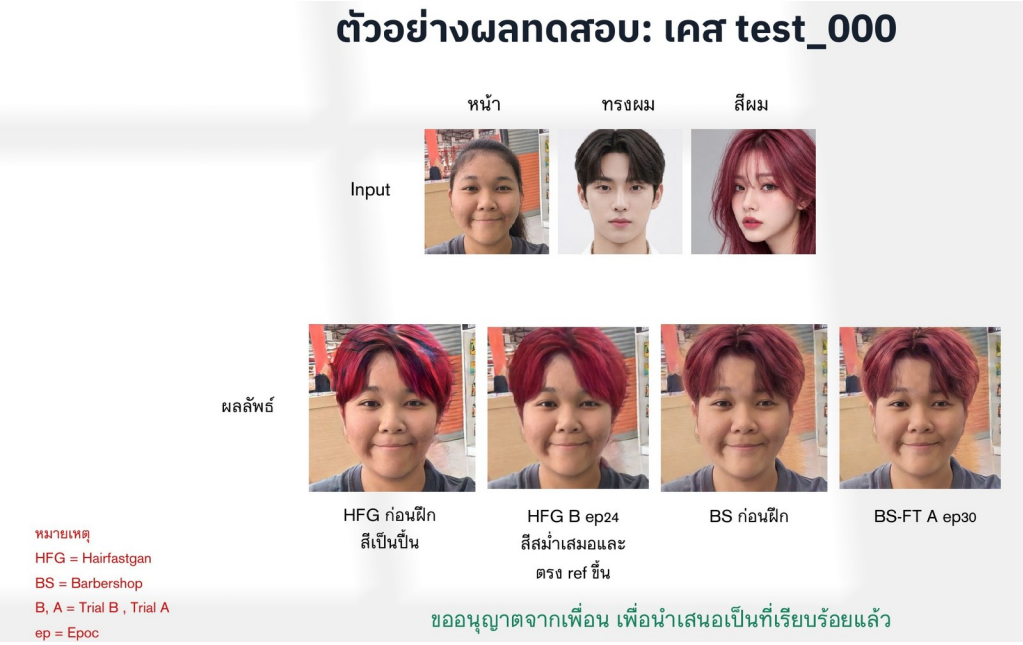
(d) MAE นอกผม



(e) SSIM นอกผม

ภาพที่ 30 ผลบนชุดทดสอบรายภาพ (ต่อ)

หมายเหตุ: IoU = Intersection over Union (สัดส่วนพื้นที่ผมที่ทับกัน), ArcFace = โมเดลจดจำใบหน้าที่ใช้วัดความเหมือนของใบหน้า, MAE = Mean Absolute Error (ค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย), SSIM = Structural Similarity Index (ดัชนีความคล้ายเชิงโครงสร้าง), HFG = HairFastGAN, BS = Barbershop ก่อนปรับจูน, BS-FT (Barbershop-FT) = Barbershop ที่ปรับจูนแล้ว (Fine-tuned), B24 = น้ำหนักของ Trial B Epoch 24, ep = Epoch, A30 = น้ำหนักของ Trial A Epoch 30



ภาพที่ 31 ตัวอย่างผลบนชุดทดสอบ (test_000) ของโมเดลก่อนและหลังปรับจูน

หมายเหตุ: HFG = HairFastGAN, BS = Barbershop ก่อนปรับจูน, BS-FT (Barbershop-FT) = Barbershop ที่ปรับจูนแล้ว (Fine-tuned), B24 = น้ำหนักของ Trial B Epoch 24, ep = Epoch, A30 = น้ำหนักของ Trial A Epoch 30

4.3 ผลของขั้นขัดเกลาด้วย Diffusion

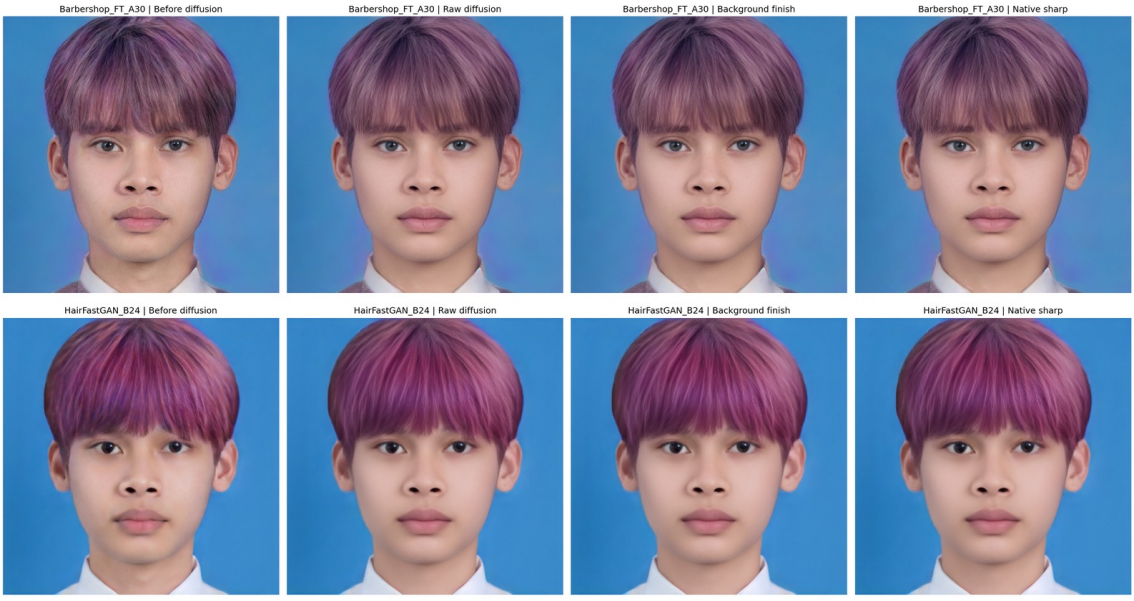
สิ่งที่ตาเห็นต้องตรวจสอบด้วยตัวเลขด้วย ผู้วิจัยจึงรันกรณีศึกษา 8 ชุดภาพ แต่ละชุดประกอบด้วยภาพใบหน้า ภาพทรงผม และภาพสีผม รวมใบหน้า 7 คน (ชุดที่ 1 และ 6 เป็นคนเดียวกันแต่ใช้ทรงและสีต่างกัน) แล้วสร้างภาพด้วย HFG B24 และ BS-FT A30 (Barbershop-FT Trial A Epoch 30) ซึ่งเป็นสองโมเดลที่ใช้ในแบบสอบถาม จากนั้นขัดเกลาด้วยค่าเดียวกันทุกอย่าง (Seed 3407, Strength 0.15, 30 ขั้น, CFG 2.5) และวัดผลหลังแต่ละขั้น ผู้วิจัยรันไว้ทั้งหมด 9 ชุด แต่ขั้นวัดผลของชุดสุดท้ายทำงานไม่เสร็จ จึงไม่นำมาคิด ภาพที่ 32 แสดงตัวอย่าง 2 ชุดจาก 8 ชุด ในแต่ละชุด แถวบนคือ BS-FT A30 และแถวล่างคือ HFG B24 จากซ้ายไปขวาคือ ก่อน Diffusion, หลัง Diffusion, หลังเก็บพื้นหลัง และหลัง Native Sharp จะเห็นว่าหลัง Diffusion เส้นผมของทั้งสองโมเดลแยกเป็นเส้นชัดขึ้น และผิวหน้าเรียบขึ้น ขณะที่ทรงผมและสีผมแทบไม่เปลี่ยน

ตารางที่ 14 แสดงผลของทุกชุด คอลัมน์ MUSIQ (Multi-scale Image Quality Transformer) และ ArcFace แสดงค่าก่อน Diffusion และหลังขั้นสุดท้าย ArcFace ในตารางนี้คือความคล้ายของใบหน้าเทียบกับรูปต้นฉบับของผู้ใช้ คอลัมน์ IoU คือความทับกันของผมหลังขัดเกลาเทียบกับผมก่อนขัดเกลา ส่วน MAE และ SSIM วัดเฉพาะพื้นที่นอกหน้ากากเทียบกับภาพก่อนขัดเกลา สองแถวล่างคือค่าเฉลี่ยของ 8 ชุด ภาพที่ 33 แสดง MUSIQ และ ArcFace ทีละขั้นเป็นกราฟเส้น แกนนอนคือขั้นตอน แกนตั้งคือค่าตัวชี้วัด เส้นสีส้มคือ HFG เส้นสีน้ำเงินคือ BS-FT เส้นจางแต่ละเส้นคือหนึ่งชุดภาพ และเส้นเข้มคือค่าเฉลี่ย

เมื่อเทียบกับเกณฑ์ในตารางที่ 8 ได้ผลดังนี้ MUSIQ ของ HFG ลดลงทั้ง 8 ชุด เฉลี่ย -1.84 คะแนน (ลดน้อยที่สุด 0.22 และมากที่สุด 4.29) ส่วนของ BS-FT แทบไม่เปลี่ยน เฉลี่ย -0.06



(a) ชุดที่ 1



(b) ชุดที่ 3

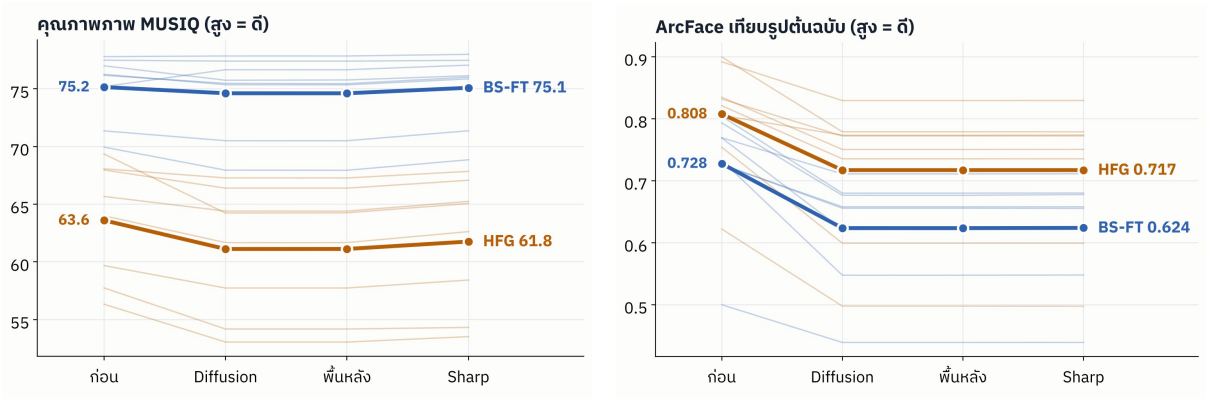
ภาพที่ 32 ตัวอย่างภาพหลังแต่ละขั้นของการขัดเกลา 2 ชุดจาก 8 ชุด (แถวบน BS-FT A30, แถวล่าง HFG B24)

หมายเหตุ: BS-FT (Barbershop-FT) = Barbershop ที่ปรับจูนแล้ว (Fine-tuned), A30 = น้ำหนักของ Trial A Epoch 30, HFG = HairFastGAN, B24 = น้ำหนักของ Trial B Epoch 24

ตารางที่ 14 ผลของการขัดเกลาด้วย Diffusion ใน 8 ชุดภาพ

ชุด	โมเดล	MUSIQ ↑	ArcFace ↑	IoU ↑	MAE ↓	SSIM ↑
1	HFG	64.00 → 62.62	0.900 → 0.779	0.968	0.0045	0.981
1	BS-FT	77.79 → 77.99	0.769 → 0.622	0.977	0.0054	0.970
2	HFG	67.96 → 67.07	0.754 → 0.599	0.990	0.0044	0.981
2	BS-FT	77.49 → 77.48	0.733 → 0.548	0.993	0.0038	0.982
3	HFG	68.06 → 67.84	0.805 → 0.774	0.986	0.0042	0.979
3	BS-FT	76.17 → 76.01	0.726 → 0.655	0.989	0.0059	0.958
4	HFG	57.74 → 54.32	0.832 → 0.772	0.992	0.0022	0.998
4	BS-FT	71.36 → 71.37	0.726 → 0.658	0.984	0.0038	0.987
5	HFG	59.68 → 58.42	0.892 → 0.829	0.975	0.0054	0.986
5	BS-FT	76.26 → 75.86	0.769 → 0.711	0.984	0.0078	0.947
6	HFG	65.67 → 65.24	0.821 → 0.735	0.992	0.0044	0.980
6	BS-FT	75.20 → 77.06	0.804 → 0.680	0.984	0.0056	0.968
7	HFG	69.35 → 65.06	0.835 → 0.751	0.978	0.0075	0.934
7	BS-FT	77.00 → 76.14	0.793 → 0.678	0.976	0.0154	0.789
8	HFG	56.33 → 53.52	0.622 → 0.497	0.983	0.0030	0.990
8	BS-FT	69.95 → 68.85	0.500 → 0.439	0.984	0.0042	0.978
เฉลี่ย	**HFG**	63.60 → 61.76	0.808 → 0.717	0.983	0.0045	0.979
เฉลี่ย	**BS-FT**	75.15 → 75.09	0.728 → 0.624	0.984	0.0065	0.947

หมายเหตุ: MUSIQ = Multi-scale Image Quality Transformer (คะแนนคุณภาพภาพ), ArcFace = โมเดลจดจำใบหน้าที่ใช้วัดความเหมือนของใบหน้า, IoU = Intersection over Union (สัดส่วนพื้นที่ผมที่ทับกัน), MAE = Mean Absolute Error (ค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย), SSIM = Structural Similarity Index (ดัชนีความคล้ายเชิงโครงสร้าง), HFG = HairFastGAN B24, BS-FT (Barbershop-FT) = Barbershop ที่ปรับจูนแล้ว (Fine-tuned) A30, → = จากก่อน Diffusion ไปหลังขั้นสุดท้าย



(a) MUSIQ **(b)** ArcFace

ภาพที่ 33 คุณภาพภาพและเอกลักษณ์ใบหน้าหลังแต่ละขั้นของการขัดเกลา (เส้นจาง = แต่ละชุดภาพ, เส้นเข้ม = ค่าเฉลี่ย 8 ชุด)

หมายเหตุ: MUSIQ = Multi-scale Image Quality Transformer (คะแนนคุณภาพภาพ), ArcFace = โมเดลจดจำใบหน้าที่ใช้วัดความเหมือนของใบหน้า, HFG = HairFastGAN, BS-FT (Barbershop-FT) = Barbershop ที่ปรับจูนแล้ว (Fine-tuned)

คะแนน (ตั้งแต่ -1.10 ถึง $+1.86$) มีเพียงชุดที่ 6 ของ BS-FT ที่เพิ่มถึง +1 จึงผ่านเกณฑ์เพียง 1 จาก 16 กรณี ArcFace ลดลงทุกกรณี HFG ลดเฉลี่ย 0.091 (0.032–0.155) และ BS-FT ลดเฉลี่ย 0.104 (0.058–0.185) จึงไม่ผ่านเกณฑ์ที่ให้ลดได้ไม่เกิน 0.02 ในทุกกรณี ด้านทรงผม IoU เทียบกับภาพก่อน Diffusion อยู่ระหว่าง 0.968–0.993 ผ่านเกณฑ์ 0.97 ใน 15 จาก 16 กรณี มีเพียงชุดที่ 1 ของ HFG ที่ได้ 0.968 ซึ่งต่ำกว่าเกณฑ์เล็กน้อย ด้านพื้นที่นอกหน้ากาก HFG ผ่านทั้ง MAE และ SSIM ใน 5 จาก 8 ชุด (MAE เฉลี่ย 0.0045, SSIM เฉลี่ย 0.979) ส่วน BS-FT ผ่านเพียง 2 จาก 8 ชุด (MAE เฉลี่ย 0.0065, SSIM เฉลี่ย 0.947) โดยชุดที่ 7 ของ BS-FT เปลี่ยนมากที่สุด (MAE 0.0154, SSIM 0.789) ซึ่งต้องตรวจภาพเป็นรายกรณีต่อไป พื้นที่นี้ไม่ได้ถูก Diffusion วาดใหม่ ความต่างที่ไม่เป็นศูนย์ส่วนใหญ่มาจากการที่ทั้งภาพต้องผ่านการบีบอัดและคืนสภาพของ VAE (หัวข้อที่ 2.3.6) และบางส่วนมาจากขั้นเก็บพื้นหลังที่ตั้งใจแก้พื้นหลังอยู่แล้ว ด้านสี ความคลาดเคลื่อนในช่อง a และ b ของ BS-FT ลดลงใน 5 จาก 8 ชุด (เฉลี่ยจาก 2.52 เป็น 2.41) แต่ของ HFG เพิ่มขึ้นทั้ง 8 ชุด (เฉลี่ยจาก 2.62 เป็น 3.09) แปลว่า Diffusion ทำให้สีผมของ HFG เพี้ยนจากเป้าหมายเล็กน้อย กราฟยังบอกด้วยว่าการเปลี่ยนแปลงเกือบทั้งหมดเกิดในขั้น Diffusion ขั้นเก็บพื้นหลังและ Native Sharp แทบไม่กระทบ ArcFace และ Native Sharp ช่วยดึง MUSIQ กลับขึ้นมาเล็กน้อยในทั้งสองโมเดล ส่วนเวลาที่เพิ่มขึ้นจากการขัดเกลาทั้งหมดคือ 2.97–3.28 วินาทีสำหรับ HFG (เฉลี่ย 3.15) และ 3.05–4.77 วินาทีสำหรับ BS-FT (เฉลี่ย 3.73)

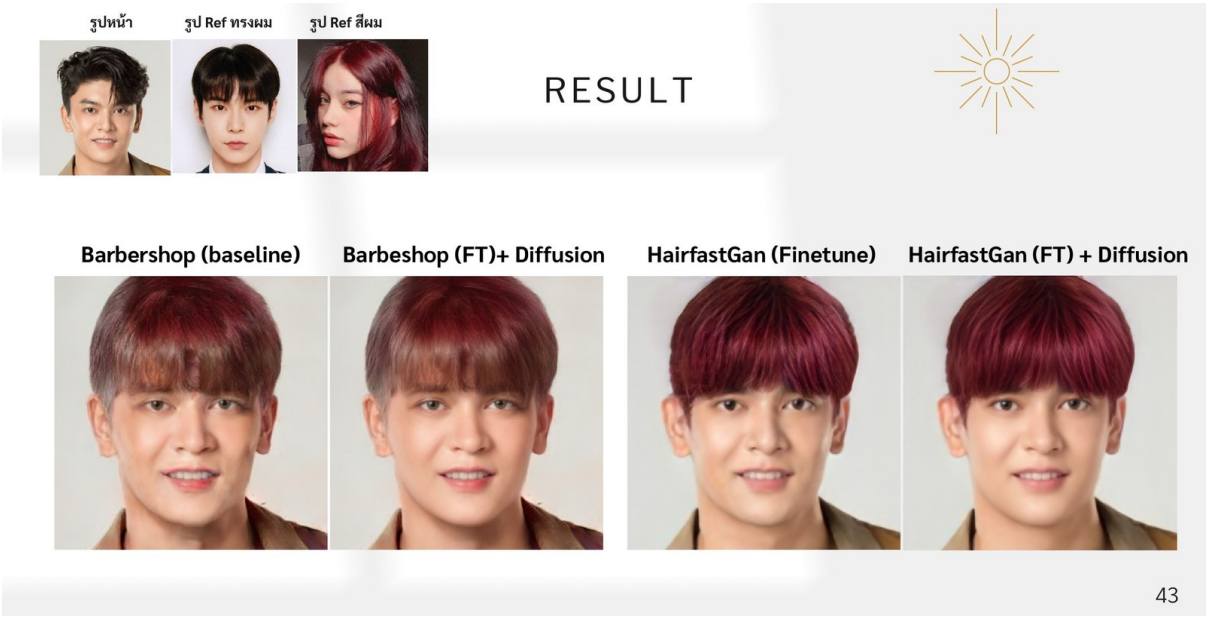
ผู้วิจัยตีความว่าตัวเลขชุดนี้บอกได้เพียงครึ่งเดียว ArcFace ที่ลดลงในทุกกรณีเป็นสัญญาณจริงว่าใบหน้าเปลี่ยน ซึ่งผู้วิจัยต้องยอมรับ แต่ ArcFace วัดความคล้ายของใบหน้า ไม่ได้วัดคุณภาพของเส้นผม ส่วน MUSIQ ประเมินคุณภาพภาพโดยรวมโดยไม่ใช้ภาพอ้างอิง คะแนนทั้งสองจึงควรพิจารณาร่วมกับคะแนนจากผู้ใช้ และจากกรณีศึกษานี้ยังระบุไม่ได้ว่าทำไมตัวเลขกับความเห็นของผู้ใช้จึงไปคนละทาง การตัดสินว่าภาพดีขึ้นจริงหรือไม่จึงต้องให้ผู้ใช้เป็นผู้บอก ดังจะเห็นในหัวข้อที่ 4.4

4.4 ผลการประเมินโดยผู้ใช้

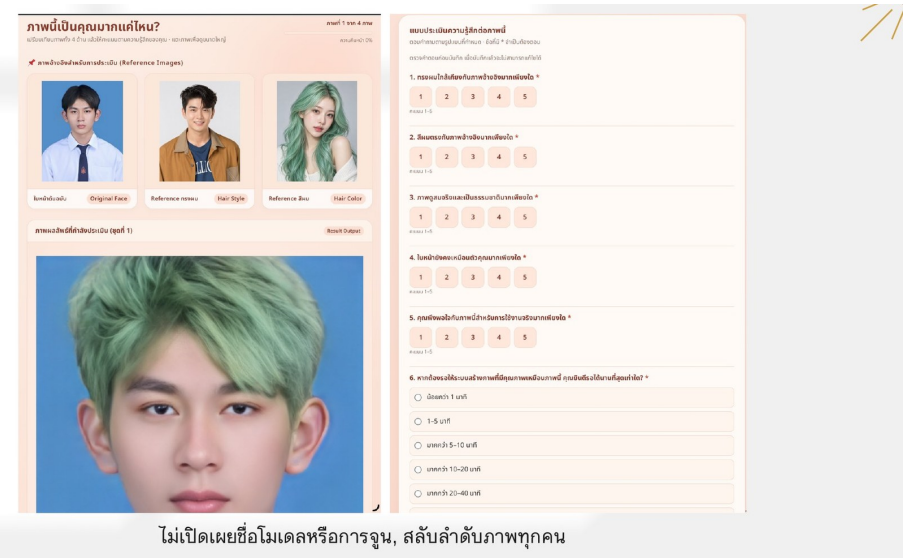
ผู้ใช้ 41 คนประเมินภาพจาก 4 ระบบโดยไม่รู้ชื่อโมเดล รวม 164 คำตอบ ภาพที่ 34 เป็นตัวอย่างภาพที่ผู้ใช้เห็น 2 ชุด มุมซ้ายบนของแต่ละชุดคือภาพนำเข้า (ใบหน้า ทรงผม และสีผม) และแถวล่างคือผลของ 4 ระบบตามชื่อที่อยู่ใต้ภาพ ถ้าดูคู่ภาพก่อนและหลัง Diffusion จะเห็นว่าผมที่ผ่าน Diffusion มีเส้นชัดขึ้น และถ้าเทียบระหว่างโมเดล HFG ยังคงหน้าตาของเจ้าของภาพได้ใกล้กว่า BS-FT

ภาพที่ 35 คือหน้าแบบประเมินจริง ด้านซ้ายมีภาพใบหน้าของผู้ใช้ ภาพทรงผม ภาพสีผม และภาพผลลัพธ์ทีละภาพ ด้านขวาคือคำถาม 6 ข้อตามตารางที่ 9 หน้านี้ไม่มีชื่อโมเดลอยู่เลย และลำดับภาพถูกสุ่มใหม่สำหรับทุกคน ผู้ใช้จึงไม่มีทางรู้ว่ากำลังให้คะแนนระบบใด

ตารางที่ 15 คือคะแนนเฉลี่ย (1–5) แต่ละแถวคือคำถามหนึ่งข้อ แต่ละคอลัมน์คือหนึ่งระบบ ตัวหนาคือคะแนนสูงสุดของแถว และแถวสุดท้ายคือเวลาต่อภาพ สิ่งแรกที่สังเกตได้คือไม่มีระบบใดชนะทุกข้อ BS-FT + Diff ได้คะแนนทรงผมและความสมจริงสูงสุด HFG B24 + Diff ได้



ภาพที่ 34 ตัวอย่างผลลัพธ์ของ 4 ระบบจากภาพนำเข้าชุดเดียวกัน



ภาพที่ 35 หน้าแบบประเมินที่ไม่เปิดเผยชื่อโมเดลและสลับลำดับภาพทุกคน

คะแนนสีผมและความพึงพอใจสูงสุด ส่วน HFG B24 ที่ไม่ผ่าน Diffusion ได้คะแนนความเหมือนของใบหน้าสูงสุด และถ้าดูแถวใบหน้าจะเห็นว่าคะแนนลดลงทุกครั้งที่ผ่าน Diffusion ทั้งสองโมเดล ซึ่งตรงกับค่า ArcFace ที่ลดลงในหัวข้อก่อน

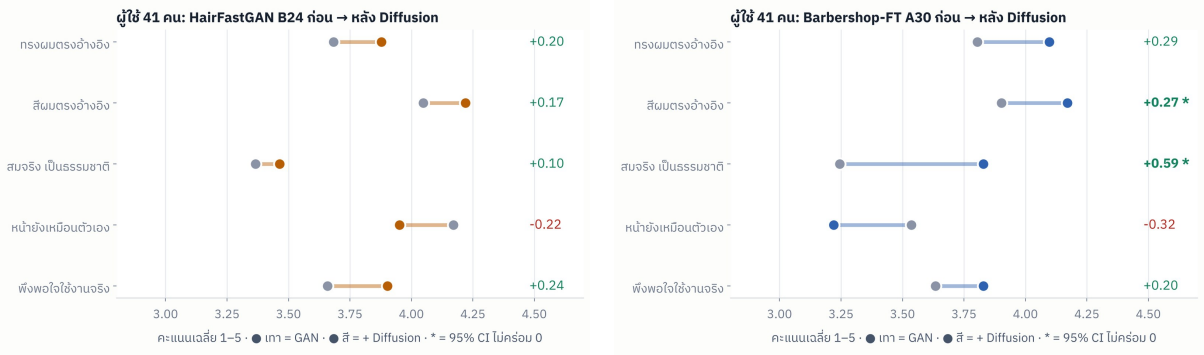
ตารางที่ 15 คะแนนเฉลี่ยจากผู้ใช้ 41 คน (คะแนน 1–5)

คำถาม	HFG B24	HFG B24 + Diff	BS-FT A30	BS-FT A30 + Diff
ทรงผมตรงภาพอ้างอิง	3.68	3.88	3.80	**4.10**
สีผมตรงภาพอ้างอิง	4.05	**4.22**	3.90	4.17
สมจริง เป็นธรรมชาติ	3.37	3.46	3.24	**3.83**
ใบหน้ายังเหมือนตัวเอง	**4.17**	3.95	3.54	3.22
พึงพอใจใช้งานจริง	3.66	**3.90**	3.63	3.83
เวลาต่อภาพ	≈ 10 วินาที	≈ 13 วินาที	≈ 11 นาที	≈ 11 นาที

หมายเหตุ: HFG = HairFastGAN, B24 = น้ำหนักของ Trial B Epoch 24, Diff = ขั้นขัดเกลาด้วย Diffusion, BS-FT (Barbershop-FT) = Barbershop ที่ปรับจูนแล้ว (Fine-tuned), A30 = น้ำหนักของ Trial A Epoch 30

4.4.1 ผลของ Diffusion ในสายตาผู้ใช้

เพื่อดูผลของ Diffusion อย่างเดียว ผู้วิจัยเทียบคะแนนที่คนเดียวกันให้ภาพก่อนและหลัง Diffusion ภาพที่ 36 แยกเป็น (a) HFG B24 และ (b) BS-FT A30 แต่ละแถวคือคำถามหนึ่งข้อ จุดสีเทาคือคะแนนก่อน Diffusion จุดสีคือคะแนนหลัง Diffusion ตัวเลขด้านขวาคือผลต่าง (สีเขียว = ดีขึ้น สีแดง = แย่ลง) และเครื่องหมาย * หมายถึงช่วงความเชื่อมั่น 95% ไม่ครอบคลุมเลข 0 ตารางที่ 16 ให้ตัวเลขชุดเดียวกันพร้อมช่วงความเชื่อมั่น คอลัมน์ที่สองและสามคือผลของ Diffusion ในแต่ละโมเดล ส่วนคอลัมน์สุดท้ายเทียบ HFG + Diff กับ BS-FT + Diff โดยตรง ซึ่งใช้ตอนเลือกโมเดลไปใช้บนเว็บ



(a) HairFastGAN B24 **(b)** Barbershop-FT A30

ภาพที่ 36 คะแนนผู้ใช้ก่อน (จุดเทา) และหลัง Diffusion (จุดสี) เครื่องหมาย * คือช่วงความเชื่อมั่น 95% ไม่คร่อมศูนย์

หมายเหตุ: B24 = น้ำหนักของ Trial B Epoch 24, BS-FT (Barbershop-FT) = Barbershop ที่ปรับจูนแล้ว (Fine-tuned), A30 = น้ำหนักของ Trial A Epoch 30, HFG = HairFastGAN, GAN = Generative Adversarial Network, CI = Confidence Interval (ช่วงความเชื่อมั่น)

ตารางที่ 16 ผลต่างคะแนนแบบจับคู่รายคน (95% CI จากบูตสแตรป)

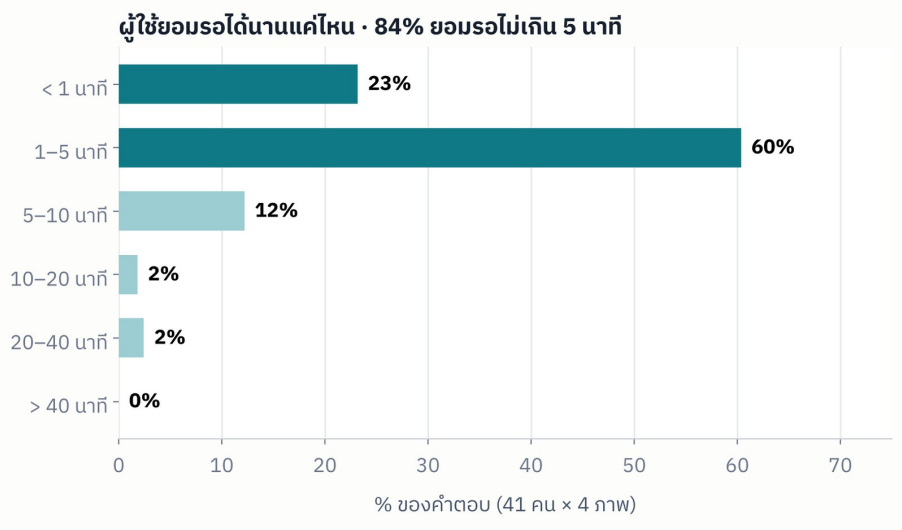
คำถาม	HFG + Diff − HFG	BS-FT + Diff − BS-FT	HFG + Diff − BS-FT + Diff
ทรงผม	+0.20 (−0.02, +0.41)	+0.29 (−0.02, +0.63)	−0.22 (−0.54, +0.10)
สีผม	+0.17 (−0.05, +0.37)	+0.27 (+0.02, +0.51)	+0.05 (−0.32, +0.44)
สมจริง	+0.10 (−0.17, +0.37)	+0.59 (+0.27, +0.93)	−0.37 (−0.63, −0.12)
ใบหน้าเหมือนตัวเอง	−0.22 (−0.46, +0.02)	−0.32 (−0.66, 0.00)	+0.73 (+0.37, +1.10)
พึงพอใจใช้งานจริง	+0.24 (0.00, +0.49)	+0.20 (−0.10, +0.49)	+0.07 (−0.24, +0.37)

หมายเหตุ: CI = Confidence Interval (ช่วงความเชื่อมั่น), HFG = HairFastGAN, Diff = ขั้นขัดเกลาด้วย Diffusion, BS-FT (Barbershop-FT) = Barbershop ที่ปรับจูนแล้ว (Fine-tuned)

ผลที่ชัดที่สุดคือความสมจริงของ BS-FT ซึ่งเพิ่มขึ้น $+0.59$ (95% CI $+0.27$ ถึง $+0.93$) มีผู้ใช้ 20 คนให้คะแนนสูงขึ้น และมีเพียง 4 คนที่ให้คะแนนต่ำลง ขณะที่ความสมจริงของ HFG เพิ่มเพียง $+0.10$ ผู้วิจัยคิดว่าเป็นเพราะภาพของ BS-FT มีรายละเอียดผมเป็นพื้นฐานอยู่แล้ว Diffusion แบบแรงต่ำจึงต่อยอดได้ดี ส่วนผมของ HFG เรียบกว่า จึงมีรายละเอียดตั้งต้นให้ Diffusion ใช้น้อยกว่า สำหรับทรงและสีผม คะแนนเฉลี่ยเพิ่มขึ้นเล็กน้อยในกลุ่มตัวอย่างที่ประเมิน โดยมีผลต่าง $+0.17$ ถึง $+0.29$ อย่างไรก็ตาม การที่ไม่พบว่าคะแนนลดลงไม่ได้พิสูจน์ว่า Diffusion ไม่ทำให้ทรงและสีผมแย่ลงเลย ส่วนสีผมของ BS-FT เพิ่มขึ้นอย่างชัดเจน ($+0.27$; $+0.02$ ถึง $+0.51$) ด้านที่เสียคือความเหมือนของใบหน้า (HFG -0.22 และ BS-FT -0.32) ซึ่งไปทางเดียวกับ ArcFace แต่เมื่อรวมทุกด้านแล้ว ผู้ใช้ยังพอใจมากขึ้น HFG $+0.24$ (95% CI 0.00 ถึง $+0.49$) และ BS-FT $+0.20$ ผลนี้สะท้อนแนวโน้มของคะแนนเฉลี่ย แต่ยังไม่ยืนยันว่าผู้ใช้ส่วนใหญ่ยอมแลกความเหมือนของใบหน้ากับรายละเอียดของผม โดยเฉพาะผลต่างความพึงพอใจของ BS-FT ที่ช่วงความเชื่อมั่นครอบคลุมเลข 0 และของ HFG ที่ขอบล่างปัดเศษแล้วเป็น 0

4.4.2 เวลาที่ผู้ใช้ยอมรอ

คำถามข้อ 6 ตอบเรื่องที่ตัวชี้วัดใดก็ตอบไม่ได้ คือผู้ใช้ยอมรอได้นานเท่าใด ภาพที่ 37 แกนตั้งคือช่วงเวลา แกนนอนคือร้อยละของคำตอบ (41 คน $\times$ 4 ภาพ) และแท่งสีเข้มคือช่วงที่ไม่เกิน 5 นาที ร้อยละ 84 ของคำตอบยอมรอได้ไม่เกิน 5 นาที คือ 137 จาก 164 คำตอบ (น้อยกว่า 1 นาที 38 คำตอบ และ 1–5 นาที 99 คำตอบ) ร้อยละ 12 ยอมรอ 5–10 นาที (20 คำตอบ) และมีเพียงร้อยละ 4 ที่ยอมรอเกิน 10 นาที (7 คำตอบ) ตัวเลขนี้ทำให้เห็นภาพชัดขึ้นมาก HFG + Diff ใช้เวลาประมาณ 13 วินาที ซึ่งสั้นกว่าขอบบนของช่วงเวลาที่สั้นที่สุดในแบบสอบถาม แต่ยังยืนยันไม่ได้ว่าทุกคนยอมรับเวลา 13 วินาที ขณะที่ BS-FT + Diff ใช้ประมาณ 11 นาที ซึ่งนานเกินกว่าที่ร้อยละ 96 ของคำตอบยอมรอ ไม่ว่าภาพจะสวยเพียงใด ถ้าผู้ใช้ไม่ยอมรอ ภาพนั้นก็ไม่ถูกใช้



ภาพที่ 37 เวลาที่ผู้ใช้ยอมรอเพื่อให้ได้ภาพคุณภาพเท่าภาพที่เห็น (41 คน $\times$ 4 ภาพ)

4.4.3 สรุปผลของ Diffusion จากตัวเลขและผู้ใช้

ตารางที่ 17 วางผลจากตัวเลขกับผลจากผู้ใช้ไว้คู่กันทีละด้าน คอลัมน์ที่สองคือผลจากตัวเลข คอลัมน์ที่สามคือผลจากผู้ใช้ และคอลัมน์สุดท้ายคือข้อสรุป ในกรณีศึกษาเชิงตัวเลข MUSIQ ลดลง แต่คะแนนความสมจริงจากผู้ใช้เพิ่มขึ้น โดยผลของ BS-FT ชัดกว่า HFG MUSIQ ไม่ใช้ภาพอ้างอิง คะแนนที่ลดลงจึงไม่ได้เกิดจากการเทียบรายละเอียดใหม่กับภาพเดิมโดยตรง และภาพในกรณีศึกษาเชิงตัวเลขกับภาพในแบบสอบถามเป็นคนละชุดกัน จึงยังระบุสาเหตุที่ผลไม่สอดคล้องกันไม่ได้ คะแนนเฉลี่ยของทรงและสีผมเพิ่มขึ้นเล็กน้อย แต่ยังไม่ได้ทดสอบทางสถิติโดยตรงว่าไม่แย่ลง คะแนนเฉลี่ยความเหมือนของใบหน้าลดลง โดยช่วงความเชื่อมั่นยังแตะหรือครอบคลุมเลข 0 ส่วนความพึงพอใจเพิ่มขึ้นในค่าเฉลี่ย แต่ยังไม่ชัดเจนสำหรับทั้งสองโมเดล สรุปได้ว่าผลจากผู้ใช้สนับสนุนว่า Diffusion ช่วยให้ภาพของ BS-FT สมจริงขึ้น ขณะที่ผลต่อ HFG และการรักษาใบหน้ายังต้องประเมินเพิ่ม โดยมีเวลาประมวลผลเพิ่มเฉลี่ย 3.15 วินาทีสำหรับ HFG ในสภาพแวดล้อมที่ทดสอบ

ตารางที่ 17 การตัดสินผลของ Diffusion จากตัวชี้วัดเชิงตัวเลขร่วมกับผู้ใช้

ด้าน	ตัวชี้วัดเชิงตัวเลข	ผู้ใช้ (41 คน)	สรุป
ความสมจริง	MUSIQ เปลี่ยน -4.3 ถึง $+1.9$ ถึงเกณฑ์ +1 เพียง 1 จาก 16 กรณี	BS-FT $+0.59$, HFG $+0.10$	ผู้ใช้สนับสนุน BS-FT
ทรงและสีผม	IoU 0.968–0.993 ผ่านเกณฑ์ 0.97 ใน 15 จาก 16 กรณี	ดีขึ้นเล็กน้อย $+0.17$ ถึง $+0.29$	ส่วนใหญ่ไม่เสีย
ใบหน้าเหมือนเดิม	ArcFace ลด 0.03–0.19 ทุกกรณี	ลดลง -0.22 ถึง -0.32	ต้องปรับปรุง
ความพึงพอใจ	–	ดีขึ้น $+0.20$ ถึง $+0.24$	ช่วยเล็กน้อย
เวลา	เพิ่ม 3.0–4.8 วินาทีต่อภาพ	ส่วนใหญ่ยอมรอไม่เกิน 5 นาที	รับได้

หมายเหตุ: MUSIQ = Multi-scale Image Quality Transformer (คะแนนคุณภาพภาพ), BS-FT (Barbershop-FT) = Barbershop ที่ปรับจูนแล้ว (Fine-tuned), HFG = HairFastGAN, IoU = Intersection over Union (สัดส่วนพื้นที่ผมที่ทับกัน), ArcFace = โมเดลจดจำใบหน้าที่ใช้วัดความเหมือนของใบหน้า

4.5 การคัดเลือกโมเดลสำหรับเว็บแอปพลิเคชัน

เมื่อมีข้อมูลครบทุกด้านแล้ว ผู้วิจัยเลือก HairFastGAN B24 + Diffusion ไปใช้บนเว็บ เหตุผลแรกและสำคัญที่สุดคือความเร็ว ระบบนี้ใช้เวลาประมาณ 13 วินาทีต่อภาพ ขณะที่ BS-FT ใช้ประมาณ 11 นาที ซึ่งร้อยละ 96 ของคำตอบบอกว่ารอไม่ได้ สำหรับเว็บที่ให้คนทั่วไปเข้ามาทดลอง ข้อนี้ข้อเดียวแทบจะตัดสินได้แล้ว

เหตุผลที่สองคือใบหน้ายังเป็นของผู้ใช้ เมื่อเทียบโดยตรงกับ BS-FT + Diff แล้ว HFG + Diff ได้คะแนนความเหมือนของใบหน้าสูงกว่าอย่างชัดเจน $+0.73$ (95% CI $+0.37$ ถึง $+1.10$) มีผู้ใช้ 25 คนให้คะแนนสูงกว่า และ 6 คนให้ต่ำกว่า และ HFG B24 ยังมีค่า ArcFace บนชุดทดสอบสูงที่สุด

(0.794) สำหรับระบบลองทรงผม ถ้าผลออกมาไม่เหมือนตัวเอง ผู้ใช้ก็ไม่ได้ข้อมูลที่ต้องการ

เหตุผลที่สามคือ Diffusion คุ้มค่าที่จะใส่ เมื่อเทียบกับ HFG B24 อย่างเดียว ความพึงพอใจเพิ่มขึ้น $+0.24$ (95% CI 0.00 ถึง $+0.49$) ทรงและสีดีขึ้นเล็กน้อย โดยใช้เวลาเพิ่มเฉลี่ยเพียง 3.15 วินาที ผลคือได้คะแนนความพึงพอใจในการใช้งานจริงสูงสุด (3.90) และสีผมตรงที่สุด (4.22) จาก 4 ตัวเลือก

การเลือกนี้มีสิ่งที่ต้องแลก ความสมจริงของ HFG + Diff ด้อยกว่า BS-FT + Diff (-0.37, 95% CI -0.63 ถึง -0.12) และ Diffusion ทำให้คะแนนความเหมือนของใบหน้าลดลงจาก HFG B24 เล็กน้อย (-0.22) แต่เมื่อชั่งน้ำหนักกับความเร็วและความเหมือนของใบหน้าแล้ว ผู้วิจัยเห็นว่าเป็นการแลกที่คุ้มค่า

4.6 ผลการทดลองใช้งานเว็บแอปพลิเคชัน

หลังเปิดเว็บ LOOKLAB (https://looklab2.vercel.app/) ที่ใช้ HFG B24 + Diff มีการทดลองใช้งานจริง 100 ครั้ง ในคำตอบเหล่านี้ ร้อยละ 80 ระบุอายุ 18–24 ปี ร้อยละ 13 อายุต่ำกว่า 18 ปี และร้อยละ 7 อายุ 25–34 ปี และมีการเลือกใช้ทรงผม 22 แบบและสีผม 22 แบบ ตารางที่ 18 แสดงคะแนนเฉลี่ย (เต็ม 5) และร้อยละของผู้ที่ให้ 4 หรือ 5 คะแนนในแต่ละหัวข้อ ทุกหัวข้อได้มากกว่า 4.6 หัวข้อที่สูงที่สุดคือความพอใจต่อเว็บไซต์ (4.90) และต่อเวลารอ (4.88) หัวข้อที่ต่ำที่สุดคือทรงผมตรงกับที่เลือก (4.62) ซึ่งเป็นเรื่องเดียวกับที่ผู้ใช้เขียนข้อเสนอแนะมา

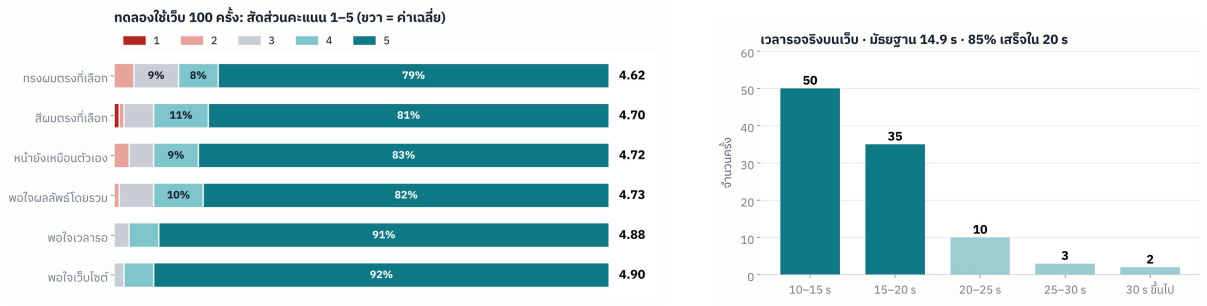
ตารางที่ 18 ผลการทดลองใช้งานเว็บแอปพลิเคชัน 100 ครั้ง

หัวข้อ	ค่าเฉลี่ย (เต็ม 5)	ร้อยละที่ให้ 4–5
ทรงผมตรงที่เลือก	4.62	87
สีผมตรงที่เลือก	4.70	92
ใบหน้ายังเหมือนตัวเอง	4.72	92
พอใจผลลัพธ์โดยรวม	4.73	92
พอใจเวลารอ	4.88	97
พอใจเว็บไซต์	4.90	98

ภาพที่ 38 (a) แสดงการกระจายของคะแนนในแต่ละหัวข้อ แต่ละแถบคือหนึ่งหัวข้อ สีของแต่ละช่วงคือคะแนน 1–5 (สีเขียวเข้ม = 5) ความยาวคือร้อยละของผู้ตอบ และตัวเลขด้านขวาคือค่าเฉลี่ย จะเห็นว่าแทบทุกแถบเป็นสีเขียวเข้มเกินครึ่ง ภาพ (b) แสดงเวลารอจริง แกนนอนคือช่วงเวลา แกนตั้งคือจำนวนครั้ง เวลารอจริงมีค่ามัธยฐาน 14.9 วินาที (เฉลี่ย 16.3 วินาที) ร้อยละ 85 เสร็จภายใน 20 วินาที และครั้งที่ช้าที่สุดใช้ 51 วินาที ค่ามัธยฐาน 14.9 วินาทีสูงกว่าเวลาที่วัดในการทดลองประมาณ 13 วินาทีเล็กน้อย ซึ่งน่าจะเป็นเพราะเวลาจริงรวมการอัปโหลดภาพ การจัดตำแหน่งใบหน้า และการส่งผลกลับผ่านเครือข่ายด้วย และเว็บจริงรันบนเซิร์ฟเวอร์ของ RunPod ไม่ใช่ Google Colab ที่ใช้จับเวลาในการทดลอง

ข้อสังเกตหนึ่งที่ควรระวังในการตีความ คือคะแนนความเหมือนของใบหน้าบนเว็บ (4.72) สูงกว่าตอนประเมินแบบปกปิดชื่อ (3.95) มาก ผู้วิจัยตั้งข้อสังเกตว่าสาเหตุหนึ่งอาจเป็นเพราะบน

เว็บผู้ใช้เห็นผลเพียงภาพเดียว ไม่มีภาพจากระบบอื่นให้เทียบ คะแนนบนเว็บจึงสะท้อนว่า “พอใจหรือไม่” มากกว่า “ดีกว่าตัวเลือกอื่นหรือไม่” การเปรียบเทียบระหว่างโมเดลจึงควรอ้างอิงผลจากการประเมินแบบปกปิดชื่อเป็นหลัก



(a) สัดส่วนคะแนน 1–5 **(b)** เวลารอจริง

ภาพที่ 38 ผลการทดลองใช้งานเว็บแอปพลิเคชัน 100 ครั้ง

ผู้ใช้เขียนข้อเสนอแนะมา 4 ความเห็น ได้แก่ “อยากให้ทรงผมดูเหมือนจริงขึ้นอีก” “ผมมีความฟูกว่าปกติจึงดูไม่ค่อยตรงภาพอ้างอิง แต่โดยรวมเว็บใช้ง่ายและหน้าเว็บสวยงาม ถ้ามีฟีเจอร์หวีผมจะดีมาก” “พื้นหลังดูแปลก” และ “ทรงผมดูไม่ค่อยเรียบเนียน แต่นอกนั้นทำได้ดี” สามในสี่ความเห็นพูดถึงทรงผม ทั้งเรื่องความฟูและความเรียบ ซึ่งตรงกับจุดอ่อนที่ผู้วิจัยทราบอยู่แล้ว เพราะส่วนที่ควบคุมทรงของ HFG ไม่ได้ถูกปรับจูน ส่วนเรื่องพื้นหลังน่าจะมาจากขั้นเก็บพื้นหลังที่เติมรายละเอียดเข้าไป ซึ่งอาจมากเกินไปสำหรับบางภาพ

4.7 อภิปรายผล

4.7.1 เหตุผลที่ปรับจูนเฉพาะโมดูล Color และ Refinement ของ Hair-FastGAN

ตอนที่ผู้วิจัยรัน HairFastGAN ครั้งแรก พบว่าผมยังเป็นปื้นและสีไม่ตรงกับภาพอ้างอิง ผู้วิจัยจึงลองปรับจูนทั้งโมเดลก่อน แต่ส่วนจัดทรง (Alignment) ไม่ดีขึ้น เมื่อลองปรับเฉพาะโมดูล Color กับ Refinement สีกลับตรงภาพอ้างอิงมากขึ้น จึงเลือกปรับจูนเฉพาะสองโมดูลนี้ ในการทดลองช่วงแรกใช้ประมาณ 5 Epoch แล้วผลดีขึ้น จึงตั้งการฝึกจริงไว้ 30 Epoch

4.7.2 ทรงผมของ Barbershop-FT แทบไม่เปลี่ยนหลังปรับจูน

การเพิ่มจำนวน Epoch ของการปรับจูนน่าจะไม่ช่วยเรื่องทรงผม เพราะทรงผมของ Barbershop ถูกกำหนดในขั้นจัดรูป (Alignment) ซึ่งค้นหารหัสแฝง (Latent) ใหม่ทุกภาพด้วยการวนซ้ำ และไม่ได้อยู่ในชั้นที่ปรับจูน สิ่งที่น่าจะช่วยได้มากกว่าคือการเพิ่มจำนวนรอบค้นหาในขั้นนั้น ซึ่งต้องแลกกับเวลาที่นานขึ้น

4.7.3 เหตุที่ Diffusion ทำให้ภาพดูดีขึ้นแต่ใบหน้าเหมือนเดิมน้อยลง

ที่ผู้ใช้ให้คะแนนดีขึ้น น่าจะเป็นเพราะ Diffusion ทำให้เส้นผมชัดขึ้น และใบหน้าสว่างใสขึ้นเล็กน้อย โดยไม่ได้เปลี่ยนไปจากเดิมมาก ส่วนที่ผู้ใช้ให้คะแนนความเหมือนของใบหน้าน้อยลง (ตารางที่ 16) ผู้วิจัยคิดว่าเป็นเพราะ Diffusion ปรับใบหน้าให้สว่างและเนียนเกินไป ใบหน้าของผู้ใช้บางคนจึงเปลี่ยนไปมากจนดูไม่เหมือนรูปต้นฉบับ แม้คะแนนความพึงพอใจโดยรวมจะยังเพิ่มขึ้น

ในกรณีศึกษาเชิงตัวเลข 8 ชุดภาพ หลังผ่าน Diffusion ค่า ArcFace ลดลง 0.03–0.19 ทุกกรณี ซึ่งไปทางเดียวกับคะแนนผู้ใช้ ArcFace เทียบใบหน้ากับรูปต้นฉบับ ถ้าใบหน้าเปลี่ยนไปจากเดิม ค่าก็จะลดลง แม้การเปลี่ยนนั้นจะทำให้ภาพดูดีขึ้นก็ตาม ส่วน MUSIQ ให้คะแนนคุณภาพภาพโดยไม่เทียบกับภาพเดิม และเปลี่ยนเพียง -4.3 ถึง $+1.9$ (เฉลี่ย -1.84 สำหรับ HFG และ -0.06 สำหรับ BS-FT) ตัวเลขจึงบอกได้ว่าใบหน้าเปลี่ยน แต่บอกไม่ได้ว่าคนดูแล้วชอบขึ้นหรือไม่ ผู้วิจัยจึงใช้ตัวเลขดูว่ามีอะไรเสีย และใช้คะแนนจากผู้ใช้ดูว่าภาพดีขึ้นหรือไม่

4.7.4 เหตุผลที่เลือก HairFastGAN B24 + Diffusion ไปใช้บนเว็บ

ถ้าดูเพียงคุณภาพของภาพ Barbershop-FT + Diffusion ทำได้ดีที่สุด เพราะได้คะแนนความสมจริงสูงสุด (3.83) และทรงผมตรงที่สุด (4.10) แต่ใช้เวลาประมาณ 11 นาทีต่อภาพ ขณะที่ร้อยละ 84 ของคำตอบยอมรอได้ไม่เกิน 5 นาที ถ้านำไปใช้บนเว็บ ผู้ใช้ส่วนใหญ่คงปิดหน้าเว็บไปก่อนได้ภาพ และระบบนี้ยังได้คะแนนความเหมือนของใบหน้าต่ำสุด (3.22) ซึ่งสำคัญมากสำหรับระบบลองทรงผม เพราะถ้าผลออกมาไม่เหมือนตัวเอง ผู้ใช้ก็ไม่รู้ว่าทรงนั้นเข้ากับตัวเองหรือไม่ HairFastGAN B24 + Diffusion ใช้เวลาประมาณ 13 วินาที ได้คะแนนความพึงพอใจสูงสุด (3.90) และคะแนนความเหมือนของใบหน้าสูงกว่า Barbershop-FT + Diffusion อยู่ $+0.73$ คะแนน ผู้วิจัยจึงเลือกระบบนี้ โดยยอมแลกกับความสมจริงที่ลดลงเล็กน้อย ผลจากการใช้งานเว็บจริงที่ได้คะแนนความพอใจต่อเวลารอ 4.88 จาก 5 สนับสนุนการเลือกนี้

4.7.5 สีผมของ HairFastGAN บนชุดทดสอบ

หลังปรับจูน สีผิดของ HairFastGAN ลดจาก 13.03 เหลือ 8.99 แต่ช่วงความเชื่อมั่นยังแตะ 0 (-8.19 ถึง $+0.30$) แปลว่ายังสรุปไม่ได้เต็มที่ว่าสีดีขึ้นในทุกกรณี สาเหตุคือมี 3 จาก 10 ภาพที่สีแย่ลง เช่น test_003 และชุดทดสอบมีเพียง 10 ชุด ภาพที่แย่ลงเพียงไม่กี่ภาพจึงทำให้ผลแกว่งได้มาก ต่างจาก ArcFace, MAE และ SSIM ที่ดีขึ้นครบทั้ง 10 ภาพ ผู้วิจัยคิดว่าการปรับจูนช่วยเรื่องสีได้จริงในภาพรวม แต่ยังไม่นิ่งพอ ถ้าจะยืนยันให้ชัด ต้องเพิ่มจำนวนชุดทดสอบ

4.7.6 ความจำเป็นของด่าน 5 ด่าน

ในการเลือก Checkpoint ถ้าดูเพียงคะแนนรวม Trial C และ D ของ Barbershop-FT ได้คะแนนใกล้กับ Trial A มาก (0.856 และ 0.858 เทียบกับ 0.841) แต่ทั้งสอง Trial มีค่า IoU ทรงผมต่ำกว่าตอนก่อนฝึกทุก Epoch แปลว่าทรงผมแย่ลงกว่าเดิม ถ้าไม่มี

ด่าน ผู้วิจัยอาจเลือกโมเดลที่ทรงผมแย่ลงโดยไม่รู้ตัว ด่านทั้ง 5 จึงช่วยกันไม่ให้เลือกโมเดลที่ดีขึ้นด้านหนึ่งแต่แย่ลงอีกด้านหนึ่ง

4.8 ข้อจำกัดที่พบ

ผู้วิจัยขอระบุข้อจำกัดของผลการทดลองไว้อย่างตรงไปตรงมา เพื่อให้ผู้อ่านตีความผลได้ถูกต้อง ข้อแรกคือระบบต้องใช้ GPU (Graphics Processing Unit) ประสิทธิภาพสูง (ทดสอบบน A100 40 GB) จึงจะได้เวลาประมาณ 11–14 วินาทีต่อภาพ บนเครื่องที่ช้ากว่านี้จะใช้เวลานานขึ้นมาก ข้อที่สองคือข้อมูลมีขนาดเล็ก ชุดตรวจสอบมี 9 ชุด ชุดทดสอบมี 10 ชุด และการวัดผลขั้น Diffusion ด้วยตัวเลขใช้เพียง 8 ชุดภาพต่อโมเดลกับ Seed เดียว ค่าสีผิดจึงแกว่งมาก และมีบางภาพที่แย่ลงหลังปรับจูน เช่น ภาพ test_003 ของ HFG ข้อที่สามคือ Barbershop-FT บันทึกน้ำหนักไว้เพียง Epoch 0 และ 30 จึงเลือกได้จาก Epoch 30 เท่านั้น ข้อที่สี่คือ IoU ทรงผมของทั้งสองโมเดลวัดกับทรงเป้าหมายที่มาจากโมดูล Shape ของ HairFastGAN ซึ่งอาจเข้าข้าง HFG อยู่บ้างเพราะเป็นทรงที่ HFG สร้างเอง ข้อที่ห้าคือ Diffusion อาจทำให้สีผมและใบหน้าเปลี่ยนเล็กน้อย และบริเวณที่ถูกแก้ไขขึ้นกับการแบ่งส่วนภาพ ถ้าหน้ากากตรวจไม่พบเส้นผมบางเส้น เส้นนั้นก็จะไม่ถูกขัดเกลา ข้อสุดท้ายคือผู้ใช้ส่วนใหญ่ทั้งในการประเมินและบนเว็บมีอายุ 18–24 ปี ผลจึงอาจไม่สะท้อนความเห็นของคนกลุ่มอายุอื่น

นอกจากนี้ ผลเชิงตัวเลขของ Diffusion เป็นกรณีศึกษา 8 ชุดภาพต่อโมเดลและ Seed เดียว แม้จะใช้ HFG B24 และ BS-FT A30 ตัวเดียวกับในแบบสอบถาม แต่เป็นภาพคนละชุดกับที่ผู้ใช้ประเมิน จึงไม่ควรสรุปขนาดผลของ Diffusion สำหรับทั้งชุดข้อมูล หรือโยงตัวเลขสองส่วนนี้เข้าหากันโดยตรง ควรขยายการวัดให้ครอบคลุมทั้งชุดทดสอบ พร้อมรายงานค่าเฉลี่ยและความแปรปรวน การวัดผลทีละขั้นเป็นการดูผลสะสม ไม่ใช่การทดลองตัดองค์ประกอบออกทีละส่วน (Ablation Study) คำอธิบายสาเหตุเกี่ยวกับโมดูลต่าง ๆ และการที่ผู้ใช้ยอมแลกความเหมือนของใบหน้ากับรายละเอียดของผม จึงยังเป็นข้อสันนิษฐาน

ช่วงความเชื่อมั่นในเล่มนี้คำนวณแยกทีละการเปรียบเทียบ และยังไม่ได้ปรับแก้สำหรับการเปรียบเทียบหลายครั้ง (Multiple Comparisons) จึงควรตีความเป็นหลักฐานเชิงสำรวจ โดยเฉพาะช่วงที่ขอบปัดเศษแล้วเป็นศูนย์ การตรวจข้อมูลซ้ำใช้ค่าแฮชของไฟล์ ซึ่งยืนยันได้ว่าไม่มีไฟล์ซ้ำข้ามชุดข้อมูล แต่ไม่ได้ตรวจว่าบุคคลเดียวกันปรากฏในหลายชุดด้วยภาพคนละภาพหรือไม่ ด้านเวลา ค่าประมาณ 10 วินาทีของ HFG วัดครั้งเดียว รวมขั้นจัดตำแหน่งภาพแต่ไม่รวมการโหลดโมเดล ส่วน 657 วินาทีของ Barbershop คือผลรวมเวลาคำนวณของขั้น W^+, FS, การจัดทรง การจัดสี และการผสม ไม่รวมการโหลดโมเดล ส่วนเวลาของขั้น Diffusion เป็นค่าเฉลี่ยจาก 8 ชุดภาพในกรณีศึกษา

บทที่ 5
สรุปผลและข้อเสนอแนะ

5.1 สรุปผล

5.1.1 สรุปภาพรวมของโครงงาน

โครงงานนี้เริ่มจากคำถามว่า ถ้านำโมเดลเปลี่ยนทรงผมที่มีอยู่แล้วมาปรับจูนด้วยข้อมูลของผู้วิจัยเอง จะแก้จุดอ่อนที่เห็นได้หรือไม่ และโมเดลแบบใดเหมาะกับการใช้งานจริง ผู้วิจัยเลือกโมเดลโครงข่ายปรปักษ์เชิงกำเนิด (Generative Adversarial Network: GAN) 2 ตัวที่ทำงานต่างกันอย่างชัดเจน คือ HairFastGAN ที่ใช้ตัวเข้ารหัส (Encoder-based) และ Barbershop ที่ค้นหารหัสทีละภาพ (Optimization-based) แล้วปรับจูนทั้งคู่ด้วยชุดฝึก 150 ชุด ใช้ฟังก์ชันสูญเสียหลักชุดเดียวกันซึ่งวัด 5 ด้าน และทดลองอัตราการเรียนรู้ (Learning Rate) 4 ชุด (Trial) ชุดละ 30 Epoch การเลือก Checkpoint ใช้กติกาฉบับแก้ไขที่เปิดเผยไว้ในบทที่ 3 คือคะแนนรวมร่วมกับเกณฑ์ 5 ด่านบนชุดตรวจสอบ จากนั้นวัดผลบนชุดทดสอบ 10 ชุด เพิ่มขั้นขัดเกลาด้วย Stable Diffusion Inpainting แบบแรงต่ำ ให้ผู้ใช้ 41 คนประเมินโดยไม่รู้ชื่อโมเดล และนำตัวเลือกที่ดีที่สุดไปพัฒนาเป็นเว็บที่มีการทดลองใช้จริง 100 ครั้ง

5.1.2 สรุปข้อค้นพบหลัก

ข้อค้นพบแรกคือการปรับจูนได้ผลกับทั้งสองโมเดล แต่ได้ผลไม่เท่ากัน HairFastGAN Trial B Epoch 24 (B24) ลดความคลาดเคลื่อนของสีผมในปริภูมิสี CIELAB (Lab) จาก 13.0 เหลือ 9.0 เพิ่มความเหมือนของใบหน้าที่วัดด้วย ArcFace (Additive Angular Margin Loss) จาก 0.73 เป็น 0.79 ลดค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย (Mean Absolute Error: MAE) นอกบริเวณผมจาก 0.041 เหลือ 0.014 และเพิ่มดัชนีความคล้ายเชิงโครงสร้าง (Structural Similarity Index: SSIM) จาก 0.904 เป็น 0.947 ผลนี้แก้ปัญหาสีเป็นปื้นและใบหน้าซีดที่พบตั้งแต่ต้นได้ตรงจุด ส่วน Barbershop-FT (Barbershop ที่ปรับจูนแล้ว) Trial A Epoch 30 (A30) ดีขึ้นน้อยกว่า แต่ดีขึ้นอย่างสม่ำเสมอ เช่น ArcFace เพิ่มขึ้น $+0.013$ (ช่วงความเชื่อมั่น 95% คือ $+0.008$ ถึง $+0.019$) และดีขึ้นครบ 10 จาก 10 ภาพ ผู้วิจัยตั้งข้อสังเกตว่าความต่างนี้อาจเกี่ยวข้องกับตำแหน่งของส่วนที่ปรับได้ แต่ยังไม่ได้แยกพิสูจน์ด้วยการทดลองตัดองค์ประกอบออกทีละส่วน (Ablation Study) HairFastGAN มีโมดูลที่ตรงกับปัญหาให้ปรับ ขณะที่ Barbershop ปรับได้เฉพาะชั้นวาดภาพ ซึ่งอยู่หลังขั้นที่กำหนดทรงไปแล้ว

ข้อค้นพบที่สองคือแต่ละโมเดลเด่นกันคนละด้าน HairFastGAN รักษาใบหน้าและบริเวณที่ไม่ควรเปลี่ยนได้ดีที่สุด และเร็วกว่าประมาณ 65 เท่า (ประมาณ 10 วินาที เทียบกับ 657 วินาทีต่อภาพ) ส่วน Barbershop-FT ให้สีผมใกล้เป้าหมายที่สุด (ความคลาดเคลื่อน 7.86) แต่

ทรงผมแทบไม่เปลี่ยนจากก่อนปรับจูน

ข้อค้นพบที่สามคือกติกาการเลือกที่มีด่านกันความผิดพลาดมีความจำเป็นจริง Barbershop-FT Trial C และ D มีคะแนนรวมใกล้เคียงกับ Trial A แต่ค่าการทับซ้อนของทรงผม (Intersection over Union: IoU) ต่ำกว่าตอนก่อนฝึกทุก Epoch ถ้าใช้คะแนนอย่างเดียว อาจได้โมเดลที่ทรงผมแย่ลงโดยไม่รู้ตัว

ข้อค้นพบที่สี่คือ Diffusion แบบแรงต่ำทำให้ภาพดูเป็นธรรมชาติขึ้น แต่มีสิ่งที่ต้องแลก ผู้ใช้เห็นว่าภาพของ Barbershop-FT สมจริงขึ้น $+0.59$ (95% CI $+0.27$ ถึง $+0.93$) คะแนนเฉลี่ยความพึงพอใจเพิ่มขึ้น $+0.20$ ถึง $+0.24$ และคะแนนเฉลี่ยของทรงกับสีผมไม่ลดลง แต่ช่วงความเชื่อมั่นของความพึงพอใจยังแตะหรือครอบคลุมเลข 0 สิ่งที่ต้องแลกคือคะแนนเฉลี่ยความเหมือนของใบหน้าที่ลดลง -0.22 ถึง -0.32 (ช่วงความเชื่อมั่นยังแตะหรือครอบคลุมเลข 0) ซึ่งไปทางเดียวกับ ArcFace ที่ลดลง 0.03–0.19 ทุกกรณีในกรณีศึกษา 8 ชุดภาพของ HFG B24 และ BS-FT A30 ขณะที่พื้นที่นอกหน้ากาก (Mask) เปลี่ยนน้อยในเกือบทุกชุด (MAE เฉลี่ย 0.0045 สำหรับ HFG และ 0.0065 สำหรับ BS-FT)

ข้อค้นพบที่ห้า ซึ่งผู้วิจัยคิดว่าสำคัญที่สุด คือตัวเลขอย่างเดียวตัดสินคุณภาพของภาพที่สร้างขึ้นใหม่ไม่ได้ ในกรณีศึกษา 8 ชุดภาพ หลังผ่าน Diffusion คะแนนคุณภาพภาพ MUSIQ (Multi-scale Image Quality Transformer) ไม่ดีขึ้นถึงเกณฑ์ และ ArcFace ลดลง แต่ผู้ใช้กลับบอกว่าภาพดีขึ้น MUSIQ ประเมินคุณภาพจากภาพผลลัพธ์โดยไม่ใช้ภาพอ้างอิง ส่วน ArcFace เปรียบเทียบเวกเตอร์ใบหน้ากับภาพต้นฉบับ ข้อมูลในกรณีศึกษานี้ยังไม่พอจะบอกว่าทำไมตัวเลขกับคะแนนผู้ใช้จึงไปคนละทาง และไม่ได้แปลว่าตัวชี้วัดเหล่านี้ใช้ไม่ได้ ถ้าดูเพียงตัวเลข ผู้วิจัยคงตัด Diffusion ออกไปแล้ว จึงควรใช้ตัวชี้วัดและการประเมินโดยผู้ใช้ร่วมกัน และตีความตามขอบเขตของกลุ่มตัวอย่างที่วัด

ข้อค้นพบที่หกคือความเร็วเป็นตัวตัดสินในการใช้งานจริง ร้อยละ 84 ของคำตอบยอมรอได้ไม่เกิน 5 นาที แม้ Barbershop-FT + Diffusion จะสมจริงที่สุด แต่ใช้เวลาประมาณ 11 นาที ผู้วิจัยจึงเลือก HairFastGAN B24 + Diffusion ซึ่งได้คะแนนความพึงพอใจในการใช้งานจริงสูงสุด (3.90) สีผมตรงที่สุด (4.22) ใช้เวลาประมาณ 13 วินาที และรักษาใบหน้าได้ดีกว่า Barbershop-FT + Diffusion $+0.73$ (95% CI $+0.37$ ถึง $+1.10$)

ข้อค้นพบสุดท้ายคือผู้ใช้พอใจเมื่อได้ใช้งานจริง การทดลองใช้เว็บ 100 ครั้งได้คะแนนความพึงพอใจโดยรวม 4.73 จาก 5 (ร้อยละ 92 ให้ 4 หรือ 5 คะแนน) คะแนนความพึงพอใจต่อเวลารอ 4.88 และเวลารอจริงมีค่ามัธยฐาน 14.9 วินาที โดยร้อยละ 85 เสร็จภายใน 20 วินาที

5.1.3 การบรรลุวัตถุประสงค์ของโครงงาน

โครงงานบรรลุวัตถุประสงค์ทั้ง 3 ข้อ วัตถุประสงค์ข้อแรก คือการศึกษาและเปรียบเทียบโมเดล ทำได้โดยเปรียบเทียบ HairFastGAN และ Barbershop ทั้งก่อนและหลังปรับจูนภายใต้ข้อมูลและตัวชี้วัดชุดเดียวกัน พร้อมระบุให้ชัดถึงค่าสูญเสียส่วนเพิ่มของ HairFastGAN ความต่างของการบันทึกน้ำหนัก และการแก้ไขเกณฑ์การเลือก วัตถุประสงค์ข้อที่สอง คือการ

วิเคราะห์ข้อดีและข้อจำกัด ทำได้โดยวัดด้วยตัวชี้วัด 5 ด้าน เวลาประมวลผล ผลของขั้น Diffusion และความเห็นของผู้ใช้ 41 คน ซึ่งทำให้เห็นทั้งจุดแข็ง จุดอ่อน และสิ่งที่ต้องแลกของแต่ละตัวเลือก และวัตถุประสงค์ข้อที่สาม คือการพัฒนาเว็บแอปพลิเคชันต้นแบบ ทำได้โดยใช้ HairFastGAN B24 + Diffusion และมีการทดลองใช้งานจริง 100 ครั้ง ได้คะแนนความพึงพอใจโดยรวม 4.73 จาก 5

5.2 ข้อเสนอแนะ

ถ้าต้องการให้ทรงผมของ Barbershop ดีขึ้น ควรเพิ่มจำนวนรอบในการค้นหา โดยเฉพาะขั้น Alignment ที่กำหนดทรงผม (ปัจจุบัน 140 รอบ) แต่เวลาประมวลผลซึ่งนานอยู่แล้ว (ประมาณ 657 วินาทีต่อภาพ) จะยิ่งเพิ่มขึ้นอีก

เรื่องใบหน้าที่เปลี่ยนหลังผ่าน Diffusion ควรลดความแรงของ Diffusion เฉพาะบริเวณใบหน้า หรือให้ Diffusion แก้ไขเฉพาะบริเวณผม เพื่อให้ใบหน้ายังเหมือนเดิม แต่ผมยังชัดขึ้น

เรื่องข้อมูล ชุดตรวจสอบและชุดทดสอบมีจำนวนน้อย (9 และ 10 ชุด) ทำให้ผลบางด้าน เช่น สีผมของ HairFastGAN ยังแกว่ง ควรเพิ่มจำนวนชุดทดสอบ และสำหรับ Barbershop-FT ควรบันทึกน้ำหนักไว้ทุก Epoch เพื่อให้เลือก Checkpoint ได้จากทุก Epoch ไม่ใช่เพียง Epoch 30

เรื่องเว็บ LOOKLAB ผู้ใช้บอกว่าผมบางทรงฟูเกินจริงและไม่ค่อยเรียบ ควรปรับปรุงส่วนที่กำหนดทรงผม และควรลดเวลารอในโหมดกล้อง ซึ่งตอนนี้ยังต้องรอประมาณ 15 วินาที ให้ใกล้เคียงแบบเรียลไทม์มากขึ้น

บรรณานุกรม

[1] P. Zhu, R. Abdal, J. Femiani, and P. Wonka, “Barbershop: GAN-based image compositing using segmentation masks,” *ACM Transactions on Graphics*, vol. 40, pp. 1–13, Dec. 2021.

[2] M. Nikolaev, M. Kuznetsov, D. Vetrov, and A. Alanov, “HairFastGAN: Realistic and robust hair transfer with a fast encoder-based approach.” arXiv preprint arXiv:2404.01094, 2024.

[3] T. Karras, S. Laine, M. Aittala, J. Hellsten, J. Lehtinen, and T. Aila, “Analyzing and improving the image quality of StyleGAN.” arXiv preprint arXiv:1912.04958, 2020.

[4] T. Wei, D. Chen, W. Zhou, J. Liao, Z. Tan, L. Yuan, W. Zhang, and N. Yu, “HairCLIP: Design your hair by text and reference image.” arXiv preprint arXiv:2112.05142, 2022.

[5] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, “High-resolution image synthesis with latent diffusion models.” arXiv preprint arXiv:2112.10752, 2022.

[6] I. J. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio, “Generative adversarial networks.” arXiv preprint arXiv:1406.2661, 2014.

[7] T. Karras, S. Laine, and T. Aila, “A style-based generator architecture for generative adversarial networks.” arXiv preprint arXiv:1812.04948, 2019.

[8] T. Kim, C. Chung, Y. Kim, S. Park, K. Kim, and J. Choo, “Style your hair: Latent optimization for pose-invariant hairstyle transfer via local-style-aware hair alignment.” arXiv preprint arXiv:2208.07765, 2022.

[9] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever, “Learning transferable visual models from natural language supervision.” arXiv preprint arXiv:2103.00020, 2021.

[10] T. Wei, D. Chen, W. Zhou, J. Liao, W. Zhang, G. Hua, and N. Yu, “HairCLIPv2: Unifying hair editing via proxy feature blending.” arXiv preprint arXiv:2310.10651, 2023.

[11] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional networks for biomedical image segmentation.” arXiv preprint arXiv:1505.04597, 2015.

[12] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need.” arXiv preprint arXiv:1706.03762, 2023.

[13] P. Zhu, R. Abdal, Y. Qin, J. Femiani, and P. Wonka, “Improved StyleGAN embedding: Where are the good latents?.” arXiv preprint arXiv:2012.09036, 2021.

[14] C. Yu, J. Wang, C. Peng, C. Gao, G. Yu, and N. Sang, “BiSeNet: Bilateral segmentation network for real-time semantic segmentation.” arXiv preprint arXiv:1808.00897, 2018.

[15] E. Xie, W. Wang, Z. Yu, A. Anandkumar, J. M. Alvarez, and P. Luo, “SegFormer: Simple and efficient design for semantic segmentation with transformers.” arXiv preprint arXiv:2105.15203, 2021.

[16] J. Deng, J. Guo, J. Yang, N. Xue, I. Kotsia, and S. Zafeiriou, “ArcFace: Additive angular margin loss for deep face recognition,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, pp. 5962–5979, Oct. 2022.

[17] O. Tov, Y. Alaluf, Y. Nitzan, O. Patashnik, and D. Cohen-Or, “Designing an encoder for StyleGAN image manipulation.” arXiv preprint arXiv:2102.02766, 2021.

[18] P. Zhu, R. Abdal, Y. Qin, and P. Wonka, “SEAN: Image synthesis with semantic region-adaptive normalization,” in *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 5103–5112, IEEE, June 2020.

[19] M. Yeung, L. Rundo, Y. Nan, E. Sala, C.-B. Schönlieb, and G. Yang, “Calibrating the Dice loss to handle neural network overconfidence for biomedical image segmentation.” arXiv preprint arXiv:2111.00528, 2022.

[20] R. Zhang, P. Isola, A. A. Efros, E. Shechtman, and O. Wang, “The unreasonable effectiveness of deep features as a perceptual metric.” arXiv preprint arXiv:1801.03924, 2018.

[21] K. Simonyan and A. Zisserman, “Very deep convolutional networks for large-scale image recognition.” arXiv preprint arXiv:1409.1556, 2015.

[22] J. Ho, A. Jain, and P. Abbeel, “Denoising diffusion probabilistic models.” arXiv preprint arXiv:2006.11239, 2020.

[23] J. Ho and T. Salimans, “Classifier-free diffusion guidance.” arXiv preprint arXiv:2207.12598, 2022.

[24] W. Zhao, L. Bai, Y. Rao, J. Zhou, and J. Lu, “UniPC: A unified predictor-corrector framework for fast sampling of diffusion models.” arXiv preprint arXiv:2302.04867, 2023.

[25] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson, “How transferable are features in deep neural networks?.” arXiv preprint arXiv:1411.1792, 2014.

[26] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization.” arXiv preprint arXiv:1412.6980, 2017.

[27] M. D. Fairchild, *Color Appearance Models*, ch. 10, pp. 199–212. John Wiley & Sons, Ltd, 2013.

[28] F. Milletari, N. Navab, and S.-A. Ahmadi, “V-Net: Fully convolutional neural networks for volumetric medical image segmentation.” arXiv preprint arXiv:1606.04797, 2016.

[29] Z. Wang, A. Bovik, H. Sheikh, and E. Simoncelli, “Image quality assessment: from error visibility to structural similarity,” *IEEE Transactions on Image Processing*, vol. 13, no. 4, pp. 600–612, 2004.

[30] J. Ke, Q. Wang, Y. Wang, P. Milanfar, and F. Yang, “MUSIQ: Multi-scale image quality transformer.” arXiv preprint arXiv:2108.05997, 2021.

[31] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. Chapman and Hall/CRC, 1st ed., 1994.

ภาคผนวก

ภาคผนวก ก
การตั้งค่าที่ใช้ในการทดลอง

ก.1 ค่าที่ใช้ในการปรับจูนและการเลือก Checkpoint

ภาคผนวกนี้รวบรวมค่าที่ใช้จริงทั้งหมดไว้ในที่เดียว เพื่อให้ผู้ที่ต้องการทำซ้ำไม่ต้องไล่หาจากหลายบท ตารางที่ 19 คือค่าของการปรับจูนและการเลือก Checkpoint คอลัมน์ “HairFast-GAN” และ “Barbershop-FT” แสดงค่าของแต่ละโมเดล (Barbershop-FT คือ Barbershop ที่ปรับจูนแล้ว) ตัวย่อในตาราง ได้แก่ IoU (Intersection over Union), ArcFace (Additive Angular Margin Loss), MAE (Mean Absolute Error), MSE (Mean Squared Error), Adam (Adaptive Moment Estimation) และ FFHQ (Flickr-Faces-HQ) ซึ่งเป็นชุดภาพใบหน้าที่ใช้ฝึก StyleGAN2 ถ้าค่าของสองโมเดลเหมือนกัน จะเขียนไว้ครั้งเดียวกลางแถว จะเห็นว่าค่าเกือบทั้งหมดเหมือนกัน ต่างกันเฉพาะส่วนที่ปรับจูนและค่าสูญเสียส่วนเพิ่มที่ใช้กับ HairFastGAN เท่านั้น ซึ่งเป็นไปตามหลักของโครงงานที่ต้องการให้ทั้งสองโมเดลอยู่ภายใต้เงื่อนไขเดียวกัน

ก.2 ค่าที่ใช้ในขั้นขัดเกลาด้วย Diffusion

ตารางที่ 20 รวบรวมค่าของขั้นขัดเกลาทั้ง 4 ขั้นย่อย โดย CFG คือ Classifier-Free Guidance และ UniPC คือ Unified Predictor-Corrector แต่ละแถวคือหนึ่งขั้นย่อย คอลัมน์กลางคือค่าที่ใช้ และคอลัมน์ขวาคือเวลาเฉลี่ยต่อภาพของ HairFastGAN (HFG) จาก 8 ชุดภาพบน GPU A100 ขั้นนี้ใช้ค่าเดียวกันกับภาพจากทั้งสองโมเดล และไม่มีการฝึกเพิ่ม ข้อความสั่งงานและข้อความเชิงลบฉบับเต็มอยู่ในหัวข้อที่ 3.9

ตารางที่ 19 ค่าที่ใช้ในการปรับจูนและการเลือก Checkpoint

รายการ	**HairFastGAN**	**Barbershop-FT**
น้ำหนักเริ่มต้น	น้ำหนักทางการของผู้พัฒนา (StyleGAN2 ฝึกบน FFHQ)	
ส่วนที่ปรับจูน	ชั้น Modulation ของ Blending Encoder และโมดูล PostProcess	`convs[6:]` และ `to_rgbs[3:]` ของ StyleGAN2 (ชั้น 64–1024 พิกเซล)
ส่วนที่ไม่ได้ปรับจูน	โมดูล Embedding (ผสม F ด้วย $\alpha = 0.95$), Pose (หมุนเฉพาะภาพสีผม ไม่หมุนภาพทรงผม) และ Shape	StyleGAN2 ชั้น 4–32 พิกเซล และขั้นค้นหารหัสตามค่าเดิม: II2S 1,100 รอบ, FS 250 รอบ, Alignment 140 + 100 รอบ, Blending 400 รอบ
ข้อมูล	ชุดฝึก 150 ชุด, ชุดตรวจสอบ 9 ชุด, ชุดทดสอบ 10 ชุด (1024×1024 พิกเซล)	
ฟังก์ชันสูญเสียหลัก	$1.0\,L_{color} + 0.2\,L_{shape} + 0.1\,L_{id} + 5.0\,L_{protect} + 0.1\,L_{detail}$	
ค่าสูญเสียส่วนเพิ่ม	$0.5\,L_{color}(I_{pre}) +$ $0.1\,L_{shape}(I_{pre}) +$ $0.01\,\mathrm{MSE}(z, z_0)$	ไม่มี
ตัวปรับค่า	Adam ($\beta_1 = 0.9$, $\beta_2 = 0.999$) ตัดเกรเดียนต์ที่ขนาด 1.0	
Batch Size / Epoch / Updates	1 / 30 / 4,500 ต่อ Trial	
อัตราการเรียนรู้	4 Trial ตามตารางที่ 5	
Seed	3407	
สูตรคะแนนการเลือก	$\frac{1}{2}(c/c_0 + e/e_0)$ เมื่อ $e = 1 - \mathrm{IoU}$	
ด่าน 5 ด่าน	สีไม่แย่ลง, IoU ไม่ลดลง, ArcFace ลดได้ไม่เกิน 0.02, MAE เพิ่มได้ไม่เกิน 0.01, Detail เพิ่มได้ไม่เกิน 0.091	
Checkpoint ที่เลือก	Trial B Epoch 24 (คะแนน 0.664)	Trial A Epoch 30 (คะแนน 0.841)

หมายเหตุ: BS-FT (Barbershop-FT) = Barbershop ที่ปรับจูนแล้ว (Fine-tuned), II2S = Improved Image2StyleGAN, StyleGAN2 = Style-based Generative Adversarial Network รุ่นที่ 2, FFHQ = Flickr-Faces-HQ, MSE = Mean Squared Error, Adam = Adaptive Moment Estimation, IoU = Intersection over Union (สัดส่วนพื้นที่ผมที่ทับกัน), ArcFace = โมเดลจดจำใบหน้าที่ใช้วัดความเหมือนของใบหน้า, MAE = Mean Absolute Error (ค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย)

ตารางที่ 20 ค่าที่ใช้ในขั้นขัดเกลาด้วย Diffusion

ขั้นย่อย	**ค่าที่ใช้**	**เวลา (วินาที)**
1. หาบริเวณที่แก้	SegFormer-B2, M_{edit} = ผม ∪ ใบหน้า	0.23
2. Diffusion	Realistic Vision v5.1 (U-Net 4 ช่องสัญญาณ) ผ่าน Inpainting Pipeline ของ Diffusers, ความละเอียด 1024, Strength 0.15, CFG 2.5, UniPC 30 ขั้น (ลบจริงประมาณ 4 ขั้น), Seed 3407	2.15
3. เก็บพื้นหลัง	High-pass $\sigma = 1.2$ หักออก 0.5, น้ำหนัก 0.45, ระยะไล่น้ำหนัก 4–36 พิกเซล, จำกัด ± 4	0.41
4. Native Sharp	Unsharp Mask $\sigma = 0.75$ (0.75) และ $\sigma = 1.35$ (0.25), หักออก 0.8, น้ำหนักผม 0.65 ใบหน้า 0.25, จำกัด ± 5	0.36
รวม		**3.15**

หมายเหตุ: SegFormer = Segmentation Transformer, CFG = Classifier-Free Guidance, UniPC = Unified Predictor-Corrector

ภาคผนวก ข
แบบประเมินที่ใช้ในโครงงาน

ข.1 แบบประเมินภาพแบบปกปิดชื่อโมเดล

แบบประเมินนี้ใช้กับผู้ใช้ 41 คน แต่ละคนส่งภาพใบหน้าของตัวเอง เลือกภาพทรงผมและภาพสีผม แล้วได้รับภาพผลลัพธ์ 4 ภาพจาก 4 ระบบ โดยไม่บอกว่าภาพใดมาจากระบบใด และสุ่มลำดับภาพใหม่สำหรับทุกคน ผู้ใช้ตอบคำถามชุดเดียวกันกับทุกภาพ ตารางที่ 21 คือคำถามและตัวเลือกคำตอบฉบับเต็ม ข้อ 1–5 ตอบเป็นคะแนน 1–5 โดย 1 หมายถึงน้อยที่สุดและ 5 หมายถึงมากที่สุด ส่วนข้อ 6 ให้เลือกช่วงเวลาหนึ่งช่วงจาก 6 ช่วง

ตารางที่ 21 คำถามในแบบประเมินภาพแบบปกปิดชื่อโมเดล

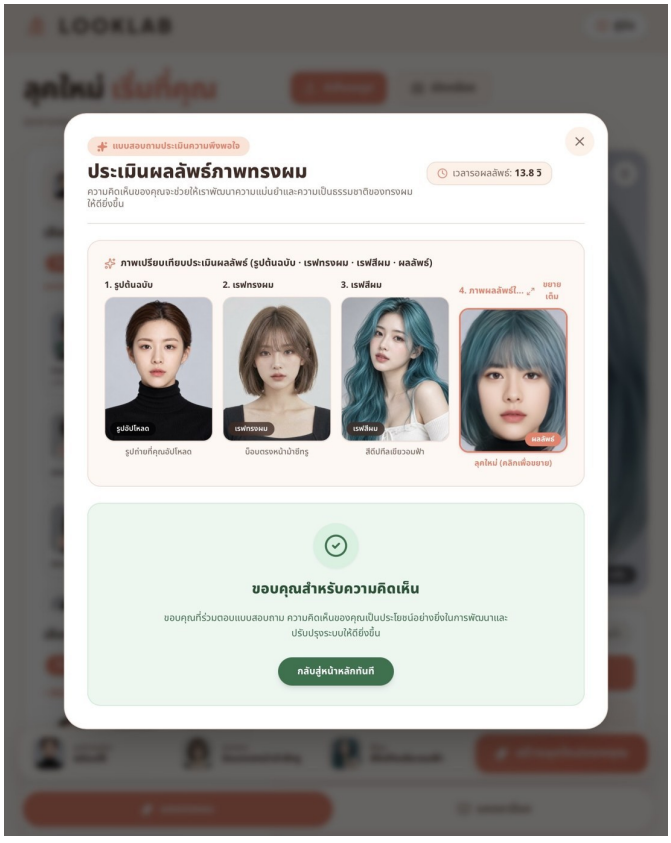
ข้อ	คำถาม	ตัวเลือกคำตอบ
1	ทรงผมใกล้เคียงกับภาพอ้างอิงมากเพียงใด	1 2 3 4 5
2	สีผมตรงกับภาพอ้างอิงมากเพียงใด	1 2 3 4 5
3	ภาพดูสมจริงและเป็นธรรมชาติมากเพียงใด	1 2 3 4 5
4	ใบหน้ายังคงเหมือนตัวคุณมากเพียงใด	1 2 3 4 5
5	คุณพึงพอใจกับภาพนี้สำหรับการใช้งานจริงมากเพียงใด	1 2 3 4 5
6	หากต้องรอให้ระบบสร้างภาพที่มีคุณภาพเหมือนภาพนี้ คุณยินดีรอได้นานที่สุดเท่าใด	น้อยกว่า 1 นาที, 1–5 นาที, 5–10 นาที, 10–20 นาที, 20–40 นาที, มากกว่า 40 นาที

ข.2 แบบประเมินหลังใช้งานเว็บแอปพลิเคชัน

แบบประเมินนี้อยู่ในเว็บ LOOKLAB และเปิดได้จากปุ่ม “แบบสอบถามประเมินผลลัพธ์” หลังได้รับภาพ ใช้เก็บข้อมูลการทดลองใช้งานจริง 100 ครั้งในบทที่ 4 ตารางที่ 22 แสดงหัวข้อทั้งหมดตามลำดับที่ปรากฏบนเว็บ ข้อ 1–6 ให้คะแนน 1–5 ดาว โดยแต่ละระดับมีคำอธิบายกำกับ เช่น ข้อ 1 คือ “ไม่ตรงเลย” “ตรงเล็กน้อย” “ตรงปานกลาง” “ตรงมาก” และ “ตรงตาม reference มากที่สุด” (คำว่า reference บนเว็บหมายถึงภาพอ้างอิง) ในข้อ 1 และ 2 ระบบจะแสดงชื่อทรงผมและสีผมที่ผู้ใช้เลือกไว้ในคำถามด้วย ถ้าผู้ใช้เลือกทรงผมต้นฉบับหรือสีธรรมชาติ คำถามจะเปลี่ยนเป็นการประเมินว่าระบบคงทรงหรือสีเดิมไว้ได้ดีเพียงใด นอกจากคำตอบของผู้ใช้ ระบบยังบันทึกเวลารอจริงของแต่ละครั้งโดยอัตโนมัติ และจะแนบรูปต้นฉบับกับรูปผลลัพธ์ไปกับคำตอบเฉพาะเมื่อผู้ใช้ติ๊กยินยอมเท่านั้น ภาพที่ 39 คือหน้าที่ผู้ใช้เห็นหลังส่งแบบประเมินเรียบร้อยแล้ว

ตารางที่ 22 หัวข้อในแบบประเมินหลังใช้งานเว็บแอปพลิเคชัน LOOKLAB

ข้อ	หัวข้อ	ตัวเลือกคำตอบ
–	คุณอยู่ในช่วงอายุใด (จำเป็นต้องตอบ)	ต่ำกว่า 18, 18–24, 25–34, 35–44, 45–54 และ 55 ปีขึ้นไป
1	ทรงผมในภาพผลลัพธ์ตรงตาม reference แค่ไหน	1–5 ดาว
2	สีผมในภาพผลลัพธ์ตรงตาม reference แค่ไหน	1–5 ดาว
3	ใบหน้าในภาพผลลัพธ์เหมือนใบหน้าต้นฉบับแค่ไหน	1–5 ดาว
4	คุณพอใจกับระยะเวลาที่รอผลลัพธ์แค่ไหน	1–5 ดาว
5	คุณพอใจกับผลลัพธ์โดยรวมมากแค่ไหน	1–5 ดาว
6	คุณพอใจกับการใช้งานเว็บไซต์นี้มากแค่ไหน	1–5 ดาว
–	ข้อเสนอแนะเพิ่มเติม (ไม่บังคับ)	เขียนตอบอิสระ
–	ยินยอมให้เก็บรูปต้นฉบับและรูปผลลัพธ์เพื่อประเมินและปรับปรุงระบบ	เลือกหรือไม่เลือกก็ได้

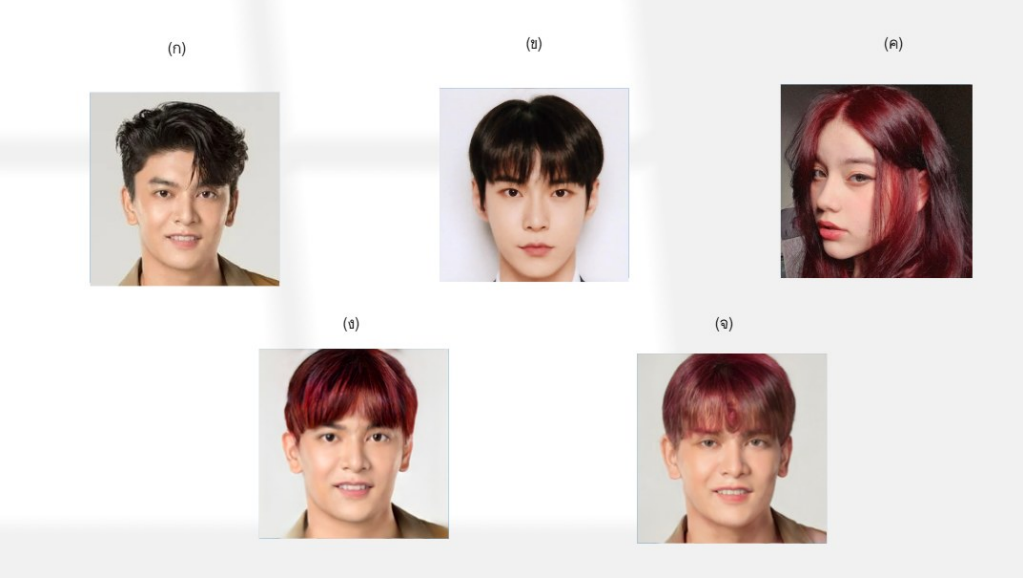


ภาพที่ 39 หน้าหลังส่งแบบประเมินบนเว็บ LOOKLAB

ภาคผนวก ค
ผลการทดลองเพิ่มเติม

ค.1 ตัวอย่างผลลัพธ์ของโมเดลตั้งต้น

ก่อนเริ่มปรับจูน ผู้วิจัยรันโมเดลตั้งต้นทั้งสองตัวกับภาพของผู้วิจัย เพื่อดูว่าแต่ละตัวมีจุดอ่อนอะไร ภาพที่ 40 เป็นตัวอย่างหนึ่งชุด แถวบนคือภาพนำเข้า ได้แก่ (ก) ภาพใบหน้า (ข) ภาพอ้างอิงทรงผม และ (ค) ภาพอ้างอิงสีผม แถวล่างคือผลของ (ง) HairFastGAN และ (จ) Barbershop ทั้งสองโมเดลวางทรงหน้าม้าและสีแดงได้ใกล้ภาพอ้างอิง แต่ผลของ HairFastGAN มีผมเรียบเกินไปจนสีดูเป็นปื้น ส่วนผลของ Barbershop มีเส้นผมมากกว่า แต่หน้าม้าดูไม่เรียบร้อยและสีไม่สม่ำเสมอ ข้อสังเกตจากภาพชุดนี้เป็นจุดเริ่มต้นของการออกแบบฟังก์ชันสูญเสียด้านสีและด้านรายละเอียดผมในบทที่ 3

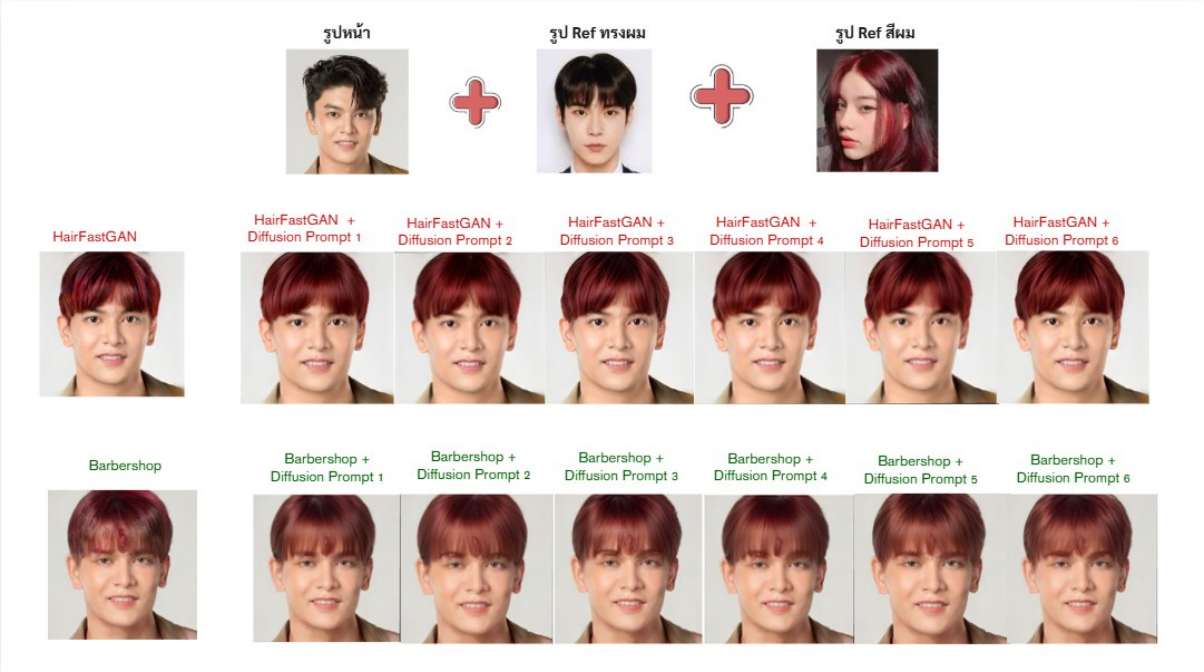


ภาพที่ 40 ตัวอย่างภาพนำเข้าและผลลัพธ์ของ HairFastGAN และ Barbershop ก่อนปรับจูน

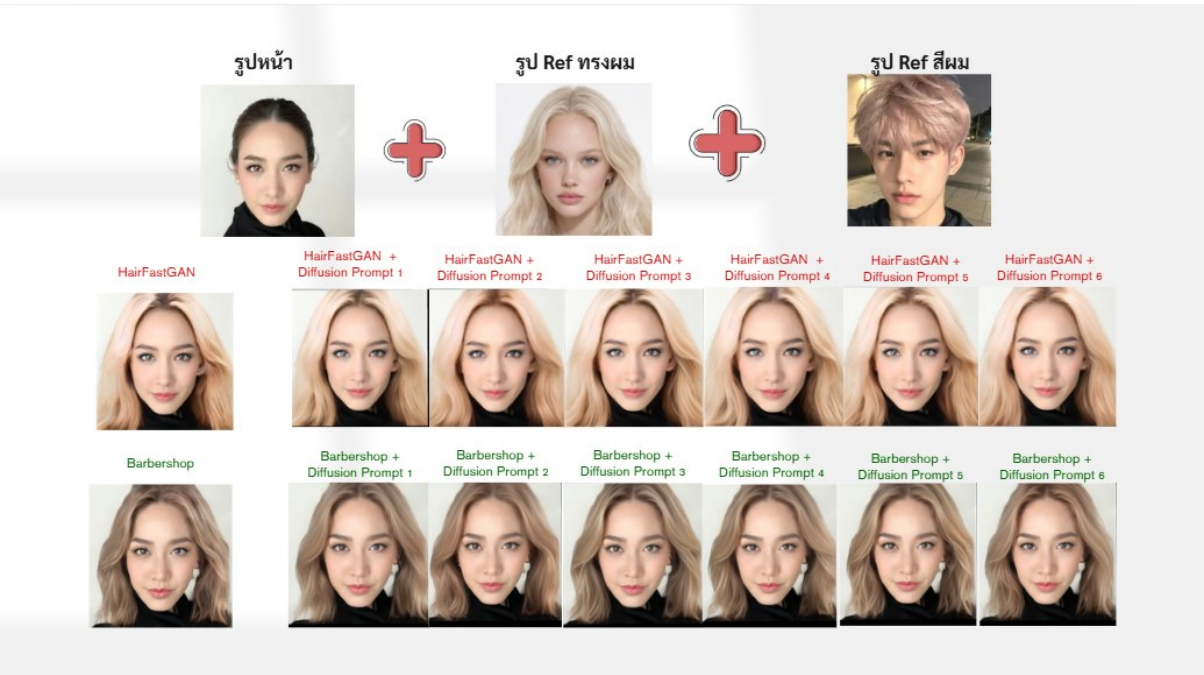
ค.2 การเปรียบเทียบข้อความสั่งงานของ Diffusion

ข้อความสั่งงาน (Prompt) มีผลต่อสิ่งที่ Diffusion วาดเพิ่ม ผู้วิจัยจึงลองข้อความ 6 แบบ (P1–P6) กับภาพจากทั้งสองโมเดลก่อนเลือกข้อความที่ใช้จริง ภาพที่ 41 และ 42 เป็นตัวอย่างสองชุด แถวบนของแต่ละภาพคือภาพนำเข้า 3 ภาพ แถวกลางคือผลของ HairFastGAN ก่อนผ่าน Diffusion (ซ้ายสุด) ตามด้วยผลหลังผ่าน Diffusion ด้วยข้อความที่ 1–6 และแถวล่างคือผลแบบเดียวกันของ Barbershop เมื่อดูด้วยตา ความต่างระหว่างข้อความแต่ละแบบมีน้อย เพราะใช้ความแรงต่ำ ความต่างหลักอยู่ที่ความชัดของเส้นผมและความเข้มของสีผมเล็กน้อย ส่วนทรงผม ใบหน้า และพื้นหลังแทบไม่เปลี่ยนในทุกข้อความ

ภาพที่ 43 วัดผลเดียวกันเป็นตัวเลข แถวบนคือ HairFastGAN และแถวล่างคือ Barbershop แต่ละคอลัมน์คือตัวชี้วัดหนึ่งตัว ได้แก่ SSIM (Structural Similarity Index), อัตราส่วนสัญญาณสูงสุดต่อสัญญาณรบกวน (Peak Signal-to-Noise Ratio: PSNR), ความคล้ายของทรงผมที่วัดด้วย CLIP (CLIP-Shape) และความคล้ายของสีผมที่วัดด้วย CLIP (CLIP-Color) ทุกตัวยิ่งสูงยิ่งดี แท่งสีจางคือภาพก่อนผ่าน Diffusion (Base) แท่งสีกลางคือข้อความ P1–P5 และแท่งสี



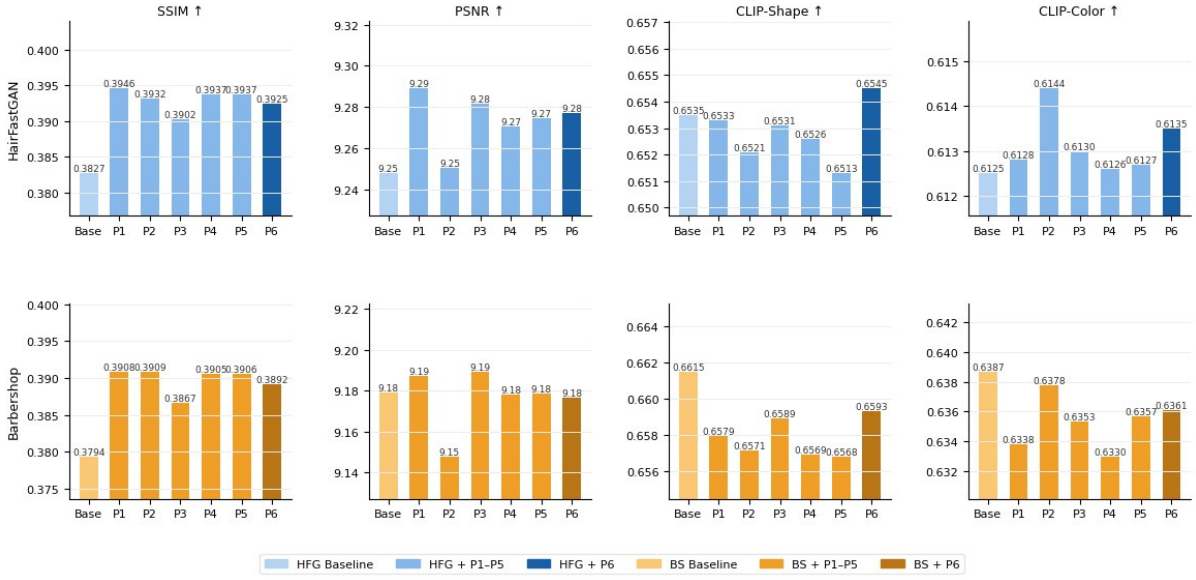
ภาพที่ 41 ผลของข้อความสั่งงาน 6 แบบกับภาพจาก HairFastGAN และ Barbershop (ตัวอย่างที่ 1)



ภาพที่ 42 ผลของข้อความสั่งงาน 6 แบบกับภาพจาก HairFastGAN และ Barbershop (ตัวอย่างที่ 2)

เข้มคือข้อความ P6

ผลที่เห็นคือทุกข้อความทำให้ SSIM สูงกว่าภาพก่อนผ่าน Diffusion (HairFastGAN จาก 0.3827 เป็น 0.390–0.395 และ Barbershop จาก 0.3794 เป็น 0.387–0.391) ส่วน PSNR, CLIP-Shape และ CLIP-Color เปลี่ยนน้อยมาก ส่วนใหญ่ต่างกันไม่ถึง 0.01 ข้อความ P6 เป็นข้อความเดียวที่ทำให้ CLIP-Shape ของ HairFastGAN สูงกว่าก่อนผ่าน Diffusion (0.6545 เทียบกับ 0.6535) และให้ค่าที่ไม่ต่ำกว่าข้อความอื่นมากในทุกตัวชี้วัด ข้อสรุปจากการทดลองนี้คือ เมื่อใช้ความแรงต่ำ การเลือกข้อความสั่งงานมีผลต่อผลลัพธ์ไม่มาก และในการทดลองนี้ Diffusion แทบไม่เปลี่ยนทรงและสีผมเมื่อวัดด้วย CLIP ซึ่งสอดคล้องกับคะแนนทรงและสีผมจากผู้ใช้ในบทที่ 4 แม้กรณีศึกษาเชิงตัวเลขในบทที่ 4 จะพบว่าสีผมของ HairFastGAN เพี้ยนจากเป้าหมายเล็กน้อยหลังผ่าน Diffusion



ภาพที่ 43 ตัวชี้วัดของภาพก่อนผ่าน Diffusion (Base) และหลังผ่านด้วยข้อความ P1–P6

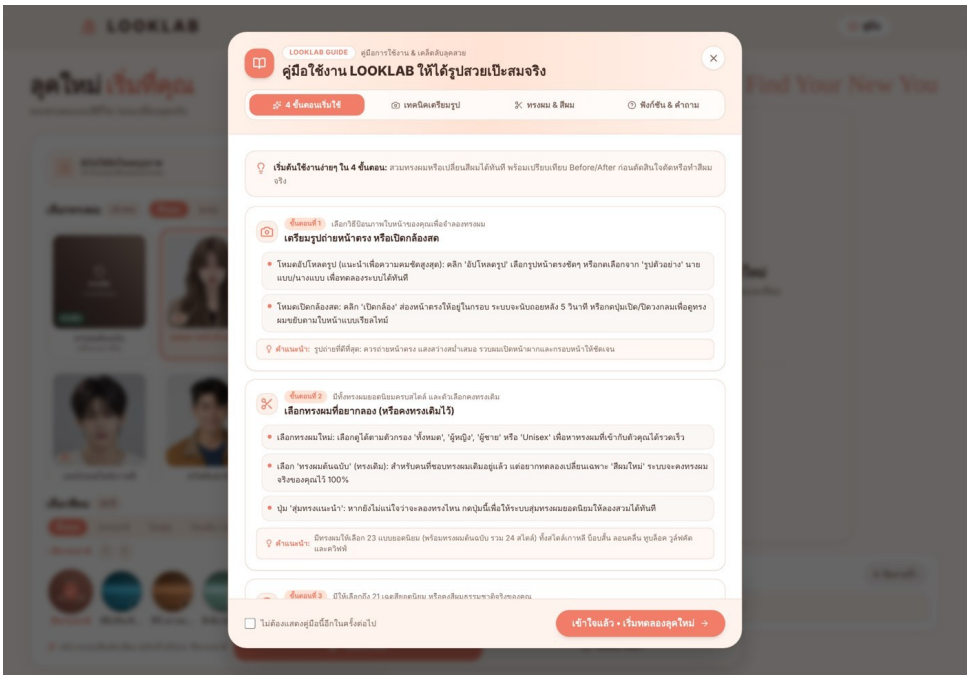
หมายเหตุ: P1–P6 = ข้อความสั่งงาน (Prompt) แบบที่ 1 ถึง 6, HFG = HairFastGAN, BS = Barbershop ก่อนปรับจูน, SSIM = Structural Similarity Index (ดัชนีความคล้ายเชิงโครงสร้าง), PSNR = Peak Signal-to-Noise Ratio, CLIP = Contrastive Language-Image Pre-training

ภาคผนวก ง
คู่มือการใช้งานเว็บแอปพลิเคชัน LOOKLAB

ง.1 การเข้าใช้งาน

LOOKLAB ใช้งานผ่านเว็บเบราว์เซอร์ได้ทันทีโดยไม่ต้องติดตั้งโปรแกรม เข้าได้ที่ https://looklab2.vercel.app/ หรือสแกนคิวอาร์โค้ดในภาพที่ 44 เมื่อเปิดเว็บครั้งแรก ระบบจะแสดงหน้าต่างคู่มือดังภาพที่ 45 ซึ่งมี 4 แท็บ คือ ขั้นตอนเริ่มใช้ เทคนิคเตรียมรูป คำแนะนำทรงผมและสีผม และคำถามที่พบบ่อย ผู้ใช้กด “เข้าใจแล้ว” เพื่อเริ่มใช้งาน และเปิดคู่มือนี้อีกครั้งได้จากปุ่ม “คู่มือ” ที่มุมขวาบน

ภาพที่ 44 คิวอาร์โค้ดสำหรับเข้าเว็บแอปพลิเคชัน LOOKLAB



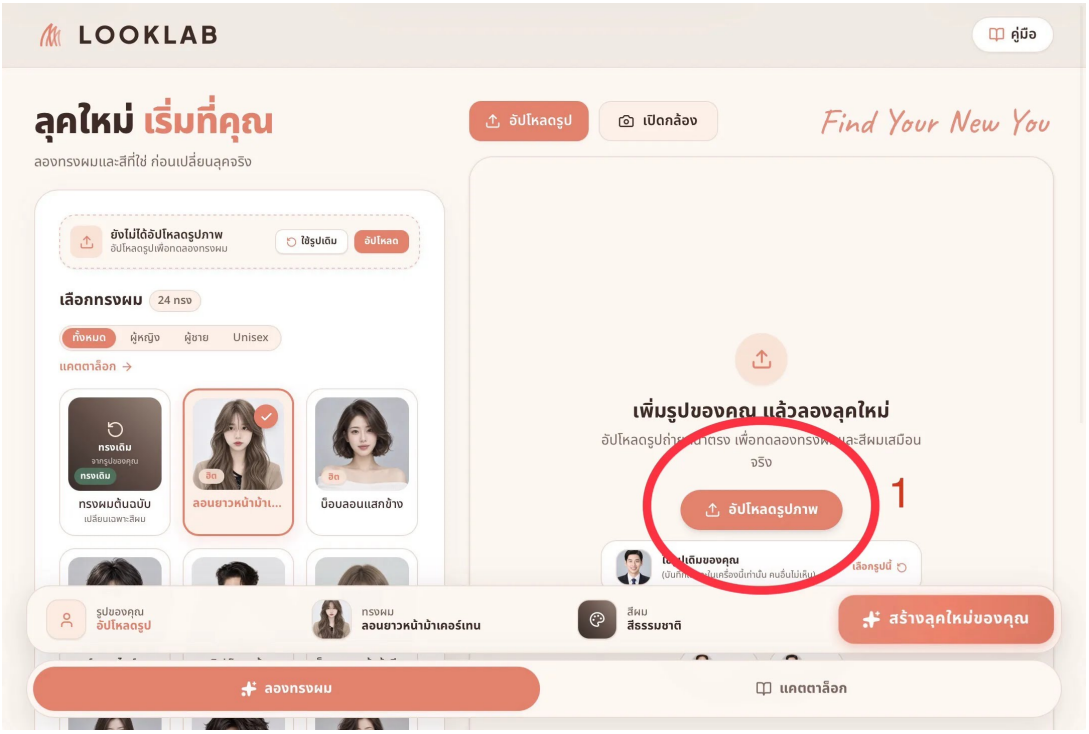
ภาพที่ 45 หน้าต่างคู่มือการใช้งานที่แสดงเมื่อเปิดเว็บครั้งแรก

ง.2 ขั้นตอนการใช้งานโหมดอัปโหลดรูป

หน้าหลักของ LOOKLAB แบ่งเป็น 3 ส่วน ด้านซ้ายเป็นแผงสำหรับเลือกทรงผมและสีผม ด้านขวาเป็นพื้นที่แสดงรูปของผู้ใช้และภาพผลลัพธ์ และด้านล่างเป็นแถบสรุปที่แสดงรูป ทรงผม

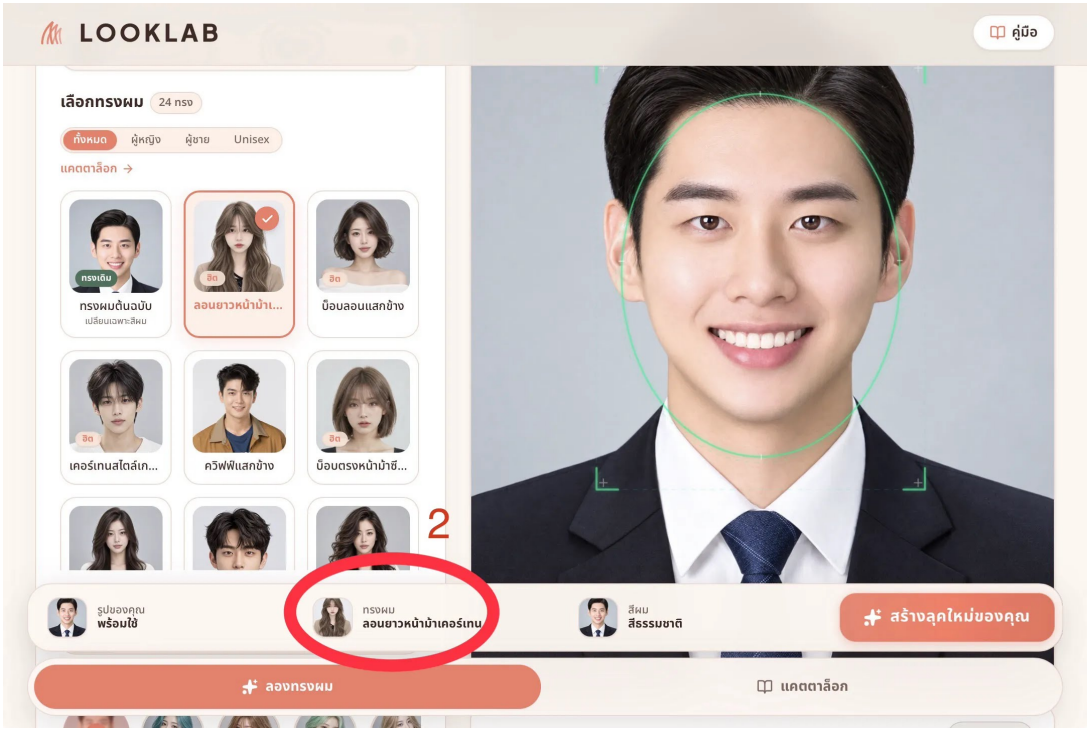
และสีผมที่เลือกอยู่ พร้อมปุ่ม “สร้างลุคใหม่ของคุณ” ผู้ใช้เลือกใช้งานได้ 2 โหมด คือ โหมดอัปโหลดรูป ซึ่งให้ภาพผลลัพธ์คุณภาพสูง และโหมดกล้องสด ซึ่งแสดงทรงผมใหม่บนภาพจากกล้องและขยับตามใบหน้า โหมดอัปโหลดรูปมี 7 ขั้นตอน ดังนี้

ขั้นที่ 1 ใส่รูปใบหน้า มี 3 วิธีให้เลือก วิธีแรกคือกดปุ่ม “อัปโหลดรูปภาพ” กลางพื้นที่ด้านขวา หรือปุ่ม “อัปโหลดรูป” ด้านบน ดังภาพที่ 46 แล้วเลือกรูปหน้าตรงจากเครื่อง หรือลากไฟล์มาวางในพื้นที่ด้านขวา วิธีที่สองคือกด “เปิดกล้อง” เพื่อถ่ายรูปจากกล้อง ซึ่งอธิบายไว้ในหัวข้อที่ ง.3 และวิธีที่สามคือกดรูปตัวอย่าง “ผู้หญิง” หรือ “ผู้ชาย” เพื่อทดลองระบบโดยไม่ต้องใช้รูปของตัวเอง ถ้าเคยใช้งานมาก่อน จะมีกล่อง “ใช้รูปเดิมของคุณ” อยู่ใต้ปุ่มอัปโหลด ให้กด “เลือกรูปนี้” หรือกด “ใช้รูปเดิม” ที่แผงด้านซ้าย รูปเดิมนี้บันทึกไว้เฉพาะในเครื่องของผู้ใช้เท่านั้น คนอื่นมองไม่เห็น



ภาพที่ 46 หน้าหลักก่อนใส่รูปและปุ่มอัปโหลดรูปภาพ

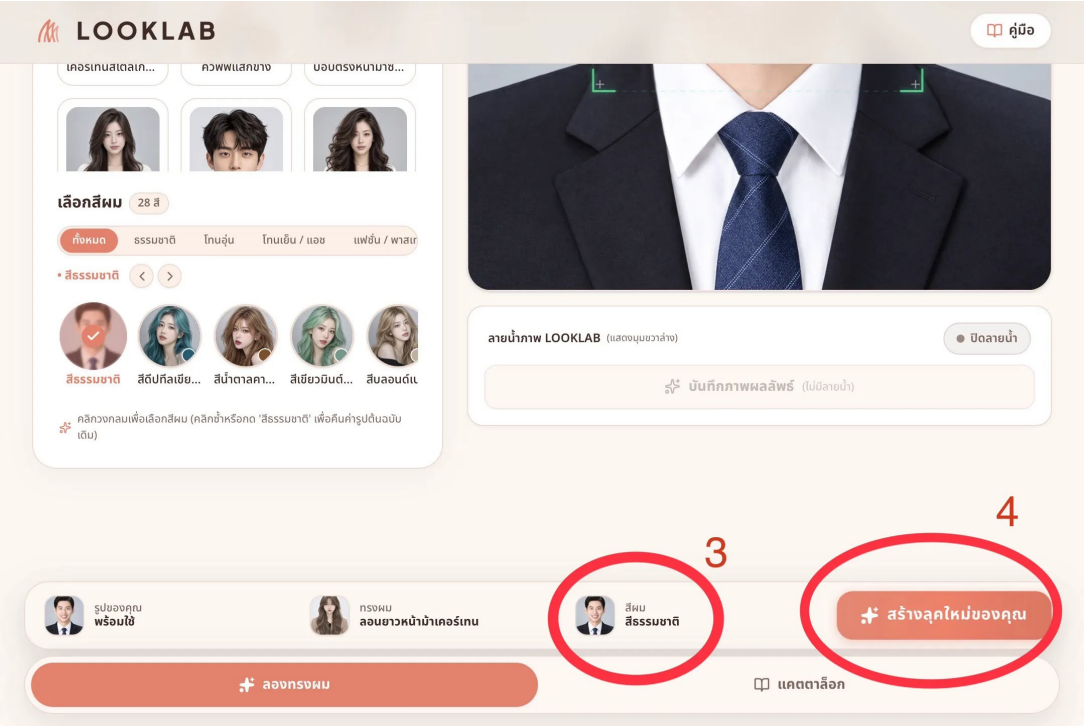
ขั้นที่ 2 ตรวจใบหน้าและเลือกทรงผม เมื่อระบบพบใบหน้า จะแสดงกรอบวงรีสีเขียวรอบใบหน้า และสถานะ “รูปของคุณ” ในแถบด้านล่างจะเปลี่ยนเป็น “พร้อมใช้” จากนั้นเลือกทรงผมจากแผง “เลือกทรงผม” ด้านซ้าย ซึ่งมีทั้งหมด 24 ทรง กรองได้ด้วยแท็บ “ทั้งหมด” “ผู้หญิง” “ผู้ชาย” และ “Unisex” ทรงที่มีป้าย “ฮิต” คือทรงยอดนิยม ทรงที่เลือกอยู่จะมีกรอบสีส้มพร้อมเครื่องหมายถูก และชื่อทรงจะแสดงในช่อง “ทรงผม” ของแถบด้านล่าง ดังภาพที่ 47 ถ้าต้องการเปลี่ยนเฉพาะสีผม ให้เลือกการ์ดแรก “ทรงผมต้นฉบับ” ระบบจะคงทรงผมเดิมไว้ และถ้าอยากดูภาพใหญ่ก่อนตัดสินใจ ให้กด “แคตตาล็อก”



ภาพที่ 47 การตรวจพบใบหน้าและการเลือกทรงผม

ขั้นที่ 3 เลือกสีผม เลื่อนแผงด้านซ้ายลงมาที่ส่วน “เลือกสีผม” ซึ่งมีทั้งหมด 28 สี กรองตามโทนได้ด้วยแท็บ “ทั้งหมด” “ธรรมชาติ” “โทนอุ่น” “โทนเย็น / แอช” และ “แฟชั่น / พาสเทล” และเลื่อนดูสีอื่นได้ด้วยลูกศรซ้ายขวา คลิกที่วงกลมเพื่อเลือกสี ชื่อสีที่เลือกจะแสดงในช่อง “สีผม” ของแถบด้านล่าง ถ้าต้องการเปลี่ยนเฉพาะทรงผม ให้เลือก “สีธรรมชาติ” หรือคลิกซ้ำที่สีที่เลือกอยู่เพื่อกลับไปใช้สีผมเดิมของรูปต้นฉบับ

ขั้นที่ 4 สร้างภาพ ตรวจสอบรูป ทรงผม และสีผมในแถบด้านล่างอีกครั้ง แล้วกดปุ่ม “สร้างลุคใหม่ของคุณ” ทางขวาของแถบ ดังภาพที่ 48



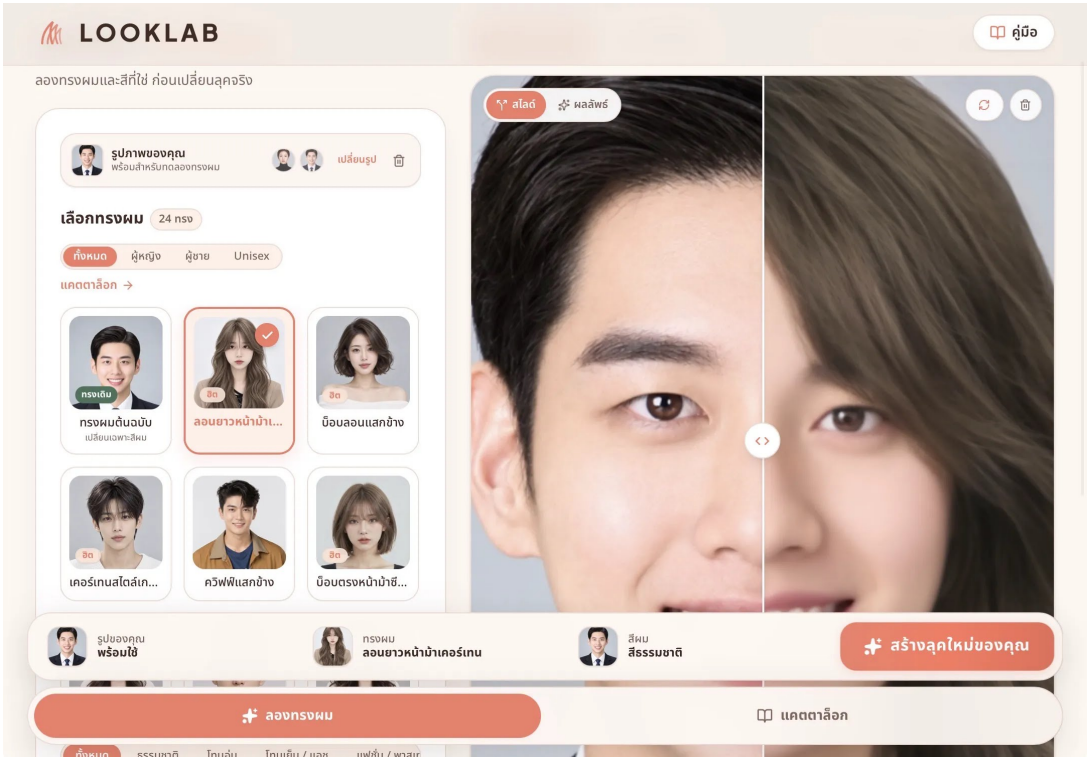
ภาพที่ 48 การเลือกสีผมและปุ่มสร้างลุคใหม่ของคุณ

ขั้นที่ 5 รอระบบประมวลผล ระบบจะแสดงหน้าต่าง “กำลังสร้างลุคทรงผมใหม่” พร้อมรูปต้นฉบับ เวลาประมวลผลที่ผ่านไป สถานะการทำงาน และภาพอ้างอิงทรงผมกับภาพอ้างอิงสีผมที่เลือก ดังภาพที่ 49 จากการทดลองใช้งานจริง ขั้นนี้ใช้เวลาประมาณ 15 วินาที (ค่ามัธยฐาน 14.9 วินาที) ระหว่างรอไม่ควรปิดหรือรีเฟรชหน้าเว็บ ถ้าต้องการเปลี่ยนตัวเลือก ให้กด “ยกเลิกการสร้างภาพ” แล้วกลับไปเลือกใหม่



ภาพที่ 49 หน้าต่างแสดงสถานะระหว่างสร้างภาพทรงผม

ขั้นที่ 6 ดูและบันทึกผลลัพธ์ เมื่อประมวลผลเสร็จ ภาพจะแสดงในโหมด “สไลด์” ซึ่งมีแถบเลื่อนแบ่งภาพ ด้านซ้ายเป็นรูปก่อนเปลี่ยน ด้านขวาเป็นภาพผลลัพธ์ ผู้ใช้ลากปุ่มกลางแถบไปทางซ้ายหรือขวาเพื่อเปรียบเทียบ หรือกด “ผลลัพธ์” เพื่อดูภาพหลังเปลี่ยนทั้งภาพ ดังภาพที่ 50 ใต้ภาพผลลัพธ์มีส่วน “ลายน้ำภาพ LOOKLAB” ให้เลือกเปิดหรือปิดลายน้ำ ซึ่งแสดงที่มุมขวาล่างของภาพ แล้วกด “บันทึกภาพผลลัพธ์” เพื่อเก็บภาพลงเครื่อง ถ้าต้องการลองทรงผมหรือสีผมอื่นกับรูปเดิม ให้เลือกใหม่แล้วกด “สร้างลุคใหม่ของคุณ” อีกครั้งโดยไม่ต้องอัปโหลดรูปใหม่ และถ้าต้องการใช้รูปอื่น ให้กด “เปลี่ยนรูป” ที่การ์ด “รูปภาพของคุณ” ด้านซ้ายบน



ภาพที่ 50 ภาพผลลัพธ์พร้อมแถบเลื่อนเปรียบเทียบก่อนและหลัง

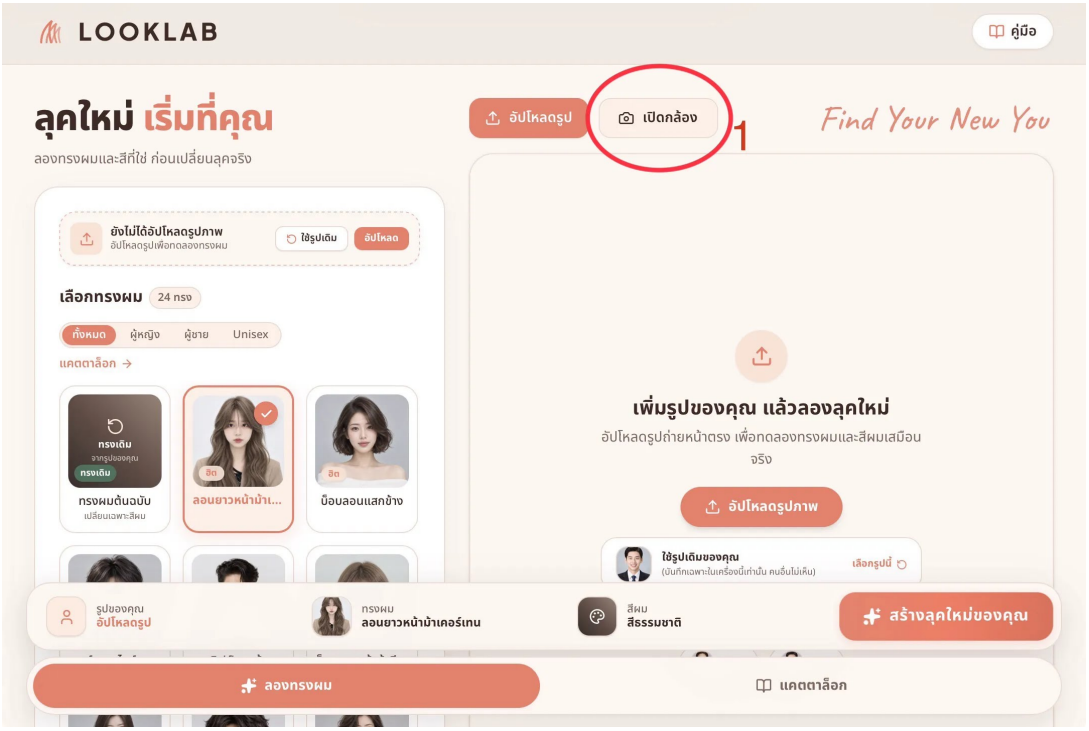
ขั้นที่ 7 ประเมินผลลัพธ์ กด “แบบสอบถามประเมินผลลัพธ์” เพื่อเปิดหน้าต่างประเมินผลลัพธ์ภาพทรงผม ด้านบนแสดงเวลารอผลลัพธ์ และภาพเปรียบเทียบ 4 ภาพ คือ รูปต้นฉบับ ภาพอ้างอิงทรงผม ภาพอ้างอิงสีผม และภาพผลลัพธ์ ผู้ใช้คลิกที่ภาพผลลัพธ์หรือกด “ขยายเต็ม” เพื่อดูภาพขนาดใหญ่ได้ จากนั้นเลือกช่วงอายุ และให้คะแนนแต่ละข้อเป็นดาว 1 ถึง 5 ดวง เช่น ทรงผมในภาพผลลัพธ์ตรงตามภาพอ้างอิงทรงผมมากน้อยเพียงใด ข้อที่มีเครื่องหมายดอกจัน (*) จำเป็นต้องตอบ เมื่อตอบครบแล้วให้ส่งแบบสอบถามที่ท้ายหน้าต่าง หรือกดปุ่มกากบาทที่มุมขวาบนเพื่อปิดหน้าต่าง หน้าต่างแบบสอบถามนี้ใช้ร่วมกันทั้งสองโหมด ตัวอย่างหน้าต่างแสดงไว้ในภาพที่ 53

ง.3 การใช้โหมดกล้องสด

โหมดกล้องสดแสดงทรงผมใหม่บนภาพจากกล้อง และให้ทรงผมขยับตามใบหน้า เหมาะกับการดูภาพรวมจากหลายมุม แต่หลังถ่ายภาพยังต้องรอประมวลผลประมาณ 15 วินาทีก่อนทรง

ผมใหม่จะปรากฏ โหมดนี้มี 5 ขั้นตอน ดังนี้

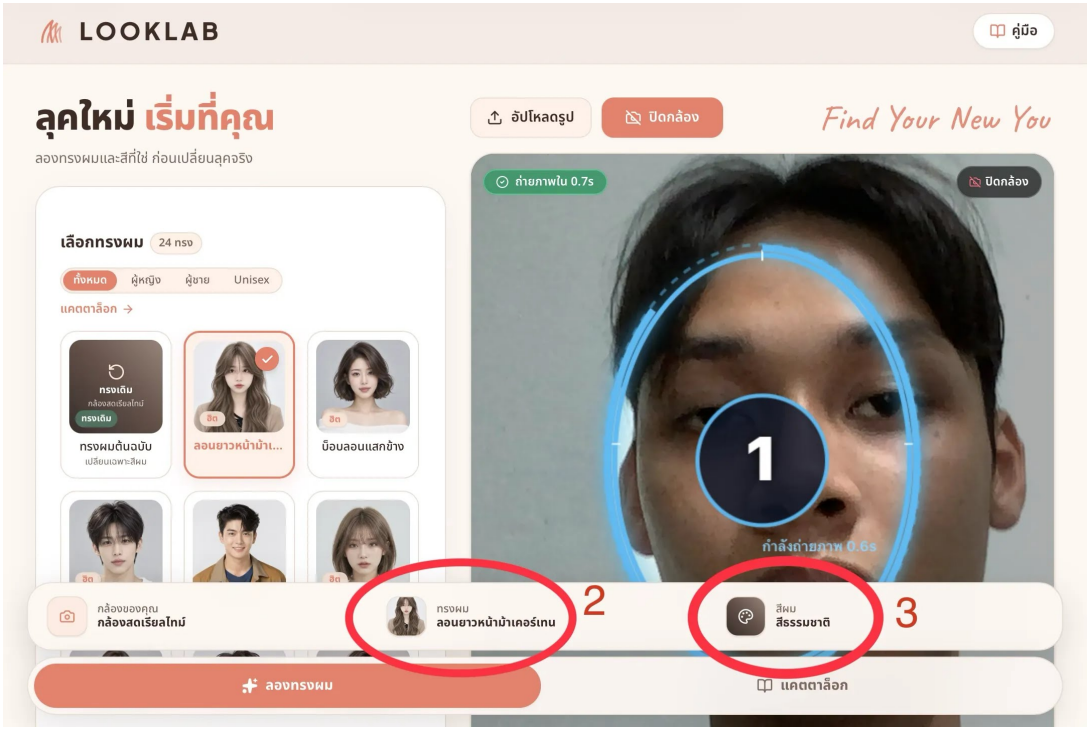
ขั้นที่ 1 เปิดกล้อง กดปุ่ม “เปิดกล้อง” ด้านบนพื้นที่แสดงภาพ ดังภาพที่ 51 เมื่อเบราว์เซอร์ถามสิทธิ์ ให้กดอนุญาตให้เว็บใช้กล้อง ภาพจากกล้องจะแสดงในพื้นที่ด้านขวา และปุ่มด้านบนจะเปลี่ยนเป็น “ปิดกล้อง”



ภาพที่ 51 ปุ่มเปิดกล้องสำหรับเข้าสู่โหมดกล้องสด

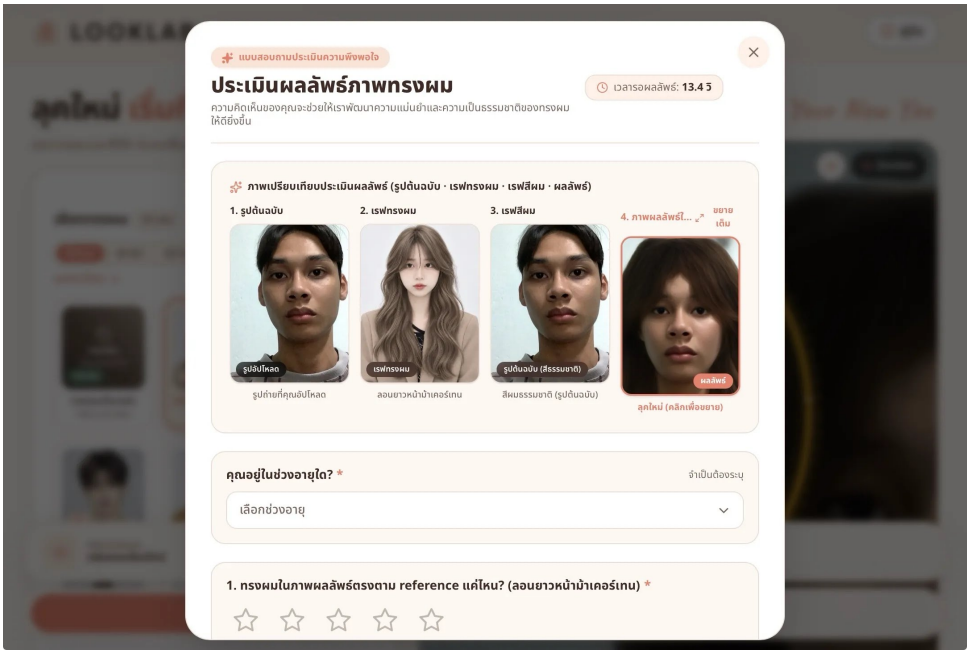
ขั้นที่ 2 เลือกทรงผม เลือกทรงผมจากแผงด้านซ้ายเหมือนโหมดอัปโหลดรูป ในโหมดนี้การ์ด “ทรงผมต้นฉบับ” หมายถึงทรงผมจริงจากกล้องสด และช่องแรกของแถบด้านล่างจะแสดงเป็น “กล้องของคุณ” พร้อมสถานะ “กล้องสดเรียลไทม์” ทรงที่เลือกจะแสดงในช่อง “ทรงผม” ของแถบด้านล่าง

ขั้นที่ 3 เลือกสีผมและถ่ายภาพ เลือกสีผมจากส่วน “เลือกสีผม” ในแผงด้านซ้ายเหมือนโหมดอัปโหลดรูป ชื่อสีที่เลือกจะแสดงในช่อง “สีผม” ของแถบด้านล่าง จากนั้นหันหน้าตรงเข้าหากล้องในระยะที่เห็นตั้งแต่ศีรษะถึงหัวไหล่ ระบบจะบอกให้ขยับใบหน้าจนอยู่ในวงรี เมื่ออยู่ในตำแหน่งแล้ว วงรีจะเปลี่ยนเป็นสีฟ้าและนับถอยหลัง 5 วินาที โดยมุมซ้ายบนของภาพจะแสดงเวลาที่เหลือก่อนถ่ายภาพ ให้อยู่นิ่งจนถ่ายภาพเสร็จ ภาพที่ 52 แสดงช่องทรงผม (ขั้นที่ 2) และช่องสีผม (ขั้นที่ 3) ในแถบด้านล่าง ระหว่างที่ระบบกำลังนับถอยหลังเพื่อถ่ายภาพ



ภาพที่ 52 การเลือกทรงผม สีผม และการนับถอยหลังเพื่อถ่ายภาพในโหมดกล้องสด

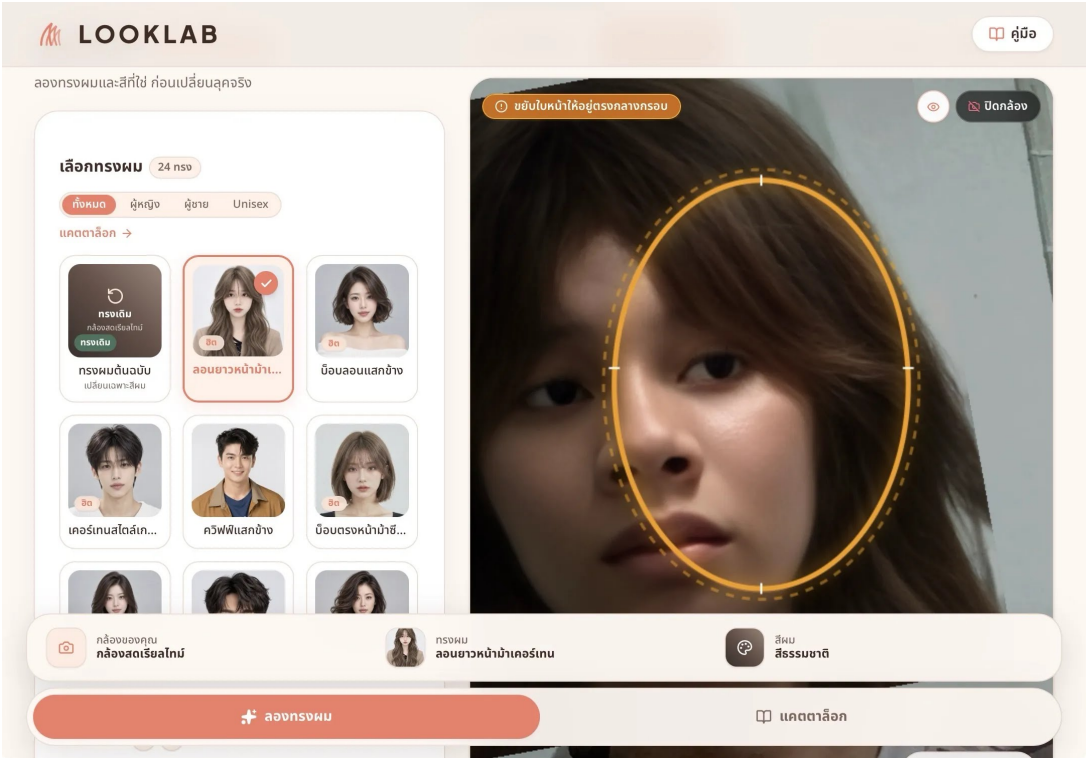
ขั้นที่ 4 ประเมินผลลัพธ์ หลังถ่ายภาพเสร็จ ระบบจะนำภาพที่ถ่ายจากกล้องไปสร้างภาพผลลัพธ์ตามทรงผมและสีผมที่เลือก ผู้ใช้ประเมินผลลัพธ์ได้ด้วยแบบสอบถามเดียวกับขั้นที่ 7 ของโหมดอัปโหลดรูป ซึ่งแสดงรูปที่ถ่ายจากกล้อง ภาพอ้างอิงทรงผม ภาพอ้างอิงสีผม และภาพผลลัพธ์เทียบกัน ดังภาพที่ 53



ภาพที่ 53 หน้าต่างแบบสอบถามประเมินผลลัพธ์ภาพทรงผมจากภาพที่ถ่ายด้วยกล้อง

ขั้นที่ 5 ดูทรงผมบนกล้องสดและบันทึกภาพ ทรงผมใหม่จะปรากฏบนภาพจากกล้องและ

ขยับตามศีรษะ ดังภาพที่ 54 ถ้าใบหน้าเลื่อนออกจากกลางกรอบ วงรีจะเปลี่ยนเป็นสีส้มพร้อมข้อความ “ขยับใบหน้าให้อยู่ตรงกลางกรอบ” ให้ขยับใบหน้ากลับเข้ากลางกรอบเพื่อให้ทรงผมวางได้ตรงตำแหน่ง ผู้ใช้กด “บันทึกภาพนิ่ง” ที่มุมขวาล่างเพื่อเก็บภาพ และกด “ปิดกล้อง” เมื่อใช้งานเสร็จ ถ้าต้องการภาพคุณภาพสูงที่สุด แนะนำให้ใช้โหมดอัปโหลดรูป



ภาพที่ 54 ทรงผมใหม่ที่แสดงบนภาพจากกล้องแบบเรียลไทม์

ง.4 ข้อแนะนำในการเตรียมรูป

ระบบทำงานได้ดีที่สุดกับรูปหน้าตรงในระดับสายตา ที่มีแสงสว่างสม่ำเสมอจากด้านหน้าและไม่ย้อนแสง ควรรวบผมหรือทัดผมให้เห็นหน้าผากและใบหู เพราะผมเดิมที่ปรกหน้าอาจโผล่ทับทรงผมใหม่ ควรถอดแว่นกรอบหนา หมวก หรือที่คาดผม ทำสีหน้าปกติ และไม่เอียงศีรษะ ฉากหลังควรเรียบและไม่กลืนกับสีผม และควรใช้รูปที่คมชัดและไม่ผ่านฟิลเตอร์ปรับรูปหน้า ข้อแนะนำนี้ใช้กับการถ่ายภาพในโหมดกล้องสดด้วย

ง.5 การแก้ปัญหาเบื้องต้น

ถ้าระบบเตือนว่าไม่พบใบหน้า หรือวางทรงผมผิดตำแหน่ง ส่วนใหญ่เกิดจากรูปมืด ย้อนแสง หรือหน้าเอียง ให้ถ่ายรูปใหม่ตามข้อแนะนำในหัวข้อที่ ง.4 แล้วลองอีกครั้ง

ถ้าเปิดกล้องไม่ได้ ให้ตรวจสอบว่าได้อนุญาตให้เว็บใช้กล้องในการตั้งค่าของเบราว์เซอร์แล้ว และไม่มีโปรแกรมอื่นใช้กล้องอยู่ จากนั้นรีเฟรชหน้าเว็บแล้วกด “เปิดกล้อง” อีกครั้ง

ถ้าการสร้างภาพใช้เวลานานกว่าปกติมาก ให้ตรวจสอบการเชื่อมต่ออินเทอร์เน็ต แล้วกด “ยกเลิกการสร้างภาพ” และกด “สร้างลุคใหม่ของคุณ” อีกครั้ง

ถ้ามีข้อสงสัยอื่น ผู้ใช้เปิดแท็บคำถามที่พบบ่อยในหน้าต่างคู่มือได้จากปุ่ม “คู่มือ” ที่มุมขวาบน

ภาคผนวก จ
การนำ Artificial Intelligence (AI) มาใช้ในงานวิจัย

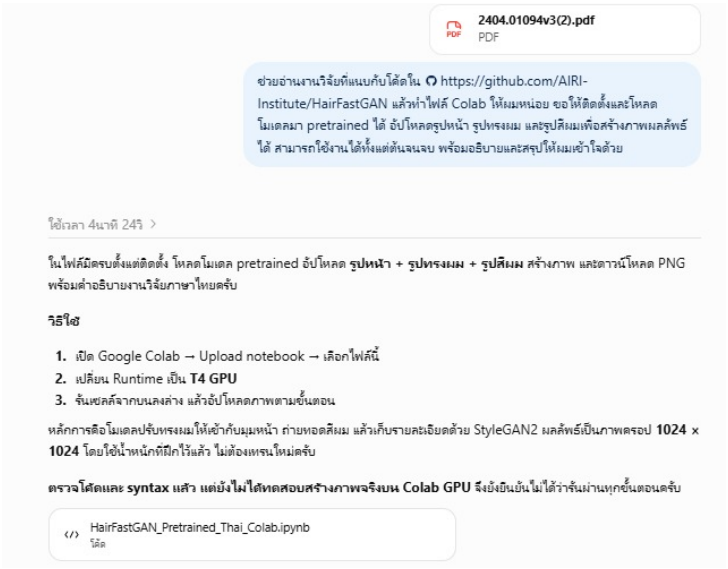
ภาคผนวกนี้บันทึกว่าผู้วิจัยใช้ AI ในขั้นไหนของโครงงานบ้าง โดย AI ที่ใช้ในหัวข้อที่ จ.1 ถึง จ.9 คือ ChatGPT หัวข้อที่ จ.10 คือ Google AI Studio และหัวข้อที่ จ.11 คือ Claude แต่ละหัวข้อเริ่มจากข้อความสั่งงาน (Prompt) ที่ผู้วิจัยพิมพ์จริง ตามด้วยสรุปว่า AI ตอบอะไรกลับมา และปิดท้ายด้วยสิ่งที่ผู้วิจัยทำกับคำตอบนั้น คือนำไปใช้เลย นำไปปรับก่อนใช้ หรือนำไปตรวจสอบกับงานวิจัย โค้ด และผลการรันจริงก่อน หลักที่ผู้วิจัยยึดตลอดคือคำตอบของ AI เป็นเพียงจุดเริ่มต้น ไม่ใช่ข้อเท็จจริงที่เชื่อได้ทันที ทุกค่าที่รายงานในบทที่ 3 และบทที่ 4 มาจากโค้ดที่ผู้วิจัยรันเองและผลที่วัดได้จริง ไม่ได้มาจากคำตอบของ AI

จ.1 การสร้าง Colab ทดลอง HairFastGAN แบบ Pretrained (ChatGPT)

ขั้นแรกของโครงงาน ผู้วิจัยต้องการรัน HairFastGAN ด้วยน้ำหนักที่ผู้พัฒนาฝึกไว้แล้ว (Pretrained) เพื่อดูว่าโมเดลตั้งต้นให้ผลอย่างไร จึงแนบไฟล์งานวิจัย HairFastGAN (arXiv:2404.01094v3) ให้ ChatGPT และส่งข้อความดังนี้

> “ช่วยอ่านงานวิจัยที่แนบกับโค้ดใน https://github.com/AIRI-Institute/HairFastGAN แล้วทำไฟล์ Colab ให้ผมหน่อย ขอให้ติดตั้งและโหลดโมเดลมา pretrained ได้ อัปโหลดรูปหน้า รูปทรงผม และรูปสีผมเพื่อสร้างภาพผลลัพธ์ได้ สามารถใช้งานได้ทั้งแต่ต้นจนจบ พร้อมอธิบายและสรุปให้ผมเข้าใจด้วย”

ChatGPT ตอบกลับเป็นไฟล์ `HairFastGAN_Pretrained_Thai_Colab.ipynb` พร้อมคำอธิบายภาษาไทย ดังภาพที่ 55 ในไฟล์มีขั้นตอนครบตั้งแต่ตรวจ GPU ติดตั้ง Python 3.10 กับ PyTorch 1.13.1 ตามที่โครงการเดิมใช้ ดาวน์โหลดน้ำหนักจาก Hugging Face โดยล็อกรุ่นของโค้ดและน้ำหนักไว้ อัปโหลดภาพทีละบทบาท แล้วเรียก `HairFast.swap(..., align=True)` ของโครงการเพื่อสร้างภาพขนาด 1024×1024 และอธิบายลำดับโมดูล Embedding, Pose, Shape, Color และ Refinement ตามงานวิจัย AI ระบุไว้เองด้วยว่าตรวจเพียงโครงสร้างไฟล์และไวยากรณ์ของโค้ด ยังไม่ได้รันจริงบน GPU และได้เปลี่ยนตัวดำเนินการของ StyleGAN2 เป็นแบบ PyTorch ล้วนเพื่อเลี่ยงการคอมไพล์ CUDA ซึ่งอาจทำให้ความเร็วและตัวเลขต่างจากต้นฉบับเล็กน้อย



ภาพที่ 55 ข้อความสั่งงานและคำตอบของ ChatGPT ในการสร้าง Colab สำหรับรัน HairFastGAN แบบ Pretrained

หมายเหตุ: AI = Artificial Intelligence (ปัญญาประดิษฐ์), GPU = Graphics Processing Unit (หน่วยประมวลผลกราฟิก), T4 = รุ่นของ GPU ที่ Colab มีให้ใช้

ผู้วิจัยไม่ได้ใช้ไฟล์นี้ตามที่ได้มาทั้งหมด แต่ใช้เป็นจุดเริ่มต้นในการทำความเข้าใจโค้ดและรันโมเดลตั้งต้น สิ่งที่ผู้วิจัยตรวจก่อนคือคำอธิบายโมดูลทั้งห้า ว่าตรงกับงานวิจัยและไฟล์ `hair_swap.py` และ `models/` ใน GitHub หรือไม่ ซึ่งเป็นพื้นฐานของหัวข้อที่ 2.3.2 จากนั้นนำโค้ดไปรันจริงบน Colab และแก้ปัญหาที่เกิดระหว่างติดตั้ง เมื่อเข้าสู่ขั้นทดลองจริง ผู้วิจัยย้ายไปใช้ GPU A100 และเขียนสมุดบันทึกของตัวเองเพิ่ม ให้โหลดน้ำหนักที่ปรับจูนแล้วพร้อมตรวจค่าแฮชของไฟล์ ตั้งค่าการผสม F เป็น 0.95 และปิดการหมุนภาพทรงผมให้เหมือนกันทั้งตอนฝึกและตอนทดสอบ รวมทั้งเก็บเวลาประมวลผลของแต่ละขั้นแยกกัน ส่วนเวลาที่ได้จาก Colab ฉบับนี้ ผู้วิจัยไม่ได้นำไปรายงาน เพราะใช้ตัวดำเนินการคนละแบบกับต้นฉบับ ตามที่ AI เตือนไว้

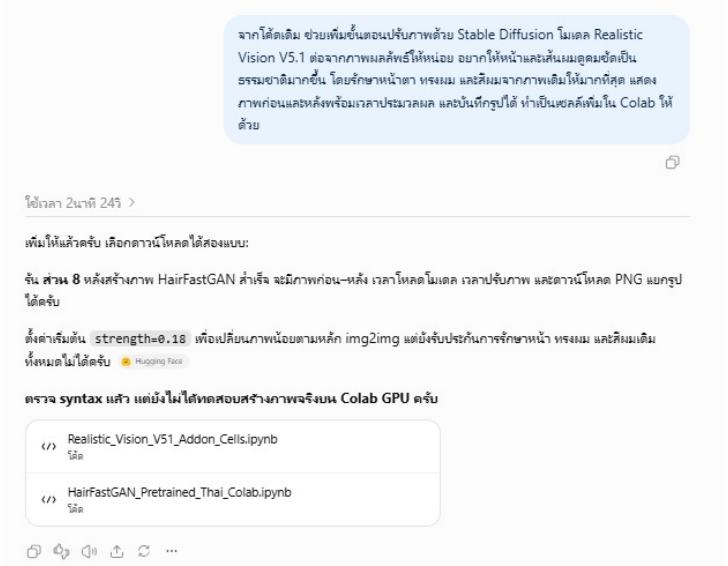
จ.2 การเพิ่มขั้นปรับภาพด้วย Realistic Vision V5.1 (ChatGPT)

หลังได้ภาพจาก HairFastGAN แล้ว ผู้วิจัยเห็นว่าเส้นผมยังนุ่มและเบลอ จึงขอให้ ChatGPT เพิ่มขั้นปรับภาพต่อท้าย

> “จากโค้ดเดิม ช่วยเพิ่มขั้นตอนปรับภาพด้วย Stable Diffusion โมเดล Realistic Vision V5.1 ต่อจากภาพผลลัพธ์ให้หน่อย อยากให้หน้าและเส้นผมดูคมชัดเป็นธรรมชาติมากขึ้น โดยรักษาหน้าตา ทรงผม และสีผมจากภาพเดิมให้มากที่สุด แสดงภาพก่อนและหลังพร้อมเวลาประมวลผล และบันทึกรูปได้ ทำเป็นเซลล์เพิ่มใน Colab ให้ด้วย”

ChatGPT ตอบกลับเป็นเซลล์เพิ่มเติม (`Realistic_Vision_V51_Addon_Cells.ipynb`) ดังภาพที่ 56 แนวทางของ AI คือแปลงทั้งภาพแบบ Image-to-Image ด้วยรุ่น `Realistic_Vision_V5.1_noVAE` คู่กับ VAE (Variational Autoencoder) รุ่น `sd-vae-ft-mse` ตัวลบสัญญาณรบกวน DPM-Solver++ ความแรง 0.18 ค่านำทาง 3.5 จำนวน 30 ขั้น

แล้วนำผลมาผสมกลับกับภาพเดิมทั้งภาพที่สัดส่วน 0.65 พร้อมแสดงภาพก่อน ภาพ Diffusion ล้วน และภาพหลังผสม และแยกเวลาโหลดโมเดลออกจากเวลาปรับภาพ AI เตือนไว้ด้วยว่าข้อความสั่งงานไม่ได้ล็อกใบหน้า และขั้นนี้ไม่รับประกันว่าภาพจะคมขึ้นทุกภาพ



ภาพที่ 56 ข้อความสั่งงานและคำตอบของ ChatGPT ในการเพิ่มขั้นปรับภาพด้วย Realistic Vision V5.1

หมายเหตุ: AI = Artificial Intelligence (ปัญญาประดิษฐ์), GPU = Graphics Processing Unit (หน่วยประมวลผลกราฟิก)

ผู้วิจัยใช้คำตอบนี้เป็นแนวคิดตั้งต้นเท่านั้น และเปลี่ยนวิธีเกือบทั้งหมดก่อนนำไปใช้จริง เหตุผลหลักคือการแปลงทั้งภาพแบบ Image-to-Image ทำให้พื้นหลังและเสื้อผ้าเปลี่ยนไปด้วย และการผสมภาพทั้งภาพที่สัดส่วนคงที่ไม่ได้แยกว่าส่วนไหนควรเปลี่ยนมากหรือน้อย ขั้นที่ใช้จริง (หัวข้อที่ 3.9) จึงเปลี่ยนเป็น Stable Diffusion Inpainting ที่ใช้ SegFormer-B2 สร้างหน้ากากให้แก้ได้เฉพาะผมกับใบหน้า ลดความแรงเหลือ 0.15 ลดค่านำทางเหลือ 2.5 ใช้ตัวลบสัญญาณรบกวน UniPC (Unified Predictor-Corrector) และเขียนข้อความสั่งงานใหม่ จากนั้นเพิ่มขั้นเก็บพื้นหลังและขั้นเพิ่มความคมที่ผู้วิจัยออกแบบเอง ค่าที่เลือกทั้งหมดมาจากการทดลองเปรียบเทียบของผู้วิจัย เช่น การเทียบข้อความสั่งงาน 6 แบบในภาคผนวก ค และวัดผลด้วย MUSIQ (Multi-scale Image Quality Transformer) ArcFace IoU (Intersection over Union) และความเห็นของผู้ใช้ในบทที่ 4 สิ่งที่ผู้วิจัยคงไว้จากคำตอบของ AI มีเพียงแนวคิดใช้ความแรงต่ำ การแสดงภาพก่อนและหลังเทียบกัน และการแยกเวลาโหลดโมเดลออกจากเวลาประมวลผล

จ.3 การวิเคราะห์ว่าส่วนไหนของ HairFastGAN ปรับจูนได้ (ChatGPT)

ก่อนเริ่มปรับจูน ผู้วิจัยต้องการรู้ว่าโค้ดของ HairFastGAN เปิดให้ฝึกส่วนไหนได้บ้าง และต้องการแยกให้ชัดว่าอะไรคือการปรับจูนน้ำหนักจริง อะไรเป็นแค่การปรับค่าตอนสร้างภาพ จึงถาม ChatGPT ว่า

> “ช่วยดูงานวิจัย โค้ดใน github ให้หน่อยว่าโมเดลเขาสามารถ fine-tune ตรงไหนได้บ้าง แต่ละส่วนทำหน้าที่อะไร และควรเลือกปรับส่วนไหนให้เหมาะกับงานของผม ต้องเตรียมข้อมูลและ

ฝึกยังไง ช่วยแยกด้วยว่าอันไหนเป็นการ fine-tune น้ำหนักโมเดลจริง และอันไหนเป็นแค่การปรับค่าตอนสร้างภาพ ขอวิเคราะห์จากโค้ดจริงและอธิบายให้เข้าใจง่ายก่อน ยังไม่ต้องเขียนโค้ด”

ChatGPT ตอบเป็นคำอธิบายยาวที่แบ่งเป็นหลายส่วน ภาพที่ 57 แสดงข้อความสั่งงานและตอนต้นของคำตอบ และภาพที่ 58 แสดงตารางที่แยกการปรับจูนจริงออกจากการปรับค่าใจความหลักของคำตอบมีดังนี้ AI อธิบายหน้าที่ของแต่ละโมดูลและบอกว่าโมดูลไหนมีสคริปต์ฝึกในโครงการ แนะนำให้เริ่มปรับจูนโมดูล Refinement (PostProcess) ก่อน เพราะตรงกับปัญหาใบหน้าและรายละเอียด โดยให้ล็อก `encoder_face` ไว้ก่อน แล้วค่อยพิจารณาปรับ Blending เมื่อพบปัญหาสีผม AI ยังเตือนจุดที่ต้องระวังในโค้ด เช่น ตัวโหลดน้ำหนักใช้ `strict=False` ซึ่งโหลดไม่ครบก็ไม่แจ้งเตือน และสคริปต์ฝึก Blending กับ Rotate สร้างโมเดลใหม่โดยไม่ได้โหลดน้ำหนักเดิมให้อัตโนมัติ ด้านข้อมูล AI บอกว่าไม่จำเป็นต้องมีภาพคนเดิมหลังเปลี่ยนทรงจริง และควรแบ่งชุดข้อมูลตามบุคคล ด้านการฝึก AI แนะนำอัตราการเรียนรู้ราว 1×10^{-5} ถึง 5×10^{-5} ให้เลือก Checkpoint จากชุดตรวจสอบโดยดูหลายด้านพร้อมกัน ไม่ใช่ดูค่าสูญเสียตอนฝึกอย่างเดียว และเสนอให้ทดลองเทียบ 4 เงื่อนไข คือ โมเดลตั้งต้น โมเดลที่ปรับจูน และทั้งสองแบบเมื่อต่อ Diffusion ท้ายคำตอบ AI ย้ำว่า Colab ที่ทำให้ก่อนหน้ายังเป็นแค่การรันโมเดลตั้งต้นต่อด้วย Diffusion ยังไม่มีการปรับจูนน้ำหนัก



ภาพที่ 57 ข้อความสั่งงานและตอนต้นของคำตอบ ChatGPT เรื่องส่วนที่ปรับจูนได้ของ HairFast-GAN

หมายเหตุ: AI = Artificial Intelligence (ปัญญาประดิษฐ์), e4e = Encoder for Editing, CLIP = Contrastive Language-Image Pre-training, BiSeNet = Bilateral Segmentation Network, StyleGAN2 = Style-based Generative Adversarial Network รุ่นที่ 2



6. อะไรเป็น fine-tune จริง และอะไรเป็นแค่ปรับค่า

สิ่งที่ทำ	จัดเป็นอะไร
โหลด pretrained แล้วสร้างภาพ	**Inference**
เปลี่ยน `mixing`, `smooth`, seed หรือการครอป	**ปรับค่าตอน inference**
เปลี่ยน prompt, strength, CFG, steps ของ Realistic Vision	**ปรับค่าตอน inference**
ผสมภาพ diffusion กลับกับภาพเดิมด้วย `BLEND_ALPHA`	**Post-processing**
เปลี่ยน scheduler หรือเพิ่ม upscaler	**ปรับ pipeline**
ปรับ latent ของภาพเดียว โดยไม่เปลี่ยนน้ำหนักเครือข่าย	**Latent optimization**
เปลี่ยน learning rate แต่ไม่ได้รันอัปเดตน้ำหนัก	ยังไม่เกิดการ fine-tune
โหลด checkpoint เดิม คำนวณ loss ทำ backward และ optimizer step เพื่อเปลี่ยนน้ำหนัก แล้วบันทึก checkpoint ใหม่	**Fine-tuning จริง**
ฝึก LoRA ให้ Realistic Vision	**Fine-tuning ของ Diffusion ผ่าน adapter** แต่ไม่ใช่ fine-tune HairFastGAN

สำหรับ Colab ที่ผมทำให้ก่อนหน้านี้ **ยังเป็น pretrained inference ของ HairFastGAN ต่อด้วย Diffusion inference เท่านั้น ยังไม่มีการ fine-tune น้ำหนักครับ**

ภาพที่ 58 ตารางในคำตอบของ ChatGPT ที่แยกการปรับจูนน้ำหนักจริงออกจากการปรับค่าตอนสร้างภาพ

หมายเหตุ: AI = Artificial Intelligence (ปัญญาประดิษฐ์), CFG = Classifier-Free Guidance, LoRA = Low-Rank Adaptation

คำตอบนี้มีประโยชน์ที่สุดในสามข้อ เพราะช่วยให้ผู้วิจัยเห็นภาพรวมของโค้ดและกำหนดขอบเขตงานได้ แต่ผู้วิจัยตรวจทุกประเด็นกับโค้ดจริงก่อน และตัดสินใจหลายเรื่องต่างจากที่ AI แนะนำ เรื่องที่ผู้วิจัยใช้ตามคำตอบ ได้แก่ การแยกการปรับจูนจริงออกจากการปรับค่าตอนสร้างภาพ การล็อกโมดูล Embedding, Pose และ Shape ไว้ การเลือก Checkpoint จากชุดตรวจสอบโดยดูหลายด้าน และแนวคิดเทียบโมเดลทั้งก่อนและหลังต่อ Diffusion ซึ่งกลายเป็นโครงของแบบประเมินผู้ใช้ เรื่องที่ผู้วิจัยตรวจแล้วแก้ คือคำเตือนเรื่อง `strict=False` ในโค้ดที่ใช้จริง ผู้วิจัยโหลดน้ำหนักด้วย `strict=True` และตรวจว่าชื่อพารามิเตอร์ที่ฝึกตรงกับชั้น Modulation ของ Blending Encoder ครบทุกตัว ส่วนเรื่องที่ผู้วิจัยทำต่างจากคำแนะนำมีสี่เรื่อง เรื่องแรก ผู้วิจัยปรับจูนทั้ง Blending (เฉพาะชั้น Modulation) และ PostProcess ทั้งโมดูลพร้อมกัน เพราะผลจากโมเดลตั้งต้นมีปัญหาทั้งสีผมที่เป็นปื้นและใบหน้าซีด เรื่องที่สอง ผู้วิจัยใช้อัตราการเรียนรู้เท่ากับหรือต่ำกว่าที่ AI แนะนำ คือ 1×10^{-5} และ 5×10^{-6} สำหรับ Blending และ 1×10^{-6} และ 5×10^{-7} สำหรับ PostProcess (ตารางที่ 5) เรื่องที่สาม ผู้วิจัยไม่ได้ใช้ฟังก์ชันสูญเสียเดิมของโครงการ แต่ออกแบบฟังก์ชันสูญเสีย 5 ด้านขึ้นเอง (หัวข้อที่ 3.6.1) และใช้ชุดเดียวกันกับ Barbershop เพื่อให้เปรียบเทียบสองโมเดลได้ยุติธรรม เรื่องสุดท้าย ผู้วิจัยเพิ่มเกณฑ์ผ่าน 5 ด่านในการเลือก Checkpoint ซึ่งไม่มีในคำตอบของ AI และขยายงานไปปรับจูน Barbershop ด้วย ซึ่งอยู่นอกขอบเขตของคำถามนี้

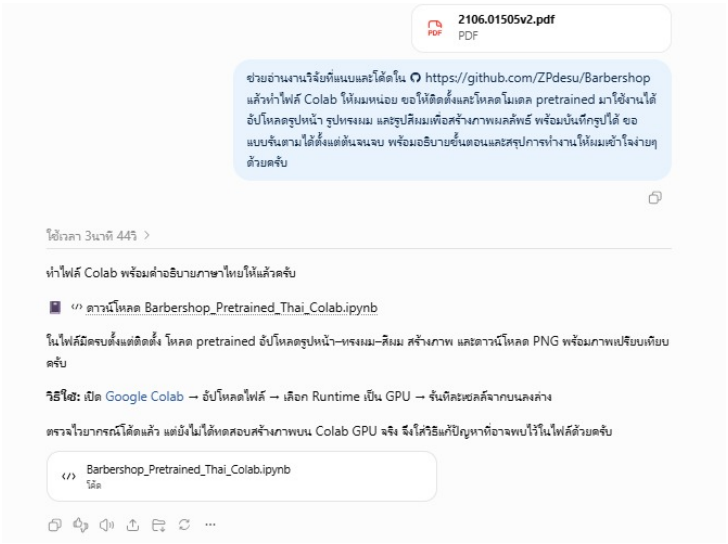
จ.4 การสร้าง Colab ทดลอง Barbershop แบบ Pretrained (ChatGPT)

หลังได้ผลของ HairFastGAN แล้ว ผู้วิจัยต้องการรัน Barbershop แบบ Pretrained เพื่อใช้เป็นโมเดลเปรียบเทียบ จึงแนบไฟล์งานวิจัย Barbershop (arXiv:2106.01505v2) ให้ ChatGPT

และส่งข้อความดังนี้

> “ช่วยอ่านงานวิจัยที่แนบและโค้ดใน https://github.com/ZPdesu/Barbershop แล้วทำไฟล์ Colab ให้ผมหน่อย ขอให้ติดตั้งและโหลดโมเดล pretrained มาใช้งานได้ อัปโหลดรูปหน้า รูปทรงผม และรูปสีผมเพื่อสร้างภาพผลลัพธ์ พร้อมบันทึกรูปได้ ขอแบบรันตามได้ตั้งแต่ต้นจนจบ พร้อมอธิบายขั้นตอนและสรุปการทำงานให้ผมเข้าใจง่าย ๆ ด้วยครับ”

ChatGPT ตอบกลับเป็นไฟล์ `Barbershop_Pretrained_Thai_Colab.ipynb` ดังภาพที่ 59 ในไฟล์ล็อกรุ่นของโค้ดจาก GitHub ไว้ ดาวน์โหลดน้ำหนัก StyleGAN2 กับ BiSeNet และโมเดลจุดสังเกตบนใบหน้า จัดแนวใบหน้าเป็นภาพ 1024×1024 แล้วรันโค้ดของผู้พัฒนาตามลำดับ คือค้นหารหัสใน W^+ ค้นหาต่อใน FS จัดรูปตามหน้ากาก และผสมสไตล์ โดยมีโหมด `official` ที่ใช้จำนวนรอบตามค่าเริ่มต้นของโค้ด (1,100 / 250 / 140 / 100 / 400 รอบ) และโหมด `preview` ที่ลดรอบไว้ทดสอบระบบเท่านั้น ChatGPT ยังแก้โค้ดเดิมบางจุดให้รันบน Colab รุ่นปัจจุบันได้ เช่น คำสั่งย่อภาพของ Pillow ที่เลิกใช้แล้ว การโหลดน้ำหนักด้วย PyTorch รุ่นใหม่ และการกันหารด้วยศูนย์เมื่อหน้ากากว่าง พร้อมบันทึกรายการที่แก้ไว้ในไฟล์แยก และระบุว่ายังไม่ได้รันสร้างภาพจริงบน GPU



ภาพที่ 59 ข้อความสั่งงานและคำตอบของ ChatGPT ในการสร้าง Colab สำหรับรัน Barbershop แบบ Pretrained

หมายเหตุ: GPU = Graphics Processing Unit (หน่วยประมวลผลกราฟิก), PNG = Portable Network Graphics (ไฟล์ภาพ)

ไฟล์นี้เป็นส่วนที่ผู้วิจัยนำไปใช้ต่อมากที่สุดในบรรดาคำตอบทั้งหมด แต่ก็ใช้หลังจากตรวจกับโค้ดต้นฉบับแล้ว ผู้วิจัยเปิดไฟล์ `main.py` ใน GitHub เทียบว่าจำนวนรอบในโหมด `official` ตรงกับค่าเริ่มต้นจริง และดูว่าการแก้โค้ดแต่ละจุดไม่ได้เปลี่ยนวิธีการของ Barbershop จากนั้นนำไปรันจริง และใช้ค่าเดียวกันนี้ในขั้นทดลอง ได้แก่ จำนวนรอบตามค่าเริ่มต้นทั้งหมด โหมด `realistic` ค่าเรียบของหน้ากาก 5 และการแก้การโหลดน้ำหนักกับคำสั่งย่อภาพแบบเดียวกัน โหมด `preview` ผู้วิจัยไม่ได้ใช้กับผลที่รายงาน เพราะ ChatGPT เตือนไว้เองว่าไม่

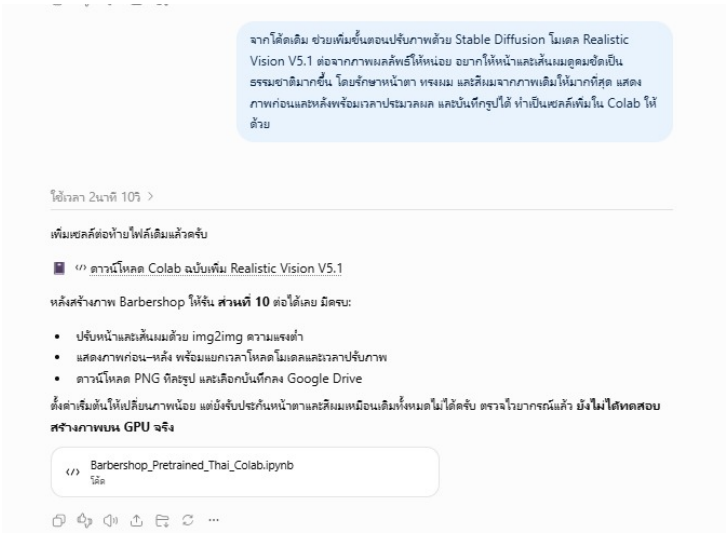
ควรใช้เป็นผลตั้งต้น สิ่งที่ผู้วิจัยเขียนเพิ่มเองสำหรับการทดลอง คือให้รันการค้นหารหัสของแต่ละภาพเพียงครั้งเดียวแล้วเก็บไว้ใช้ซ้ำ ตรวจว่าน้ำหนักตัวสร้างภาพไม่ถูกเปลี่ยนระหว่างรัน และจับเวลาของแต่ละขั้นแยกกัน

จ.5 การเพิ่มขั้นปรับภาพต่อจาก Barbershop (ChatGPT)

เมื่อได้ภาพจาก Barbershop แล้ว ผู้วิจัยขอให้ ChatGPT เพิ่มขั้นปรับภาพต่อท้าย ด้วยข้อความเดียวกับที่ใช้กับ HairFastGAN

> “จากโค้ดเดิม ช่วยเพิ่มขั้นตอนปรับภาพด้วย Stable Diffusion โมเดล Realistic Vision V5.1 ต่อจากภาพผลลัพธ์ให้หน่อย อยากให้หน้าและเส้นผมดูคมชัดเป็นธรรมชาติมากขึ้น โดยรักษาหน้าตา ทรงผม และสีผมจากภาพเดิมให้มากที่สุด แสดงภาพก่อนและหลังพร้อมเวลาประมวลผล และบันทึกรูปได้ ทำเป็นเซลล์เพิ่มใน Colab ให้ด้วย”

ChatGPT เพิ่มส่วนที่ 10 ต่อท้ายไฟล์เดิม ดังภาพที่ 60 แนวทางยังเป็น Image-to-Image ทั้งภาพเหมือนของ HairFastGAN แต่ค่าต่างออกไปเล็กน้อย คือความแรง 0.15 ค่านำทาง 3.5 จำนวน 40 ขั้น และผสมภาพจาก Diffusion ร้อยละ 70 กับภาพเดิมร้อยละ 30 พร้อมแสดงภาพก่อนและหลัง แยกเวลาโหลดโมเดลออกจากเวลาปรับภาพ และเลือกบันทึกลง Google Drive ได้ ChatGPT ระบุไว้ว่ายังไม่ได้ทดสอบบน GPU จริง และข้อความ “same person” ในข้อความสั่งงานไม่ได้ล็อกใบหน้าให้เหมือนเดิม



ภาพที่ 60 ข้อความสั่งงานและคำตอบของ ChatGPT ในการเพิ่มขั้นปรับภาพต่อจาก Barbershop

หมายเหตุ: GPU = Graphics Processing Unit (หน่วยประมวลผลกราฟิก), PNG = Portable Network Graphics (ไฟล์ภาพ)

ผู้วิจัยไม่ได้ใช้ค่าชุดนี้ ปัญหาที่พบคือคำตอบของ ChatGPT ให้ค่าไม่เท่ากันระหว่างสองโมเดล (HairFastGAN ความแรง 0.18 ผสม 0.65 แต่ Barbershop ความแรง 0.15 ผสม 0.70) ถ้านำไปใช้ตรง ๆ จะเปรียบเทียบผลของ Diffusion ระหว่างสองโมเดลไม่ได้ ผู้วิจัยจึงใช้ขั้นขัดเกลาชุดเดียวกันกับภาพจากทั้งสองโมเดล ตามที่อธิบายในหัวข้อที่ จ.2 คือ Inpainting เฉพาะผมกับ

ใบหน้า ความแรง 0.15 ค่านำทาง 2.5 UniPC 30 ขั้น และ Seed 3407 สิ่งที่คงไว้จากคำตอบนี้คือแนวคิดแยกเวลาโหลดโมเดลออกจากเวลาประมวลผล และการเก็บภาพก่อนและหลังไว้เทียบกัน

จ.6 การวิเคราะห์ว่าส่วนไหนของ Barbershop ปรับจูนได้ (ChatGPT)

ผู้วิจัยถามคำถามเดียวกับหัวข้อที่ จ.3 แต่เปลี่ยนเป็น Barbershop เพราะต้องการรู้ว่าโมเดลที่ไม่มีเครือข่ายทายรหัสจะปรับจูนตรงไหนได้บ้าง

> “ช่วยดูงานวิจัย โค้ดใน github ให้หน่อยว่าโมเดลเขาสามารถ fine-tune ตรงไหนได้บ้าง แต่ละส่วนทำหน้าที่อะไร และควรเลือกปรับส่วนไหนให้เหมาะกับงานของผม ต้องเตรียมข้อมูลและฝึกยังไง ช่วยแยกด้วยว่าอันไหนเป็นการ fine-tune น้ำหนักโมเดลจริง ๆ และอันไหนเป็นแค่การปรับค่าตอนสร้างภาพ ขอวิเคราะห์จากโค้ดจริงและอธิบายให้เข้าใจง่ายก่อน ยังไม่ต้องเขียนโค้ด”

ChatGPT ตอบว่าประเด็นสำคัญที่สุดคือ Barbershop เดิมไม่ได้ปรับจูนน้ำหนักโมเดลเลย ดังภาพที่ 61 แม้ในโค้ดจะมีการหาอนุพันธ์และตัวปรับค่าทำงานทุกรอบ แต่สิ่งที่ถูกปรับคือรหัสแฝงของแต่ละภาพ ส่วนน้ำหนักของ StyleGAN2 และ BiSeNet ถูกล็อกไว้ จากนั้นเสนอทางเลือกที่เป็นการปรับจูนจริง ได้แก่ ปรับจูน BiSeNet ปรับ StyleGAN2 บางส่วน ปรับตัวสร้างภาพเฉพาะบุคคล (Pivotal Tuning Inversion: PTI) ฝึก LoRA ของ Realistic Vision หรือฝึกตัวเข้ารหัสเพิ่ม ถ้าเลือกปรับ StyleGAN2 ChatGPT แนะนำให้เริ่มจากบล็อกช่วงหลังที่คุมรายละเอียด และล็อก Mapping Network กับบล็อกช่วงต้นไว้ ดังภาพที่ 62 และเตือนว่าตัวสร้างภาพที่ปรับแล้วควรถูกใช้ตลอดทั้งกระบวนการ ตั้งแต่ขั้นค้นหารหัส ChatGPT ยังแยกให้เห็นว่าการเปลี่ยนจำนวนรอบ อัตราการเรียนรู้ของการค้นหา หรือค่าของ Diffusion เป็นเพียงการปรับค่า (Hyperparameter Tuning) ไม่ควรเรียกว่าการปรับจูนโมเดล แนะนำให้แบ่งข้อมูลตามบุคคล และเสนอให้ตรวจว่าภาพเสียคุณภาพตั้งแต่ขั้นไหนก่อนเลือกส่วนที่จะฝึก



ช่วยดูงานวิจัย โค้ดใน github ให้หน่อยว่าโมเดลเขาสามารถ fine-tune ตรงไหนได้บ้าง แต่ละส่วนทำหน้าที่อะไร และควรเลือกปรับส่วนไหนให้เหมาะกับงานของผม ต้องเตรียมข้อมูลและฝึกยังไง ช่วยแยกด้วยว่าอันไหนเป็นการ fine-tune น้ำหนักโมเดลจริงๆ และอันไหนเป็นแค่การปรับค่าตอนสร้างภาพ ขอวิเคราะห์จากโค้ดจริงและอธิบายให้เข้าใจง่ายก่อน ยังไม่ต้องเขียนโค้ด ทำให้หน่อยสิ เอาประมาณนี้

ใช้เวลา 38วิ >

ได้ครับ ผมวิเคราะห์ **Barbershop ที่เราใช้อยู่ และ Realistic Vision V5.1 ที่ต่อท้าย** จากงานวิจัยและโค้ดจริง โดยอิง commit เดียวกับ Colab ที่ทำให้ครับ

ประเด็นสำคัญที่สุดคือ Barbershop เดิมยังไม่ได้ fine-tune น้ำหนักโมเดลตอนสร้างภาพ แม้จะมี `loss.backward()` และ optimizer ทำงานหลายรอบก็ตาม สิ่งที่ปรับคือ **latent code ของภาพแต่ละรูป** ส่วนน้ำหนักโมเดลยังคงเดิม

สำหรับงานของคุณที่ต้องการ **หน้าเหมือนเดิม ทรงและสีผมตรงตามแบบ ภาพดูคมชัด และใช้งานบนเว็บได้เร็ว** ผมแนะนำให้แยกปัญหาเป็นส่วน ๆ ก่อนเลือกฝึก เพราะการ fine-tune ทุกส่วนพร้อมกันอาจทำให้คุณภาพลดลงและสรุปผลการทดลองยากครับ

1. แต่ละส่วนทำอะไร และส่วนไหนกำลังถูกปรับจริง

ส่วน	หน้าที่	โค้ดเดิมปรับอะไร	Fine-tune น้ำหนักโมเดลหรือไม่
จัดแนวใบหน้า	ครอปและจัดตำแหน่งตา–ปากให้ตรงกับโมเดล	ตำแหน่งและขนาดภาพ	ไม่ใช่
StyleGAN2	สร้างภาพใบหน้าและเส้นผม	โหลดน้ำหนัก pretrained แล้วตรึงไว้	ยังไม่ใช่
W+ inversion	หาโค้ดที่ทำให้ภาพสร้างใหม่คล้ายภาพอ้างอิง	latent W+ ของแต่ละภาพ	ไม่ใช่
FS inversion	เก็บรายละเอียดและตำแหน่งโครงสร้างภาพได้มากขึ้น	feature tensor F และ appearance code S	ไม่ใช่
BiSeNet	แยกผม ใบหน้า และบริเวณอื่น	โหลดน้ำหนัก segmentation แล้วตรึงไว้	ยังไม่ใช่
Semantic alignment	ทำให้บริเวณหน้าและผมสอดคล้องกับ mask เป้าหมาย	latent ที่ใช้สร้างภาพ	ไม่ใช่

ภาพที่ 61 ข้อความสั่งงานและตอนต้นของคำตอบ ChatGPT เรื่องส่วนที่ปรับจูนได้ของ Barbershop

หมายเหตุ: StyleGAN2 = Style-based Generative Adversarial Network รุ่นที่ 2, FS = พื้นที่แฝงที่แยกโครงร่าง (F) และสไตล์ (S), BiSeNet = Bilateral Segmentation Network



Fine-tune StyleGAN2 บางส่วน	น้ำหนักอินสร้างภาพที่เลือก	reconstruction หน้า/เสนผมไม่ดี แม้ inversion เหมาะสมแล้ว	ทดลองได้ แต่ต้องระวังหน้าและสเปลี่ยน
ปรับ generator แบบ PTI	น้ำหนัก generator สำหรับภาพหรือบุคคลเฉพาะ	หน้า reconstruct ไม่เหมือนต้นฉบับ	เหมาะกับการศึกษา identity แต่เพิ่มเวลาต่อบุคคล
LoRA ของ Realistic Vision	น้ำหนัก adapter ที่เพิ่มใน diffusion	ต้องการปรับการสร้างรายละเอียดให้เข้ากับภาพฉานของเรา	เป็นทางเลือกที่ควรลองทีหลังมากกว่าเบา
ฝึก encoder เพิ่ม	น้ำหนักเครือข่ายใหม่สำหรับทำนาย latent	inversion เร็วเกินไปสำหรับเว็บ	ตรงกับเรื่องความเร็ว แต่เป็นงานเพิ่มอีกโมเดล

PTI เป็นวิธีปรับ generator เพื่อช่วย inversion และ editing ของภาพจริง มี implementation แยกต่างหาก ไม่ได้รวมอยู่ใน Barbershop เดิม ส่วน LoRA ฝึกน้ำหนักเพิ่มขนาดเล็ก โดยตรึงน้ำหนักฐานไว้ได้ GitHub +1

3. ถ้าจะ fine-tune StyleGAN2 ควรแตะตรงไหน

ใน `models/stylegan2/model.py` มีส่วนสำคัญดังนี้

ส่วนใน generator	บทบาทโดยทั่วไป	ข้อพิจารณา
`style`	แปลง z เป็น w	ไม่ใช่จุดเริ่มที่เหมาะ เพราะหลายขั้นตอนของ Barbershopป้อน W+ โดยตรงด้วย `input_is_latent=True`
synthesis ช่วงต้น	มีอิทธิพลต่อโครงสร้างภาพระดับกว้าง	เปลี่ยนแล้วอาจกระทบรูปหน้าและรูปทรงผม
synthesis ช่วงหลัง	มีอิทธิพลต่อรายละเอียดระดับละเอียด	เป็นจุดเริ่มทดลองได้ หากเน้น texture
`to_rgbs`	แปลง feature เป็นภาพสีในแต่ละระดับ	เปลี่ยนแล้วอาจกระทบโทนสีและสีผม

ข้อเสนอของผม: หากจะทดลองฝึก Barbershop จริง ให้เริ่มจาก **synthesis blocks ช่วงหลังบางส่วน** โดยตรึง mapping และช่วงต้นไว้ก่อน แล้วเปรียบเทียบกับการไม่ฝึก

อย่างไรก็ตาม นี่เป็นสมมติฐานสำหรับทดลอง ไม่ใช่ข้อรับประกันว่า "ชั้นหลังแก้เฉพาะความคมชัด" เพราะน้ำหนักเหล่านี้ยังมีผลต่อหน้าตาและสีได้ด้วย

มีข้อควรระวังเฉพาะ Barbershop อีกอย่างคือ **ภาพ face, shape และ color ต้องใช้ generator ที่เข้ากันตลอด pipeline** หาก fine-tune generator แยกตนละตัวแล้วนำ F/S มาผสมกันทันที latent อาจไม่สอดคล้องกัน วิธีที่ปลอดภัยกว่าคือใช้ generator ที่ปรับแล้วตัวเดียว และคำนวณ inversion ของภาพ ↓ ...ใหม่ทั้งหมด

ถ้าปรับ mapping network ด้วย ต้องพิจารณา `latent_avg` และ PCA สำหรับ p-norm ใหม่ด้วย เพราะโค้ดเดิมใช้สถิติที่มุก

ภาพที่ 62 คำตอบของ ChatGPT เรื่องส่วนของ StyleGAN2 ที่ควรปรับจูนใน Barbershop

หมายเหตุ: PTI = Pivotal Tuning Inversion, LoRA = Low-Rank Adaptation, StyleGAN2 = Style-based Generative Adversarial Network รุ่นที่ 2

คำตอบนี้เป็นที่มาของการตัดสินใจหลักในการปรับจูน Barbershop ผู้วิจัยตรวจกับไฟล์ `models/Net.py` แล้วพบว่าน้ำหนักของตัวสร้างภาพถูกตั้งไม่ให้รับเกรเดียนต์จริงตามที่ ChatGPT บอก จึงเลือกทางเลือกปรับ StyleGAN2 บางส่วนตามคำแนะนำ โดยปรับเฉพาะชั้น `convs[6:]` และ `to_rgbs[3:]` ซึ่งเป็นชั้นความละเอียด 64–1024 พิกเซล และล็อก Mapping Network กับชั้นช่วงต้นไว้ (หัวข้อที่ 3.4) ส่วนที่ผู้วิจัยทำต่างจากคำแนะนำมีสองเรื่อง เรื่องแรก ระหว่างฝึกผู้วิจัยไม่ได้ค้นหารหัสใหม่ด้วยตัวสร้างภาพที่ปรับแล้วทุกรอบ แต่ใช้รหัสที่ค้นไว้ครั้งเดียวจากตัวสร้างภาพเดิม เพราะถ้าค้นใหม่ทุกรอบ การฝึกหนึ่ง Trial จะใช้เวลาหลายสัปดาห์ ผู้วิจัยยอมรับข้อจำกัดนี้และเขียนไว้ในบทที่ 3 แต่ตอนทดสอบและสร้างภาพให้ผู้ใช้ประเมิน ผู้วิจัยรวมน้ำหนักที่ปรับแล้วเข้ากับไฟล์ `ffhq.pt` และใช้ตัวสร้างภาพตัวนี้ตลอดทั้งกระบวนการตามที่ ChatGPT เตือน เรื่องที่สอง ผู้วิจัยไม่ได้ทำทางเลือกอื่น เช่น PTI หรือ LoRA เพราะต้องการให้ Barbershop ใช้ฟังก์ชันสูญเสีย ชุดข้อมูล และกติกาการเลือก Checkpoint ชุดเดียวกับ HairFastGAN เพื่อให้เปรียบเทียบได้ตรงกัน การแยกการปรับจูนจริงออกจากการปรับค่าตามคำตอบนี้ ทำให้ผู้วิจัยรายงานในบทที่ 3 ได้ชัดว่า จำนวนรอบค้นหาทั้งหมดใช้ค่าเดิมของผู้พัฒนา และสิ่งที่ถูกฝึกจริงมีเพียงชั้นของ StyleGAN2 ที่ระบุไว้

จ.7 การเปรียบเทียบ Barbershop A30 กับ HairFastGAN B24 (ChatGPT)

หลังปรับจูนเสร็จและเลือก Checkpoint ได้แล้ว ผู้วิจัยต้องการเครื่องมือที่สร้างภาพจากสองโมเดลด้วยภาพนำเข้าชุดเดียวกัน ต่อด้วยขั้นขัดเกลาชุดเดียวกัน แล้ววัดผลทุกขั้น จึงส่งไฟล์เปรียบเทียบเดิมของโครงการให้ ChatGPT พร้อมข้อความดังนี้

> “หลังจาก fine-tune เสร็จแล้ว ช่วยทำไฟล์ Colab เปรียบเทียบ Barbershop ที่ใช้ checkpoint A30 กับ HairFastGAN ที่ใช้ checkpoint B24 ให้หน่อย โดยใช้รูปหน้า รูปทรงผม และรูปสีผมชุดเดียวกัน แล้วนำผลของทั้งสองโมเดลไปต่อ Diffusion Realistic Vision V5.1 และปรับความคมด้วยวิธีและค่าเดียวกัน แสดงภาพแต่ละขั้นตอน พร้อมเปรียบเทียบเวลาและประเมินคุณภาพภาพ การรักษาใบหน้า ทรงผม และสีผม สรุปเป็นตารางกับกราฟ พร้อมบันทึกภาพและผลประเมินได้ ขอแบบรันตามได้ตั้งแต่ต้นจนจบ พร้อมอธิบายให้เข้าใจง่าย ๆ”

ChatGPT ตอบกลับเป็นไฟล์ `Barbershop_A30_vs_HairFastGAN_B24_Complete.ipynb` ดังภาพที่ 63 ไฟล์นี้ต่อยอดจากไฟล์เปรียบเทียบเดิมของโครงการ ไม่ได้เขียนวิธีการใหม่ ส่วนที่ ChatGPT เพิ่มคือการตรวจไฟล์น้ำหนัก A30 ก่อนใช้ โดยดูเลข Epoch ชื่อ และขนาดของพารามิเตอร์ ว่ามีเฉพาะชั้นที่ปรับจูนจริง แล้วรวมเข้ากับ `ffhq.pt` เป็นไฟล์ใหม่ และบันทึกค่าแฮชของทั้งไฟล์ A30 และไฟล์ที่รวมแล้วไว้ในบันทึกการรัน ด้านการวัดผล ไฟล์วัดภาพทั้ง 8 ภาพ (2 โมเดล $\times$ 4 ขั้น) ด้วย MUSIQ ArcFace ความคลาดเคลื่อนสีผมในปริภูมิ Lab IoU ของผมเทียบกับภาพก่อน Diffusion และ MAE กับ SSIM นอกหน้ากาก แยกผลต่างเป็น 4 ช่วง จับเวลาแต่ละขั้นแยกกัน และมีส่วนเลือกจับเวลาขั้นขัดเกลาซ้ำหลายรอบ ChatGPT อธิบายข้อจำกัดของตัวชี้วัดไว้ด้วย เช่น MUSIQ ไม่ได้บอกว่าทรงผมถูกต้อง IoU เทียบภาพก่อน Diffusion ไม่ใช่การวัดว่าตรงทรงเป้าหมาย และผลจากภาพชุดเดียวยังสรุปเป็นผลวิจัยไม่ได้ และแจ้งว่าตรวจเพียงไวยากรณ์ของโค้ด ยังไม่ได้รันกับน้ำหนักจริงบน GPU



ภาพที่ 63 ข้อความสั่งงานและคำตอบของ ChatGPT ในการสร้างไฟล์เปรียบเทียบ Barbershop A30 กับ HairFastGAN B24

หมายเหตุ: A30 = น้ำหนักของ Barbershop-FT Trial A Epoch 30, B24 = น้ำหนักของ HairFastGAN Trial B Epoch 24, CSV = Comma-Separated Values (ไฟล์ตาราง), PNG = Portable Network Graphics (ไฟล์ภาพ), GPU = Graphics Processing Unit (หน่วยประมวลผลกราฟิก)

ก่อนใช้ ผู้วิจัยตรวจว่าค่าของขั้นขัดเกลาในไฟล์ตรงกับที่ตั้งไว้ในบทที่ 3 ทุกค่า ได้แก่ Seed 3407 ความแรง 0.15 จำนวน 30 ขั้น ค่านำทาง 2.5 และน้ำหนักเพิ่มความคมของผม 0.65 ใบหน้า 0.25 จำกัด ± 5 ระดับ และตรวจว่าทั้งสองโมเดลใช้ภาพที่จัดแนวแล้วชุดเดียวกัน ผลกรณีศึกษาในหัวข้อที่ 4.3 ใช้ตัวชี้วัดและการแยกเวลาชุดเดียวกับไฟล์นี้ และผู้วิจัยตีความผลตามข้อจำกัดที่ ChatGPT เตือนไว้ คือรายงานเป็นกรณีศึกษา 8 ชุดภาพ ไม่สรุปเป็นผลทั่วไป และไม่ใช้ MUSIQ หรือ IoU เทียบภาพก่อนเป็นตัวตัดสินคุณภาพของทรงผม ส่วนที่ผู้วิจัยทำเพิ่มเองคือรันกับภาพ 8 ชุด รวมใบหน้า 7 คน และสรุปผลเป็นรายชุดพร้อมค่าเฉลี่ย นำตัวเลขทั้งหมดมาจากไฟล์ผลลัพธ์ที่บันทึกไว้โดยตรง และใช้ความเห็นของผู้ใช้ 41 คนเป็นหลักในการตัดสินว่าภาพดีขึ้นหรือไม่

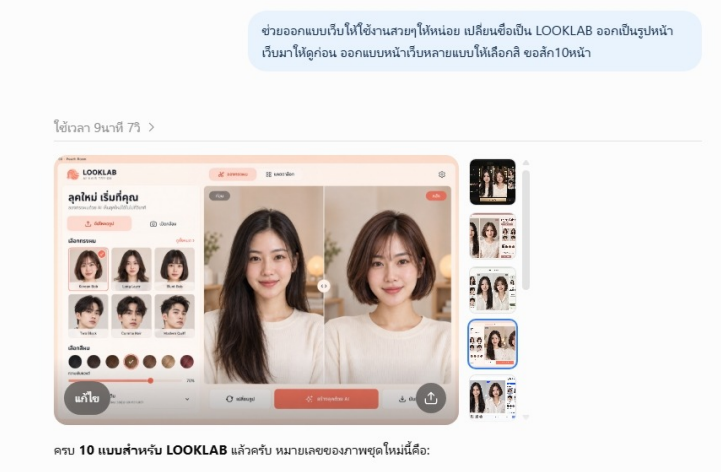
จ.8 การออกแบบหน้าเว็บ LOOKLAB (ChatGPT)

เมื่อโมเดลพร้อมใช้งานแล้ว ผู้วิจัยต้องการหน้าเว็บที่ดูดีและใช้ง่ายสำหรับให้คนทั่วไปทดลอง แต่ยังไม่มีภาพในใจว่าหน้าเว็บควรเป็นแบบไหน จึงขอให้ ChatGPT ออกแบบหน้าตาเว็บมาให้เลือกก่อน

> “ช่วยออกแบบเว็บให้ใช้งานสวย ๆ ให้หน่อย เปลี่ยนชื่อเป็น LOOKLAB ออกเป็นรูปหน้าเว็บมาให้ดูก่อน ออกแบบหน้าเว็บหลายแบบให้เลือกสิ ขอสัก 10 หน้า”

ChatGPT ตอบกลับเป็นภาพตัวอย่างหน้าเว็บ 10 แบบ ดังภาพที่ 64 แต่ละแบบใช้ชุดสีและการจัดวางต่างกัน และ ChatGPT สรุปชื่อกับแนวของแต่ละแบบเป็นตาราง ดังภาพที่ 65 เช่น แบบ

01 Rose Atelier โทนชมพูกุหลาบ แบบ 03 Peach Room โทนพีช–คอรัล อบอุ่น และแบบ 08 Nordic Blue โทนฟ้าหม่น ChatGPT ระบุไว้ว่าทั้งหมดเป็นภาพแนวทางการออกแบบเท่านั้น ยังไม่ได้แก้โค้ด และแนะนำว่าเลือกแบบเดียว หรือผสมสีกับการจัดวางจากหลายแบบก็ได้



ภาพที่ 64 ข้อความสั่งงานและภาพตัวอย่างหน้าเว็บที่ ChatGPT ออกแบบ (แบบ 03 Peach Room)



ครบ 10 แบบสำหรับ LOOKLAB แล้วครับ หมายเลขของภาพชุดใหม่นี้คือ:

แบบ	ชื่อ	สไตล์
01	Rose Atelier	ชมพูกุหลาบ เรียบหรู
02	Midnight Salon	ดำ–ทอง ซาลอนพรีเมียม
03	Peach Room	พีช–คอรัล อบอุ่น
04	Sage Minimal	เขียวเซจ สะอาด มินิมอล
05	Cobalt Studio	ขาว–น้ำเงินสด พร้อมแถบสรุปตัวเลือก
06	Editorial Wine	ครีม–แดงไวน์ แมกาซีน
07	Lilac Glass	ม่วงอ่อน แผงโปร่งแสง
08	Nordic Blue	ฟ้าหม่น เครื่องมือเป็นระเบียบ
09	Apricot Pop	เหลือง–ส้ม สดใส
10	Emerald Night	เขียวมัม–ทอง สุขุม

ทั้งหมดเป็น ภาพแนวทางออกแบบ ยังไม่ได้แก้โค้ด ครับ เลือกหมายเลขที่ชอบ หรือผสมสีและการจัดวางจากหลายแบบได้ เช่น สี 01 + แถบด้านล่างของ 05

ภาพที่ 65 ตารางสรุปหน้าเว็บ 10 แบบที่ ChatGPT ออกแบบให้เลือก

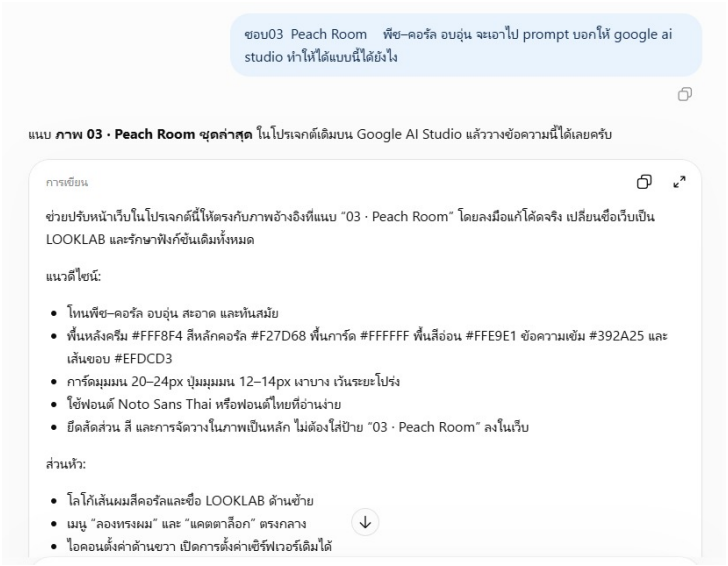
ผู้วิจัยใช้ภาพชุดนี้เป็นตัวเลือกด้านหน้าตาเท่านั้น โดยดูทั้ง 10 แบบแล้วเลือกแบบ 03 Peach Room เพราะโทนพีช–คอรัลดูอบอุ่นและเป็นมิตรกับผู้ใช้ทั่วไป และการจัดวางแบ่งเป็นแผงเลือกทรงและสีด้านซ้ายกับภาพผลลัพธ์ด้านขวา ซึ่งตรงกับลำดับการใช้งานของเว็บ คืออัปโหลดรูป เลือกทรง เลือกสี แล้วสร้างภาพ ภาพตัวอย่างใช้ภาพบุคคลและผลลัพธ์ที่ ChatGPT สร้างขึ้นเพื่อแสดงแนวการออกแบบ ผู้วิจัยจึงไม่ได้นำภาพเหล่านี้ไปใส่ในเว็บ ภาพทรงผม ภาพสีผม และภาพผลลัพธ์บนเว็บจริงมาจากชุดภาพของโครงการและจากโมเดลที่ทำงานจริงทั้งหมด

จ.9 การเขียนข้อความสั่งงานเพื่อสร้างหน้าเว็บจริง (ChatGPT)

หลังเลือกแบบได้แล้ว ผู้วิจัยต้องนำแบบนี้ไปสร้างเป็นหน้าเว็บจริงใน Google AI Studio ซึ่งเป็นเครื่องมือที่ใช้พัฒนาโปรเจกต์เว็บของโครงการ จึงถาม ChatGPT ว่าควรสั่งงานอย่างไร

> “ชอบ 03 Peach Room พีช–คอรัล อบอุ่น จะเอาไป prompt บอกให้ google ai studio ทำให้ได้แบบนี้ได้ยังไง”

ChatGPT ตอบกลับเป็นข้อความสั่งงานสำเร็จรูปให้นำไปวางใน Google AI Studio พร้อมแนบภาพแบบ 03 ดังภาพที่ 66 ข้อความนี้กำหนดแนวการออกแบบเป็นค่าที่ชัดเจน เช่น พื้นหลังครีม #FFF8F4 สีหลักคอรัล #F27D68 พื้นสีอ่อน #FFE9E1 ข้อความสีเข้ม #392A25 เส้นขอบ #EFDCD3 มุมการ์ดโค้ง 20–24 พิกเซล และฟอนต์ Noto Sans Thai กำหนดการจัดวางหน้าคอมพิวเตอร์เป็นสองคอลัมน์ ด้านซ้ายประมาณร้อยละ 36 สำหรับอัปโหลดรูป เลือกทรง และเลือกสี ด้านขวาประมาณร้อยละ 64 สำหรับภาพผู้ใช้ ตัวเลื่อนเทียบก่อนและหลัง และปุ่ม “สร้างลุคด้วย AI” และกำหนดลำดับการแสดงผลบนมือถือ ส่วนที่สำคัญที่สุดคือข้อความนี้สั่งให้รักษาฟังก์ชันเดิมทั้งหมด ได้แก่ การอัปโหลด กล้อง AR การเลือกทรงและสี การเชื่อมต่อ HairFastGAN ผ่าน API การตั้งค่าเซิร์ฟเวอร์ การดาวน์โหลด และคีย์ localStorage เดิม ห้ามนำภาพหน้าจอมาวางแทนหน้าเว็บ และเมื่อแก้เสร็จต้อง build ตรวจ TypeScript และตรวจหน้าจอทั้งคอมพิวเตอร์และมือถือ



ภาพที่ 66 ข้อความสั่งงานและข้อความสำหรับ Google AI Studio ที่ ChatGPT เขียนให้

หมายเหตุ: AI = Artificial Intelligence (ปัญญาประดิษฐ์), #FFF8F4, #F27D68 และอื่น ๆ = รหัสสีแบบเลขฐานสิบหก (Hex Color Code)

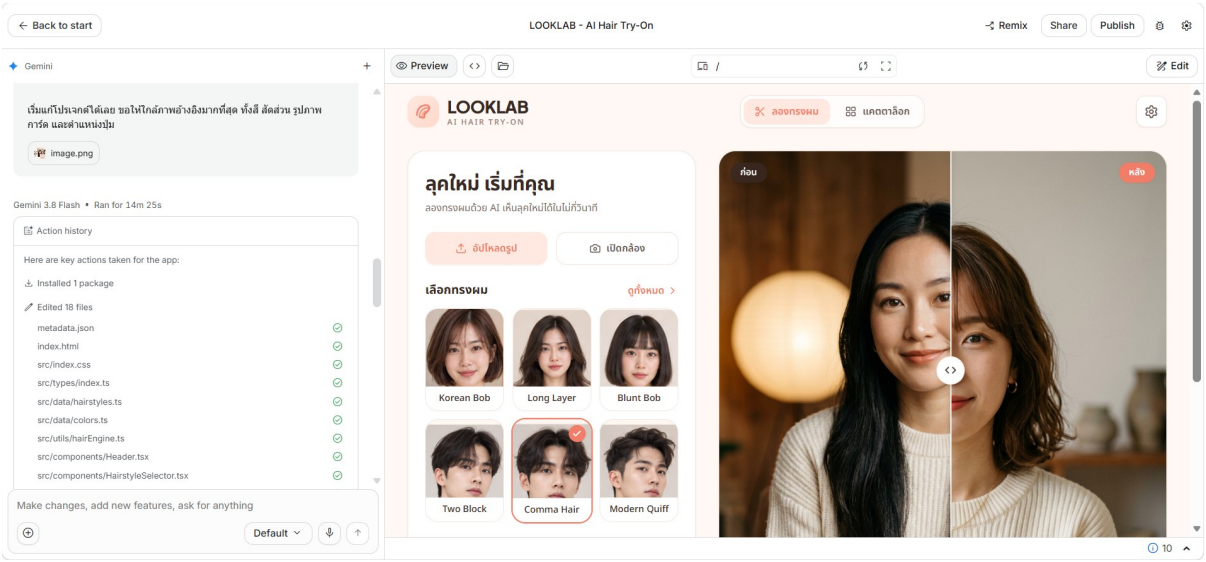
ผู้วิจัยนำข้อความนี้ไปใช้กับ Google AI Studio โดยไม่ได้แก้ข้อความ เพราะระบุสิ่งที่ต้องการได้ชัดกว่าที่ผู้วิจัยเขียนเอง โดยเฉพาะส่วนที่สั่งให้รักษาฟังก์ชันเดิม ซึ่งผู้วิจัยใช้เป็นรายการตรวจผลที่ได้ในหัวข้อถัดไป ผลที่ได้จาก Google AI Studio และสิ่งที่ผู้วิจัยตรวจพบอธิบายไว้ในหัวข้อที่ จ.10

จ.10 การสร้างหน้าเว็บตามแบบที่เลือก (Google AI Studio)

ผู้วิจัยนำข้อความสั่งงานที่ ChatGPT เขียนให้ในหัวข้อที่ จ.9 ไปวางใน Google AI Studio พร้อมแนบภาพแบบ 03 Peach Room และพิมพ์ต่อท้ายว่า

> “เริ่มแก้โปรเจกต์ได้เลย ขอให้ใกล้ภาพอ้างอิงมากที่สุด ทั้งสี สัดส่วน รูปภาพ การ์ด และตำแหน่งปุ่ม”

Google AI Studio ใช้โมเดล Gemini ทำงานประมาณ 14 นาที แก้ไฟล์ 18 ไฟล์ และได้หน้าเว็บตามภาพที่ 67 หน้าตาที่ได้ใกล้กับแบบที่เลือกมาก ทั้งชุดสี การ์ดมุมโค้ง แผงเลือกทรงและสีด้านซ้าย และตัวเลื่อนเทียบก่อนและหลังด้านขวา โค้ดใช้ค่าสีตามข้อความสั่งงานครบ คือ #FFF8F4 #F27D68 #FFE9E1 #392A25 และ #EFDCD3 กับฟอนต์ Noto Sans Thai



ภาพที่ 67 หน้าเว็บที่ Google AI Studio สร้างตามข้อความสั่งงานและแบบ 03 Peach Room

หมายเหตุ: AI = Artificial Intelligence (ปัญญาประดิษฐ์)

แม้หน้าตาจะตรงกับที่ต้องการ แต่เมื่อผู้วิจัยเปิดโค้ดเทียบกับโปรเจกต์เดิม กลับพบว่า Google AI Studio ไม่ได้แก้แค่หน้าตา แต่เขียนโครงสร้างของเว็บขึ้นใหม่ และทำให้ฟังก์ชันเดิมหายไปหลายส่วน ทั้งที่ข้อความสั่งงานกำหนดให้รักษาไว้ทั้งหมด ความต่างหลักสรุปไว้ในตารางที่ 23 คอลัมน์กลางคือโค้ดที่ Google AI Studio สร้าง และคอลัมน์ขวาคือเว็บ LOOKLAB ที่ใช้จริง

ตารางที่ 23 เปรียบเทียบโค้ดที่ Google AI Studio สร้างกับเว็บ LOOKLAB ที่ใช้จริง

รายการ	**โค้ดจาก Google AI Studio**	**เว็บ LOOKLAB ที่ใช้จริง**
หน้าตาและชุดสี	ตามแบบ 03 Peach Room	ตามแบบ 03 Peach Room (สีข้อความปรับเป็น #432B25)
จำนวนทรงผม	10 ทรง (ภาพที่ AI สร้างขึ้น)	24 ทรง จากชุดภาพของโครงการ
จำนวนสีผม	7 สี	28 สี และตัวเลือกสีธรรมชาติ
โหมดกล้อง	เปิดกล้องได้ แต่ไม่มีการติดตามใบหน้า	ติดตามใบหน้าด้วย MediaPipe FaceLandmarker และวางทรงผมแบบ AR
การเชื่อมต่อโมเดล	เรียกเซิร์ฟเวอร์โดยตรง ไม่มีเซิร์ฟเวอร์กลาง	ผ่านเซิร์ฟเวอร์กลาง Express ไปยัง FastAPI บน GPU และติดตามสถานะงาน
เมื่อเชื่อมต่อเซิร์ฟเวอร์ไม่ได้	แต่งสีผมบนภาพด้วย Canvas หรือแสดงภาพตัวอย่าง แล้วแจ้งว่าสร้างสำเร็จ	แจ้งข้อผิดพลาดเป็นภาษาไทย ไม่แสดงภาพที่ไม่ได้มาจากโมเดล
แบบประเมินหลังใช้งาน	ไม่มี	มีแบบประเมิน 6 หัวข้อ และขอความยินยอม
คีย์ localStorage	เปลี่ยนเป็นชุดใหม่	ใช้คีย์เดิม

หมายเหตุ: AI = Artificial Intelligence (ปัญญาประดิษฐ์), AR = Augmented Reality (ความเป็นจริงเสริม), GPU = Graphics Processing Unit (หน่วยประมวลผลกราฟิก), API = Application Programming Interface, localStorage = พื้นที่เก็บข้อมูลในเบราว์เซอร์

ปัญหาที่ร้ายแรงที่สุดคือแถวที่หก เมื่อไม่ได้ตั้งค่าเซิร์ฟเวอร์ หรือเชื่อมต่อเซิร์ฟเวอร์ไม่ได้ โค้ดของ Google AI Studio จะหน่วงเวลา 0.8 วินาทีให้ดูเหมือนกำลังประมวลผล แล้วระบายสีทับบริเวณผมด้วย Canvas หรือแสดงภาพตัวอย่างที่เตรียมไว้ และถ้าไม่ได้ตั้งค่าเซิร์ฟเวอร์ ยังแจ้งผู้ใช้ว่าสร้างลุคสำเร็จ ถ้านำขึ้นเว็บทั้งแบบนี้ ผู้ใช้อาจได้ภาพที่ไม่ได้มาจาก HairFastGAN เลยโดยไม่รู้ตัว และคะแนนประเมินจากการทดลองใช้ 100 ครั้งก็จะไม่ได้วัดโมเดลของโครงการจริง

ผู้วิจัยจึงไม่ได้ใช้โค้ดชุดนี้แทนโปรเจกต์เดิม แต่ใช้เป็นต้นแบบด้านหน้าตาเท่านั้น โดยนำชุดสี ฟอนต์ ขนาดมุมโค้ง และการจัดวางแบบสองคอลัมน์มาปรับเข้ากับโค้ดเดิมของ LOOKLAB และคงทุกส่วนที่ทำงานจริงไว้ ได้แก่ ทรงผม 24 แบบ สีผม 28 สี โหมดกล้องที่ติดตามใบหน้า เซิร์ฟเวอร์กลางที่เชื่อมกับโมเดล แบบประเมินหลังใช้งาน และคีย์ localStorage เดิม เมื่อเชื่อมต่อเซิร์ฟเวอร์ไม่ได้ เว็บที่ใช้จริงจะแจ้งข้อผิดพลาด ไม่สร้างภาพขึ้นเอง หน้าเว็บสุดท้ายแสดงในภาพที่ 22 (หัวข้อที่ 3.11) ซึ่งหน้าตาใกล้กับภาพที่ 67 แต่ทุกภาพผลลัพธ์มาจากโมเดลของโครงการ

จ.11 การนำเว็บขึ้นใช้งานบน Vercel และ RunPod (Claude)

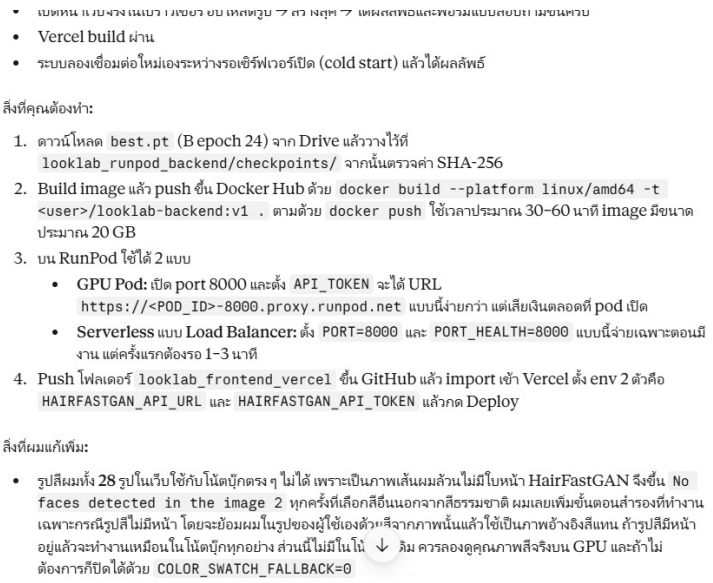
ช่วงทดสอบแรก เซิร์ฟเวอร์โมเดลรันอยู่บน Google Colab และเชื่อมกับเว็บผ่าน ngrok ซึ่งต้องเปิด Colab ค้างไว้ตลอด ผู้วิจัยจึงต้องการย้ายหน้าเว็บไปไว้บน Vercel และย้ายเซิร์ฟเวอร์โมเดลไปไว้บน RunPod ซึ่งเป็นบริการเช่า GPU โดยให้เซิร์ฟเวอร์ใช้กระบวนการจากสมุดบันทึก LOOKLAB_Diffusion_Native_Sharp.ipynb ที่ผู้วิจัยใช้อยู่ จึงแนบสมุดบันทึกนั้น โค้ดเซิร์ฟเวอร์เดิม (khem_backend.zip) และโค้ดเว็บ (looklab_final.zip) ให้ Claude พร้อมข้อความดังนี้

> “เราอยากเอา frontend ไปขึ้น vercel แล้วเอา backend ไปรันในรันพอต โดยเปลี่ยนไปใช้โหลดจากไฟล์ LOOKLAB_Diffusion_Native_Sharp.ipynb ของเราเอาไปแทนอันเดิม ทำให้หน่อยสิให้มันเอาไปใช้ให้ได้ ต้องไปทำยังไงบ้างทำให้ทุกขั้นตอนตั้งแต่จนเสร็จ”

Claude ตอบกลับเป็นไฟล์ looklab_deploy.zip และคู่มือภาษาไทย DEPLOY_TH.md ดังภาพที่ 68 และ 69 ในไฟล์แบ่งเป็นสองส่วน ส่วนแรกคือเซิร์ฟเวอร์โมเดลที่ย้ายโค้ดจากสมุดบันทึกมาเป็น Docker Image สำหรับ RunPod โดยตรวจค่าแฮชของไฟล์น้ำหนัก B24 ก่อนเริ่มทำงาน ใช้ค่าขั้นขัดเกลาเดิม (ความแรง 0.15, 30 ขั้น, ค่านำทาง 2.5, Seed 3407) และมีเส้นทาง /generate, /health และ /feedback เหมือนเดิม พร้อมเพิ่ม /ping ที่ RunPod ใช้ตรวจสถานะ ส่วนที่สองคือหน้าเว็บสำหรับ Vercel ที่เปลี่ยนเซิร์ฟเวอร์กลาง Express เป็น Vercel Functions แยกไฟล์ในโฟลเดอร์ api/ เก็บ API key ของ RunPod ไว้ฝั่งเซิร์ฟเวอร์ ย่อรูปไม่ให้เกินด้านยาว 1,536 พิกเซลก่อนส่ง เพราะ Vercel รับข้อมูลได้ไม่เกิน 4.5 MB ต่อครั้ง และลองเชื่อมต่อใหม่อัตโนมัติระหว่างรอเซิร์ฟเวอร์เริ่มทำงาน (Cold Start) Claude ยังพบว่ารูปสีผม 28 รูปในเว็บเดิมเป็นภาพเส้นผมล้วนที่ไม่มีใบหน้า ทำให้ HairFastGAN หาใบหน้าไม่เจอทุกครั้งที่เลือกสีอื่นนอกจากสีธรรมชาติ จึงเพิ่มขั้นสำรองที่ย้อมผมในรูปของผู้ใช้ด้วยสีจากภาพนั้นแล้วใช้เป็นภาพอ้างอิงสีแทน และเตือนว่าไฟล์ .env ในโค้ดเซิร์ฟเวอร์เดิมมี API key จริงอยู่ ควรสร้าง key ใหม่ Claude แจ้งว่าทดสอบฟังก์ชันประมวลผลภาพ เส้นทาง API และการ build บน Vercel แล้ว แต่ยังไม่ได้ build Docker Image จริงและยังไม่ได้รันโมเดลบน GPU



ภาพที่ 68 ข้อความสั่งงานและคำตอบของ Claude เรื่องการนำเว็บขึ้น Vercel และ RunPod



ภาพที่ 69 ขั้นตอนที่ Claude ให้ผู้วิจัยทำต่อ และสิ่งที่ Claude แก้เพิ่ม

หมายเหตุ: GPU = Graphics Processing Unit (หน่วยประมวลผลกราฟิก), API = Application Programming Interface, SHA-256 = Secure Hash Algorithm 256 บิต (ค่าแฮชสำหรับตรวจไฟล์), env = Environment Variable (ตัวแปรสภาพแวดล้อม)

ผู้วิจัยใช้คำตอบนี้เป็นแนวทางหลักในการย้ายระบบ แต่ไม่ได้ใช้โค้ดทุกส่วนตามที่ได้มา ตารางที่ 24 เทียบโค้ดหน้าเว็บที่ Claude ทำให้กับโค้ดหน้าเว็บที่ใช้จริงหลังย้ายขึ้น Vercel

ตารางที่ 24 เปรียบเทียบหน้าเว็บสำหรับ Vercel ที่ Claude ทำให้กับที่ใช้จริง

รายการ	โค้ดจาก Claude	โค้ดที่ใช้จริง
วิธีให้ `/api` ทำงานบน Vercel	เขียน Vercel Functions แยกไฟล์ใหม่แทน `server.ts`	รวม `server.ts` เดิมเป็น Function เดียวด้วยสคริปต์ตอน build
ที่เก็บ API key	ตัวแปรสภาพแวดล้อมฝั่ง Vercel	ตัวแปรสภาพแวดล้อมฝั่ง Vercel และเลิกรับ key จากเบราว์เซอร์
การย่อรูปก่อนส่ง	ด้านยาวไม่เกิน 1,536 พิกเซล JPEG คุณภาพ 92%	ใบหน้าไม่เกิน 1,600 พิกเซล รูปอ้างอิงไม่เกิน 1,408 พิกเซล JPEG คุณภาพ 92%
รูปอ้างอิงสีผม	ภาพเส้นผมล้วน และย้อมผมในรูปผู้ใช้แทนเมื่อหาใบหน้าไม่เจอ	ภาพบุคคลที่เห็นใบหน้า 28 ภาพ ส่งให้ HairFastGAN ได้โดยตรง
การเชื่อมต่อแบบ ngrok	ปิดไว้ เปิดได้ด้วยตัวแปรสภาพแวดล้อม	นำออกทั้งหมด

หมายเหตุ: API = Application Programming Interface, JPEG = Joint Photographic Experts Group (รูปแบบไฟล์ภาพ)

สิ่งที่ผู้วิจัยใช้ตามคำตอบคือโครงสร้างการแยกหน้าเว็บไว้บน Vercel กับเซิร์ฟเวอร์โมเดลไว้บน RunPod แบบ Load Balancer การเก็บ API key ไว้ฝั่งเซิร์ฟเวอร์ การย่อรูปก่อนส่งให้อยู่ในขีดจำกัดของ Vercel และการลองเชื่อมต่อใหม่ระหว่าง Cold Start ส่วนที่ผู้วิจัยทำต่างไปมีสองเรื่อง เรื่องแรก ผู้วิจัยไม่ได้ใช้ Vercel Functions ที่เขียนใหม่แยกไฟล์ แต่รวม `server.ts` ตัวเดิมเป็น Function เดียว เพื่อให้หน้าเว็บบนเครื่องของผู้วิจัยและบน Vercel ใช้โค้ดเซิร์ฟเวอร์ชุดเดียวกัน เรื่องที่สอง ผู้วิจัยไม่ได้ใช้ขั้นย้อมผมในรูปผู้ใช้ เพราะภาพที่ได้จะไม่ใช่ภาพอ้างอิงสีจริง แต่เปลี่ยนรูปสีผมทั้ง 28 รูปเป็นภาพบุคคลที่เห็นใบหน้าชัด ซึ่งตรงกับวิธีที่ HairFastGAN ถูกออกแบบให้ใช้ ก่อนเปิดให้ทดลองใช้จริง ผู้วิจัยตรวจว่าหน้าเว็บบน Vercel เชื่อมกับเซิร์ฟเวอร์บน RunPod ได้ ลองสร้างภาพจากทั้งโหมดอัปโหลดและโหมดกล้อง และส่งแบบประเมินได้ครบ นอกจากนี้ผู้วิจัยสร้าง API key ใหม่ตามที่ Claude เตือน และไม่นำไฟล์ `.env` ขึ้น GitHub

จ.12 สรุปการใช้คำตอบจาก AI

ตารางที่ 25 สรุปคำถามทั้งสิบเอ็ดข้อ ข้อ 1–9 ถาม ChatGPT ข้อ 10 ใช้ Google AI Studio และข้อ 11 ถาม Claude คอลัมน์ “สิ่งที่ AI ให้” คือผลลัพธ์จากการถาม คอลัมน์ “การนำไปใช้” บอกว่าผู้วิจัยใช้คำตอบแบบไหน และคอลัมน์สุดท้ายคือวิธีที่ผู้วิจัยใช้ตรวจสอบ จะเห็นว่าไม่มีคำตอบข้อไหนที่ถูกนำไปใช้ทันทีโดยไม่ตรวจ ทุกข้อผ่านการเทียบกับงานวิจัยต้นฉบับ โค้ดใน GitHub หรือผลการรันจริงก่อน

ตารางที่ 25 สรุปการใช้คำตอบจาก AI ในโครงงาน

คำถาม (AI ที่ใช้)	**สิ่งที่ AI ให้**	**การนำไปใช้**	**วิธีตรวจสอบ**
สร้าง Colab รัน HairFastGAN แบบ Pretrained (ChatGPT)	สมุดบันทึกติดตั้ง ดาวน์โหลดน้ำหนัก และสร้างภาพ พร้อมคำอธิบายโมดูล	ใช้เป็นจุดเริ่มต้น แล้วเขียนสมุดบันทึกสำหรับทดลองจริงขึ้นใหม่	เทียบคำอธิบายกับงานวิจัยและโค้ด รันจริงบน Colab และไม่ใช้เวลาจากสมุดบันทึกนี้
เพิ่มขั้นปรับภาพต่อจาก HairFastGAN (ChatGPT)	เซลล์ Image-to-Image ความแรง 0.18 ค่านำทาง 3.5 ผสมกลับ 0.65	เปลี่ยนวิธีเกือบทั้งหมด เป็น Inpainting เฉพาะผมกับใบหน้า ความแรง 0.15 ค่านำทาง 2.5	ทดลองเทียบข้อความสั่งงาน วัดด้วย MUSIQ ArcFace IoU และความเห็นผู้ใช้
วิเคราะห์ส่วนที่ปรับจูนได้ของ HairFastGAN (ChatGPT)	คำอธิบายโมดูล คำแนะนำส่วนที่ควรปรับ การเตรียมข้อมูล และการแยกการปรับจูนจากการปรับค่า	ใช้บางส่วน และปรับขอบเขต อัตราการเรียนรู้ และฟังก์ชันสูญเสียเอง	ตรวจกับโค้ดจริง โหลดน้ำหนักด้วย `strict=True` และเลือก Checkpoint ด้วยชุดตรวจสอบ
สร้าง Colab รัน Barbershop แบบ Pretrained (ChatGPT)	สมุดบันทึกล็อกรุ่นโค้ด ดาวน์โหลดน้ำหนัก และรันตามค่าเริ่มต้น พร้อมแก้โค้ดให้รันบน Colab ได้	ใช้จำนวนรอบและการแก้โค้ดตามคำตอบ แล้วเพิ่มส่วนเก็บรหัสและจับเวลาเอง	เทียบจำนวนรอบกับ `main.py` ตรวจว่าการแก้ไม่เปลี่ยนวิธีการและรันจริง
เพิ่มขั้นปรับภาพต่อจาก Barbershop (ChatGPT)	เซลล์ Image-to-Image ความแรง 0.15 ค่านำทาง 3.5 ผสมกลับ 0.70	ไม่ใช้ค่าชุดนี้ ใช้ขั้นขัดเกลาชุดเดียวกับ HairFastGAN	เทียบค่ากับคำตอบของ HairFastGAN แล้วพบว่าไม่เท่ากัน
วิเคราะห์ส่วนที่ปรับจูนได้ของ Barbershop (ChatGPT)	อธิบายว่าโค้ดเดิมไม่ได้ฝึกน้ำหนัก เสนอทางเลือกการปรับจูน และแนะนำให้ปรับ StyleGAN2 ช่วงหลัง	ใช้แนวทางปรับ StyleGAN2 ช่วงหลัง แต่ฝึกบนรหัสที่เก็บไว้	ตรวจกับ `models/Net.py` และใช้ตัวสร้างภาพที่ปรับแล้วตลอดกระบวนการตอนทดสอบ
เปรียบเทียบ Barbershop A30 กับ HairFastGAN B24 (ChatGPT)	ไฟล์เปรียบเทียบที่ตรวจน้ำหนัก A30 วัดผล 8 ภาพ แยกเวลา และอธิบายข้อจำกัดของตัวชี้วัด	ใช้ตัวชี้วัดและการแยกเวลาตามไฟล์ รันกับภาพ 8 ชุด และตีความเป็นกรณีศึกษา	เทียบค่าขั้นขัดเกลากับบทที่ 3 และนำตัวเลขจากไฟล์ผลลัพธ์โดยตรง

ต่อหน้าถัดไป

ตารางที่ 25 (ต่อ)

คำถาม (AI ที่ใช้)	**สิ่งที่ AI ให้**	**การนำไปใช้**	**วิธีตรวจสอบ**
ออกแบบหน้าเว็บ LOOKLAB (ChatGPT)	ภาพตัวอย่างหน้าเว็บ 10 แบบพร้อมชื่อและแนวสี	เลือกแบบ 03 Peach Room เป็นแนวทาง ไม่ใช้ภาพตัวอย่างในเว็บ	เทียบแบบกับลำดับการใช้งานของเว็บ
เขียนข้อความสั่งงานสำหรับ Google AI Studio (ChatGPT)	ข้อความกำหนดสี การจัดวาง การแสดงผลบนมือถือ และให้รักษาฟังก์ชันเดิม	ใช้ทั้งข้อความกับ Google AI Studio	ใช้รายการฟังก์ชันในข้อความเป็นรายการตรวจผลในหัวข้อถัดไป
สร้างหน้าเว็บตามแบบที่เลือก (Google AI Studio)	โค้ดหน้าเว็บใหม่ที่หน้าตาตรงแบบ แต่ตัดฟังก์ชันเดิมและจำลองผลเมื่อไม่มีเซิร์ฟเวอร์	ไม่ใช้แทนโค้ดเดิม ใช้เฉพาะหน้าตาเป็นต้นแบบ	เปิดโค้ดเทียบกับโปรเจกต์เดิมทีละส่วน
นำเว็บขึ้น Vercel และ RunPod (Claude)	โค้ดเซิร์ฟเวอร์โมเดลสำหรับ RunPod โค้ดหน้าเว็บสำหรับ Vercel และคู่มือขั้นตอน	ใช้โครงสร้างและการตั้งค่าตามคำตอบ แต่รวม `server.ts` เดิมเป็น Function เดียว และเปลี่ยนรูปสีผมแทนขั้นย้อมผม	ทดลองสร้างภาพทั้งสองโหมดและส่งแบบประเมินบนเว็บจริงก่อนเปิดใช้

หมายเหตุ: AI = Artificial Intelligence (ปัญญาประดิษฐ์), MUSIQ = Multi-scale Image Quality Transformer (คะแนนคุณภาพภาพ), ArcFace = โมเดลจดจำใบหน้าที่ใช้วัดความเหมือนของใบหน้า, IoU = Intersection over Union (สัดส่วนพื้นที่ผมที่ทับกัน)